

Manual para el curso Modelos Lineales Avanzados (XS-0125) Primer Examen

Anderson Martínez, Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1	Modelos Mixtos	2
1.1	Efectos fijos	2
1.2	Efectos aleatorios	2
1.3	Gráfico para el comportamiento de la respuesta entre lotes	3
1.4	Ejemplo de las escuelas	3
1.5	En resumen:	5
2	Tipos y estructuras de datos	5
3	Diferencias entre los diferentes tipos de modelos	5
3.1	Diferencia entre un modelo con bloques y un modelo mixto.	5
3.2	Diferencias entre modelo mixto y modelo lineal clásico.	5
3.3	Sobre los Modelos lineales mixtos	6
4	Supuestos en los modelos mixtos	6
5	El modelo	6
5.1	Distribuciones del modelo	7
5.1.1	Apuntes importantes de los errores	7
5.1.2	Distribuciones de cada nivel	7
5.1.3	¿Cuándo se nos habla de verificar la normalidad a que se refiere?	8
5.2	Componentes de la varianza	9
5.3	Coefficiente de correlación intraclase (ICC)	9
6	Modelo con Interacción	10
6.1	Gráficos de interacción	11
6.2	Modelo con interacción en r	12
6.3	Comparación de modelos con y sin interacción	12
6.4	Esperanza marginal del factor de la unidad de nivel 2	13
6.5	Componentes de la varianza	13
7	Prueba de razón de verosimilitud	14
7.1	Prueba RMLE a mano	15
8	Estimación de modelos mixtos en r	16
8.1	Estimaciones manuales mediante un modelo lineal	16
8.2	Intervalos de confianza para las varianzas	16
8.2.1	Código para las diferencias entre intervalos de confianza	17
9	Intervalos de confianza para las diferencias de diferentes categorías	17
9.1	Hipótesis sobre la diferencias entre categorías	18

9.2	Intervalos de confianza mediante la función emmeans	18
9.3	Comparaciones para el nivel de significancia α cuando se usa emmeans (Bonferroni)	19
9.3.1	Proceso manual para la creación de intervalos de confianza	20
10	Parcelas divididas	21
10.1	Cambio de categórica a numérica	22
10.2	Sobre el diseño de bloques y parcelas	23
11	Diseños multinivel	23
11.1	Diseño con 2 niveles y factor fijo en ambos niveles	23
11.1.1	Análisis de diferencias de medias con emmeans	24
11.1.2	Corrección de intervalos de confianza	27
11.2	Diseño con 3 niveles	28
11.2.1	Gráfico de interacción	28
11.2.2	Creación del modelo en r	29
12	Diseños Anidados	30
12.1	Definición de diseño a anidado	30
12.1.1	Gráfico para representar gráficamente los datos y observar variabilidad	30
12.1.2	De un diseño anidado a un multinivel	32
12.2	Modelo del diseño anidado	32
12.2.1	Obtener manualmente los efectos de instructor	33
12.2.2	Obtención de manual de la suma de cuadrados de instructor dentro de cada escuela	33
12.2.3	Comparación de instructores dentro de cada escuela	34
12.2.4	Indicarle a R que es un modelo para un diseño anidado	34
12.2.5	Comparaciones entre instructores	35
12.2.6	Comparaciones entre escuelas	36
13	Simulaciones	36
13.1	Simulación de intervalos de confianza	36
13.2	Combinaciones múltiples del ancho del intervalo	37
13.3	Simulación de potencia para diferentes combinaciones de días y máquinas	38
13.4	Simulación de potencia, para un experimento de tres niveles, sin interacción	39
13.5	Gráfico para comparar la respuesta observada y simulada	40

1 Modelos Mixtos

1.1 Efectos fijos

- En un factor de efectos fijos el interés está sólo en aquellos niveles que están siendo usados en el experimento y sus efectos. Todas las conclusiones de están limitadas a los tratamientos que están siendo observados en el experimento.
- Se asume que el experimentador ha considerado para el factor todos los posibles niveles que éste puede tomar o se escogieron deliberadamente, no de forma aleatoria.
- Ejemplo: la temperatura (10°, 16°, 27°) sería un factor fijo si esas fueran las únicas temperaturas de interés para el investigador.

1.2 Efectos aleatorios


- En un factor de efectos aleatorios se asumen que se ha considerado tan solo una muestra de los posibles niveles que éste puede tomar.
- El efecto que tiene cada nivel de ese factor se considera proveniente de una distribución de efectos cuya esperanza es cero.

- Los efectos de los niveles escogidos son aleatorios en el sentido de que son una muestra de esa distribución de efectos.

1.3 Gráfico para el comportamiento de la respuesta entre lotes

El código general de este gráfico es `qplot(X,Y,geom="boxplot")`, a continuación se le da un ejemplo

```
load("colorantes.Rdata")
library(ggplot2)
qplot(lote,prod,geom="boxplot",ylab="producción",data=base)
```




Intepretación del gráfico: Hay algunos lotes que tienen producciones muy bajas mientras que otros las tienen muy altas, aunque no interesa identificar cuáles son los lotes con producción más baja o más alta puesto que los lotes son aleatorios.

1.4 Ejemplo de las escuelas

ATENCIÓN AL SIGUIENTE EJEMPLO EXPUESTO EN CLASE

Ejemplo: La escuela es analizada como un factor que puede influir sobre el nivel de aprendizaje y se han considerado en el experimento solo 10 de las muchas escuelas posibles. La escuela es un factor aleatorio en el experimento y sus efectos provienen de una distribución. Además se toma en cuenta otro factor sobre si la escuela es privada o pública.



Descripción del gráfico

Negro: La distribución de los grupos de una escuela pública.

Azul: La distribución de los grupos de una escuela privada.

Celeste: La distribución de las medias de las escuelas públicas.

Rojo: La distribución de las medias de las distribuciones de las escuelas privadas.

Unidades del nivel 1

Son los grupos de las escuelas, las distribuciones de este nivel son las de color **Negro** y **Azul**. Es decir cada distribución corresponde a una escuela.

- La variable respuesta (Y) se mide en el nivel 1, la distribución es la siguiente $f(Y|Escuela)$
- μ_j : Es el promedio de una escuela (una distribución negra o azul). Todas las μ_j se unen y forman las curvas de los colores **Celeste** y **Rojo**
- σ_j^2 : Es la varianza del error, esta se encuentra en el nivel 1.
- Debido a la homocedasticidad podemos asumir que σ_j^2 es constante.

Unidades del nivel 2

Este nivel corresponde a las medias de todas las escuelas, cada tipo de escuela tiene una distribución, **Celeste** para las escuelas pública y **Rojo** para las escuelas privadas. Puede ser que las varianzas de estas distribuciones sean iguales, pero no necesariamente sucede ese caso, de hecho es muy utópico pensar que todo tenga la misma varianza.

- Los μ_j son los que forman la distribución en el nivel 2

- La forma de la distribución es $f(\mu_j|\text{Tipo de escuela})$

Conceptos importantes

Error: Es la distancia de un punto de la distribución a su media, por ejemplo imagine un punto de una de las distribuciones negras a su media.

Efecto: Un ejemplo de efecto es la distancia entre la media de una de las distribuciones **negras** con la media de la distribución **celeste**. Como hay escuelas infinitas, esto implica que hay efectos infinitos.

Sea γ el efecto, este se distribuye como $\gamma \sim f(0, \sigma_\gamma^2)$. Para cada uno de los tipos de escuelas hay infinitos efectos con una cierta varianza, en donde ambos tipos de escuela pueden tener la misma.

1.5 En resumen:

- Efectos fijos son los factores
- Efectos aleatorios son las unidades

Cuando las unidades están en el nivel 1, los experimentos son como los del curso pasado, en cambio cuando estas unidades se encuentran del nivel 2 hacia arriba a esto le llamaremos como un modelo mixto. Estos corresponden a lo que se llama un modelo multinivel.

Notas:

- Normalmente a los efectos aleatorios se le asigna un factor fijo
- La unidad normalmente contiene efectos aleatorios.
- Siempre tienen que haber unidades aleatorias en el nivel 1

2 Tipos y estructuras de datos

Datos agrupados	Medidas repetidas	Datos longitudinales
* La variable dependiente se mide una vez por cada sujeto.	* La variable dependiente se mide más de una vez en la misma unidad de análisis.	* La variable dependiente se mide en muchos momentos a lo largo del tiempo, para cada unidad de análisis.
* Las unidades de análisis se agrupan (clusters de unidades).	* La medición se realiza en varios niveles de un factor de medidas repetidas.	

3 Diferencias entre los diferentes tipos de modelos

3.1 Diferencia entre un modelo con bloques y un modelo mixto.

Es un modelo mixto, cuando hay dos factores o más en el nivel 1, en un diseño de dos niveles o más. Por el contrario cuando hay dos niveles, pero el nivel 1 solo tiene un factor es un diseño de bloques. Además si hay un factor en el nivel dos, también hay que usar modelos mixtos.

3.2 Diferencias entre modelo mixto y modelo lineal clásico.

- El modelo de regresión lineal simple requiere de formular muchos supuestos para que su uso sea adecuado.
- Los modelos lineales mixtos permiten tomar en cuenta la violación a algunos de los supuestos del modelo lineal simple.

- En la práctica, permiten modelar situaciones comunes en las ciencias sociales y en otras ciencias, como la presencia de estructuras jerárquicas.
- Los Modelos Lineales Mixtos Generalizados (GLMM) incluyen técnicas de modelación no solo para variables continuas, sino también nominales, ordinales, conteos, respuestas asimétricas, entre otras.

3.3 Sobre los Modelos lineales mixtos

Modelos para variables continuas en los que los residuos se distribuyen normalmente, pero podrían no ser independientes o no tener varianza constante.

El término “lineal” proviene del hecho de que estos modelos son lineales en los parámetros.

El término “mixto” es debido a que las covariables pueden incluir un “mix” de efectos fijos y efectos aleatorios

4 Supuestos en los modelos mixtos

Los modelos mixtos permiten manejar estructuras de variabilidad que no son homogéneas y homogéneas (homocedasticidad), este último no es tan común en modelos mixtos. Con respecto al análisis de varianza (ANOVA) sabemos que este no necesita linealidad. Por otro lado sabemos que esto es distinto cuando el modelo contiene covariables ó variables numéricas como en regresión, en el caso de los modelos mixtos necesitamos linealidad. Si sucede el caso no se cumple, debemos realizar una transformación.

En un caso extremo donde los datos se comporten de una forma muy extraña, lo que podemos hacer es convertir la variable continua en una forma categórica, de manera que se parte la variable continua y se forman las categorías con dichos intervalos. Además para los modelos mixtos el hecho de que las variables predictoras no estén correlacionadas, lo que conocemos en otros cursos como el supuesto de no multicolinealidad, para que así los errores estándar no se inflen y las variables puedan explicar adecuadamente el modelo.

Hay algunos modelos que no tienen una distribución normal, por lo que se usa una distribución conocida con la que se realiza dicho modelo, debido a que es muy difícil realizar las estimaciones por medio de una distribución normal. Por ejemplo un conteo de autos durante cada hora, el cual normalmente se modela con una Poisson. A esto se le llama Modelos Lineales Generalizados, los mismo se utilizan cuando la respuesta no es normal, este tema se abordará más adelante en el curso. Por último sino se cumple la independencia de la unidades de la respuesta y esa la variable Y no se comporta como una normal, pasamos a los *Modelos Lineales Mixtos Generalizados*.

Nota: En un experimento la multicolinealidad automáticamente se cumple.

5 El modelo

El efecto de la unidad i -ésima del nivel 2 se denota como: δ_i .

La j -ésima observación dentro de la i -ésima unidad del nivel 2 se puede expresar como:

$$y_{ij} = \beta_0 + \delta_i + \varepsilon_{ij}$$

La esperanza condicional dado la unidad del nivel dos es:

$$E[Y|i] = \mu_i = \beta_0 + \delta_i$$

donde:

- $\beta_0 = \mu$ (Intercepto)
- $\delta_i = \mu_i - \mu$ (Definición de error)

5.1 Distribuciones del modelo

1. Se consideran dos fuentes de variabilidad:

- La variación de unidad del nivel 2 a una unidad del nivel 2 (inter sujeto): σ_δ^2
- La variación entre los datos dentro de una misma unidad de nivel 2.

Tomando como ejemplo el diseño de las escuelas vistas en clase

$$V(Y|\text{escuela}) = V(\text{error})$$

Nota: La definición de error se encuentra arriba.

5.1.1 Apuntes importantes de los errores

- Los errores se distribuyen como $\varepsilon \sim N(0, \sigma_\varepsilon)$
- Debido a que hay homocedasticidad podemos juntar a todos los errores. La función de unir todos los errores nos ayuda a observar la normalidad.

5.1.2 Distribuciones de cada nivel

Existen dos en el ejemplo de las escuelas:

$V(\varepsilon)$: Esta corresponde a una varianza por cada escuela, pero si hay homocedasticidad habría solo una. En un caso extremo se puede tener $V(\varepsilon|\text{Pública}) \neq V(\varepsilon|\text{Privada})$

$V(\mu|\text{Tipo de escuela})$: Hay dos una para la escuela pública y otra para la privada. De igual forma si hay homocedasticidad solo habría una, es decir $V(\mu|\text{Pública}) = V(\mu|\text{Privada})$

2. Los efectos de las unidades del nivel 2 son aleatorias y se obtienen de una distribución normal con media cero:

$$\delta \sim \mathcal{N}(0, \sigma_\delta^2)$$

3. La distribución condicional de la respuesta dado la unidad del nivel 2 también es normal:

$$Y|i \sim \mathcal{N}(\mu_i, \sigma_\varepsilon^2)$$


4. La variancia total de la respuesta es la suma de la variancia de los componentes aleatorios más la variancia del error:

$$V(Y) = \sigma_\delta^2 + \sigma_\varepsilon^2$$

Nota: Esta suma nos sirve para ver en terminos relativos (%), la variabilidad, normalmente se usa para dar conclusiones. De tal manera que podemos tener estos dos casos $\sigma_\delta^2 < \sigma_\varepsilon^2$ ó $\sigma_\delta^2 > \sigma_\varepsilon^2$. En palabras simples, nos sirve para buscar quien es el culpable de generar mayor variabilidad. *Ver en el índice el ICC sección 7.3*

A continuación se representan las distribuciones por medio de una figura

Notación explicada con curvas



donde:


- **Curvas azules** corresponden a $Y|i \sim N(\mu_i, \sigma_\varepsilon^2)$
- **Curva Roja** corresponde a $\mu_i \sim N(\mu, \sigma^2)$, sin embargo se quiere calcular el efecto que este es $\delta = \mu_i - \mu$, el cual se distribuye como $\delta \sim N(0, \sigma_\delta^2)$.

Nota: Es lo mismo decir $V(\delta_i) = V(\mu_i)$

5.1.3 ¿Cuándo se nos habla de verificar la normalidad a que se refiere?

Se refiere a evaluar el supuesto de normalidad en la distribución $Y|i \sim N(\mu_i, \sigma_\varepsilon^2)$, la explicación de esta la puede encontrar en la parte de arriba. Si tenemos muy pocos efectos en la muestra y queremos probar normalidad, la debemos asumir porque para probar esto se debe tener una cantidad considerable de observaciones. Sin embargo podemos unir todos los residuales para probar normalidad en el caso de que se cumple el supuesto de *Homocedasticidad*

Descomposicion de Distancias Horizontales (Delta y Epsilon)



5.2 Componentes de la varianza

- El modelo tiene solo un coeficiente **fijo** que es el **intercepto** o media general, y tiene un componente aleatorio que son los efectos de las unidades del segundo nivel.
- Interesa determinar si hay efecto de las unidades del segundo nivel, pero no interesa estimar la magnitud de los mismos ya que son solo una muestra de una población mayor de unidades infinitas.
- La variancia de cualquier observación se obtiene a partir de dos fuentes: la de unidad de nivel 2 a unidad de nivel 2 (inter sujeto) y la residual (intra sujeto).
- Si realmente hay un efecto de la unidad del nivel 2, la variancia entre unidades del nivel 2 será mayor a cero. Como se denota a continuación:

$$H_0 : \sigma_i = 0$$

$$H_1 : \sigma_i > 0$$

5.3 Coeficiente de correlación intraclase (ICC)

- Es una medida que relaciona la variabilidad entre los grupos con la variabilidad dentro de los grupos.
- Es la proporción de la variación en la variable respuesta que ocurre entre grupos con respecto a la variación total.
- Formalmente: Siendo σ_ϵ^2 la variancia dentro de los grupos, y siendo σ_δ^2 la variancia entre los grupos, el coeficiente de correlación intraclase (ρ_I) es:

$$\rho_I = \frac{\sigma_\delta^2}{\sigma_\delta^2 + \sigma_\varepsilon^2}$$

Esto nos dice que porcentaje de variabilidad se debe a las unidades del nivel 2. Si hay **baja** variabilidad intra clase $\rho_I \rightarrow 0$, quiere decir que las unidades del segundo nivel son muy similares, por el contrario si $\rho_I \rightarrow 1$, nos esta diciendo que son muy diferentes.

A continuación se le presenta un ejemplo sobre un cálculo en r

```
sigma_delta = 1764
sigma_epsilon = 2451
sigma_delta/(sigma_delta+sigma_epsilon)*100
```

```
## [1] 41.85053
```

Respuesta: El 41.8% de la variabilidad es debida a las unidades del nivel 2.

Si se requiere sacar un intervalo de confianza para las varianzas, se recomienda utilizar estadística Bayesiana.

6 Modelo con Interacción

Una inconsistencia en el factor del nivel 2, es lo que nos da la sospecha que haya interacción

El efecto del i-ésimo del factor del nivel 2 se denota con: τ_i

El efecto del j-ésima unidad de nivel 2 se denota con: δ_j

El efecto de interacción para el i-ésimo factor en la j-ésima unidad de nivel 2 se denota con:

A continuación el modelo es explicado, basándose en el ejemplo de las máquinas vistas en clase

La k-ésima muestra dentro del j-ésimo día, para la i-ésima máquina se puede expresar como:

$$y_{ijk} = \beta_0 + \tau_i + \delta_j + (\tau\delta)_{ij} + \varepsilon_{ijk}$$

La esperanza condicional dado la unidad de nivel 2 y el factor del mismo nivel, se denota de la siguiente manera:


$$E[Y|ij] = \mu_{ij} = \beta_0 + \tau_i + \delta_j + (\tau\delta)_{ij}$$

Notas:

- $\delta_j = \mu_j - \mu$, es decir la media de la unidad de nivel 2 menos la media general (media de las medias).
- Los efectos de interacción son infinitos, por lo que son aleatorios.
- τ_i es fijo, ya que este depende de la restricción que elijamos (suma nula o referencia)

6.1 Gráficos de interacción

A continuación se le presenta un ejemplo de como se ve gráficamente un modelo con / sin interacción



Código para crear el gráfico anterior

```
library(lattice)
xyplot(Y ~ Maquina, groups = Dia, data = datos,
       type = c("p", "a"), lwd=2,
       auto.key = list(columns = 4, title = "Día", cex=0.8),
       main = "Escenario A: CON INTERACCIÓN\n(Tendencias Cruzadas)",
       ylab = "Triglicéridos (mg/dl)", xlab = "Máquina")
```

Gráfico de puntos para la interacción


El siguiente gráfico normalmente se utiliza debido a que es una cantidad de observaciones pequeña.

En este experimento se tiene un estudio con 2 niveles con un factor en el nivel 1, lo que corresponde a lo que conocemos como un diseño de bloques.


Tenemos dos varianzas: σ_ϵ varianza del error la cual corresponde, a la de muestra a muestra dentro de un día y una muestra. Por otro lado σ_δ varianza de los efectos del día.

En ambos gráficos podemos observar que las maquinas no son consistentes, esto indica que se sospecha de una posible interacción, debido a que estas no dan los mismos resultados a lo largo de los días. Por otro lado para el caso sin interacción se da cuando las maquinas son bastante consistentes, como se puede ver en el gráfico de la derecha.

Escenario Con interacción



Escenario B Sin interacción



```
dotplot(Trig_NoInt ~ Maquina|Dia,xlab="día",ylab="triglicéridos", data = datos)
```

6.2 Modelo con interacción en r

```
library(lme4)
mod1=lmer(trigli~1+maq+(1|dia)) #Código de modelo sin interacción
mod1_int=lmer(trigli~1+maq+(1|dia)+(1|dia:maq))
```

Observe que la interacción se coloca con : de manera que se coloca con esta indicación (1|dia:maq). Recuerde que los factores aleatorios se colocan así (1|factor).

6.3 Comparación de modelos con y sin interacción

Para verificar si hay interacción o no, necesitamos probar la siguiente hipótesis:

$$H_0 : \sigma_{\tau\delta}^2 = 0 \quad (\text{No existe interacción})$$

$$H_1 : \sigma_{\tau\delta}^2 > 0 \quad (\text{Existe interacción significativa})$$

Esta hipótesis se puede realizar mediante el método realizado en la sección de la prueba de la razón de verosimilitud

En r se realiza de la siguiente manera

```
anova(mod1, mod1_int, test = "LRT")

## refitting model(s) with ML (instead of REML)
## Data: NULL
## Models:
## mod1: trigli ~ 1 + maq + (1 | dia)
## mod1_int: trigli ~ 1 + maq + (1 | dia) + (1 | dia:maq)
##      npar      AIC      BIC logLik -2*log(L)  Chisq Df Pr(>Chisq)
## mod1      6 228.12 236.92 -108.06    216.12
## mod1_int  7 224.39 234.65 -105.19    210.39 5.7338  1    0.01664 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

# También se puede de esa manera anova(mod1, mod1_int, test = "Chisq")
#, depende de la versión del R
```

```
VarCorr(mod1)
```

```
## Groups   Name                Std.Dev.
## dia      (Intercept)  7.0879
## Residual                                6.5494
```

```
(7.0879)^2
```

```
## [1] 50.23833
```

```
(6.5494)^2
```

```
## [1] 42.89464
```

Observe que la variancia de día a día es 50.24 y la variancia residual es 42.89.

6.4 Esperanza marginal del factor de la unidad de nivel 2

En un modelo sin interacción podemos tener la siguiente esperanza:

$$E[E[Y|ij]] = \mu_{i*} = \beta_0 + \tau_i$$

6.5 Componentes de la varianza

Se consideran tres fuentes de variabilidad:

- La variación entre unidades de nivel 2 (inter sujeto): σ_δ^2
- La variación entre los datos dentro de una misma unidad de nivel 2 dentro del mismo factor (intra sujeto): σ_ε^2
- La variación de interacción: $\sigma_{\tau\delta}^2$

Como el intercepto β_0 y el efecto del factor τ_i es fijo esto nos lleva a que la varianza total es:

$$V(Y|i) = \sigma_i^2 = \sigma_\delta^2 + \sigma_{\tau\delta}^2 + \sigma_\varepsilon^2$$

7 Prueba de razón de verosimilitud

Definición de la verosimilitud creada en la clase: *La verosimilitud es que tan creíble la estimación de un parámetro, basado en los datos de la muestra. Con el objetivo de dar una medida de la credibilidad de la estimación.*

Esta nos sirve para probar la hipótesis relativa a la variancia del componente aleatorio de interacción: $H_0 : \sigma_\delta^2 = 0$ contra la alternativa: $H_1 : \sigma_\delta^2 > 0$.

Aunque la hipótesis se plantea en términos de una restricción para el parámetro, hay que tener presente que lo que se compara es la calidad del ajuste obtenido con **dos modelos anidados**. La prueba de la razón de verosimilitud (LRT) equivale a la diferencia de las devianzas de los dos modelos que se comparan (la fórmula está más abajo).

El estadístico LRT usa como distribución de referencia aproximada una chi-cuadrado con grados de libertad equivalente a la diferencia en el número de parámetros de ambos modelos.

A continuación se le presenta la fórmula

$$\begin{aligned}\chi^2_{(\nu)} &= D_\omega - D_\Omega \\ &= -2 \log(\mathcal{L}_\omega) - (-2 \log(\mathcal{L}_\Omega)) \\ &= -2 \log\left(\frac{\mathcal{L}_\omega}{\mathcal{L}_\Omega}\right)\end{aligned}$$

donde:

- Los ν es la diferencia del número de parámetros de los dos modelos
- D_ω : devianzia del modelo pequeño
- D_Ω : devianzia del modelo grande
- $\mathcal{L}_\omega$: valor de la máxima verosimilitud del modelo ω con los parámetros que la maximizan. Lo mismo para $\mathcal{L}_\Omega$
- $\frac{\mathcal{L}_\omega}{\mathcal{L}_\Omega}$ es la razón de las verosimilitudes **Esto es el LRT**

En este caso el valor-p obtenido debe tomarse con cautela ya que el parámetro que se prueba está en el borde del dominio de posibles valores para el parámetro.

El valor-p será conservador en el sentido de que será mayor que el valor-p que se obtendría en simulaciones.

En el peor de los casos el valor-p será el doble de lo que debería ser.

Ejemplo:

Tenemos los siguientes modelos:

Modelo 1:

$$y_{ij} = \beta_0 + \beta_1 X_1 + \delta_i + \varepsilon_{ij}$$

Modelo 2:

$$y_{ijk} = \beta_0 + \beta_1 X_1 + \tau_k + \delta_i + \varepsilon_{ijk}$$

donde: τ es un factor con tres niveles

Para el **modelo 1**:

- 2 parámetros fijos (β_0, β_1)
- 2 parámetros aleatorios ($\sigma_\delta^2, \sigma_\varepsilon^2$)

Para el **modelo 2**:

- 4 parámetros fijos ($\beta_0, \beta_1, \tau_1, \tau_2$)
- 2 parámetros aleatorios ($\sigma_\delta^2, \sigma_\varepsilon^2$)

Note que para el modelo 2 se usa suma nula. Por lo que $\sum \tau_i = 0$

Si se comparan estos dos modelos sería con la siguiente fórmula:

$$\chi^2_{(\nu)} = D_\omega - D_\Omega \sim \chi^2_{(2)}$$

Con esto podemos probar la siguientes hipótesis:

$$\begin{cases} H_0 : \tau_1 = \tau_2 = 0 \\ H_1 : \text{Al menos un } \tau_i \neq 0 \end{cases}$$

Con esto podemos concluir que las medias condicionales son iguales para los dos niveles del factor de los τ . Esto nos sirve para ver si las medias son iguales o distintas de dos modelos.

Si yo quiero probar el coeficiente δ_j , para ver si es importante que se encuentre en el modelo no lo puedo hacer con la función `drop1()`, así como se puede hacer con el factor del ejemplo anterior. Por ello para probar la hipótesis al inicio de esta sección se necesita el LRT. Normalmente este caso en específico se usa para observar si es necesario realizar o utilizar bloques en un experimento.

7.1 Prueba RMLE a mano

El siguiente ejemplo se basa en el experimento de las maquinas

Queremos ver la significancia del factor maquina, esto nos lleva a la siguiente hipótesis:

$$H_0 : \mu_{1\bullet} = \mu_{2\bullet} = \mu_{3\bullet} = \mu_{4\bullet}$$

Con esta hipótesis queremos decir que si la media para los 4 días es igual sin importar la maquina.

Realizandolo con la función `drop1`, obtenemos lo siguiente:

```
mod1=lmer(trigli~1+maq+(1|dia))
drop1(mod1, test = "Chisq")

## Single term deletions
##
## Model:
## trigli ~ 1 + maq + (1 | dia)
##          npar      AIC      LRT    Pr(Chi)
## <none>         228.12
## maq           3 248.18 26.058 9.275e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Para obtener ese valor de `Pr(Chi)` de forma manual tenemos que realizar el siguiente proceso:

```
mod1=lmer(trigli~1+maq+(1|dia), REML = F) #Modelo grande (con el factor máquina)
mod2=lmer(trigli~1+(1|dia), REML = F) #Modelo pequeño (sin el factor máquina)
LRT=-2*logLik(mod2)+2*logLik(mod1) #Resta de deviancias
gl = 3 # Son tres grados de libertad, porque son 3 coef en el modelo
p = pchisq(LRT,gl, lower.tail = F) #Se coloca el resultado en la prueba chi respectiva
cat("Prueba de razón de verosimilitud", LRT, "\nProbabilidad de la prueba chi-cuadrado es", p)
```

```
## Prueba de razón de verosimilitud 26.05783
## Probabilidad de la prueba chi-cuadrado es 9.275148e-06
```

8 Estimación de modelos mixtos en r

```
library(lme4) #librería para modelos mixtos

mod1=lmer(prod~(1|lote),data=base)

mod1.2=lmer(prod~(1|lote),data=base, REML = F) #Modelo con la máxima verosimilitud no restringida
```

Notas: El REML Máxima Verosimilitud Restringida. Además al ser un modelo sencillo el β_0 es igual a la media observada.

Con respecto al modelo REML, debido a que en los modelos mixtos se utilizan muchos parámetros para la estimación de máxima verosimilitud, lo que se realiza es fijar uno de los parámetros, para maximizar todos, para así de esa manera ir realizando combinaciones y como resultado se obtiene la maximización de todos. Puede ser que por este método de lo mismo que cuando se maximizan todos los parámetros al mismo tiempo.

8.1 Estimaciones manuales mediante un modelo lineal

Para poder explicar este tema se usa el siguiente caso de **Colorantes** en donde se tiene un solo factor aleatorio que son lotes de producción, y se quiere verificar si la variabilidad existente entre los promedios de los lotes es mucho mayor que la variabilidad del error.

```
mod2=lm(prod~lote,data=base)
anova(mod2)
```

Primero se debe tener claro este concepto:

$$\begin{aligned} V[\mu_i] &= V[\mu + \delta_i] \\ V[\mu_i] &= V[\mu] + V[\delta_i] \quad \text{donde } V[\mu] = 0 \\ V[\mu_i] &= \sigma_\delta^2 \end{aligned}$$

Se parte de las esperanzas de los cuadrados medios:

$$E[CM_{Lote}] = \sigma_\epsilon^2 + n\sigma_\delta^2$$

$$E[CM_{Res}] = \sigma_\epsilon^2$$

Se empieza estimando σ_{ϵ}^2 con el CMRes y se sustituye en la primera ecuación:

$$CM_{Lote} = CM_{Res} + n\sigma_\delta^2$$

Por lo tanto:

$$\hat{\sigma}_\delta^2 = \frac{CM_{Lote} - CM_{Res}}{n}$$

8.2 Intervalos de confianza para las varianzas


```
confint(mod1)
```

Nota: Se le llama **sigma** a la desviación estándar del error, **sig01** es la del lote. Para obtener la varianza recuerde elevar al cuadrado los resultados. Además note que los intervalos no son simétricos, debido a que el $\pm$ en el intervalo de confianza de varianzas no se utiliza. Si el límite inferior da cero quiere decir que el intervalo no se tuvo que haber realizado, debido a que la varianza puede ser cero.

Obtener los efectos aleatorios (δ) de forma directa

```
deltas = ranef(mod)
```

8.2.1 Código para las diferencias entre intervalos de confianza

```
ci = confint(mod)
ci = t(ci)
diff(ci)
```

Con esta diferencia podemos ver potencia, el ancho del intervalo. Para ello se tiene que simular varias veces y guardar esos resultados, para analizar cada uno de los casos anteriores. Para al final sacar el promedio del ancho del intervalo. De manera que cambiando **r** y **n** se llegue a un ancho del intervalo deseado.

9 Intervalos de confianza para las diferencias de diferentes categorías

Para las siguientes secciones se utilizará el siguiente ejemplo:

Se está desarrollando un nuevo modelo de espectrofotómetro para uso en laboratorios clínicos con el objetivo de cuantificar sustancias y microorganismos. Se quiere evaluar el funcionamiento de estos instrumentos sabiendo que un componente crítico del desempeño es la consistencia de las mediciones de un día a otro, y de una máquina a otra. Se quiere saber si la variabilidad de las mediciones entre las máquinas operadas durante varios días está dentro de los estándares aceptables.

Se cuenta con 4 máquinas etiquetadas como A, B, C y D. Cada día se preparan 8 replicaciones de muestras de suero en sangre. Dos muestras de suero se asignan aleatoriamente a cada una de las 4 máquinas en cada uno de los 4 días para un diseño completamente al azar con 2 repeticiones de cada tratamiento. En todas las muestras se usó el mismo lote de reactivos. Se miden los niveles de triglicéridos (mg/dl) en las muestras de suero.

Estos intervalos los podremos realizar, siempre y cuando el modelo que estemos analizando no posea interacción, ya que si la tiene el análisis es distinto, debido a que en estos modelos podemos tener unidades infinitas dependiendo del factor que se este analizando.

Para este tema usaremos el modelo **sin interacción** presentado en la sección de Modelo con interacción en **r**

```
fixef(mod1) # Se extraen los efectos fijos del modelo
```

```
## (Intercept)      maqB      maqC      maqD
##    147.0000      1.8000     -9.0750    -15.9875
```

Observe que **maqB** = 1.8, esto quiere decir que la maquina B es 1.8 puntos mayor que la máquina A, esto es debido a que estamos con el modelo de tratamiento de referencia y esa medida corresponde al efecto de la maquina B que se calcula de la siguiente manera $\alpha_b = \mu_b - \mu_a$. Es importante resaltar que la máquina que tiene menor media es la D. Recuerde que la restricción de referencia es $\alpha_1 = 0$

```
confint(mod1)
```

```
## Computing profile confidence intervals ...
```

```
##           2.5 %    97.5 %
## .sig01      2.903589 15.684370
## .sigma      4.863709  8.245133
## (Intercept) 138.251867 155.748123
## maqB        -4.478779  8.078779
## maqC       -15.353779 -2.796221
## maqD       -22.266279 -9.708721
```

Al observar el intervalo de 95% de confianza se tiene que la desviación estándar de día a día está entre 2.9 y 15.7. Esto confirma que esta fuente de variabilidad es importante. Por lo tanto, hay evidencia que hay fuentes de variabilidad que deben revisarse para que este modelo de espectrofotómetro funcione mejor. Se esperaría mayor consistencia de uno a otro día.

9.1 Hipótesis sobre la diferencias entre categorías

Basado en el mismo ejemplo de la sección anterior queremos probar lo siguiente:

$$H_0 : \alpha_i = 0 \forall_i \text{ ó } \alpha_2 = \alpha_3 = \alpha_4$$

La función `drop1` nos sirve para probar si las medias de las 4 máquinas son iguales que es lo mismo que probar si los efectos de las 4 máquinas son iguales a cero.

```
drop1(mod1,test="Chisq") # En este caso, nos sirve para probar un factor fijo.
```

```
## Single term deletions
##
## Model:
## trigli ~ 1 + maq + (1 | dia)
##           npar    AIC    LRT   Pr(Chi)
## <none>         228.12
## maq           3 248.18 26.058 9.275e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
#drop1(mod1_int,test="Chisq") # ESTE CÓDIGO ESTA MAL, YA QUE drop1, SOLO SIRVE PARA FIJOS
```

En el resultado la línea de `maq` es la prueba que nos sirve para probar si las medias de las 4 máquinas son iguales, que es lo mismo que probar que los efectos de las máquinas son iguales a cero **Ver hipótesis inicial.**

Para la calcularlo a pie

```
pchisq(26.058,3, lower.tail = F) # Fórmula a pie, para el chisq
```

```
## [1] 9.274407e-06
```

Restamos las devianzas de los modelos y ese valor lo colocamos en el siguiente código en lugar de 26.058, el número 3 son los grados de libertad porque el modelo que incluye máquina tiene 3 coeficientes más que el que no tiene este factor, son 3 coeficientes porque son 4 máquinas en el experimento.

Conclusión del resultado: Con $p < 0.001$ en la prueba LRT se rechaza esta hipótesis y se concluye que no se están obteniendo los mismos promedios en todas las máquinas.

9.2 Intervalos de confianza mediante la función `emmeans`

Corrección de Bonferroni: El profesor recomienda realizar este ya que es más seguro, debido a que se trata de un modelo mixto

```
library(emmeans)
em.mod1=emmeans(mod1,pairwise~maq,adjust="bonferroni")
#emmeans(mod1,pairwise~factor_fijo,adjust="bonferroni")
em.mod1$contrasts
```

```
## contrast estimate SE df t.ratio p.value
## A - B -1.80 3.27 31.4 -0.550 1.0000
## A - C 9.07 3.27 31.4 2.771 0.0558
## A - D 15.99 3.27 31.4 4.882 0.0002
## B - C 10.88 3.27 31.4 3.321 0.0137
## B - D 17.79 3.27 31.4 5.432 <0.0001
## C - D 6.91 3.27 31.4 2.111 0.2571
##
## Degrees-of-freedom method: kenward-roger
## P value adjustment: bonferroni method for 6 tests
```

El p-value se compara contra α , ya que la función hace la corrección de una vez.

Tuckey

```
em.mod2=emmeans(mod1,pairwise~maq) #Realizados mediante prueba tuckey
em.mod2$contrasts
```

```
## contrast estimate SE df t.ratio p.value
## A - B -1.80 3.27 31.4 -0.550 0.9459
## A - C 9.07 3.27 31.4 2.771 0.0438
## A - D 15.99 3.27 31.4 4.882 0.0002
## B - C 10.88 3.27 31.4 3.321 0.0116
## B - D 17.79 3.27 31.4 5.432 <0.0001
## C - D 6.91 3.27 31.4 2.111 0.1718
##
## Degrees-of-freedom method: kenward-roger
## P value adjustment: tukey method for comparing a family of 4 estimates
```

Observe que el p-value cambia

9.3 Comparaciones para el nivel de significancia α cuando se usa emmeans (Bonferroni)

Tipo de Prueba	Emmeans	A pie (Manual)
Una cola	$\frac{p}{2} < \alpha$ ó $p < 2 \cdot \alpha$	$p < \frac{\alpha}{d}$
Dos colas	$p < \alpha$	$p < \frac{\alpha}{2d}$

9.3.1 Proceso manual para la creación de intervalos de confianza

Dado el siguiente modelo:

$$y_{ijk} = \beta_0 + \tau_i + \delta_i$$

donde:

- τ_i : Es el efecto de la maquina i-ésima
- δ_i : Ese es el efecto del día (recuerde que este aleatorio)

```
contrasts(maq)
```

```
##      B C D
## A  0 0 0
## B  1 0 0
## C  0 1 0
## D  0 0 1

A=c(0,0,0,0)
B=c(0,1,0,0)
C=c(0,0,1,0)
D=c(0,0,0,1)
AB=A-B
CD=C-D
AD =A-D
AC = A-C
BC = B-C
BD = B-D
h =cbind(AB, AC, AD, BC, BD, CD)
coef = fixef(mod1)
L = t(h)%*%coef
ee = sqrt(diag(t(h)%*%vcov(mod1)%*%h))
q = abs(L)/ee
p = pt(q,25,lower.tail = F)
round(p*12,3) # Estas son las probabilidad que tira el emmeans

##      [,1]
## AB 3.525
## AC 0.062
## AD 0.000
## BC 0.017
## BD 0.000
## CD 0.270

# round(p*6,3) probabilidades de una cola
```

Comparaciones

```
# Recuerde que el número de diferencias es 6 en este caso
cat("Comparación de dos colas", p < 0.05/12 )
```

```
## Comparación de dos colas FALSE FALSE TRUE TRUE TRUE FALSE
cat("\nComparación de una cola",p < 0.05/6)
```

```
##
## Comparación de una cola FALSE TRUE TRUE TRUE TRUE FALSE
```

Podemos extraer los valores estimados de la función `emmeans`, para mejorar los intervalos de confianza

Podemos mejorar los intervalos, debido a que la función `emmeans`, toma en cuenta todas las diferencias posibles. Sin embargo, no todas las diferencias son significativas, por lo que se necesita aplicar el siguiente proceso para mejorar su precisión.

```
d = confint(em.mod1)$contrasts[3:5,2] #Extraemos las que fueron significativas
ee = confint(em.mod1)$contrasts[3:5,3] #Extraemos sus errores estándar
gl = 25 #Esto lo podemos obtener del emmeans
t = qt(1-0.05/2*length(d),gl)
ic = cbind(d-t*ee,d+t*ee)
round(ic,3)
```

```
##           [,1]      [,2]
## [1,] 11.124 20.851
## [2,]  6.012 15.738
## [3,] 12.924 22.651
```

10 Parcelas divididas


Cuando el diseño es de dos niveles con un factor en cada nivel, al mismo se le puede llamar como parcelas divididas. Un ejemplo de esto sería un experimento que quiere comparar el crecimiento de dos especies de papa en dos tipos de clima. En donde se siembran dos especies de papas en fincas que se encuentran en un clima frío y en otras que tienen un clima caliente.

Aspectos importantes de este diseño:

- El factor que clasifica a los bloques es el factor superior o factor de parcela.
- El factor cuyos niveles están dentro del bloque es el factor de subparcela.
- Este tipo de diseños se analizan con el enfoque de modelos mixtos, donde el efecto del bloque se considera aleatorio pues los bloques se extraen de una población mayor de bloques.
- Estos diseños nacen en Agronomía y literalmente obedecen a una parcela agrícola que se divide.
- *Cuando se trata de un diseño en otro contexto se llama simplemente diseño multinivel con un factor en el nivel 1 y factor en el nivel 2.*


10.1 Cambio de categórica a numérica

Observe el siguiente ejemplo basado en el experimento del papel



A la izquierda podemos ver los resultados del experimento, sin embargo podemos ver que la variable temperatura se encuentra como una categoría. Lo que se nos viene la siguiente pregunta: *¿Podemos convertirla en una variable numérica?*, por lo que tratamos de unir todas las respuesta, como lo podemos observar en el gráfico de la derecha, esto nos puede ocasionar un problema, ya que al realizar esto, estaríamos ignorando el cumplimiento del supuesto de linealidad, debido a que este no se cumple, no podemos convertir la variable *Temperatura* en una variable numérica.

Observe esta otra situación:



Para este caso, sí podemos convertir la temperatura en una variable categórica en una variable numérica debido a que parece que no hay problemas con el supuesto de linealidad. También es importante ver el comportamiento inverso, si los datos se conforman en grupos y no de manera continua, por lo que podemos realizar el cambio de una variable numérica a una categórica.

10.2 Sobre el diseño de bloques y parcelas

La ventaja de usar parcelas divididas o bloques, es que nosotros podemos medir cuanta variabilidad están ocasionando los bloques y parcelas, por lo que esta variabilidad la podemos extraer y con esto al final desinflamos la variabilidad, con esto podemos obtener predicciones más precisas. Por otro lado, cuando el diseño es totalmente aleatorio esa variabilidad de bloque a bloque no la puedo extraer, por lo que no la puedo eliminar del modelo, como consecuencia toda esa variabilidad no cuantificada se dirige a la variabilidad del error. También si hay una varianza del error mayor, esto nos obliga a utilizar una mayor cantidad de muestra para observar resultados en nuestro experimento.

11 Diseños multinivel

11.1 Diseño con 2 niveles y factor fijo en ambos niveles

Un fabricante de papel está interesado en tres métodos para preparar la pulpa y cuatro temperaturas de cocción de la pulpa. Aunque la temperatura es una variable continua, solo se van a estudiar 4 temperaturas.

El fabricante desea estudiar el efecto del método y de la temperatura sobre la resistencia a la tensión del papel, que es el esfuerzo máximo a tensión obtenido durante una prueba hasta la ruptura bajo unas condiciones prescritas. El esfuerzo es expresado como la fuerza por unidad del ancho de la muestra puesta a prueba, medido en kg/cm.

El experimento se lleva a cabo de la siguiente forma:

- Produce tres lotes de pulpa con cada uno de los tres métodos que está estudiando en un orden aleatorio. En total produce 9 lotes de pulpa.
- Cada vez que produce un lote lo divide en cuatro partes o muestras y realiza la cocción de cada muestra a una temperatura diferente.

Además es importante resaltar que este tipo de diseño es un diseño de parcelas divididas.

1. Recordar realizar el análisis gráfico de interacción mediante el gráfico `xyplot()`

Ejemplo de código

```
library(lattice)
xyplot(res ~ metodo, groups = temp, type="a", auto.key=list(columns=4),
       xlab="método", ylab="resistencia", data=base)
```

2. Realizar el modelo con la interacción

```
library(lme4)
options(contrasts = c("contr.treatment", "contr.poly")) #Nos pasamos a suma nula
mod1=lmer(res~metodo*temp+(1|lote),data=base) #Lote es aleatorio y porque tiene diferentes observaciones
```

3. Probar la hipótesis de interacción mediante la función `drop1`

```
drop1(mod1,test="Chisq") #Se usa drop1, porque metodo y temp son fijos
```

```
## Single term deletions
##
## Model:
## res ~ metodo * temp + (1 | lote)
##               npar      AIC      LRT Pr(Chi)
## <none>                179.97
## metodo:temp      6 183.32 15.349 0.01771 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nota: Analice si existen valores que pueden estar afectando la hipótesis de interacción, por medio del gráfico `xyplot()`. Lo mismo lo puede analizar con el siguiente código:

```
which(base$res == min(base$res)) #Ubicar el valor mínimo o máximo
base2 = base[-26,] # Eliminar el valor
mod2=lmer(res~metodo*temp+(1|lote),data=base2) #Hacer el modelo con la nueva base
drop1(mod2,test="Chisq") #Probar de nuevo la hipótesis de interacción
```

11.1.1 Análisis de diferencias de medias con `emmeans`

1. Realizar la hipótesis de diferencias entre medias

```
library(emmeans)
a = emmeans(mod1, pairwise~temp|metodo, adjust="bonferroni")$contrasts
# El código de arriba nos indica que se van a comparar las temperaturas dentro de cada método.
# Esto se lo indicamos a R por medio del temp/metodo, si no hay interacción se quita el método.
a

## metodo = M1:
## contrast      estimate    SE df t.ratio p.value
## temp200 - temp225   -5.000 1.68 18  -2.983  0.0478
## temp200 - temp250   -7.333 1.68 18  -4.376  0.0022
## temp200 - temp275   -9.333 1.68 18  -5.569  0.0002
```



```
## temp225 - temp250 -2.333 1.68 18 -1.392 1.0000
## temp225 - temp275 -4.333 1.68 18 -2.586 0.1119
## temp250 - temp275 -2.000 1.68 18 -1.193 1.0000
##
## metodo = M2:
## contrast estimate SE df t.ratio p.value
## temp200 - temp225 -5.667 1.68 18 -3.381 0.0200
## temp200 - temp250 -6.333 1.68 18 -3.779 0.0082
## temp200 - temp275 -8.667 1.68 18 -5.171 0.0004
## temp225 - temp250 -0.667 1.68 18 -0.398 1.0000
## temp225 - temp275 -3.000 1.68 18 -1.790 0.5417
## temp250 - temp275 -2.333 1.68 18 -1.392 1.0000
##
## metodo = M3:
## contrast estimate SE df t.ratio p.value
## temp200 - temp225 0.667 1.68 18 0.398 1.0000
## temp200 - temp250 -4.000 1.68 18 -2.387 0.1691
## temp200 - temp275 -9.667 1.68 18 -5.768 0.0001
## temp225 - temp250 -4.667 1.68 18 -2.785 0.0734
## temp225 - temp275 -10.333 1.68 18 -6.166 <0.0001
## temp250 - temp275 -5.667 1.68 18 -3.381 0.0200
##
## Degrees-of-freedom method: kenward-roger
## P value adjustment: bonferroni method for 6 tests
```

Del resultado anterior podemos concluir lo siguiente:

Método 1 :	200	<u>225</u>	<u>250</u>	<u>275</u>
Método 2 :	200	<u>225</u>	<u>250</u>	<u>275</u>
Método 3 :	<u>200</u>	<u>225</u>	<u>250</u>	275

donde la linea temperatura, presenta que no hubieron diferencias significativas entre ellas.

Lo anterior tiene implicaciones en las conclusiones depende el método que se escoja. Por lo tanto **si hay que escoger una temperatura escogemos al 275**

Ahora realizando el análisis desde el otro punto de vista, **desde cuál método escojo según la temperatura**

```
b = emmeans(mod1, pairwise~metodo|temp, adjust="bonferroni")$contrasts
b
```

```
## temp = 200:
## contrast estimate SE df t.ratio p.value
## M1 - M2 -3.67 2.23 15.3 -1.646 0.3604
## M1 - M3 -1.00 2.23 15.3 -0.449 1.0000
## M2 - M3 2.67 2.23 15.3 1.197 0.7484
##
## temp = 225:
## contrast estimate SE df t.ratio p.value
## M1 - M2 -4.33 2.23 15.3 -1.945 0.2110
## M1 - M3 4.67 2.23 15.3 2.095 0.1596
## M2 - M3 9.00 2.23 15.3 4.040 0.0031
##
## temp = 250:
## contrast estimate SE df t.ratio p.value
## M1 - M2 -2.67 2.23 15.3 -1.197 0.7484
```

```
## M1 - M3      2.33 2.23 15.3    1.047 0.9335
## M2 - M3      5.00 2.23 15.3    2.244 0.1199
##
## temp = 275:
## contrast estimate SE df t.ratio p.value
## M1 - M2      -3.00 2.23 15.3   -1.347 0.5930
## M1 - M3      -1.33 2.23 15.3   -0.599 1.0000
## M2 - M3       1.67 2.23 15.3    0.748 1.0000
##
## Degrees-of-freedom method: kenward-roger
## P value adjustment: bonferroni method for 3 tests
```

Temp 200 M1 M2 M3

$$\text{Temp 225} \begin{cases} \frac{M_3}{M_1} & \text{No hay diferencia} \\ \frac{M_1}{M_2} & \text{No hay diferencia} \\ M_3 \neq M_2 & \text{Diferencia significativa} \end{cases}$$

Temp 250 M1 M2 M3

Temp 275 M1 M2 M3

Esto nos lleva a que podemos escoger cualquier método para las temperaturas 200, 250, 275. En cambio para la temperatura debemos escoger el método uno o dos ya que este último es el mayor en esta temperatura, esto lo puede verificar viendo el `estimate`, para la temperatura 225. Sin embargo no tiene diferencias significativas con el método uno entonces da lo mismo escoger uno o dos. También lo podemos analizar mediante el gráfico `xyplot()`.

Si quiero usar el resultado anterior, pero con dos colas

```
p_valores <- as.data.frame(a)$p.value # Extracción del p valor
2*p_valores < 0.05 #Para comparar con una cola

ic = confint(a)
ic
```

```
## metodo = M1:
## contrast      estimate SE df lower.CL upper.CL
## temp200 - temp225  -5.000 1.68 18   -9.97  -0.0348
## temp200 - temp250  -7.333 1.68 18  -12.30  -2.3681
## temp200 - temp275  -9.333 1.68 18  -14.30  -4.3681
## temp225 - temp250  -2.333 1.68 18   -7.30   2.6319
## temp225 - temp275  -4.333 1.68 18   -9.30   0.6319
## temp250 - temp275  -2.000 1.68 18   -6.97   2.9652
##
## metodo = M2:
## contrast      estimate SE df lower.CL upper.CL
## temp200 - temp225  -5.667 1.68 18  -10.63  -0.7014
## temp200 - temp250  -6.333 1.68 18  -11.30  -1.3681
## temp200 - temp275  -8.667 1.68 18  -13.63  -3.7014
## temp225 - temp250  -0.667 1.68 18   -5.63   4.2986
## temp225 - temp275  -3.000 1.68 18   -7.97   1.9652
## temp250 - temp275  -2.333 1.68 18   -7.30   2.6319
```

```
##
## metodo = M3:
## contrast      estimate    SE df lower.CL upper.CL
## temp200 - temp225    0.667 1.68 18    -4.30    5.6319
## temp200 - temp250   -4.000 1.68 18    -8.97    0.9652
## temp200 - temp275   -9.667 1.68 18   -14.63   -4.7014
## temp225 - temp250   -4.667 1.68 18    -9.63    0.2986
## temp225 - temp275  -10.333 1.68 18   -15.30   -5.3681
## temp250 - temp275   -5.667 1.68 18   -10.63   -0.7014
##
## Degrees-of-freedom method: kenward-roger
## Confidence level used: 0.95
## Conf-level adjustment: bonferroni method for 6 estimates
```

11.1.2 Corrección de intervalos de confianza

Como la función `emmeans` usa un nivel de significancia global, estos intervalos son más anchos. Para ello debemos reconstruirlos tomando en cuenta solo aquellas diferencias que son significativas. Esto lo debemos realizar para observar si esa diferencias es relevante para nuestro estudio u objetivo.

Para realizar ese proceso tome como ejemplo, los coeficientes del siguiente modelo:

```
round(summary(mod1)$coef[,1],2)
```

```
##      (Intercept)      metodoM2      metodoM3      temp225
##      29.67      3.67      1.00      5.00
##      temp250      temp275 metodoM2:temp225 metodoM3:temp225
##      7.33      9.33      0.67      -5.67
## metodoM2:temp250 metodoM3:temp250 metodoM2:temp275 metodoM3:temp275
##      -1.00      -3.33      -0.67      0.33
```

Nota: Recuerde que este análisis es marginal, solo para las temperaturas

```
c=summary(mod1)$coef[,1]
c200=c(1,0,0,0,0,0,0,0,0,0,0,0)
c225=c(1,0,0,1,0,0,0,0,0,0,0,0)
c250=c(1,0,0,0,1,0,0,0,0,0,0,0)
c275=c(1,0,0,0,0,1,0,0,0,0,0,0)
c225.200=c225-c200
c250.200=c250-c200
c275.200=c275-c200
c250.225=c250-c225
c275.225=c275-c225
c275.250=c275-c250
cont=cbind(c225.200,c250.200,c275.200,c250.225,c275.225,c275.250)
L=t(cont)%*%c
ee=sqrt(diag(t(cont)%*%vcov(mod1)%*%cont))
t=L/ee
round(pt(t,18,lower.tail = F),5)
```

```
##      [,1]
## c225.200 0.00398
## c250.200 0.00018
## c275.200 0.00001
## c250.225 0.09040
## c275.225 0.00933
## c275.250 0.12410
```

```
t = qt(1-0.05/12,18) # recuerde que el número de diferencias es 6, por lo que estamos haciendo interval
ic = cbind(L-t*ee,L+t*ee)
round(ic,3)
```

```
##           [,1]    [,2]
## c225.200  0.035  9.965
## c250.200  2.368 12.299
## c275.200  4.368 14.299
## c250.225 -2.632  7.299
## c275.225 -0.632  9.299
## c275.250 -2.965  6.965
```


11.2 Diseño con 3 niveles

Como variante del ejercicio anterior (experimento papel), suponga que la capacidad de la planta solo permite realizar 15 corridas por día y se sospecha que de un día a otro se pueden experimentar diferencias en la resistencia. Entonces el fabricante decide considerar los días como bloques y corre una réplica en cada uno de tres días. Lleva a cabo el experimento así:

- Cada día produce tres lotes de pulpa, cada lote con uno de los tres métodos que está estudiando en un orden aleatorio.
- Cada lote se divide en cuatro partes o muestras y realiza la cocción de cada muestra con una temperatura diferente, asignada aleatoriamente.

11.2.1 Gráfico de interacción

```
xyplot(res ~ metodo|dia, groups = temp,type=c("p","a"),auto.key=list(columns=4),
       xlab="método",ylab="resistencia",data=base)
```



11.2.2 Creación del modelo en r

```
#Estos dos códigos son los mismo
mod1=lmer(res~metodo*temp+(1|dia/lote1),data=base)
mod2 =lmer(res~metodo*temp+(1|dia)+(1|lote1), data = base)
```

Código para extraer las varianzas de los factores aleatorios

```
VarCorr(mod2)
```

```
## Groups   Name                Std.Dev.
## lote1    (Intercept) 0.0000
## dia      (Intercept) 1.3707
## Residual                    2.3533
```

Hipótesis de interacción

```
drop1(mod2,test="Chisq")
```

```
## Single term deletions
##
## Model:
## res ~ metodo * temp + (1 | dia) + (1 | lote1)
##          npar    AIC    LRT Pr(Chi)
## <none>         184.06
## metodo:temp    6 181.74 9.6848  0.1386
```

Como no hay interacción podemos realizar comparaciones marginales, es decir podemos comparar los métodos

sin importar la temperatura o viceversa. Además nos pasamos un modelo que asume que no hay interacción.

12 Diseños Anidados

Esta sección se basa en el siguiente ejemplo

Una compañía manufacturera tiene tres escuelas de mecánica regionales, una en cada una de sus regiones de operación. Cada escuela tiene dos instructores que dan cursos de tres semanas a 15 mecánicos aproximadamente. La compañía está interesada en conocer el efecto de la escuela (factor A) y el instructor (factor B) en el aprendizaje logrado. Se hace un experimento en el que se forman grupos en cada región y se asigna cada grupo a uno de los instructores. A cada instructor se le asignan dos grupos.


$$\text{Estructura del Experimento} \left\{ \begin{array}{ll} \text{Nivel 3 (Escuela)} & \rightarrow \text{Factor Principal (Regional)} \\ \text{Nivel 2 (Instructor)} & \rightarrow \text{Anidado en Escuela} \\ \text{Nivel 1 (Grupo)} & \rightarrow \text{Unidad Observacional (Mecánicos)} \end{array} \right.$$

12.1 Definición de diseño a anidado

En un diseño anidado, los niveles de un factor (el anidado) son únicos para cada nivel del factor superior. Esto significa que el *Instructor 1* de la Escuela A no es la misma persona que el *Instructor 1* de la Escuela B; comparten un nombre o etiqueta, pero son unidades distintas. Si son idénticos en todos los niveles de un factor no es anidado.

12.1.1 Gráfico para representar gráficamente los datos y observar variabilidad

```
dotplot(puntaje ~ instructor | escuela,xlab="instructor",  
layout = c(3,1),data=base) # el layout normalmente se pone en lugar del 3, la cantidad de cajas que se
```




Debido a que este diseño es anidado, **no se analiza la interacción**, porque la interacción compara dos niveles (los mismos dos niveles), en cada nivel del otro factor, esto es debido a que todos son diferentes en cada uno de los niveles.

La cantidad de niveles se debe analizar dentro de cada factor, en el ejemplo anterior se debe analizar dentro de cada región, por lo que en este caso hay 2 por región.

Observe el siguiente gráfico, para observar las diferencias entre escuelas

```
bwplot(puntaje~escuela,xlab="escuela",ylab="puntaje",data=base)
```



Se nota que algunas escuelas tienen puntajes promedio más altos que otras, por lo que sí se esperaría un efecto de la escuela en el aprendizaje. En particular, se notan mayores diferencias entre la escuela Central y Región K. Sin embargo, aquí no se está aislando la variabilidad que producen los instructores, lo que hace que esas diferencias no sean tan claras.

12.1.2 De un diseño anidado a un multinivel

En un país extremadamente grande habían muchas escuelas de instructores y se seleccionan 3 escuelas. Además se quiere generalizar el estudio para todas las escuelas, por lo que me interesa es observar la variabilidad entre estas. Dentro de cada escuela hay una cantidad considerable de instructores, así que se seleccionaron en cada una de las escuelas elegidas anteriormente dos instructores, por lo que estos ya son una muestra del total de instructores y cada uno de esos dos instructores tiene dos grupos, los cuales son los que voy a observar para el estudio.

Note que no hay factores fijos, por lo que es un diseño de dos niveles sin factores

Lo anterior es un ejemplo de un diseño multinivel, debido a que mi interés es ver la variabilidad entre escuelas.

12.2 Modelo del diseño anidado

$$\mu_{ij} = \mu + \alpha_1 C_1 + \alpha_2 C_2 + \beta_{2(1)} B_{21} + \beta_{2(2)} B_{22} + \beta_{2(3)} B_{23}$$

donde:

- α_1, α_2 , es el efecto de la región (escuela), la cual tiene la restricción $\alpha_3 = -\alpha_1 - \alpha_2$
- $\beta_{2(1)}, \beta_{2(2)}, \beta_{2(3)}$, es el efecto del instructor dentro de cada región. Las restricciones de cada nivel de forma resumida es $\beta_{2(i)} = -\beta_{1(i)}$

A continuación se le presentan las variables auxiliares

$$\mathbf{C} = \begin{array}{c|cc} & C_1 & C_2 \\ \hline \text{Reg 1} & 1 & 0 \\ \text{Reg 2} & 0 & 1 \\ \text{Reg 3} & -1 & -1 \end{array}, \quad \mathbf{B} = \begin{array}{c|ccc} & B_{21} & B_{22} & B_{23} \\ \hline I_{1(1)} & -1 & 0 & 0 \\ I_{2(1)} & 1 & 0 & 0 \\ I_{1(2)} & 0 & -1 & 0 \\ I_{2(2)} & 0 & 1 & 0 \\ I_{1(3)} & 0 & 0 & -1 \\ I_{2(3)} & 0 & 0 & 1 \end{array}$$

12.2.1 Obtener manualmente los efectos de instructor

Estos efectos representan la distancia de la media general de cada instructor hasta la media general de los instructores de esa escuela.

```
medinst=with(base,tapply(puntaje,list(instructor,escuela),mean))
medinst
```

```
## Región K Región D Central
## 1 27.0 8.5 18.5
## 2 12.5 20.0 3.5
```

```
medesc=with(base,tapply(puntaje,escuela,mean))
medesc
```

```
## Región K Región D Central
## 19.75 14.25 11.00
```

```
bj.1=medinst[,1]-medesc[1]
bj.2=medinst[,2]-medesc[2]
bj.3=medinst[,3]-medesc[3]
efinst=rbind(bj.1,bj.2,bj.3)
efinst
```

```
## 1 2
## bj.1 7.25 -7.25
## bj.2 -5.75 5.75
## bj.3 7.50 -7.50
```

12.2.2 Obtención de manual de la suma de cuadrados de instructor dentro de cada escuela

$$SCInst = \sum_{i=1}^R \sum_{j=1}^I 2\beta_{j(i)}^2$$

donde:

- R : cantidad de regiones
- I : cantidad de instructores dentro de cada región

$$CMInst = \frac{SCInst}{\sum_{i=1}^R (b_i - 1)}$$

donde

- b_i : número de intructores dentro de cada escuela

```
with(base,table(instructor,escuela)) #Réplicas por tratamiento
```

```
##          escuela
## instructor Región K Región D Central
##          1         2         2         2
##          2         2         2         2
```

```
r=2 #número de instructores por cada escuela
scinst=sum(r*efinst^2)
scinst
```

```
## [1] 567.5
```

```
gl=(2-1)*3
gl
```

```
## [1] 3
```

```
cminst=scinst/gl
cminst
```

```
## [1] 189.1667
```

El cuadrado medio de instructor dentro de escuela es 189.2. Esta es una medida de la variabilidad entre los promedios obtenidos por los instructores de cada escuela.

12.2.3 Comparación de instructores dentro de cada escuela

Como son independientes las comparaciones, no se necesita realizar corrección, ya que lo que nos interesa es si existen diferencias entre ellos, pero dentro de cada grupo. Lo cual nos lleva a la siguiente hipótesis:

$$H_0 : \beta_{1(i)} = 0, \quad \forall i$$

$$H_1 : \text{Al menos un } \beta_{1(i)} \neq 0$$

$$H_0 : \mu_{1(i)} = \mu_{2(i)}, \quad \forall i$$

$$H_1 : \text{Al menos un } \mu_{1(i)} \neq \mu_{2(i)}$$

```
mod2=lm(puntaje~escuela+instructor1,data=base)
anova(mod2)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Response: puntaje
```

```
##          Df Sum Sq Mean Sq F value    Pr(>F)
## escuela    2  156.5    78.25   11.179 0.009473 **
## instructor1 3  567.5   189.17   27.024 0.000697 ***
## Residuals   6   42.0     7.00
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Note que en los `gl` dan $(n-1)$, ya que el total de observaciones eran 12 y sumando la columna de los `df` nos da como resultado 11. `instructor1` es la variable no anidada. Por lo tanto, lo correcto es que se haga con la variable normal.

12.2.4 Indicarle a R que es un modelo para un diseño anidado

```
options(contrasts=c("contr.sum","contr.poly")) #Suma nula
mod3=lm(puntaje~escuela+escuela/instructor,data=base)
```

Estimaciones automáticas de los efectos

```
model.tables(aov(mod3))
```

```
## Tables of effects
##
## escuela
## escuela
## Región K Región D Central
## 4.75 -0.75 -4.00
##
## escuela:instructor
## instructor
## escuela 1 2
## Región K 7.25 -7.25
## Región D -5.75 5.75
## Central 7.50 -7.50
```

```
anova(mod3)#da lo mismo que con el mod2
```

```
## Analysis of Variance Table
##
## Response: puntaje
##      Df Sum Sq Mean Sq F value    Pr(>F)
## escuela      2  156.5    78.25  11.179 0.009473 **
## escuela:instructor 3  567.5   189.17  27.024 0.000697 ***
## Residuals      6   42.0     7.00
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

12.2.5 Comparaciones entre instructores

```
(em2=emmeans(mod3,pairwise~instructor|escuela))$contrasts
```

```
## escuela = Central:
## contrast      estimate    SE df t.ratio p.value
## instructor1 - instructor2    15.0 2.65 6  5.669 0.0013
##
## escuela = Región D:
## contrast      estimate    SE df t.ratio p.value
## instructor1 - instructor2   -11.5 2.65 6 -4.347 0.0048
##
## escuela = Región K:
## contrast      estimate    SE df t.ratio p.value
## instructor1 - instructor2    14.5 2.65 6  5.480 0.0015
```

Recuerde que las comparaciones se hacen con un $\alpha = 0.05$

Se realizan los intervalos de confianza

```
confint(em2)$contrasts
```

```
## escuela = Central:
## contrast      estimate    SE df lower.CL upper.CL
```

```
## instructor1 - instructor2      15.0 2.65  6      8.53   21.47
##
## escuela = Región D:
## contrast          estimate    SE df lower.CL upper.CL
## instructor1 - instructor2    -11.5 2.65  6    -17.97    -5.03
##
## escuela = Región K:
## contrast          estimate    SE df lower.CL upper.CL
## instructor1 - instructor2     14.5 2.65  6      8.03   20.97
##
## Confidence level used: 0.95
```

12.2.6 Comparaciones entre escuelas

```
TukeyHSD(aov(mod3), "escuela")
```

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = mod3)
##
## $escuela
##              diff          lwr          upr          p adj
## Región D-Región K -5.50 -11.240216  0.2402158 0.0586129
## Central-Región K  -8.75 -14.490216 -3.0097842 0.0081224
## Central-Región D  -3.25  -8.990216  2.4902158 0.2676596
```

Observe que existe diferencias entre Central-Región K, por lo que se realiza un intervalo de confianza

```
t=qt(1-0.05/2,6)
round(c(8.75-t*1.87,8.75+t*1.87),2)
```

```
## [1]  4.17 13.33
```

13 Simulaciones

13.1 Simulación de intervalos de confianza

```
sim_ancho <- function(n, r, k = 10, med = 1500, sd.lote = 42, sd.res = 49.51) {
  # Los argumentos deberían ir aquí si no estamos en una función
  lote <- rep(1:n, each = r) # Creación de la variable lote
  res <- matrix(nrow = k, ncol = 3) # Creación de la matriz de resultados

  for(i in 1:k) {
    ef.lote <- rnorm(n, 0, sd.lote) # Simulación del efecto del lote
    muj <- med + ef.lote # Media de cada lote
    mujs <- rep(muj, each = r) # Repetición de la media para cada réplica
    y <- rnorm(n * r, mujs, sd.res) # Simulación de la respuesta
    modn <- lmer(y ~ (1 | lote)) # Creación del modelo con esa variable
    ci <- confint(modn) # Intervalos de confianza para el modelo creado
    res[i, ] <- diff(t(ci)) # Cálculo de anchos de los intervalos y se guardan en la matriz
    prom = apply(res, 2, mean) # Se calcula la media de los resultados de la matriz
  }
}
```

```

    return(list(prom,res))
}

```

```

sim_ancho(6,5) #Ejemplo de uso de la función anterior

```

13.2 Combinaciones múltiples del ancho del intervalo

```

sim_ancho_todos <- function(k = 10, med = 1500, sd.lote = 42, sd.res = 49.51) {
  # Los parámetros pueden ir en esta parte cuando no se trate de una función
  resultado_final <- data.frame()

  for(n in 2:10) { #Número de lotes
    for(r in 2:10) { #número de réplicas por lote

      if(n * r <= 30) { # Número máximo de réplicas

        lote <- rep(1:n, each = r) # Creación de la variable lote
        res <- matrix(nrow = k, ncol = 3) #Creación de la matriz de resultados

        for(i in 1:k) {
          ef.lote <- rnorm(n, 0, sd.lote)
          muj <- med + ef.lote
          mujs <- rep(muj, each = r)
          y <- rnorm(n * r, mujs, sd.res)
          modn <- lmer(y ~ (1 | lote))
          ci <- confint(modn)
          res[i, ] <- diff(t(ci))
        }

        prom <- apply(res, 2, mean)

        resultado_final <- rbind(resultado_final,
                                data.frame(n = n,
                                             r = r,
                                             Ntotal = n * r,
                                             ancho1 = prom[1],
                                             ancho2 = prom[2],
                                             ancho3 = prom[3]))
      }
    }
  }

  return(resultado_final)
}

```

```

resultado <- sim_ancho_todos(k = 10)
resultado

```

```

#encontrar el ancho mínimo de ancho1
ancho_min <- min(resultado$ancho1)

```

```

#encontrar en qué fila está
fila_min <- which(resultado$ancho1 == ancho_min)

```

```
#mostrar la combinación
resultado[fila_min, ]
```

13.3 Simulación de potencia para diferentes combinaciones de días y máquinas

```
library(lme4)

pot = function(n, r, nsim = 100){

  if(r %% 4 != 0){ # Que tiene que ser divisible por 4
    stop("r debe ser múltiplo de 4, porque hay 4 máquinas.")
  }
  # Parámetros de la simulación
  sd.dia = 7.1
  sd.res = 6.55
  alfa = c(0, -5, 5, 0) # Aquí es donde se coloca el delta

  rechazos = 0 # Creamos un contador para la cantidad de veces de rechazo

  for(i in 1:nsim){
    muj = 147 + rnorm(n, 0, sd.dia) #Simulación de la media de cada día
    mujs = rep(muj, each = r) #Repetición de cada media según la cantidad de réplicas
    y = rnorm(n * r, mujs, sd.res) #Simulación de la respuesta
    alfai = rep(alfa, each = r/4, times = n) #Simulación de los efectos
    y1 = y + alfai #Simulación de la nueva respuesta
    DIA = factor(rep(1:n, each = r)) #Creación de la variable día
    MAQ = factor(rep(c("A","B","C","D"), each = r/4, times = n)) #Creación de la variable máquina

    mod = try(lmer(y1 ~ MAQ + (1|DIA)), silent = TRUE) # Creación del modelo

    if(!inherits(mod, "try-error")){ # Condición sobre si hay un error se ignora

      tabla = try(drop1(mod, test = "Chisq"), silent = TRUE) #Guardar la tabla del drop1

      if(!inherits(tabla, "try-error") && nrow(tabla) > 1){

        pval = tabla$`Pr(Chi)`[2] #extraer la probabilidad

        if(!is.na(pval) && pval < 0.05){ #Calcular la proporción de rechazos (potencia)
          rechazos = rechazos + 1
        }
      }
    }
  }

  rechazos / nsim
}

#Serie de pruebas
pot(n=4, r=8)
## [1] 0.66
pot(n=6, r=8)
## [1] 0.86
```

```

pot(n=8, r=8)
## [1] 0.94
pot(n=10, r=8)
## [1] 1
pot(n=12, r=8)
## [1] 1

```

13.4 Simulación de potencia, para un experimento de tres niveles, sin interacción

La simulación se basa en el experimento de papel visto en clase

```

library(lme4)
nsim <- 800
# Se crea el vector donde se guardará la potencia de las variables
p_metodo <- numeric(nsim)
p_temp <- numeric(nsim)

# Se definen los parametros
n_lotes <- 9
n_met <- 3
n_temp <- 4
#Estos se obtienen del VarCorr(mod)
sd.lote <- 1.7
sd.res <- 2.3619

#Estos se obtienen del fixef(mod)
mu <- 30.4722
ef.met <- c(0, 3.41, -1.166)
ef.temp <- c(0, 3.33, 5.888, 9.222)

# Creación de las variables
Lote <- factor(rep(1:n_lotes, each = n_met * n_temp))
metodo <- factor(rep(rep(1:n_met, each = n_temp), n_lotes))
temp <- factor(rep(1:n_temp, n_lotes * n_met))

# Se crean los vectores para la simulación
sdlote = c()
sdres = c()

# For para realizar la simulacion

for (i in 1:nsim) {

  #Simulación del efecto del lote y se guarda con el ancho de la variable lote con [Lote]
  ef_lote_sim <- rnorm(n_lotes, 0, sd.lote)[Lote]

  # Simulación de la respuesta
  y <- mu +
    ef.met[metodo] +
    ef.temp[temp] +
    ef_lote_sim +
    rnorm(n_lotes * n_met * n_temp, 0, sd.res)

  # Creación del modelo

```

```

mod <- lmer(y ~ metodo + temp + (1 | Lote))

# Se obtiene las sd estimadas del modelo
vc = VarCorr(mod)
vc = as.data.frame(vc)
sdlote[i] = vc[1,5] # Se guarda la sdlote en su respectivo vector
sdres[i] = vc[2,5]

# Se obtiene la significancia
sig <- drop1(mod, test = "Chisq")

p_metodo[i] <- sig[2, 4]
p_temp[i] <- sig[3, 4]
}

cat("Potencia para Método:", mean(p_metodo < 0.05), "\n")
cat("Potencia para Temperatura:", mean(p_temp < 0.05), "\n")

# Salidas de la simulacion: vectores con las desviaciones estandar de lote y res.

varlote = sdlote^2
varres = sdres^2

# Media de cada distribucion: sigma cuadrado lote y sigma cuadrado
mean_lote = mean(varlote)
mean_res = mean(varres)
cat("El promedio de la varianza del lote es:", round(mean_lote,3), "\nEl promedio de la distribucion de

```

13.5 Gráfico para comparar la respuesta observada y simulada

```

library(ggplot2)
library(gridExtra)
p1 = qplot(maq, trigli, geom="boxplot", ylab="respuesta observada",
xlab="máquina", ylim=c(100,170))
trigli2= trigli-lm(trigli~dia)$fit+mean(trigli) #Centramos trigli por día
p2 = qplot(maq, trigli2, geom="boxplot", ylab="respuesta observada\ncentrada",
xlab="máquina", ylim=c(100,170))
p3 = qplot(maq, y1, geom="boxplot", ylab="respuesta simulada",
xlab="máquina", ylim=c(100,170))
y2 = y1-lm(y1~dia)$fit+mean(y1)
p4 = qplot(maq, y2, geom="boxplot", ylab="respuesta simulada\ncentrada",
xlab="máquina", ylim=c(100,170))
grid.arrange(p1, p2, p3, p4, ncol=2, nrow=2)

```