

Manual para el curso Modelos Lineales Avanzados (XS-0125)

Segundo Examen

Autor: Anderson Martínez

Colaboradores: Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1	Variables continuas como predictores	1
1.1	Comparación del diseño de papel, cuando la variable temperatura es numérica o categórica .	1
1.2	Modelos para variables continuas en modelos mixtos	3
1.2.1	Modelo con interacción de una variable categórica	3
1.2.2	Modelo con interacción de una variable numérica	4
2	Análisis del experimento papel	12
2.1	Modelo completo para el experimento de papel	15
2.1.1	Sobre la interacción entre los factores aleatorios	16
2.1.2	Resumen de pruebas de hipótesis a realizar	17
3	Correlación de los interceptos	17
3.1	Mover la variable para descubrir el intercepto	18
3.2	hipótesis de la correlación	19
4	Ejemplo de las playas	21
4.1	Gráfico para ver linealidad	21
4.2	¿Cómo encontrar una pendiente relevante?	24
4.3	Código de gráfico de interceptos y pendientes para identificadores únicos	24

1 Variables continuas como predictores


Este tipo de variables sería como si en el ejemplo de **Papel** que lo analizamos en el caso anterior tuviera el factor de temperatura, como una variable numérica, no como una categoría. Dado esto, para estos casos es crucial el **supuesto de linealidad**.

1.1 Comparación del diseño de papel, cuando la variable temperatura es numérica o categórica


Para dicho experimento teníamos dos niveles:

- Nivel 1: El número de muestras, este tiene como factor la temperatura. *Es importante notar que la temperatura puede ser un factor o una variable continua.*
- Nivel 2: El lote, este tiene como factor el método.

A continuación se le brinda un ejemplo de gráfico de la temperatura como categoría



A continuación se le brinda un ejemplo de gráfico de la temperatura como numérica



Para convertir la variable temperatura a una variable numérica, es super importante que se cumpla el **susuesto de linealidad**, para poder realizar este cambio en el análisis. Si sucede que los puntos tienen otra forma, como una cuadrática, logarítmica etc. Se necesitarían más datos, para asegurarlo, en cambio con la linealidad, esto no sucede así, debido a que es usual que con 4 datos está se pueda observar correctamente. Es importante resaltar que la linealidad se debe cumplir dentro de la unidad de nivel 2, en nuestro ejemplo sería, en cada lote. Si sucede el caso de que en todos los lotes, los datos están muy desordenados, es altamente recomendado trabajarlo como factor. Por último, si tenemos muchas observaciones dentro de cada lote, lo recomendable es realizar agrupaciones, para tener un mayor control de la variable.

1.2 Modelos para variables continuas en modelos mixtos

Una vez teniendo en cuenta las diferencias entre una variable categórica y una continua, a continuación se le presentan ambos modelos:

Los siguientes modelos, se contruyen basados en el ejemplo del experimento Papel

1.2.1 Modelo con interacción de una variable categórica

$$y_{ijkl} = \beta_0 + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \delta_k + \varepsilon_{ijkl}$$

donde:

- **Los factores fijos corresponden a :** β_0 : Es el intercepto, α_i : Efecto del método, β_j : Efecto de la temperatura y el efecto de interacción entre estos factores $(\alpha\beta)_{ij}$
- **Las distribuciones de los factores aleatorios, asociadas al modelo corresponden a :** $\delta_k \sim \mathcal{N}(0, \sigma_2^2 \delta)$. De $\varepsilon \sim \mathcal{N}(0, \sigma_2^2 \varepsilon)$, también esta la distribución $Y_{ij} \sim \mathcal{N}(\mu_j, \sigma_2^2 \varepsilon)$. Por último, sabemos que $\delta_k = \mu_k - \mu$, de esto obtenemos que $\mu_j \sim \mathcal{N}(0, \sigma_2^2 \delta)$

1.2.2 Modelo con interacción de una variable numérica

Para este modelo debemos pensar que la temperatura no es un factor, sino una variable numérica, que cumple con el supuesto de linealidad. Dado lo anterior, el modelo resultante queda de la siguiente manera:

$$y_{iTjkl} = \beta_0 + \alpha_i + \gamma_1 T + \omega_i T + \delta_{k(i)} + \lambda_{k(i)} T + \varepsilon_{ijkl}$$

Utilizando tratamiento de referencia

donde:

- β_0 : Es el intercepto del modelo.
- α_i : Efecto del método, con las restricciones $\alpha_1 = 0$.
- $\delta_{k(i)}$: Efecto del lote del i-ésimo método, el cuál tiene la distribución $\delta_k \sim \mathcal{N}(0, \sigma_\delta^2)$.
- $\lambda_{k(i)}$: Es lo que aumenta o disminuye la pendiente de ese lote, con respecto a la pendiente general del método i-ésimo, lo cual es lo mismo que decir que el efecto de interacción entre lote y temperatura, el mismo se distribuye como $\lambda_{k(1)} \sim \mathcal{N}(0, \sigma_\lambda^2)$.

Modelo para el método 1

$$y_{1Tjkl} = \beta_0 + \gamma_1 T + \delta_{k(1)} + \lambda_{k(1)} T + \varepsilon_{ijkl}$$

donde:

- β_0 : Es el intercepto del modelo.
- γ_1 : Es la pendiente.
- $\delta_{k(1)}$: Efecto del lote dentro del método 1, este se ubica en el intercepto, el cual se distribuye como $\delta_{k(1)} \sim \mathcal{N}(0, \sigma_\delta^2)$
- Es lo que aumenta o disminuye la pendiente de ese lote, con respecto a la pendiente general del método 1 $\lambda_{k(1)} \sim \mathcal{N}(0, \sigma_\lambda^2)$

Modelo para el método 2

$$y_{2Tjkl} = (\beta_0 + \alpha_2) + (\gamma_1 + \omega_2) T + \varepsilon_{ijkl}$$

donde:

- $\beta_0 + \alpha_2$: Es el intercepto del modelo, en este caso α_2 representa cuando cambia la media con respecto al método 1 en el intercepto.
- $\gamma_1 + \omega_2$: Es la pendiente.

Modelo para el método 3


$$y_{3Tjkl} = (\beta_0 + \alpha_3) + (\gamma_1 + \omega_3) T + \varepsilon_{ijkl}$$

donde:

- $\beta_0 + \alpha_3$: Es el intercepto del modelo, en este caso α_3 representa cuando cambia la media con respecto al método 1 en el intercepto.
- $\gamma_1 + \omega_3$: Es la pendiente.

Representación de los Efectos Fijos del Método

Distancia del intercepto definida por $\alpha_i = \mu_i - \mu$



Cuando no hay interacción los α , representan la diferencias entre las medias con respecto al método 1 (referencia). En el caso cuando hay interacción, los α representan la diferencia cuando la temperatura es 0, lo cual no tendría ningún sentido en el experimento de papel, en otros casos ese análisis si puede tener sentido.

A continuación se le presenta de un gráfico de cuando no se presenta interacción entre lote y método, pero si entre método y temperatura

Nota: Puede ser que salga una pregunta de crear este gráfico en el examen, por ello el código queará visible y comentado

```
# 1. Simulación de datos con Interacción (Pendientes diferentes)
set.seed(2026)
temp_cont <- seq(200, 275, length.out = 50)
metodos <- c("Metodo 1", "Metodo 2", "Metodo 3")

df_interaccion <- expand_grid(
  temp = temp_cont,
  metodo = metodos,
  lote_id = 1:4
) %>%
mutate(
  lote_unico = as.factor(paste(metodo, "Lote", lote_id)),
  # INTERACCIÓN: Cada método tiene una pendiente (beta) distinta
  beta = case_when(
    metodo == "Metodo 1" ~ 0.04,
    metodo == "Metodo 2" ~ 0.44, # Pendiente más pronunciada
    metodo == "Metodo 3" ~ -0.20 # Pendiente negativa
  ),
```

```

# Efecto del lote (desplazamiento vertical constante = no interacción lote x temp)
efecto_lote = lote_id * 2.5,
# Resultado lineal exacto (sin ruido para que sean líneas rectas puras)
res = 18 + efecto_lote + (beta * temp)
)

# 2. Cálculo de la línea de la media por método
df_medias <- df_interaccion %>%
  group_by(metodo, temp) %>%
  summarise(res_media = mean(res), .groups = 'drop')


# 3. Gráfico Único
ggplot() +
  # Líneas de los Lotes (delgadas, color según método)
  geom_line(data = df_interaccion,
            aes(x = temp, y = res, color = metodo, group = lote_unico),
            size = 0.7, alpha = 0.4) +

  # LÍNEAS DE LA MEDIA (más gruesas y de un color sólido para contrastar)
  # Usamos 'grey20' o un color oscuro para que resalte sobre los colores de los lotes
  geom_line(data = df_medias,
            aes(x = temp, y = res_media, group = metodo, color = metodo),
            size = 1) +

  # Estética y Etiquetas
  scale_color_manual(values = c("Metodo 1" = "#E41A1C",
                                "Metodo 2" = "#377EB8",
                                "Metodo 3" = "#4DAF4A")) +

  labs(
    title = "Modelo Lineal con Interacción Método × Temperatura",
    x = "Temperatura ()",
    y = "Resistencia",
    color = "Método"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    plot.subtitle = element_text(hjust = 0.5),
    legend.position = "bottom"
  )

```



No habría interacción entre lote y método, cuando dentro de un mismo método las líneas son paralelas, como se pudo observar en el gráfico anterior. Por lo que en este caso $\sigma_{\lambda} = 0$

A continuación se le presenta el caso contrario, el cual es un gráfico de cuando se presenta interacción entre lote y método, pero no entre método y temperatura

```
# 1. Simulación (Mantenemos tu lógica exacta)
set.seed(2026)
temp_cont <- seq(200, 275, length.out = 50)
metodos <- c("Metodo 1", "Metodo 2", "Metodo 3")
lotes_por_metodo <- 1:4

df_pendientes <- expand.grid(
  temp = temp_cont,
  metodo = metodos,
  lote_id = lotes_por_metodo
) %>%
  group_by(metodo, lote_id) %>%
  mutate(
    lote_unico = as.factor(paste(metodo, "Lote", lote_id)),
    beta_base = 0.20,
    beta_lote = rnorm(1, mean = 0, sd = 0.15),
    beta_final = beta_base + beta_lote,
    efecto_metodo = case_when(
      metodo == "Metodo 1" ~ 10,
      metodo == "Metodo 2" ~ 30,
      metodo == "Metodo 3" ~ 50
    )
  )
```

```

    ),
    res = efecto_metodo + (beta_final * (temp - 200))
  ) %>%
  ungroup()

# 2. SOLUCIÓN AL ERROR: Crear un dataframe de medias INDEPENDIENTE
# Esto garantiza que las líneas negras sean perfectamente paralelas (Pendiente = 0.20)
df_medias_p <- expand_grid(
  temp = temp_cont,
  metodo = metodos
) %>%
  mutate(
    efecto_metodo = case_when(
      metodo == "Metodo 1" ~ 10,
      metodo == "Metodo 2" ~ 30,
      metodo == "Metodo 3" ~ 50
    ),
    res_media = efecto_metodo + (0.20 * (temp - 200)) # Pendiente fija
  )


# 3. Gráfico Único
ggplot() +
  # Líneas de los lotes (Divergentes)
  geom_line(data = df_pendientes,
    aes(x = temp, y = res, color = metodo, group = lote_unico),
    size = 0.7, alpha = 0.4) +

  # Líneas de la MEDIA (Negras y PARALELAS)
  geom_line(data = df_medias_p,
    aes(x = temp, y = res_media, group = metodo),
    color = "black", size = 1.2) +

  scale_color_manual(values = c("Metodo 1" = "#E41A1C",
                                "Metodo 2" = "#377EB8",
                                "Metodo 3" = "#4DAF4A")) +

  labs(
    title = "Interacción Lote × Método",
    x = "Temperatura ()",
    y = "Resistencia",
    color = "Método"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    plot.subtitle = element_text(hjust = 0.5),
    legend.position = "bottom"
  )

```



Observe que para este caso hay interacción entre lote y método, ya que las pendientes de todos los lotes son muy distintas, pero para el caso de método y temperatura no hay interacción debido a que las pendientes son las mismas. Para esta situación el $\delta_k = \mu_{k(i)} - \mu_{(i)}$, debido a que este diseño es anidado y por la interacción se tiene que considerar el método en el que se encuentra, ya que los lotes son únicos para cada método. Por último, si hay interacción entonces $\sigma_\lambda^2 \neq 0$

En muchas ocasiones nuestro objetivo no se centra en la parte aleatoria, sin embargo siempre se debe analizar primero, comenzando con la interacción aleatorio, como en este ejemplo es $\lambda_{k(i)}$.

Existe otro caso, donde no tiene sentido tener el intercepto en el modelo el cual se debe observar de la siguiente manera.

```
# 1. Simulación de datos: Interacción Lote x Temperatura
set.seed(2026)
temp_cont <- seq(200, 275, length.out = 50)
metodos <- c("Metodo 1", "Metodo 2", "Metodo 3")
lotes_por_metodo <- 1:4
df_pendientes <- expand.grid(
  temp = temp_cont,
  metodo = metodos,
  lote_id = lotes_por_metodo
) %>%
  group_by(metodo, lote_id) %>%
  mutate(
    lote_unico = as.factor(paste(metodo, "Lote", lote_id)),
    # 1. NO INTERACCIÓN MÉTODO x TEMP: Pendiente base igual para todos


    beta_base = 0.20,
```

```

# 2. INTERACCIÓN LOTE x TEMP: Variación en pendiente (beta)
# Aumentamos el sd para que se note la diferencia de inclinación
beta_lote = rnorm(1, mean = 0, sd = 0.15),
beta_final = beta_base + beta_lote,
# Efecto del Método (Intercepto fijo por método)


efecto_metodo = case_when(
  metodo == "Metodo 1" ~ 10,
  metodo == "Metodo 2" ~ 10,
  metodo == "Metodo 3" ~ 10
),
# Resultado lineal: Todos los lotes de un método comparten el mismo intercepto
# pero difieren en su pendiente (beta_final)
res = efecto_metodo + (beta_final * (temp - 200))
) %>%
ungroup()
# 2. Cálculo de la línea de la media por método
df_medias_p <- df_pendientes %>%
  group_by(metodo, temp) %>%
  summarise(res_media = mean(res), .groups = 'drop')
# 3. Gráfico Único
ggplot() + # Líneas de los Lotes (Mismo origen, distinta pendiente)
  # geom_line(data = df_pendientes,
  #           aes(x = temp, y = res, color = metodo, group = lote_unico),
  #           size = 0.7, alpha = 0.4) +
  # Líneas de la MEDIA (
  geom_line(data = df_medias_p,
            aes(x = temp, y = res_media, group = metodo),
            color = "black", size = 1.2) +
  #scale_color_manual(values = c("Metodo 1" = "#E41A1C", "Metodo 2" = "#377EB8", "Metodo 3" = "#4DAF4A"))
  labs(
    title = "Interacción Lote x Temperatura",
    x = "Temperatura ()",
    y = "Resistencia",
    color = "Método"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    plot.subtitle = element_text(hjust = 0.5),
    legend.position = "bottom"
  )

```




Efecto de Interacción Lote × Temperatura

Delta representa la distancia de la pendiente del lote respecto a la media



2 Análisis del experimento papel

```
library(lattice)
xyplot(res~temp|lote,type=c("r","p"),xlab="temperatura",
ylab="resistencia",data=base)
```



Observe que en este caso, en la mayoría hay linealidad, en algunos hay otros comportamientos, pero los mismos no son consistentes. Además con solo cuatro puntos no podemos asegurar ningún otro tipo de comportamiento, por lo que asumimos que se cumple el supuesto de linealidad.

De la siguiente forma, obtenemos cuantos lotes por cada método tenemos


```
apply(table(base$metodo, base$lote) > 0, 1, sum)
```

```
## 1 2 3
```

```
## 3 3 3
```

A continuación se gráficán los lotes dentro de cada método


```
xyplot(res~temp|metodo, groups=lote, type=c("r"), xlab="temperatura",  
ylab="resistencia", layout=c(3,1), data=base)
```



En este caso note que las pendientes de los lotes no son iguales dentro de cada método, por lo que se podría sospechar de una posible interacción entre lote y temperatura.

A continuación se gráficán las líneas de cada método

```
xyplot(res~temp, groups=metodo, type=c("r"), xlab="temperatura",
ylab="resistencia", data=base, auto.key = T)
```



Apesar de que se observe una pequeña interacción, no es tan fuerte como la que se vió en el gráfico anterior. *Es importante resaltar que esto lo estamos haciendo debido a que la temperatura es bastante lineal.*

Nota: La ventaja de que la temperatura sea numérica y super lineal, es se puede usar para interpolar valores para cualquier temperatura.

Las ecuaciones de las rectas para cada método son las siguientes

Método 1

$$\mu_{1,T} = \beta_0 + \beta_1 T$$

Método 2

$$\mu_{2,T} = (\beta_0 + \alpha_2) + (\beta_1 + \gamma_2)T$$

Método 3

$$\mu_{3,T} = (\beta_0 + \alpha_3) + (\beta_1 + \gamma_3)T$$

Note que mediante las restas de estas ecuaciones cuando $T = 0$, obtenemos los α_i

2.1 Modelo completo para el experimento de papel

Se tiene el siguiente modelo:

$$y_{iTjkl} = \beta_0 + \beta_1 T + \alpha_i + \gamma_j T + \omega_i T + \delta_{k(i)} + \lambda_{k(i)} T + \varepsilon_{ijkl}$$

donde:

Usando tratamiento de referencia

- α_i : Efecto del i-ésimo método en el intercepto, con las restricciones $\alpha_1 = 0$ y que $\alpha_2 = \mu_{2,T=0} - \mu_{1,T=0}$, La representación gráfica de estos efectos se encuentran en la sección de arriba.
- β_1 : Pendiente de la temperatura.
- γ_j : Efecto j-ésimo de interacción entre el método y temperatura, con la restricción $\gamma_1 = 0$, este significa cuánto aumenta la temperatura con respecto al método 1.
- δ_k : Efecto del lote con respecto a la línea media del método al que corresponde, en el intercepto, el cuál se distribuye como $\delta_k \sim \mathcal{N}(0, \sigma_\delta^2)$. Recuerde que en la sección anterior hay una representación gráfica de este efecto.
- $\lambda_{k(i)}$: Es el efecto de interacción entre lote y temperatura, el cual significa cuánto cambia la pendiente del k-ésimo lote con respecto a la pendiente general del i-ésimo método. Este se distribuye como $\lambda_{k(i)} \sim \mathcal{N}(0, \sigma_\lambda)$

2.1.1 Sobre la interacción entre los factores aleatorios

Tenemos los siguientes casos

- Si $\rho = 0$, entonces δ_k y $\lambda_{k(i)}$ se distribuyen de forma independiente.
- $\rho \neq 0$, entonces $(\delta_k, \lambda_{k(i)}) \sim \mathcal{N}_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma \right)$.

La matriz de covarianzas se contruye de la siguiente manera

$$\Sigma = \begin{pmatrix} \sigma_\delta^2 & \sigma_{\delta\lambda} \\ \sigma_{\lambda\delta} & \sigma_\lambda^2 \end{pmatrix}$$


Además de lo anterior tenemos lo siguiente:

$$\rho = \frac{\sigma_{\delta\lambda}}{\sigma_\delta \sigma_\lambda} \implies \sigma_{\delta\lambda} = \rho \sigma_\delta \sigma_\lambda$$


A continuación se gráfica, como se ve ρ según cada caso

Warning: package 'mvtnorm' was built under R version 4.5.3


$\rho = 0$



$\rho = 0.5$



$\rho = 0.99$



2.1.2 Resumen de pruebas de hipótesis a realizar

1. $H_0 : \rho = 0$
2. $H_0 : \sigma_\lambda = 0$. En ocasiones si no hay correlación este paso puede omitirse.
- 2.5. $H_0 : \sigma_\delta$: Hay que tener cuidado, porque depende del signo este no se puede eliminar
3. $H_0 : \gamma_j = 0$
 - Rechazo: Hay interacción entre método y temperatura, *Ver el gráfico de la sección de arriba.*
 - No rechazo: No hay interacción entre método y temperatura, *Ver el gráfico de la sección de arriba.* Luego de estos realizamos las hipótesis de los demás factores fijos ($H_0 : \alpha_i = 0$) Si son significativos realizamos los intervalos de confianza, si sucede el caso contrario se debe analizar potencia.
4. $H_0 : \beta_1 = 0$

Nota: Cuando la diferencia es significativa, pero no relevante, esto se debe a la poca variabilidad y cuando una muestra es muy grande

3 Correlación de los interceptos

Tenemos la siguiente ecuación del lote k-ésimo:


$$\mu_k = (\beta_0 + \alpha_j + \delta_k) + (\beta_1 + \gamma_j + \lambda_k)T$$

Lo que se quiere observar si δ_k y λ_k , están correlacionados, para ello tenemos que calcular las diferentes rectas para cada lote s

```

beta0=beta1=c()
for(i in 1:9) { # Ojo que son 9 lotes
  mod=lm(res~temp,base[base$lote==i,]) #Los lotes está enumerado del 1 al 9
  beta0[i]=mod$coef[1]
  beta1[i]=mod$coef[2]
}
plot(beta1,beta0,pch=18,col=4)
abline(lm(beta0~beta1))

```



Observe que conforme el intercepto baja, la pendiente aumenta, por lo que se puede sospechar una correlación negativa fuertes entre β_0 y β_1 . Lo mismo lo podemos verificar con el siguiente código:

```
cor(beta0,beta1)
```

```
## [1] -0.9531819
```

Observe que la correlación es -0.95, esto nos confirma lo visto en el gráfico anterior. En términos del experimento de `papel`, esto nos dice que un lote que comienza con baja resistencia al principio tiene un crecimiento más rápido en la resistencia, comparado con un lote que comienza con alta resistencia, esto tiene sentido debido que si se tiene baja resistencia al principio el margen de mejora va a ser mayor, en comparación que cuando se empieza con una buena resistencia.

3.1 Mover la variable para descubrir el intercepto

Para obtener verdaderamente de donde comienza el intercepto, lo que hacemos es mover la variable de modo que el intercepto verdaderamente represente el inicio de la variable, como por ejemplo en el experimento de `papel` debido a que la temperatura comienza en 200, restamos esos 200 para que comience en cero. Es

importante aclarar que esto nos funciona, para variables que tiene un mínimo. **Esto nos va a afectar la corrección entre interceptos, por lo que se recomienda hacer cuando tenga sentido.**

Ejemplo del proceso de mover la variable

$$\begin{aligned} temp1 &= temp - 200 \\ \text{Si } temp &= 200 \implies temp1 = 0 \\ \text{Si } temp &= 225 \implies temp1 = 25 \\ \text{Si } temp &= 250 \implies temp1 = 50 \\ \text{Si } temp &= 275 \implies temp1 = 75 \end{aligned}$$

3.2 hipótesis de la correlación

$$H_0 : \rho = 0$$

Modelo correlacionado, ya que los coeficientes (β_0 y β_1) están juntos dentro del lote.

```
library(lme4)
mod1=lmer(res~1+metodo*temp+(1+temp|lote),data=base)
```

Modelo no correlacionado, se le pone el, 0 para que ignore el intercepto.

```
mod2=lmer(res~1+metodo*temp+(1|lote)+(0+temp|lote),data=base)
# Se puede colocar 0 o -1, par ignorar el intercepto
```

Comparación del modelo

```
anova(mod1,mod2,test="LRT")

## refitting model(s) with ML (instead of REML)

## Data: base
## Models:
## mod2: res ~ 1 + metodo * temp + (1 | lote) + (0 + temp | lote)
## mod1: res ~ 1 + metodo * temp + (1 + temp | lote)
##      npar    AIC    BIC logLik -2*log(L)  Chisq Df Pr(>Chisq)
## mod2     9 184.36 198.61 -83.179   166.36
## mod1    10 186.19 202.02 -83.094   166.19 0.1702  1     0.6799
```

Observe que no se rechaza la hipótesis, por lo que nos asumimos que no hay correlación.

Luego lo que queremos es ver la interacción, por lo que se prueba la siguiente hipótesis

$$H_0 : \sigma_\lambda = 0$$

```
mod2=lmer(res~1+metodo*temp+(1|lote)+(0+temp|lote),data=base)
mod3=lmer(res~metodo*temp+(1|lote),base)
anova(mod2,mod3)

## refitting model(s) with ML (instead of REML)

## Data: base
## Models:
## mod3: res ~ metodo * temp + (1 | lote)
## mod2: res ~ 1 + metodo * temp + (1 | lote) + (0 + temp | lote)
##      npar    AIC    BIC logLik -2*log(L)  Chisq Df Pr(>Chisq)
## mod3     8 182.79 195.46 -83.396   166.79
## mod2     9 184.36 198.61 -83.179   166.36 0.4331  1     0.5105
```

No se rechaza la hipótesis, por lo que no son diferentes las pendientes entre los lotes de un mismo método. Cuando hay muy pocas unidades en el nivel 2 es muy difícil encontrar diferencias entre las pendientes.

Ahora queremos ver si hay interacción, pero en la parte fija

```
drop1(mod3,test="Chisq")
```

```
## Single term deletions
##
## Model:
## res ~ metodo * temp + (1 | lote)
##          npar      AIC      LRT Pr(Chi)
## <none>          182.79
## metodo:temp      2 179.54 0.74589 0.6887
```

No resulta significativa la interacción entre temperatura y método, por lo que asumimos que no hay, con esto podemos decir que podemos comparar los métodos sin importar la temperatura.

Luego se pone a prueba la significancia de la temperatura

$$H_0 : \beta_1 = 0$$

```
mod4=lmer(res~metodo+temp+(1|lote),base)
drop1(mod4,test="Chisq")
```

```
## boundary (singular) fit: see help('isSingular')
## Single term deletions
##
## Model:
## res ~ metodo + temp + (1 | lote)
##          npar      AIC      LRT   Pr(Chi)
## <none>          179.54
## metodo      2 183.13  7.590   0.02248 *
## temp       1 216.26 38.726 4.876e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Debido a que $p < 0.001$, podemos decir que el coeficiente de temperatura es diferente de 0.

```
fixef(mod4)
```

```
## (Intercept)      metodo2      metodo3      temp
##   6.3722222   3.4166667 -1.1666667   0.1208889
```

El coeficiente de temperatura se interpreta para un aumento de temperatura que tenga sentido, por ejemplo, 25 grados. Entonces por cada 25 grados que aumente la temperatura se espera que la resistencia promedio aumente ($0.1209 \times 25 = 3.02$) 3.02 kg/cm, en cualquiera de los 3 métodos.

```
confint(mod4)[6,]*25
```

```
## Computing profile confidence intervals ...
##      2.5 %    97.5 %
## 2.345015 3.699429
```

El aumento en la resistencia es entre 2.34 y 3.70 kg/cm por cada 25 grados que aumente la temperatura, en cualquiera de los 3 métodos

```
library(emmeans)
```

```
## Warning: package 'emmeans' was built under R version 4.5.3
```

```
## Welcome to emmeans.
```

```
## Caution: You lose important information if you filter this package's results.
```

```
## See '? untidy'
```

```
emmeans(mod4,pairwise~metodo,adjust="bonferroni")$contrast
```

```
## contrast      estimate    SE df t.ratio p.value
## metodo1 - metodo2   -3.42 1.69  6  -2.022  0.2691
## metodo1 - metodo3    1.17 1.69  6   0.690  1.0000
## metodo2 - metodo3    4.58 1.69  6   2.712  0.1051
##
## Degrees-of-freedom method: kenward-roger
## P value adjustment: bonferroni method for 3 tests
```

Nota: Si el intervalo es significativo, pero no es relevante, esto sucede cuando la muestra es muy grande.


4 Ejemplo de las playas

```
load("riqueza.Rdata")
```

```
base$riq = apply(base[, 2:76] > 0,1,sum)# Se suma por fila, para contar el número de especies
```

4.1 Gráfico para ver linealidad

```
xyplot(riq~NAP|playa,pch=18,
ylab="riqueza promedio",type=c("p","r"),data=base)
```



En la mayoría de las playas, los puntos siguen una tendencia bastante lineal, por lo que parece acertado seguir con una regresión lineal.

El modelo para este experimento es el siguiente:

$$y_{NAP,k,l} = \beta_0 + \beta_1 NAP + \delta_k + \gamma_{k,NAP} + \varepsilon_{NAP,k,l}$$

$\gamma_{k,NAP}$: Este nos indica que cada playa tendrá una pendiente diferente

δ_k : Cuánto sube la riqueza promedio, respecto a la media general cuando $NAP = 0$, en la playa k-ésima.

γ_k : Cuánto cambia la pendiente de NAP de la playa k-ésima con respecto a la pendiente general.

$y_{NAP,k,l}$: Representa la observación de un NAP particular, en una playa, de una cierta observación.

Nota: En los efectos aleatorios, le media cero, representa el modelo de suma nula.

Si $\rho \neq 0 \implies (\delta_k, \gamma_k) \sim \mathcal{N}_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma \right)$, por lo que no tiene sentido eliminar γ_k

Si $\rho = 0 \implies \delta_k \sim \mathcal{N}(0, \sigma_\delta)$ y $\gamma_k \sim \mathcal{N}(0, \sigma_\gamma)$

En R esto lo probamos de la siguiente manera

```
# mod1 es con \rho = 0
mod1=lmer(riq~1+NAP+(1+NAP|playa),data=base) # 1+NAP|playa, pendiente e intercepto de cada playa
# mod2 es con \rho \diff = 0
mod2=lmer(riq~1+NAP+(1|playa)+(0+NAP|playa),data=base)
```

```
anova(mod1,mod2,test="LRT")
```

```
## refitting model(s) with ML (instead of REML)
## Data: base
## Models:
## mod2: riq ~ 1 + NAP + (1 | playa) + (0 + NAP | playa)
## mod1: riq ~ 1 + NAP + (1 + NAP | playa)
##      npar    AIC    BIC logLik -2*log(L)  Chisq Df Pr(>Chisq)
## mod2     5 251.21 260.25 -120.61   241.21
## mod1     6 246.66 257.50 -117.33   234.66 6.5556  1    0.01046 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Observe que si existe correlación entre el NAP y la playa

Ahora lo que queremos probar es la significancia del NAP, por lo que probamos la siguiente hipótesis:

$$H_0 : \beta_1 = 0$$

```
drop1(mod1, test = "Chisq")#Recuerde que beta1 es fijo
```

```
## Single term deletions
##
## Model:
## riq ~ 1 + NAP + (1 + NAP | playa)
##      npar    AIC    LRT Pr(Chi)
## <none>    246.66
## NAP      1 254.24 9.5841 0.001963 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Debido a que $p = 0.001 < 0.05$, esto nos dice que el NAP, tiene un efecto lineal en la respuesta promedio, como las líneas son decrecientes, entonces podemos afirmar que conforme sube el NAP, baja la riqueza promedio. Lo anterior lo sabemos por el signo del coeficiente.

```
fixef(mod1)[2]
```

```
##      NAP
## -2.830117
```

Esto nos indica que conforma el NAP aumenta una unidad, la riqueza promedio baja 2.83 unidades

Dado el resultado anterior, obtenemos su intervalo de confianza

```
confint(mod1)
```

```
## Computing profile confidence intervals ...
##      2.5 %    97.5 %
## .sig01    2.2785514  7.3735166
## .sig02    0.5727413      Inf
## .sig03   -1.0000000 -0.3632263
## .sigma    2.1616710  3.4369126
## (Intercept) 3.9761568  9.1670419
## NAP      -4.4083924 -1.3563699
```

En este caso `.sig03`, corresponde a σ_γ , note que llega hasta infinito, esto se debe a la poca cantidad de datos y a una playa que contiene un valor de influencia que puede estar generando problemas. Una solución ante esto puede ser, recolectar más muestra o también recolectar más datos con diferentes tipos de NAP, en cada playa.

En la parte aleatoria, `.sig01` es la desviación estándar de los interceptos aleatorios, `.sig02` es la correlación entre interceptos y pendientes y `.sigma` es la desviación estándar del error. Es evidente que el intervalo para la correlación no incluye al cero pues va de -1 a -0.36, lo que indica que sí hay una correlación importante entre los interceptos y las pendientes.

El intercepto representa la riqueza promedio cuando el NAP es cero, es decir cuando se ubica en el nivel medio de la marea, entonces, entre más alta es la riqueza promedio al nivel medio de la marea, se va a tener un mayor decrecimiento en la riqueza al aumentar el NAP, lo cual tiene sentido.

Se puede dar una interpretación al coeficiente fijo de NAP que corresponde a la pendiente general fija. Aquí se puede decir que como medida general de la tendencia (sin tomar en cuenta una playa particular), al aumentar el NAP en una unidad, la cantidad de especies disminuye en promedio entre 1.3 y 4.4 especies, con 95% de confianza. Además, el intercepto general está entre 3.97 y 9.18 lo cual representa el rango en que se espera que se encuentre el número de especies promedio cuando se ubica en el nivel medio de la marea.

4.2 ¿Cómo encontrar una pendiente relevante?

Encontrar un valor relevante a partir de los datos es engañoso, para ello se necesitará la ayuda del criterio de un experto. Por ejemplo si el experto nos indica que dos poblaciones deben tener una diferencia de 2 unidades y en el estudio que se realiza una población tiene una riqueza promedio de 8 y otra con una población con una riqueza promedio de 10. Entonces eso quiere decir que al aumentar una distancia una desviación estándar de NAP, la riqueza debe aumentar dos unidades en promedio, esto nos lleva a que $\beta_1 = \frac{2}{\sigma}$.

4.3 Código de gráfico de interceptos y pendientes para identificadores únicos

Este código es un ejemplo de un estudio de medidas repetidas

```
beta0=beta1=c()
ind=as.numeric(names(table(base$sujeto)))
for(i in 1:18) {
  mod=lm(reac~dias,base[base$sujeto==ind[i],])
  beta0[i]=mod$coef[1]
  beta1[i]=mod$coef[2]
}
plot(beta1,beta0,pch=18)
abline(lm(beta0~beta1))
```