

# Manual para el curso Modelos Lineales Avanzados (XS-0125) Tercer Examen

**Autor:** Anderson Martínez

**Colaboradores:** Sebastián Calvo, Justin Zhu, Fabián Almirall

## Contents

|          |                                                           |          |
|----------|-----------------------------------------------------------|----------|
| <b>1</b> | <b>Introducción a los modelos lineales generalizados</b>  | <b>1</b> |
| <b>2</b> | <b>Componentes de un modelo lineal generalizado (GLM)</b> | <b>2</b> |
| 2.1      | Componente aleatorio . . . . .                            | 2        |
| 2.2      | Componente sistemático . . . . .                          | 2        |
| 2.3      | Función de enlace . . . . .                               | 2        |
| 2.4      | Función de enlace logit . . . . .                         | 3        |
| 2.5      | Función de enlace Poisson . . . . .                       | 4        |

## 1 Introducción a los modelos lineales generalizados

Todos los modelos vistos anteriormente en los cursos anteriores y en este, son una combinación lineal de  $\beta's$  y  $X's$ , por esta razón es que todos estos modelos les colocamos el nombre de modelos lineales.

Los  $\beta's$  y  $X's$  que normalment escribimos del modelo, le llamaremos la parte lineal del modelo, es decir la **parte lineal** en la modelación univariada (*la variables respuesta es una variable*) es igual a:

$$\sum_{j=0}^{p-1} \beta_j X_j$$

Además tenemos este nuev elemento llamado la **función de enlace**, la cual es:

$$g(\cdot)$$

También sabemos que cada variable respuesta está asociada a una distribución, a esto le llamamos la **parte aleatoria** la cual se denota de la siguiente manera:

$$y|x \sim f(y|x)$$

La unión de los compenentes anteriores es lo que nos forma un modelo lineal generalizado:

$$g(\mu_{y|x}) = \sum_{j=0}^{p-1} \beta_j X_j$$

## 2 Componentes de un modelo lineal generalizado (GLM)

- Componente aleatoria: identifica la variable respuesta y su distribución de probabilidad.
- Componente sistemática: especifica las variables explicativas (independientes o predictoras) utilizadas en la función predictora lineal (una combinación lineal de las variables predictoras).
- Función de enlace: es una función del valor esperado de  $Y$ ,  $E(Y)$  o  $\mu_Y$ , que relaciona la esperanza de la respuesta con las variables predictoras, es decir, la componente aleatoria con la sistemática.

### 2.1 Componente aleatorio

- La componente aleatoria de un GLM consiste en una variable aleatoria  $Y$  con observaciones independientes  $(y_1, \dots, y_n)$ .
- En muchas aplicaciones las observaciones son continuas y se puede asumir para  $Y$  una distribución condicional normal.
- En otros casos las observaciones de  $Y$  son binarias, y se identifican como éxito y fracaso. Aunque de modo más general, cada  $Y_i$  indicaría el número de éxitos de entre un número fijo de ensayos, y se modelizaría como una distribución condicional binomial.
- En otras ocasiones cada observación es un conteo, con lo que se puede asignar a  $Y$  una distribución condicional de Poisson o una distribución condicional binomial negativa.
- Cuando la respuesta  $Y$  tiene una distribución asimétrica con valores continuos a partir de cero, se puede usar la distribución condicional gamma.

*Nota:* observe que en todos los casos se habla de la distribución condicional.

### 2.2 Componente sistemático

- El componente sistemático de un GLM especifica las variables explicativas, que entran en forma de efectos fijos en un modelo lineal, es decir, las variables  $X$  se relacionan como:

$$\eta = \beta_1 X_1 + \dots + \beta_p X_p$$

- Esta combinación lineal se denomina *predictor lineal* y se representa con  $h$ .
- Algunos de los  $\beta$ 's en esta combinación son coeficientes de variables continuas.
- Otros son coeficientes de factores. Recordando que en esos casos se crean variables auxiliares y cada una lleva un coeficiente.
- También se pueden incluir interacciones entre dos o más factores, así como entre factores y variables continuas.
- Los parámetros del predictor lineal  $\beta$ 's son fijos para cualquier valor que tomen las  $X$ 's. Sin embargo, los valores de esos parámetros son desconocidos y se deben estimar. Por lo tanto, para un vector de valores de las  $X$  ( $x_1, \dots, x_n$ ), el correspondiente predictor lineal  $h$  es fijo (dados los coeficientes del modelo).

### 2.3 Función de enlace

- La función de enlace especifica una función  $g(\cdot)$  que relaciona la esperanza de la respuesta  $\mu_Y$  con el predictor lineal  $h$  como:
- La función  $g$  más simple es  $g(\mu)=\mu$ , esto es, la identidad que da lugar al modelo de regresión lineal clásico.

- Entonces el modelo lineal clásico para respuestas continuas (normales) son un caso particular de un GLM con una función de enlace identidad.
- Los GLM generalizan la regresión clásica de dos modos: 1) permitiendo que  $Y$  tenga distribuciones diferentes a la normal, 2) incluyendo distintas funciones de enlace.

*Notas:*

1. En `r` un `glm` con `family = "normal"` es lo mismo que un `lm`.
2. Sabemos `lmer` es para modelos lineales mixtos, en el caso de modelos generalizados mixtos es con `glmer`.
3. En este caso como algunos modelos generalizados no dependen de la función normal el supuesto de normalidad se cae.

## 2.4 Función de enlace logit

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) \quad \text{para } p \in (0, 1)$$

Si tenemos una distribución de forma que  $y|x \sim \text{Bernoulli}(\pi_x)$ , esto nos lleva que el valor esperado **condicional**  $E[y|x] = \pi_x = \mu_{y|x}$

El modelo lineal generalizado para este caso que tenga un factor con tres niveles queda de la siguiente manera:

*Tenemos que la parte lineal usando el modelo de suma nula es:*

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2$$

Este modelo tiene la restricción de que  $\beta_3 = -\beta_1 - \beta_2$

*Tenemos que la función de enlace es:*

$$\log\left(\frac{\pi_j}{1-\pi_j}\right)$$

Note que  $\pi$  depende del  $j$ -ésimo tratamiento

*Uniendo ambos compentes obtenemos el siguiente resultado:*

$$\log\left(\frac{\pi_j}{1-\pi_j}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

Esto nos dice que la probabilidad en el tratamiento  $j$ -ésimo se modela de la forma.

Para despejar esa probabilidad lo que hacemos es que colocamos una exponencial

$$\left(\frac{\pi_j}{1-\pi_j}\right) = e^{PL}$$

Despejamos el  $\pi_j$  y esto nos lleva a que:

$$\pi_j = \frac{e^{PL}}{1 + e^{PL}}$$

donde:

- $PL = \beta_0 + \beta_1 X_1 + \beta_2 X_2$ , lo cual corresponde a la parte lineal

Observe que

$$\pi_j = \begin{cases} 0.5 & \text{si } PL = 0 \\ > 0.5 & \text{si } PL > 0 \\ < 0.5 & \text{si } PL < 0 \end{cases}$$

$$\lim_{PL \rightarrow \infty} \pi_j = 1 \quad \text{y} \quad \lim_{PL \rightarrow -\infty} \pi_j = 0$$

*Nota:* La parte lineal no tiene ninguna interpretación

## 2.5 Función de enlace Poisson

$$\log(\lambda_j) = \beta_0 + \tau_j$$

$$\lambda_j = e^{PL}$$

$$\lim_{PL \rightarrow \infty} \lambda_j = 1 \quad \text{y} \quad \lim_{PL \rightarrow -\infty} \lambda_j = 0$$