

Proyecto Final – Teoría Estadística (XS3310)

Universidad de Costa Rica · Ciclo I 2026

Anderson Martínez Abarca, Sebastián Calvo, Justin Zhu, Fabián Almirall

28 de June de 2026

Índice general

1	Parte I. Comparación de intervalos de confianza utilizando diferentes técnicas	1
1.1	Ejercicio 1. Análisis descriptivo de la población	1
1.2	Ejercicio 2. Muestra aleatoria y estimación kernel	2
1.3	Ejercicio 3. IC exacto con varianza conocida ($\sigma^2 = 100$)	3
1.4	Ejercicio 4. IC asintótico con varianza desconocida	4
1.5	Ejercicio 5. IC bootstrap estándar ($B = 1000$, sin librería <code>boot</code>)	4
1.6	Ejercicio 6. Comparación de los tres intervalos	5
2	Parte II. Estudio de simulación	5
2.1	Ejercicio 1. Objetivo del estudio de Monte Carlo	5
2.2	Configuración	5
2.3	Ejercicio 2. Resultados con medidas de variabilidad	6
2.4	Ejercicio 3. Comparación de coberturas y efecto de la semilla	7
2.5	Ejercicio 4. Diseño de una simulación más completa	7

1 Parte I. Comparación de intervalos de confianza utilizando diferentes técnicas

El archivo `población.RData` contiene un vector de altura (en centímetros) de una población de 1500 estudiantes universitarios en Costa Rica. El objetivo es extraer una muestra de tamaño $n = 50$ de esta población con reemplazo y realizar inferencia sobre la altura promedio poblacional, denotada por θ . Específicamente, se busca el intervalo de confianza del 99% para θ utilizando tres métodos.

```
archivo <- list.files(pattern = "\\..RData$")[1]
load(archivo)
```

1.1 Ejercicio 1. Análisis descriptivo de la población

```
hist(x,
     probability = TRUE,
     col = "lightblue",
     main = "Histograma de Alturas vs. Curva Normal",
     xlab = "Alturas (cm)",
     ylab = "Densidad")

Z2 <- seq(min(x), max(x), length = 1500)
```

```
lines(Z2, dnorm(Z2, mean = mean(x), sd = sd(x)), col = "red", lwd = 2)
abline(v = mean(x), col = "darkblue", lwd = 2, lty = 2)
legend("topright",
      legend = c("Curva normal teórica", "Media poblacional"),
      col = c("red", "darkblue"), lty = c(1, 2), lwd = 2, bty = "n")
```




Figura 1: Distribución de alturas de la población ($N = 1500$).

La distribución de alturas muestra una forma aproximadamente simétrica y unimodal centrada alrededor de 160.03 cm, con la curva normal teórica ajustándose razonablemente bien al histograma. Dado el tamaño poblacional ($N = 1500$) y la forma acampanada observada, **es razonable asumir que la población sigue una distribución normal** como aproximación de trabajo.

1.2 Ejercicio 2. Muestra aleatoria y estimación kernel

```
set.seed(1117)
n <- sample(x, 50, replace = TRUE)

densidad_h1 <- density(n, kernel = "gaussian", bw = 1)
densidad_h5 <- density(n, kernel = "gaussian", bw = 5)

hist(n, probability = TRUE, col = "gray90", border = "white",
     ylim = c(0, max(densidad_h1$y)),
     main = "Efecto del Ancho de Banda (h) en el Kernel Gaussiano",
     xlab = "Alturas (cm)", ylab = "Densidad")

lines(densidad_h1, col = "tomato", lwd = 2.5)
lines(densidad_h5, col = "royalblue", lwd = 2.5)
```

```
legend("topright",
      legend = c("Kernel h = 1", "Kernel h = 5"),
      col = c("tomato", "royalblue"), lwd = 2.5, bty = "n")
```




Figura 2: Estimación kernel con $h = 1$ (rojo) y $h = 5$ (azul).

Con $h = 1$ la curva sigue de cerca cada fluctuación de los datos, captando ruido muestral y produciendo múltiples modas espurias. Con $h = 5$ la estimación es más suave y revela mejor la forma global unimodal de la distribución. Para $n = 50$, $h = 5$ es **más apropiada** porque reduce la varianza del estimador a costa de un sesgo leve, ofreciendo una representación más estable de la distribución subyacente.

1.3 Ejercicio 3. IC exacto con varianza conocida ($\sigma^2 = 100$)

Deducción. Sea $X_1, \dots, X_n \stackrel{iid}{\sim} N(\theta, \sigma^2)$ con $\sigma^2 = 100$ conocida. El estimador de máxima verosimilitud es $\bar{X}_n$, con distribución exacta $\bar{X}_n \sim N(\theta, \sigma^2/n)$. El pivote

$$Z = \frac{\bar{X}_n - \theta}{\sigma/\sqrt{n}} \sim N(0, 1)$$

lleva al **IC exacto al 99%**:

$$IC_{0.99} = \left[\bar{X}_n - z_{0.995} \frac{\sigma}{\sqrt{n}}, \quad \bar{X}_n + z_{0.995} \frac{\sigma}{\sqrt{n}} \right]$$

```
xbarra <- mean(n)
varx   <- 100
alpha  <- 0.01
```

```

z      <- qnorm(1 - alpha / 2)
ee     <- sqrt(varx / length(n))
ic     <- cbind(xbarra - z * ee, xbarra + z * ee)

cat("Con un 99% de confianza, la altura promedio se encuentra entre",
    round(ic[1, 1], 2), "y", round(ic[1, 2], 2), "cm.")

```

Con un 99% de confianza, la altura promedio se encuentra entre 156.21 y 163.5 cm.

1.4 Ejercicio 4. IC asintótico con varianza desconocida

Deducción. Cuando σ^2 es desconocida se estima con S_n . Por el Teorema de Slutsky,

$$Z_n = \frac{\bar{X}_n - \theta}{S_n / \sqrt{n}} \stackrel{a}{\sim} N(0, 1)$$

lo que da el **IC asintótico al 99%**:

$$IC_{0.99} = \left[\bar{X}_n - z_{0.995} \frac{S_n}{\sqrt{n}}, \quad \bar{X}_n + z_{0.995} \frac{S_n}{\sqrt{n}} \right]$$

```

xbarra <- mean(n)
sd_    <- sd(n)
alpha  <- 0.01
z      <- qnorm(1 - alpha / 2)
ee     <- sd_ / sqrt(length(n))
ic     <- cbind(xbarra - z * ee, xbarra + z * ee)

cat("Con un 99% de confianza, la altura promedio se encuentra entre",
    round(ic[1, 1], 2), "y", round(ic[1, 2], 2), "cm.")

```

Con un 99% de confianza, la altura promedio se encuentra entre 155.91 y 163.81 cm.

1.5 Ejercicio 5. IC bootstrap estándar ($B = 1000$, sin librería boot)

Deducción. El IC bootstrap estándar aproxima el error estándar de $\bar{X}_n$ con la desviación estándar de las medias bootstrap $\hat{\sigma}_{boot} = \text{sd}(\bar{X}_1^*, \dots, \bar{X}_B^*)$, dando:

$$IC_{0.99}^{boot} = [\bar{X}_n - z_{0.995} \hat{\sigma}_{boot}, \quad \bar{X}_n + z_{0.995} \hat{\sigma}_{boot}]$$

```

B      <- 1000
Tboot_b <- c()

for (b in 1:B) {
  xb      <- sample(n, size = length(n), replace = TRUE)
  Tboot_b[b] <- mean(xb)
}

alpha <- 0.01
q_z   <- qnorm(1 - alpha / 2)

(media_boots <- mean(Tboot_b))

```

[1] 159.7758

```
(sdboot <- sd(Tboot_b))
```

```
## [1] 1.497824
```

```
ic <- cbind(xbarra - q_z * sdboot,  
            xbarra + q_z * sdboot)
```

```
cat("Con un 99% de confianza, la altura promedio se encuentra entre",  
    round(ic[1, 1], 2), "y", round(ic[1, 2], 2), "cm.")
```

```
## Con un 99% de confianza, la altura promedio se encuentra entre 156 y 163.72 cm.
```

1.6 Ejercicio 6. Comparación de los tres intervalos

Los tres métodos producen intervalos similares en este escenario (distribución aproximadamente normal, $n = 50$). El **IC exacto (a)** es teóricamente correcto bajo normalidad con $\sigma^2 = 100$ conocida, pero depende de un supuesto difícil de verificar. El **IC asintótico (b)** es el más práctico: no requiere conocer σ^2 y el TCL garantiza su validez para n suficientemente grande. El **IC bootstrap (c)** es el más flexible (no asume distribución), aunque introduce variabilidad adicional por el remuestreo. En la práctica se preferiría el **IC asintótico (b)**.

2 Parte II. Estudio de simulación

2.1 Ejercicio 1. Objetivo del estudio de Monte Carlo

El objetivo es **evaluar empíricamente la cobertura real** de cinco métodos de construcción de IC al 99%. Dado que se dispone de la población completa, se generan $S = 1000$ muestras independientes de tamaño $n = 50$ y se calcula para cada una los cinco IC. La cobertura estimada de cada método es la proporción de intervalos que contienen al verdadero parámetro θ . Cada evaluación constituye un ensayo de Bernoulli (éxito = el IC contiene a θ), lo que permite estimar p_j y compararla con el nivel nominal del 99%.

2.2 Configuración

El siguiente código es el provisto por el enunciado y se usa tal cual:

```
set.seed(16)
```

```
gen_fun <- function(nrep = 50, x) {  
  X <- sample(x, size = nrep, replace = TRUE)  
  return(X)  
}
```

```
data <- replicate(n = 1000, gen_fun(nrep = 50, x = x), simplify = FALSE)
```

```
CI_pivote <- function(X) {  
  n <- length(X)  
  IC1 <- c(0.99,  
           mean(X) + qnorm(0.005) * sqrt(100),  
           mean(X) + qnorm(0.995) * sqrt(100))  
  return(IC1)  
}
```

```
CI_aprox <- function(X) {  
  n <- length(X)
```

```

  IC1 <- c(0.99,
          mean(X) + qnorm(0.005) * sd(X) / sqrt(n),
          mean(X) + qnorm(0.995) * sd(X) / sqrt(n))
  return(IC1)
}

CI_boot <- function(dat, type) {
  mean_func <- function(data, indices) {
    a <- mean(data[indices], na.rm = TRUE)
    return(a)
  }
  results <- boot(data = dat, statistic = mean_func, R = 1000)
  return(boot.ci(results, conf = 0.99, type = type)[[4]][-c(2, 3)])
}

library(boot)
library(purrr)

media.verdadera <- mean(x)

cal_fun <- function(dat) {
  CI1 <- CI_pivote(dat)
  CI2 <- CI_aprox(dat)
  CI3 <- CI_boot(dat, "bca")
  CI4 <- CI_boot(dat, "basic")
  CI5 <- CI_boot(dat, "perc")
  return(c(findInterval(vec = CI1[-1], x = media.verdadera) == 1,
              findInterval(vec = CI2[-1], x = media.verdadera) == 1,
              findInterval(vec = CI3[-1], x = media.verdadera) == 1,
              findInterval(vec = CI4[-1], x = media.verdadera) == 1,
              findInterval(vec = CI5[-1], x = media.verdadera) == 1))
}

results <- map(data, cal_fun)

porcentaje.cobertura <- apply(do.call(rbind, results), 2, sum) / 1000
porcentaje.cobertura

## [1] 1.000 0.979 0.983 0.978 0.983

```

2.3 Ejercicio 2. Resultados con medidas de variabilidad

Cada repetición es un ensayo de Bernoulli: éxito si el IC contiene a θ . La cobertura estimada del método j es $\hat{p}_j$ y su error estándar es $\widehat{SE}(\hat{p}_j) = \sqrt{\hat{p}_j(1 - \hat{p}_j)/S}$.

Cuadro 1: Cobertura empírica de los cinco metodos (semilla 16, S = 1000)

Metodo	Cobertura	Error estandar	IC 95% inf.	IC 95% sup.
Pivote (var. conocida)	1.000	0.0000	1.0000	1.0000
Asintotico (var. desconocida)	0.979	0.0045	0.9701	0.9879
Bootstrap BCA	0.983	0.0041	0.9750	0.9910
Bootstrap Basic	0.978	0.0046	0.9689	0.9871

Metodo	Cobertura	Error estandar	IC 95% inf.	IC 95% sup.
Bootstrap Percentil	0.983	0.0041	0.9750	0.9910

2.4 Ejercicio 3. Comparación de coberturas y efecto de la semilla

¿Difieren del 99%? El método de pivote alcanza cobertura del 100%, superior al nivel nominal. Esto ocurre porque se asume $\sigma^2 = 100$ cuando la varianza real de la población es ≈ 125.4 , produciendo un IC más ancho de lo necesario — es decir, el método es conservador. Los métodos asintótico y bootstrap se acercan razonablemente al 99%, con variaciones dentro del margen de error Monte Carlo esperado.

¿Qué cobertura se esperaba para el pivote? Dado que $\sigma^2 = 100 < \sigma_{real}^2$, el IC construido con el pivote es más ancho de lo que correspondería, por lo que se espera una cobertura *superior* al 99%. Esto es consistente con el resultado observado.

Tres semillas adicionales:

```

coberturas_alt <- matrix(NA, nrow = 3, ncol = 5)
semillas      <- c(42, 123, 999)

for (i in seq_along(semillas)) {
  set.seed(semillas[i])
  data_alt      <- replicate(n = 1000, gen_fun(nrep = 50, x = x), simplify = FALSE)
  results_alt   <- map(data_alt, cal_fun)
  coberturas_alt[i, ] <- apply(do.call(rbind, results_alt), 2, sum) / 1000
}

tabla_semillas <- data.frame(
  Semilla    = semillas,
  Pivote     = coberturas_alt[, 1],
  Asintotico = coberturas_alt[, 2],
  BCA        = coberturas_alt[, 3],
  Basic      = coberturas_alt[, 4],
  Percentil  = coberturas_alt[, 5]
)
knitr::kable(tabla_semillas,
  col.names = c("Semilla", "Pivote", "Asintotico",
                "Boot BCA", "Boot Basic", "Boot Percentil"),
  caption   = "Cobertura empirica segun semilla (S = 1000)")

```

Cuadro 2: Cobertura empirica segun semilla (S = 1000)

Semilla	Pivote	Asintotico	Boot BCA	Boot Basic	Boot Percentil
42	1	0.982	0.986	0.976	0.981
123	1	0.985	0.991	0.978	0.985
999	1	0.992	0.995	0.991	0.996

Las coberturas son estables entre semillas. El pivote mantiene cobertura de ~100% en todos los casos. Los métodos asintótico y bootstrap oscilan cerca del 99% dentro del margen de variabilidad Monte Carlo esperado.

2.5 Ejercicio 4. Diseño de una simulación más completa

Para obtener evidencia más sólida se propone una simulación factorial que varíe:

- **Tamaño de muestra:** $n \in \{15, 30, 50, 100, 200\}$, para estudiar la velocidad de convergencia al nivel nominal.
- **Número de repeticiones:** $S = 5000$ o más, reduciendo el error estándar de $\hat{p}$ por debajo de 0.3 puntos porcentuales.
- **Distribución de la población:** reemplazar la población de alturas por datos de distribuciones asimétricas (χ^2 , log-normal) o bimodales, para evaluar robustez de cada método ante desviaciones de la normalidad.
- **Múltiples semillas:** usar al menos 20 semillas y reportar la mediana y rango intercuartílico de las coberturas, en lugar de depender de una sola.

Se reportaría una tabla o gráfico de cobertura versus n para cada método y distribución, lo que permitiría identificar a partir de qué n cada método alcanza el nivel nominal y cuál es más robusto.