

Manual para el curso Minería de Datos y Análisis Multivariado (XS-0126)

Autor: Anderson Martínez

Colaboradores: Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1	Aprendizaje supervisado	2
2	Aprendizaje no supervisado	2
3	Diferencia entre aprendizaje supervisado y no supervisado	3
4	Características del aprendizaje no supervisado	3
5	Proceso de Análisis de componentes principales (PCA)	6
5.1	Maldición de la dimensionalidad	7
5.2	Requisitos para que PCA tenga sentido	7
5.3	Ejemplo de aplicación	7
6	Comparación de análisis factorial con componentes principales	9
6.1	Ejemplo de análisis factorial	9
6.2	Diferencias entre análisis factorial y PCA	10
7	Valores y Vectores propios	10
7.1	¿Cuándo centrar y cuándo estandarizar?	11
7.2	Valores y vectores propios en R	11
7.3	Construcción de Z 's	13
8	HEPTATLON	14
8.1	Proceso de cambios en las variables	14
8.2	Matriz de correlaciones	15
8.2.1	Cálculo en R	15
8.2.2	Gráfico de correlación librería corrgram de colores	15
8.2.3	Gráfico de correlación librería corrgram de números (correlaciones)	16
8.2.4	Gráfico del paquete corplot	17
8.3	Análisis de valores extremos mediante leverage	18
8.3.1	Formas de averiguar y eliminar el valor extremo	19
8.4	Obtención del determinante de la matriz R	19
8.5	Hipótesis de matriz de correlaciones	20
8.6	KMO	20
8.7	Análisis con la matriz de covarianzas	21
8.7.1	Comparación de varianzas de las variables	21
8.7.2	Descomposición espectral de matriz de covarianzas	21
8.8	Obtención de los componentes principales Z 's	23
8.8.1	Cálculo de cuánto porcentaje explica el componente	23

8.8.2	¿Es normal que tenga media cero?	24
8.8.3	Forma automática con <code>prcomp()</code>	24
9	Análisis con matriz de correlaciones	25
9.1	Estadarizando las variables pprimero	25
9.2	Descomposición espectral de la matriz de correlaciones y obtención de los valores propios.	26
9.3	Porcentaje de explicación de un componente principal	27
9.4	Forma automática	27
9.5	Obtención del primer componente manualmente	28
9.6	Comparación de Varianza y lambdas	28
9.7	Cambio a los signos de los coeficientes de Z_1	29
10	Biplot	29
10.1	Biplot categórico	30
11	Gráfico de sedimentación	31
11.0.1	Conclusión de estudio	32
11.1	Reproducción de la matriz de correlaciones	32
11.2	Obtención de correlaciones	34
12	Prueba de los componentes en una regresión	34
12.1	Forma automática	35
12.2	Interpretaciones de regresión	35
13	Conglomerados	36
13.1	Distancias entre individuos	36
13.2	Distancia Euclidea	36
13.3	Distancia de Mahalanobis	40
13.4	Distancia City-block (Manhattan)	41
13.4.1	Nota importante de las distancias	42

1 Aprendizaje supervisado

Se aprenden funciones, relaciones que asocian entradas con salidas, por lo que se ajustan a un conjunto de ejemplos de los que conocemos la relación entre la entrada y la salida deseada.

Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre:

- Modelos de clasificación, si la salida es un valor categórico (por ejemplo, una enumeración, o un conjunto finito de clases).
- Modelos de regresión, si la salida es un valor de un espacio continuo.

2 Aprendizaje no supervisado

No estamos interesados en ajustar pares (entrada, salida), sino en aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros que provengan del mismo fenómeno), por ejemplo:

- Dando una agrupación de los datos según su similitud.
- Simplificando la estructura de los mismos manteniendo sus características fundamentales (como en los procesos de reducción de la dimensionalidad).
- Extrayendo la estructura interna con la que se distribuyen los datos en su espacio original (aprendizaje topológico).

3 Diferencia entre aprendizaje supervisado y no supervisado

El aprendizaje supervisado tiene variable respuesta Y , mientras que el aprendizaje no supervisado no la tiene. Además es importante resaltar que el no supervisado es más descriptivo.

4 Características del aprendizaje no supervisado

- No existe una salida o variable respuesta, por lo que no se utiliza un modelo que relacione un conjunto de variables con una respuesta.
- Esto hace que sea difícil validar los resultados, al contrario del aprendizaje supervisado en el que existen métricas que permiten evaluar con claridad la bondad del aprendizaje realizado.
- Es parte de un análisis exploratorio de datos.
- Algoritmos no supervisados resultan ser muy costosos porque requieren de más pruebas de ensayo y error, haciendo que requieran de un aparatado teórico y computacional mucho más elaborado.

Ejemplo 1

Suponga que tiene la siguiente regresión:

$$\mu_{y|x} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_{p-1} X_{p-1}$$

Recuerde que $\mu_{y|x}$ es la respuesta

Se tiene el siguiente subconjunto de X 's:

$$X_1, \dots, X_k \text{ Altamente Correlacionadas}$$

Nota: Cuando las X 's están muy correlacionadas hay problemas de multicolinealidad y eso nos infla los errores estándar.

Note que este conjunto de variable es de dimensión k , esto lo que nos dice en realidad es que estas X 's miden un subconjunto menor de conceptos, lo que nos lleva al siguiente conjunto:

$$Z_1, \dots, Z_q$$

Donde $q < k$ (No Correlacionadas)

Reemplazando en el modelo original tenemos el siguiente resultado:

$$\mu_{y|x,z} = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \dots + \beta_q Z_q + \beta_{k+1} X_{k+1}$$

En este modelo la primera parte es no supervisado ya que no utilizamos la variable respuesta, para el último modelo obtenido si es supervisado ya que se utiliza con la variable respuesta.


Ejemplo 2

1. Se tienen $X_1, \dots, X_p$ Grupos
2. Formo k grupos
3. Se crea una variable G , la cual se crea a partir del aprendizaje no supervisado. Ya que se crea basado en las X 's

Observación (i)	X_1	X_2	$\dots$	X_p	$G = f(X_1, \dots, X_p)$
1	x_{11}	x_{12}	$\dots$	x_{1p}	g_1
2	x_{21}	x_{22}	$\dots$	x_{2p}	g_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
i	x_{i1}	x_{i2}	$\dots$	x_{ip}	g_i
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
n	x_{n1}	x_{n2}	$\dots$	x_{np}	g_n

Nota: Si agregamos una variable edad, podríamos realizar un análisis de varianza, ya que dicha variable funcionaría como una variable respuesta.

Distribución de Edad por Grupo



Ejemplo 3

Observación (i)	Altura (cm)	N.º de Hojas	Grosor del Tallo (mm)	Peso del Racimo (kg)	pH del Suelo
1	24.5	6	3.2	0.45	5.4
2	28.1	7	3.8	0.58	5.6
3	31.4	8	4.1	0.65	5.5
4	52.6	14	7.5	1.85	6.1
5	58.0	15	8.2	2.10	6.3
6	61.3	17	8.9	2.40	6.2
7	84.7	22	12.4	4.15	6.8

Observación (i)	Altura (cm)	N.º de Hojas	Grosor del Tallo (mm)	Peso del Racimo (kg)	pH del Suelo
8	89.2	25	13.1	4.60	7.0

Note que la Altura (cm), N.º de Hojas, Grosor del Tallo (mm), Peso del Racimo (kg) están muy correlacionadas, mientras que el H del Suelo no tanto.

Con esas variables correlacionadas puede crear una variable Z_1

```
library(ggplot2)
library(dplyr)
# 1. Definir los datos de la tabla (8 observaciones)
datos <- data.frame(
  obs      = 1:8,
  altura   = c(24.5, 28.1, 31.4, 52.6, 58.0, 61.3, 84.7, 89.2),
  hojas    = c(6, 7, 8, 14, 15, 17, 22, 25),
  grosor   = c(3.2, 3.8, 4.1, 7.5, 8.2, 8.9, 12.4, 13.1),
  peso     = c(0.45, 0.58, 0.65, 1.85, 2.10, 2.40, 4.15, 4.60),
  ph_suelo = c(5.4, 5.6, 5.5, 6.1, 6.3, 6.2, 6.8, 7.0)
)


# 2. Extracción de Z_1 como el Primer Componente Principal (CP1 estandarizado)
# Z_1 captura la mayor parte de la variabilidad conjunta del crecimiento/rendimiento
pca_morfologia <- prcomp(
  datos[, c("altura", "hojas", "grosor", "peso")],
  center = TRUE,
  scale. = TRUE
)

# Asignar los scores de Z_1 al dataframe
datos$Z1 <- pca_morfologia$x[, 1]

# 3. Scatterplot con ggplot2
ggplot(datos, aes(x = ph_suelo, y = Z1)) +
  geom_point(color = "#1f77b4", size = 4, alpha = 0.9) +
  geom_smooth(method = "lm", se = TRUE, color = "#d62728", linetype = "dashed", fill = "#e0e0e0", alpha = 0.5) +
  labs(
    title = expression(bold("Diagrama de Dispersión:") ~ bolditalic(Z)[1] ~ bold("vs. pH del Suelo")),
    subtitle = expression(italic(Z)[1] ~ "construida como el primer componente principal (" * CP[1] * ")"),
    x = "pH del Suelo",
    y = expression(italic(Z)[1] ~ "(Índice Morfológico /" ~ CP[1] * ")")
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold", hjust = 0.5),
    plot.subtitle = element_text(hjust = 0.5, color = "gray35", margin = margin(b = 10)),
    axis.title = element_text(face = "bold"),
    panel.grid.minor = element_blank()
  )
```

Diagrama de Dispersión: Z_1 vs. pH del Suelo

Z_1 construida como el primer componente principal (CP_1)



5 Proceso de Análisis de componentes principales (PCA)

$$\mu_{y|x_1, x_2, x_3, x_4} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4$$

Suponga que X_2, X_3, X_4 están muy correlacionadas, para ello se crea una variable Z_1 .

$$\mu_{y|x_1, z_1} = \beta_0 + \beta_1 X_1 + \gamma_1 Z_1$$

Sin embargo, como pasamos de tres variables (X_2, X_3, X_4) a una (Z_1) perdemos cierta información. Es decir Z_1 explica un cierto porcentaje de (X_2, X_3, X_4). Por ejemplo Z_1 explica un 80% de (X_2, X_3, X_4).

Se puede dar el caso que Z_1 no explique suficiente.

Existe otro modelo que puede explicar más que el siguiente:

$$\mu_{y|x_1, x_3} = \beta_0 + \beta_1 X_1 + \beta_3 X_3$$

Nota: Es importante resaltar que los tres modelos anteriores no son lo mismo, cada uno tiene sus ventajas y desventajas.

El PCA sirva para eliminar la multicolinealidad, solo si lo queremos usar para una regresión. Otro uso que se le puede dar es para obtener gráficos más simples.

5.1 Maldición de la dimensionalidad

- Cuando se cuenta con demasiadas variables es difícil hacer un análisis gráfico para tener una idea inicial del comportamiento de los datos.
- Muchas variables son un obstáculo para aplicar otras técnicas multivariadas.

5.2 Requisitos para que PCA tenga sentido

- Si las variables originales casi no están correlacionadas, nada se gana al llevar a cabo un PCA.
- Cuando el determinante de una matriz es cero, se tiene que hay columnas linealmente dependientes. Esto se llama multicolinealidad.
- Si el determinante de la matriz de correlación (R) es cercano a cero, hay indicación de altas correlaciones entre las variables, de lo contrario, cuando el determinante es alto un PCA puede no tener sentido.

5.3 Ejemplo de aplicación

Se tienen los siguientes datos

Observación (<i>i</i>)	X_1	X_2	X_3	X_4
1	3	4	2	5
2	5	1	1	3
3	4	3	3	2
4	2	7	4	0
$\bar{X} \rightarrow$	3.6	3.75	2.5	2.5
$S \rightarrow$	1.24	2.5	1.24	2.05

Luego estandarizamos mediante la siguiente fórmula:

$$X_i = \frac{X_i - \bar{X}}{S_i}$$

```
# 1. Definición de la matriz de datos X (4 observaciones x 4 variables)
X <- matrix(
  c(
    3, 4, 2, 5,
    5, 1, 1, 3,
    4, 3, 3, 2,
    2, 7, 4, 0
  ),
  nrow = 4,
  byrow = TRUE,
  dimnames = list(paste0("ID_", 1:4), paste0("X", 1:4))
)

# 2. Visualizar resultados
print("Matriz Original X:")

## [1] "Matriz Original X:"
```

```

print(X)

##      X1 X2 X3 X4
## ID_1  3  4  2  5
## ID_2  5  1  1  3
## ID_3  4  3  3  2
## ID_4  2  7  4  0

# 2. Estandarización con scale()
# scale() por defecto resta la media muestral (center = TRUE)
# y divide entre la desviación estándar muestral s con n-1 grados de libertad (scale = TRUE)
Z <- scale(X, center = TRUE, scale = TRUE)
print("Matriz Estandarizada Z (Z-scores):")

## [1] "Matriz Estandarizada Z (Z-scores):"

print(round(Z, 4))

##      X1  X2  X3  X4
## ID_1 -0.3873  0.1 -0.3873  1.2010
## ID_2  1.1619 -1.1 -1.1619  0.2402
## ID_3  0.3873 -0.3  0.3873 -0.2402
## ID_4 -1.1619  1.3  1.1619 -1.2010
## attr("scaled:center")
##      X1  X2  X3  X4
## 3.50 3.75 2.50 2.50
## attr("scaled:scale")
##      X1      X2      X3      X4
## 1.290994 2.500000 1.290994 2.081666

```

Interpretación El ID_4 en X_1 está 1.16 desviaciones estándar debajo la media (recuerde que la desviación estándar de X_1 es 1.29). Para el ID_1 está 0.1 desviaciones estándar sobre la media, es decir está prácticamente en la media.

Nota: El máximo de desviaciones estándar en una normal son 3 que son el 99.7% de los datos.

Luego obtenemos los coeficientes para Z_1 y hacemos la siguiente regresión:

$$Z_1 = 0.2X_1^s + 0.4X_2^s + 0.01X_3^s + 0.5X_4^s$$

Nota: En regresión estandarizabamos los coeficientes para poder compararlos en este caso, estandarizamos y la que tiene más peso en el resultado de Z_1 es X_4

Luego sustituimos con los valores que tenemos

$$\begin{aligned}
 Z_1^{(1)} &= 0.2(-0.39) + 0.4(0.10) + 0.01(-0.39) + 0.5(1.20) \\
 &= -0.078 + 0.040 - 0.0039 + 0.600 = \mathbf{0.5581}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(2)} &= 0.2(1.16) + 0.4(-1.10) + 0.01(-1.16) + 0.5(0.24) \\
 &= 0.232 - 0.440 - 0.0116 + 0.120 = \mathbf{-0.0996}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(3)} &= 0.2(0.39) + 0.4(-0.30) + 0.01(0.39) + 0.5(-0.24) \\
 &= 0.078 - 0.120 + 0.0039 - 0.120 = \mathbf{-0.1581}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(4)} &= 0.2(-1.16) + 0.4(1.30) + 0.01(1.16) + 0.5(-1.20) \\
 &= -0.232 + 0.520 + 0.0116 - 0.600 = \mathbf{-0.3004}
 \end{aligned}$$

Nota: Si uno tiene p variables originales, puede llegar a p variables nuevas, la idea es siempre obtener menos que p

Más adelante se explicará la obtención de los Z 's mediante la descomposición espectral.

Además los coeficientes de los Z 's, como están normalizados la suma de ellos es igual a 1.

Sub-Ejemplo

Se tiene el siguiente Z

$$Z_2 = 0.8X_1 + 0.8X_2 + 0.01x_3 + 0.01X_4$$

Como X_3, X_4 prácticamente no pesan, por lo que se interpretaría como un promedio entre X_1 y X_2

Para este otro caso

$$Z_3 = 0.8X_1 + 0.6X_2 + 0.5x_3 + 0.01X_4$$

En esta situación es una especie de ponderación donde el que tiene más peso es X_1

Caso inusual

$$Z_4 = 0.5X_1 - 0.5X_2 + 0.01x_3 + 0.01X_4$$

- Si $X_1 = X_2 = 0$ significa que está muy parecido

PREGUNTAR

- Si $X_1 > X_2$
- Si $X_1 < X_2$

6 Comparación de análisis factorial con componentes principales

- La estructura del análisis de factores es similar a los componentes principales.
- En componentes principales las variables conocidas X se combinan con los coeficientes a para producir nuevas variables Z llamadas componentes principales. Una propiedad importante en el análisis de componentes principales es $Cov(Z_i, Z_j) = 0$
- En factores se combinan factores latentes desconocidos f para formar las variables conocidas X . Esto es más complejo

6.1 Ejemplo de análisis factorial

Tenemos un estudio con f_1 que es la habilidad cuantitativa de una persona y f_2 es la habilidad de razonamiento verbal, para estos dos variables no tienen una forma directa de medirse, ya que f_1 se podría medir mediante un problema o un cuestionario, pero dentro de las preguntas del cuestionario, mientras se mide la habilidad cuantitativa, también se podría estar midiendo el razonamiento verbal, ya que la persona necesita entender la pregunta para resolver el problema.

Por ejemplo una persona obtuvo en una pregunta un valor de $f_1 = 0.5$ y $f_2 = 0.5$, asuma que $\lambda_{11} = 7$ y $\lambda_{12} = 7.5$

Esto nos lleva a que

$$7.25 = 0.5 * 7 + 0.5 * 7.5$$

En otra pregunta se tiene el resultado de otro puntaje, sin embargo lo que cambia es f_1 y f_2 , en el caso de los λ 's no cambian y se pueden obtener por medio de **PCA**, esta es la confusión que muchas personas tienen con este tema.

Factores comunes	Componentes principales
$\begin{aligned} X_1 &= \lambda_{11}f_1 + \lambda_{12}f_2 + \cdots + \lambda_{1m}f_m + \eta_1 \\ X_2 &= \lambda_{21}f_1 + \lambda_{22}f_2 + \cdots + \lambda_{2m}f_m + \eta_2 \\ &\vdots \\ X_q &= \lambda_{q1}f_1 + \lambda_{q2}f_2 + \cdots + \lambda_{qm}f_m + \eta_q \end{aligned}$	$\begin{aligned} Z_1 &= a_{11}X_1^s + a_{12}X_2^s + \cdots + a_{1q}X_q^s \\ Z_2 &= a_{21}X_1^s + a_{22}X_2^s + \cdots + a_{2q}X_q^s \\ &\vdots \\ Z_q &= a_{q1}X_1^s + a_{q2}X_2^s + \cdots + a_{qq}X_q^s \end{aligned}$

6.2 Diferencias entre análisis factorial y PCA

Factores comunes	Componentes principales
- El interés es la explicación de la estructura de covarianza o de correlación (o ambas) entre las variables medidas. - Puede haber cambios sustanciales en todos los factores si se cambia el número de factores. - El cálculo de los puntajes es complejo y existen varios métodos. - Se obtienen resultados equivalentes si se usa la matriz de covarianza o la de correlaciones. - Si las variables están casi no correlacionadas este análisis no tiene sentido. - En tal caso los factores no tienen nada que explicar.	- El interés se centra en la explicación de la variabilidad total del conjunto de variables (Como una regresión). - Si el número de componentes que se utilizan se incrementa, esos componentes no cambian. - El cálculo de los puntajes es sencillo y se basa en una única descomposición espectral. No hay relación directa entre los componentes obtenidos de la matriz de covarianza y la de correlaciones. - Si las variables están casi no correlacionadas este análisis no tiene sentido. - En tal caso se obtienen componentes que son muy similares a las variables originales.

Nota: Al agregar Z 's en componentes principales, las coeficientes para obtener los componentes no cambien, en cambio en análisis factorial al yo incluir más cosas que quiero medir (X 's), las f cambian. Además, si las variancias específicas son pequeñas ambos análisis dan resultados similares.

7 Valores y Vectores propios

A continuaci3n el siguiente tema se explica mediante un ejemplo.

Tenemos la siguiente matriz de varianzas y covarianzas:

$$\mathbf{S} = \begin{bmatrix} 8 & 10 & -3 \\ 10 & 6 & -4 \\ -3 & 4 & -2 \end{bmatrix}$$

Note que la $tr(\mathbf{S}) = 8 + 6 + 2 = 16$, esta corresponde a la suma de las varianzas, lo que signica que es la **Varianza total**

Una vez teniendo esto podemos calcular la matriz de correlaci3n por medio de la siguiente f3rmula:

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}$$

Nota: Recordar que en la diagonal la correlación es 1 ya que es la misma variable.

$$\mathbf{R} = \begin{bmatrix} 1 & 1.44 & -0.75 \\ 1.44 & 1 & -1.16 \\ -0.75 & 1.16 & 1 \end{bmatrix}$$

La $tr(R) = 3$, esta representa el número de variables. Además la matriz de correlaciones es la estandarización de una matriz de varianzas y covarianzas en este caso, ya que la varianza de cada una de las variables es 1. Esto nos lleva a la siguiente equivalencia:

$$Cov(X_i^s, X_j^s) = r_{ij}$$

Así que la $tr(R) = 3$ representa que la varianza total de las variables estandarizadas.

7.1 ¿Cuándo centrar y cuándo estandarizar?

Cuando se tienen variables con las mismas escalas solo se necesitan centrar, pero cuando son muy diferentes es altamente recomendado estandarizarlos.

7.2 Valores y vectores propios en R

Valores propios

```
valores = c(8, 10, -3, 10, 6, 4, -3, 4, 2)
S = matrix(
  valores,
  nrow = 3,
  ncol = 3,
  byrow = TRUE
)

v = eigen(S)
round(v$values, 2)
```

```
## [1] 17.07 5.04 -6.11
```

Esto nos dice que $\lambda_1 = 17.07$, $\lambda_2 = 5.04$, $\lambda_3 = -6.11$

Note que la suma de estos valores no da la varianza total original

```
sum(v$values)
```

```
## [1] 16
```

Vectores propios

Estos deben cumplir con la propiedad de que:

$$A \times a = \lambda \times a$$

A continuación se le representa el proceso en R, para obtenerlos

Tenemos la matriz asociada a los vectores propios

```
v$vectors
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.73550267 -0.3755265  0.5639288
## [2,] 0.67670738  0.3663738 -0.6386215
## [3,] 0.03321052  0.8513226  0.5235904
```

Los extraemos de la misma matriz

```
e1 = v$vectors[, 1] # Asociado a lambda_1 = 17.06
e2 = v$vectors[, 2] # Asociado a lambda_2 = 5.05
e3 = v$vectors[, 3] # Asociado a lambda_3 = -6.11
```

Verificamos con la condición de modo que $S \%*\% e_1 == \lambda_1 * e_1$

```
t(round(S \%*\% e1, 4))
```

```
##           [,1]      [,2]      [,3]
## [1,] 12.5515 11.5481  0.5667
```

```
round(v$values[1] * e1, 4)
```

```
## [1] 12.5515 11.5481  0.5667
```

Observe que la condición se cumple.

También otra propiedad que se tiene que resaltar es la ornormalidad de los mismos.

Verificación sobre si la norma es 1

```
# Norma 1: ||e_1|| = 1
sqrt(sum(e1^2))
```

```
## [1] 1
```

Verificación de ortogonalidad


```
# Ortogonales entre sí: e_1 \%*\% e_2 = 0
round(t(e1) \%*\% e2, 4)
```

```
##           [,1]
## [1,]      0
```

7.3 Construcción de Z's

Cambio de Base en ACP: Traslación y Rotación de Ejes

Lectura de coordenadas (X_1, X_2) vs. Puntuaciones (Z_1, Z_2)



Observando la figura anterior tenemos que:

$X_1 = 5.5 \rightarrow Z_1 = 1.95$ y $X_2 = 3.2 \rightarrow Z_2 = -0.82$. Con lo siguiente $r_{x_1, x_2} = 0.45 \rightarrow r_{z_1, z_2} = 0$

¿Cómo se construyen los Z's de la figura anterior?

- Si se utiliza la matriz de correlaciones, se deben estandarizar las variables, esto se hace cuando las escalas de las variables son similares. ($X_1^s, X_2^s \rightarrow S$)
- Si se utiliza la matriz de covarianzas y varianzas, se debe centrar solamente, sin embargo esto se debe hacer solo cuando las escalas sean muy similares. ($X_1^c, X_2^c \rightarrow R$)

Proceso de obtención de los Z's

Sabemos que en el anterior ejercicio los vectores propios son:

El primer vector propio es 0.74 0.67

El segundo vector propio es -0.67 0.74

Tenemos que las medias son:

Media de X_1 es 3.5

Media de X_2 es 2.5

Hacemos las operaciones para llegar al resultado

$$\begin{aligned}
Z_1 &= 0.74 X_1^c + 0.67 X_2^c \\
&= 0.74 (5.5 - 3.5) + 0.67 (3.2 - 2.5) \\
&= 0.74 (2.0) + 0.67 (0.7) \\
&= 1.48 + 0.469 \\
&= 1.95
\end{aligned}$$

$$\begin{aligned}
Z_2 &= -0.67 X_1^c + 0.74 X_2^c \\
&= -0.67 (5.5 - 3.5) + 0.74 (3.2 - 2.5) \\
&= -0.67 (2.0) + 0.74 (0.7) \\
&= -1.34 + 0.518 \\
&= -0.82
\end{aligned}$$

Haciendolo en una base de datos grande lo que se está haciendo es lo siguiente:

$$\mathbf{X}^c = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & x_{n3} \end{bmatrix} - \begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \vdots & \vdots & \vdots \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \end{bmatrix}$$

Luego se multiplica por el vector propio:

$$\mathbf{X}^c = \begin{bmatrix} x_{11}^c & x_{12}^c & x_{13}^c \\ x_{21}^c & x_{22}^c & x_{23}^c \\ \vdots & \vdots & \vdots \\ x_{n1}^c & x_{n2}^c & x_{n3}^c \end{bmatrix} \cdot \begin{bmatrix} a_{11} \\ a_{22} \\ a_{33} \end{bmatrix} = \begin{bmatrix} Z_{1(1)} \\ Z_{2(1)} \\ \vdots \\ Z_{n(1)} \end{bmatrix}$$

Con esto llegamos obtener el vector con los valores de la primera variable nueva, para todos los individuos de la base de datos o lo que es lo mismo que decir que el vector del primer componente principal.

Nota: Si se calculan las varianzas de los Z 's da como resultado los λ 's encontrados para los vectores propios, por lo que la variabilidad total es igual si se mantiene el mismo número de variables originales.

8 HEPTATLON

```
setwd("~/GitHub/Apuntes-Modelos-lineales-Avanzados/VI Ciclo/Minería de Datos y Análisis Multivariado")
```

8.1 Proceso de cambios en las variables

Para cambiar el sistema de puntuación realizamos la siguiente transformación de tal manera que:

Observación (i)	→	Observación Nueva
3		7
5		5
8		2
10		0

La fórmula utilizada es:

$$x_{new} = max - x_i$$

```
load("Heptatlon.Rdata")
base$vallas=with(base,max(vallas)-vallas)
base$car200=with(base,max(car200)-car200)
base$car800=with(base,max(car800)-car800)
```

8.2 Matriz de correlaciones

8.2.1 Cálculo en r

```
round(cor(base[, -8]), 2)
```


```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.81 0.65  0.77      0.91      0.01  0.78
## saltoalto   0.81      1.00 0.44  0.49      0.78      0.00  0.59
## tiro        0.65      0.44 1.00  0.68      0.74      0.27  0.42
## car200       0.77      0.49 0.68  1.00      0.82      0.33  0.62
## saltolargo  0.91      0.78 0.74  0.82      1.00      0.07  0.70
## javalina    0.01      0.00 0.27  0.33      0.07      1.00 -0.02
## car800      0.78      0.59 0.42  0.62      0.70     -0.02  1.00
```

8.2.2 Gráfico de correlación librería corrgram de colores

```
library(corrgram)
```

```
## Warning: package 'corrgram' was built under R version 4.5.3
```

```
corrgram(base[, -8], lower.panel=panel.pts, order=T) # order = T nos ordena las correlaciones
```



Los colores azules significan una correlación positiva, mientras que los rojos significan una correlación negativa. Además, en los gráficos de puntos, en los ejes están los valores de cada variable según corresponda.


8.2.3 Gráfico de correlación librería corrgram de números (correlaciones)

```
corrgram(base[,-8], lower.panel=panel.pts, upper.panel=panel.conf,
          diag.panel=panel.density, order=T)
```

```
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
```



```
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
## Warning in par(usr): argument 1 does not name a graphical parameter
```




8.2.4 Gráfico del paquete corrplot

```
library(corrplot)
```

```
## Warning: package 'corrplot' was built under R version 4.5.3
```

```
## corrplot 0.95 loaded
```

```
corrplot(cor(base[, -8]), method = "square", type = "lower") # El parámetro lower ordena el correlograma
```




8.3 Análisis de valores extremos mediante leverage

Recuerde que este proceso se realiza mediante el cálculo de la matriz:

$$H = X(X^T X)^{-1} X^T$$

A continuación se le presenta el código en *r*, para los leverage

```
lev=hat(base[, -8])
plot(lev)
lim=2*mean(lev)
abline(h=lim)
```



8.3.1 Formas de averiguar y eliminar el valor extremo

Formas de averiguar

```
which.min(base$saltoalto) # Es el punto menor que se ve en los gráficos de correlación más arriba
```

```
## [1] 25
```

```
which.max(lev) # El valor más alto que se sale de la línea en los leverage
```

```
## [1] 25
```

Formas de eliminar

```
base1 = subset(base, lev<lim)
```

```
base1 = base[-25,]
```

Nota: Recordar que en este caso se quitó el valor extremo por términos del ejercicio y nunca se puede quitar sin una justificación en concreto.

8.4 Obtención del determinante de la matriz R

```
base2=base1[,-8] # Es una base sin la respuesta (solo con las X's)
```

```
R=cor(base2)
```

```
det(R)
```

```
## [1] 0.003511559
```

Conforme las correlaciones, aumenta el determinante tiende a cero.

Correlación alta $\implies$ Determinante casi cero

8.5 Hipótesis de matriz de correlaciones

Existe una prueba de hipótesis que verifica si la matriz de correlaciones es igual a la identidad, ya que si es similar a la identidad, indicaría que las correlaciones son prácticamente cero.

Nota: Para hacer el análisis de PCA **mínimo**, se debe rechazar esta hipótesis.

$$H_0 : R = I$$

```
library(psych)
cortest.bartlett(R,n=nrow(base2)) # Proporcionadle a la función la matriz

## $chisq
## [1] 112.092
##
## $p.value
## [1] 1.973466e-14
##
## $df
## [1] 21

cortest.bartlett(base2) # En esta opción, la base de datos no puede contener la respuesta

## $chisq
## [1] 112.092
##
## $p.value
## [1] 1.973466e-14
##
## $df
## [1] 21
```

8.6 KMO

En ocasiones la prueba de correlaciones falla debido a la gran cantidad de datos, ya que debido a la gran potencia que tienen, ocasiona que la prueba se rechaze siempre.

Una solución ante este problema es usar esta prueba, que tiene como condición que solo si $n/q < 5$, donde q es el número de variables.

A continuación se le presentan los criterios del KMO

Rango KMO	Interpretación / Calidad
[0.9, 1.0]	Muy bueno (Excelente)
[0.8, 0.9]	Meritorio
[0.7, 0.8]	Mediano (Aceptable)
[0.6, 0.7]	Mediocre (Regular)
[0.5, 0.6]	Bajo
[0.0, 0.5]	Inaceptable (Desaconsejable)

KMO(R)

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = R)
## Overall MSA = 0.73
## MSA for each item =
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.87      0.55      0.82      0.72      0.72      0.47      0.84
```

En este caso la Correlación es aceptable

8.7 Análisis con la matriz de covarianzas

Cpmo se mencionó anteriormente, este análisis se recomienda hacerlo cuando las varianzas de las variables son bastantes similares, ya que en este caso los valores no están estandarizados, tal y como sucede con el análisis de la matriz de correlación.

8.7.1 Comparación de varianzas de las variables

```
v=apply(base2, 2,var) # Note que el 2 es porque es la varianza para cada columna
round(v,3)
```

```
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.265      0.003      2.241      0.878      0.161      12.032      37.789
```

Nota: Con ver este resultado podemos concluir que no tiene sentido hacer un análisis por la matriz de covarianzas debido a la gran diferencia entre varianzas.

Este cálculo lo puede hacer también de la siguiente forma:

```
round(diag(var(base2)),3)
```

```
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.265      0.003      2.241      0.878      0.161      12.032      37.789
```

La variabilidad total de las variables originales la obtenemos, sumando todas las varianzas

```
sum(v)
```

```
## [1] 53.36842
```

8.7.2 Descomposición espectral de matriz de covarianzas

Obtenemos la matriz de covarianzas

```
S=var(base2)
round(S,2)
```

```
##      vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      0.26      0.02 0.59  0.40      0.18      0.59  1.77
## saltoalto    0.02      0.00 0.04  0.02      0.01      0.06  0.05
## tiro         0.59      0.04 2.24  0.94      0.47      1.78  3.76
## car200        0.40      0.02 0.94  0.88      0.31      1.53  3.30
## saltolargo    0.18      0.01 0.47  0.31      0.16      0.40  1.29
## javalina      0.59      0.06 1.78  1.53      0.40     12.03  5.46
## car800        1.77      0.05 3.76  3.30      1.29      5.46 37.79
```

$$S = AA'A' = A\Lambda^{\frac{1}{2}}\Lambda^{\frac{1}{2}}A'$$

donde:

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

Por medio de `eigen` hacemos la descomposición

```
espec=eigen(S)
```

A continuación se le presenta código en `R`, de como obtener los valores y vectores propios

```
lambda=espec$val
round(lambda,2)
```

```
## [1] 39.82 11.11 2.00 0.35 0.06 0.02 0.00
```

Nota: Observe que la suma de los λ ' es lo mismo que la varianza total

```
sum(lambda) # Da lo mismo que la varianza total (summa de las varianzas de cada predictor)
```

```
## [1] 53.36842
```

Esto nos lleva a escribir esta propiedad

$$\sum_{i=1}^q S_i^2 = \sum_{i=1}^q \lambda_j$$

```
A=espec$vec
round(A,2)
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
## [1,] -0.05 0.03 -0.22 -0.26 0.77 -0.54 0.04
## [2,] 0.00 0.01 -0.01 -0.01 0.11 0.11 -0.99
## [3,] -0.11 0.11 -0.88 0.42 -0.14 -0.03 -0.01
## [4,] -0.09 0.08 -0.31 -0.85 -0.40 -0.03 -0.04
## [5,] -0.04 0.02 -0.18 -0.18 0.46 0.84 0.15
## [6,] -0.20 0.96 0.16 0.05 0.02 0.01 0.01
## [7,] -0.97 -0.23 0.11 0.05 -0.01 0.00 0.00
```

```
L = diag(lambda)
L
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
## [1,] 39.82137 0.00000 0.000000 0.0000000 0.0000000 0.0000000 0.00000000
## [2,] 0.00000 11.11262 0.000000 0.0000000 0.0000000 0.0000000 0.00000000
## [3,] 0.00000 0.00000 2.003319 0.0000000 0.0000000 0.0000000 0.00000000
## [4,] 0.00000 0.00000 0.000000 0.3483982 0.0000000 0.0000000 0.00000000
## [5,] 0.00000 0.00000 0.000000 0.0000000 0.06044327 0.0000000 0.00000000
## [6,] 0.00000 0.00000 0.000000 0.0000000 0.0000000 0.0213549 0.00000000
## [7,] 0.00000 0.00000 0.000000 0.0000000 0.0000000 0.0000000 0.000921165
```

Aplicamos la fórmula que esta arriba para obtener la matriz de covarianzas

```
S1 = round(A%*%L%*%t(A),2)
S1
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
## [1,] 0.26 0.02 0.59 0.40 0.18 0.59 1.77
```

```
## [2,] 0.02 0.00 0.04 0.02 0.01 0.06 0.05
## [3,] 0.59 0.04 2.24 0.94 0.47 1.78 3.76
## [4,] 0.40 0.02 0.94 0.88 0.31 1.53 3.30
## [5,] 0.18 0.01 0.47 0.31 0.16 0.40 1.29
## [6,] 0.59 0.06 1.78 1.53 0.40 12.03 5.46
## [7,] 1.77 0.05 3.76 3.30 1.29 5.46 37.79
```

8.8 Obtención de los componentes principales Z 's

```
basec=scale(base2,scale=F) # Datos centrados
Z1=basec%*%A[,1]
Z1 # Z1 de las 25 competidoras
```

```
## [1]
## Joyner-Kersee (USA) -7.6475882
## John (GDR) -9.2440142
## Behmer (GDR) -11.3128880
## Sablovskaitė (URS) -3.1851196
## Choubenkova (URS) -8.2870298
## Schulz (GDR) -9.1650206
## Fleming (AUS) -2.1745470
## Greiner (USA) -0.6871351
## Lajbnerova (CZE) 0.8133054
## Bouraga (URS) 0.2255227
## Wijnsma (HOL) -2.5575479
## Dimitrova (BUL) -2.1814057
## Scheider (SWI) -1.0375723
## Braun (FRG) 6.9911347
## Ruotsalainen (FIN) 1.3308934
## Yuping (CHN) 11.8352342
## Hagger (GB) 4.6816897
## Brown (USA) 10.6025928
## Mulliner (GB) 3.8401768
## Hautenauve (BEL) 0.4282646
## Kytola (FIN) -0.8310151
## Geremias (BRA) 9.2945847
## Hui-Ing (TAI) 3.2318624
## Jeong-Mi (KOR) 5.0356220
```

8.8.1 Cálculo de cuánto porcentaje explica el componente

$$\frac{Var(Z_1)}{Var_{total}} * 100$$

```
var(Z1)/sum(diag(var(base2)))*100
```

```
## [1]
## [1,] 74.61597
```

Otra forma de obtenerlo

```
lambda[1]/sum(lambda)*100
```

```
## [1] 74.61597
```

8.8.2 ¿Es normal que tenga media cero?

Es completamente normal, ya que cuando se usa la matriz de covarianzas al momento de centrar las variables, la media es prácticamente cero

```
mean(Z1)
```

```
## [1] 1.741662e-15
```

8.8.3 Forma automática con prcomp()

```
pca1=prcomp(base2) #Recordar que base2 no contiene la respuesta  
pca1
```

```
## Standard deviations (1, .., p=7):  
## [1] 6.3104174 3.3335599 1.4153864 0.5902527 0.2458521 0.1461332 0.0303507  
##  
## Rotation (n x k) = (7 x 7):  
##  
##          PC1      PC2      PC3      PC4      PC5  
## vallas    -0.048990549 -0.025316574 0.21976922 0.258721171 -0.770392335  
## saltoalto -0.001689277 -0.005045357 0.01412828 0.007663199 -0.113562325  
## tiro      -0.109842256 -0.109469326 0.88429017 -0.415089588 0.143844257  
## car200    -0.093344900 -0.082933532 0.30995644 0.850113115 0.403820065  
## saltolargo -0.035796182 -0.016070106 0.18428548 0.183911499 -0.457550175  
## javalina   -0.203545182 -0.964064905 -0.16268061 -0.046437981 -0.021370194  
## car800    -0.966491838 0.225372406 -0.11416509 -0.045089141 0.005346563  
##  
##          PC6      PC7  
## vallas    -0.535642857 -0.036141682  
## saltoalto 0.106582607 0.987652319  
## tiro      -0.029989278 0.009599705  
## car200    -0.033144859 0.038395656  
## saltolargo 0.836474571 -0.147084795  
## javalina   0.006126305 -0.005703870  
## car800    0.001303485 0.001955278
```

```
names(pca1)
```

```
## [1] "sdev"      "rotation" "center"    "scale"     "x"
```

sdev: Son las desviaciones estándar para obtener lo siguiente:

```
(round(pca1$sdev,2))^2
```

```
## [1] 39.8161 11.0889 2.0164 0.3481 0.0625 0.0225 0.0009
```

rotation: Es la matriz de los vectores propios

```
round(pca1$rotation,2) # Los vectores propios
```

```
##          PC1  PC2  PC3  PC4  PC5  PC6  PC7  
## vallas    -0.05 -0.03 0.22 0.26 -0.77 -0.54 -0.04  
## saltoalto 0.00 -0.01 0.01 0.01 -0.11 0.11 0.99  
## tiro      -0.11 -0.11 0.88 -0.42 0.14 -0.03 0.01  
## car200    -0.09 -0.08 0.31 0.85 0.40 -0.03 0.04  
## saltolargo -0.04 -0.02 0.18 0.18 -0.46 0.84 -0.15  
## javalina   -0.20 -0.96 -0.16 -0.05 -0.02 0.01 -0.01  
## car800    -0.97 0.23 -0.11 -0.05 0.01 0.00 0.00
```

x: Es lo que contiene los Z's


```
round(pca1$x,2)
```

```
##          PC1  PC2  PC3  PC4  PC5  PC6  PC7
## Joyner-Kersee (USA) -7.65 -3.28  1.93  0.61 -0.16  0.23 -0.04
## John (GDR)          -9.24  0.30  2.07 -0.61 -0.07 -0.15 -0.02
## Behmer (GDR)       -11.31 -0.99 -0.18  0.43  0.10  0.07  0.02
## Sablovskaitė (URS)  -3.19 -1.13  1.51 -0.44  0.43 -0.10  0.04
## Choubenkova (URS)   -8.29 -4.61 -0.13 -0.63  0.18 -0.05 -0.06
## Schulz (GDR)       -9.17  0.54 -1.00 -0.65 -0.01  0.13  0.03
## Fleming (AUS)       -2.17  1.44  0.05  1.03  0.05 -0.08  0.01
## Greiner (USA)      -0.69  3.32  1.36 -0.12 -0.01  0.07  0.00
## Lajbnerova (CZE)    0.81 -1.24  0.88 -0.67 -0.02 -0.15  0.04
## Bouraga (URS)       0.23  2.14  0.28  1.31 -0.03 -0.23 -0.01
## Wijnsma (HOL)      -2.56  4.12 -0.09 -0.28 -0.17  0.13  0.05
## Dimitrova (BUL)    -2.18  1.43  0.08  1.07 -0.06 -0.15  0.01
## Scheider (SWI)     -1.04 -5.80 -2.56  0.07 -0.32  0.04  0.03
## Braun (FRG)         6.99 -4.95  0.28  0.03 -0.18 -0.06  0.01
## Ruotsalainen (FIN)  1.33 -4.40 -1.23  0.20 -0.13 -0.02 -0.01
## Yuping (CHN)       11.84 -0.15  2.56 -0.14  0.03  0.23  0.03
## Hagger (GB)         4.68  4.63  0.74 -0.07 -0.58 -0.02 -0.04
## Brown (USA)        10.60 -5.46  0.23  0.27  0.00  0.15  0.01
## Mulliner (GB)       3.84  2.79  0.22  0.03  0.42  0.26 -0.05
## Hautenauve (BEL)    0.43  5.87 -0.84 -0.21 -0.15  0.02  0.00
## Kytola (FIN)       -0.83  2.37 -1.78 -0.53  0.04  0.00  0.02
## Geremias (BRA)      9.29 -0.35  0.58 -0.46  0.30 -0.32 -0.01
## Hui-Ing (TAI)       3.23  1.97 -2.77  0.55  0.53  0.07 -0.01
## Jeong-Mi (KOR)      5.04  1.44 -2.19 -0.80 -0.19 -0.05 -0.05
```

Note que da todos los z's de todos los individuos

```
summary(pca1)
```

```
## Importance of components:
##          PC1  PC2  PC3  PC4  PC5  PC6  PC7
## Standard deviation  6.3104 3.3336 1.41539 0.59025 0.24585 0.1461 0.03035
## Proportion of Variance 0.7462 0.2082 0.03754 0.00653 0.00113 0.0004 0.00002
## Cumulative Proportion 0.7462 0.9544 0.99192 0.99845 0.99958 1.0000 1.00000
```

Esto nos resume todo lo del análisis y cuánto aporta cada componente

9 Análisis con matriz de correlaciones

9.1 Estadarizando las variables prrimero

```
v1=scale(base2$vallas)
```

Observe que la media es 0 y la varianza es 1.

```
mean(v1)
```

```
## [1] -1.550003e-16
```

```
var(v1)
```

```
##      [,1]
## [1,]    1
```

Estandarice todas las variables. Para hacerlo de una sola vez, puede usar: `scale(base2)`.

```
base3=scale(base2)
```

Verificación de que todas las medias son 0 y las variancias son 1.

```
round(apply(base3,2,mean),10)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##           0           0           0           0           0           0           0
```

```
apply(base3,2,var)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##           1           1           1           1           1           1           1
```

9.2 Descomposición espectral de la matriz de correlaciones y obtención de los valores propios.

```
espec1=eigen(R)
lambda1=espec1$val
round(lambda1,2)
```

```
## [1] 4.32 0.90 0.83 0.47 0.30 0.11 0.07
```

```
S = var(base3)
```

```
S1 = var(base2) # esro no es lo mismo que S, no tiene sentido porque las variables no están estandariza
```

```
R = cor(base2)
```

Note que S y R son iguales

```
S;R
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina
## vallas      1.0000000 0.5817409 0.7666860 0.8300371 0.8893472 0.3324779
## saltoalto 0.5817409 1.0000000 0.4646854 0.3909024 0.6626910 0.3480793
## tiro      0.7666860 0.4646854 1.0000000 0.6694330 0.7840380 0.3430333
## car200    0.8300371 0.3909024 0.6694330 1.0000000 0.8106176 0.4707969
## saltolargo 0.8893472 0.6626910 0.7840380 0.8106176 1.0000000 0.2870826
## javalina  0.3324779 0.3480793 0.3430333 0.4707969 0.2870826 1.0000000
## car800    0.5587794 0.1523350 0.4082925 0.5731902 0.5233809 0.2559348
```

```
##      car800
## vallas      0.5587794
## saltoalto  0.1523350
## tiro       0.4082925
## car200     0.5731902
## saltolargo 0.5233809
## javalina   0.2559348
## car800     1.0000000
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina
## vallas      1.0000000 0.5817409 0.7666860 0.8300371 0.8893472 0.3324779
## saltoalto 0.5817409 1.0000000 0.4646854 0.3909024 0.6626910 0.3480793
## tiro      0.7666860 0.4646854 1.0000000 0.6694330 0.7840380 0.3430333
## car200    0.8300371 0.3909024 0.6694330 1.0000000 0.8106176 0.4707969
## saltolargo 0.8893472 0.6626910 0.7840380 0.8106176 1.0000000 0.2870826
## javalina  0.3324779 0.3480793 0.3430333 0.4707969 0.2870826 1.0000000
## car800    0.5587794 0.1523350 0.4082925 0.5731902 0.5233809 0.2559348
```

```
##          car800
## vallas    0.5587794
## saltoalto 0.1523350
## tiro      0.4082925
## car200    0.5731902
## saltolargo 0.5233809
## javalina  0.2559348
## car800    1.0000000
```

9.3 Porcentaje de explicación de un componente principal

Para averiguar ese porcentaje de explicación utilice la siguiente fórmula:

$$\frac{Var(Z_j)}{\sum_{j=1}^q}$$

donde q es el número total de variables

A continuación se le detalla el proceso en r

Obtenemos el primer valor propio

```
lambda1[1]
```

```
## [1] 4.323642
```

Luego obtenemos el número total de variables o sumamos los valores propios.

```
sum(lambda1)
```

```
## [1] 7
```

```
round(lambda1[1]/sum(lambda1),2)
```

```
## [1] 0.62
```

Esto quiere decir que Z_1 explica un 62% de la variabilidad total, cuando las variables están estandarizadas.

9.4 Forma automática

```
pca1=prcomp(base2,scale=T)
lambda2=pca1$sdev**2
round(lambda2,2)
```

```
## [1] 4.32 0.90 0.83 0.47 0.30 0.11 0.07
```

Note que con `summary()`, podemos obtener directamente cuánto porcentaje explica cada componente.

```
summary(pca1)
```

```
## Importance of components:
##          PC1      PC2      PC3      PC4      PC5      PC6      PC7
## Standard deviation  2.0793 0.9482 0.9109 0.68320 0.54619 0.33745 0.26204
## Proportion of Variance 0.6177 0.1284 0.1185 0.06668 0.04262 0.01627 0.00981
## Cumulative Proportion 0.6177 0.7461 0.8646 0.93131 0.97392 0.99019 1.00000
```

Obtención del primer vector propio

```
a1=pca1$rot[,1]
round(a1,2)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##      -0.45      -0.31      -0.40      -0.43      -0.45      -0.24      -0.30
```

Observe que las variables con más peso en este caso son: `vallas`, `saltolargo` y `saltolargo`. Además todos son negativos, esto es positiva ya que en términos de interpretación estos se van a estabilizar.

Es importante fijarse en el signo de los coeficientes que pesen más. Si hay uno que pese muy poco comparado con los demás, pero tiene signo diferente lo que se puede hacer es ignorarlo ya que no va a afectar tanto

9.5 Obtención del primer componente manualmente

```
Z1=base3%*%a1
Z1a=pca1$x[,1]
cbind(Z1,Z1a)
```

```
##                                Z1a
## Joyner-Kersey (USA) -4.757530189 -4.757530189
## John (GDR)          -3.147943402 -3.147943402
## Behmer (GDR)        -2.926184760 -2.926184760
## Sablovskaitė (URS)  -1.288135516 -1.288135516
## Choubenkova (URS)   -1.503450994 -1.503450994
## Schulz (GDR)        -0.958467101 -0.958467101
## Fleming (AUS)       -0.953445060 -0.953445060
## Greiner (USA)       -0.633239267 -0.633239267
## Lajbnerova (CZE)    -0.381571974 -0.381571974
## Bouraga (URS)       -0.522322004 -0.522322004
## Wijnsma (HOL)       -0.217701500 -0.217701500
## Dimitrova (BUL)     -1.075984276 -1.075984276
## Scheider (SWI)      0.003014986  0.003014986
## Braun (FRG)         0.109183759  0.109183759
## Ruotsalainen (FIN)  0.208868056  0.208868056
## Yuping (CHN)        0.232507119  0.232507119
## Hagger (GB)         0.659520046  0.659520046
## Brown (USA)         0.756854602  0.756854602
## Mulliner (GB)       1.880932819  1.880932819
## Hautenauve (BEL)    1.828170404  1.828170404
## Kytola (FIN)        2.118203163  2.118203163
## Geremias (BRA)      2.770706272  2.770706272
## Hui-Ing (TAI)       3.901166920  3.901166920
## Jeong-Mi (KOR)      3.896847898  3.896847898
```

En contexto de este problema mientras más pequeño sea el número mejor es la puntuación, esto nos lleva que la atleta Jeong-Mi (KOR), es la que peor puntuación tiene ya que tiene un valor de Z_1 alto. Otro aspecto importante a notar es que Scheider (SWI) se mantiene muy cerca del promedio, esto debido a su valor en el componente es casi cero.

9.6 Comparación de Varianzas y lambdas

```
var(Z1a)
```

```
## [1] 4.323642
```

```
lambda1[1]
```

```
## [1] 4.323642
```

Observe que son iguales, recuerde que esto siempre va a suceder

9.7 Cambio a los signos de los coeficientes de Z_1

```
Z1b=-Z1a  
var(Z1b)
```

```
## [1] 4.323642
```

Nota: Recuerde que la varianza es la misma ya que las constantes salen al cuadrado, por lo que el menos que le incluimos se le anula.

10 Biplot

Este es el código para hacer el gráfico normal


```
biplot(pca1, cex=0.6)
```

El gráfico que se le presenta a continuación fue arreglado para términos de presentación y explicación

```
## Warning: package 'factoextra' was built under R version 4.5.3
```

```
## Welcome to factoextra!
```

```
## Want to learn more? See two factoextra-related books at https://www.datanovia.com/library/principal-
```



Del gráfico podemos notar que la participante Joyner-Kersee (USA) tienen a tener puntajes altos por ello se ubica en esa posición. Por otro lado está la participante Geremias (BRA), esta posicionada al otro lado completamente de la participamos anteriormente, dicha posición es resultado de que a la participante

Geremias (BRA) no le fue tan bien en las tres flechas que van en esa dirección (vallas, saltolargo y saltolargo).

Se puede observar que todas las flechas van hacia la izquierda debido a que su signo es negativo. Además, se puede ver que las que pesan más en el primer componente son aquellas que tienen una flecha más larga, por ejemplo en el gráfico anterior javalina es la que tiene una menor longitud en la flecha debido a que el peso de este es menor que el de las demás variables. Por otro lado, las que más pesan como habíamos visto anteriormente son vallas, saltolargo y saltolargo, estas mismas están agrupadas en este gráfico.

Para el segundo componente primero debemos observar el siguiente vector propio:

```
a2=pca1$rot[,2]
round(a2,2)
```

##	vallas	saltoalto	tiro	car200	saltolargo	javalina	car800
##	0.06	-0.65	-0.02	0.19	-0.02	-0.33	0.66

Note que para este caso las que tiene más peso son las variables saltoalto y car800, por esta razón estos son los que tiene una flecha de mayor tamaño con respecto al eje vertical. Además note que el signo de car800 es positivo, por eso es que la flecha tiene una dirección hacia arriba.

Un aspecto importante a resaltar de la participante Brown (USA), es que le fue mejor en saltoalto que en car800, mientras que en vallas, saltolargo y saltolargo está en el promedio, en el otro extremo del gráfico la participante Bouraga (URS), le fue de manera intermedia (o se encuentra en el promedio) en las otras variables, pero le fue mucho mejor en car800 en comparación con saltoalto.


10.1 Biplot categórico

```
library(AMR)
```

```
## Warning: package 'AMR' was built under R version 4.5.3
```

```
library(dplyr)
data=data.frame(c("AM","EU","EU","EU","EU","EU","OC","AM","EU",
                  "EU","EU","EU","EU","EU","EU","AS","EU","AM",
                  "EU","EU","EU","AM","AS","AS"),row.names(base2),base2)
names(data)=c("Continente","Nombre",names(base2))
pca2=data %>%
  pca(vallas,saltoalto,tiro,car200,saltolargo,javalina,car800)
```


```
ggplot_pca(pca2)
```



11 Gráfico de sedimentación

este gráfico nos sirve para ver como va bajando la varianza explicada de cada componente

```
plot(pca1, type="l")
```



Para este gráfico puede usar `plot(pca$sdev^2)` o `plot(pca)`

El criterio usando el gráfico dice que se deben escoger la cantidad de componentes antes de que caiga abruptamente la variabilidad, en este caso solo podríamos escoger uno, ya que en el gráfico anterior después del primer valor la varianza se desploma.

Cuándo usamos los porcentajes la idea es que el PCA siempre represente al menos un 80% de la variabilidad, para este caso tenemos el siguiente resultado.

```
sum(lambda1[1:3])/length(lambda1)
```

```
## [1] 0.8646255
```

Usaríamos tres componentes en lugar de uno, lo que pasa es que con dos componente no puedo lograr el objetivo de hacer los gráfico más fácil.

Si un componente tiene una varianza menor a uno, no se justifica incluirlo ya que una variable explica más que un componente, debido a que las variables como están estandarizadas tienen varianza 1. Normalmente esto ocurre porque las variables no se están tan correlacionadas entre sí.

11.0.1 Conclusión de estudio

Debido a que según el gráfico solo debemos quedarnos con un componente y con el criterio del porcentaje con tres componentes, lo cual no nos sirve para el análisis, por lo que aplicar PCA para este estudio no fue satisfactorio.

11.1 Reproducción de la matriz de correlaciones

Usando todos los componentes.


```
A=pca1$rot
L=diag(pca1$sdev**2)
R1=A%*%L%*%t(A)
round(R1,2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.58 0.77  0.83      0.89      0.33  0.56
## saltoalto    0.58      1.00 0.46  0.39      0.66      0.35  0.15
## tiro         0.77      0.46 1.00  0.67      0.78      0.34  0.41
## car200       0.83      0.39 0.67  1.00      0.81      0.47  0.57
## saltolargo   0.89      0.66 0.78  0.81      1.00      0.29  0.52
## javalina     0.33      0.35 0.34  0.47      0.29      1.00  0.26
## car800       0.56      0.15 0.41  0.57      0.52      0.26  1.00
```

Verificación

```
round(R,2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.58 0.77  0.83      0.89      0.33  0.56
## saltoalto    0.58      1.00 0.46  0.39      0.66      0.35  0.15
## tiro         0.77      0.46 1.00  0.67      0.78      0.34  0.41
## car200       0.83      0.39 0.67  1.00      0.81      0.47  0.57
## saltolargo   0.89      0.66 0.78  0.81      1.00      0.29  0.52
## javalina     0.33      0.35 0.34  0.47      0.29      1.00  0.26
## car800       0.56      0.15 0.41  0.57      0.52      0.26  1.00
```

```
round(abs(R1-R),10)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      0          0  0      0          0          0  0
## saltoalto    0          0  0      0          0          0  0
## tiro         0          0  0      0          0          0  0
## car200       0          0  0      0          0          0  0
## saltolargo   0          0  0      0          0          0  0
## javalina     0          0  0      0          0          0  0
## car800       0          0  0      0          0          0  0
```

Ahora con sólo dos componentes obtenemos una predicción de R y vea las discrepancias. Para facilidad vea las discrepancias con solo un decimal.

```
A2=pca1$rot[,1:2]
L2=diag(lambda1[1:2])
R2=A2%*%L2%*%t(A2)
round(R2-R,1)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas     -0.1      0.0 0.0      0.0      0.0      0.1  0.1
## saltoalto   0.0     -0.2 0.1      0.1      0.0      0.2 -0.1
## tiro        0.0      0.1 -0.3  0.1      0.0      0.1  0.1
## car200       0.0      0.1 0.1     -0.2      0.0     -0.1  0.1
## saltolargo   0.0      0.0 0.0      0.0     -0.1      0.2  0.1
## javalina     0.1      0.2 0.1     -0.1      0.2     -0.7 -0.1
## car800       0.1     -0.1 0.1      0.1      0.1     -0.1 -0.2
```

- Haga lo mismo con tres componentes y decida si vale la pena usar 3 componentes.

```
A3=pca1$rot[,1:3]
L3=diag(lambda1[1:3])
R3=A3%*%L3%*%t(A3)
round(R3-R,1)

##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      -0.1      0.0  0.0   0.0      0.0      0   0.0
## saltoalto    0.0     -0.2  0.1   0.1      0.0      0  -0.2
## tiro         0.0      0.1 -0.3   0.1      0.0      0   0.1
## car200        0.0      0.1  0.1  -0.2      0.0      0   0.1
## saltolargo    0.0      0.0  0.0   0.0     -0.1      0   0.0
## javalina      0.0      0.0  0.0   0.0      0.0      0   0.0
## car800        0.0     -0.2  0.1   0.1      0.0      0  -0.2
```

11.2 Obtención de correlaciones

Obtenemos la correlación entre cada variable original y Z1a.

```
cor(base2,Z1a)

##          [,1]
## vallas     -0.9365076
## saltoalto  -0.6539754
## tiro       -0.8369090
## car200     -0.8880557
## saltolargo -0.9377059
## javalina   -0.5038399
## car800     -0.6298453
```

Obtenemos las correlaciones a partir del primer valor propio y el primer vector propio. Compare los resultados.

```
a1=sqrt(lambda1[1]) # a1 es el primer vector propio

##          vallas saltoalto      tiro      car200 saltolargo  javalina      car800
## -0.9365076 -0.6539754 -0.8369090 -0.8880557 -0.9377059 -0.5038399 -0.6298453
```

12 Prueba de los componentes en una regresión

```
Z1=pca1$x[,1]
Z2=pca1$x[,2]
Y=base1$puntaje
mod=lm(Y~Z1+Z2)
summary(mod)

##
## Call:
## lm(formula = Y ~ Z1 + Z2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -233.905   -7.667    3.637   25.755   88.441
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6154.125     11.981  513.665  <2e-16 ***
```

```
## Z1          -230.017      5.886 -39.080  <2e-16 ***
## Z2           6.373      12.908   0.494   0.627
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 58.69 on 21 degrees of freedom
## Multiple R-squared:  0.9864, Adjusted R-squared:  0.9851
## F-statistic: 763.8 on 2 and 21 DF,  p-value: < 2.2e-16
```

Observe que Z1 es significativo y Z2 no es significativo, recuerde que estos son variables así que puede ser que los resultados sean muy distintos para otros estudios.

12.1 Forma automática

```
step(mod)

## Start:  AIC=198.27
## Y ~ Z1 + Z2
##
##           Df Sum of Sq      RSS      AIC
## - Z2       1         840    73184 196.54
## <none>                        72344 198.27
## - Z1       1    5261348 5333693 299.48
##
## Step:  AIC=196.54
## Y ~ Z1
##
##           Df Sum of Sq      RSS      AIC
## <none>                        73184 196.54
## - Z1       1    5261348 5334533 297.48
##
## Call:
## lm(formula = Y ~ Z1)
##
## Coefficients:
## (Intercept)          Z1
##          6154         -230
```

12.2 Interpretaciones de regresión

Tenemos esta ecuación resultante del modelo anterior:

$$\hat{y} = 6154.13 - 230.02(-0.45*vallas - 0.31*salto\ alto - 0.4*Tiro - 0.43*car200 - 0.45*salto\ largo + 0.24*javalina - 0.3*car800)$$

Multiplicamos los coeficientes de Z_1 , por el coeficiente de Z_1

```
a = c(-0.45, -0.31, -0.40, -0.43, -0.45, 0.24, -0.3)
-230.02*a
```

```
## [1] 103.5090  71.3062  92.0080  98.9086 103.5090 -55.2048  69.0060
```

$$\hat{y} = 6154.13 + 103.54\ vallas^s + 71.03*salto\ alto^s + 92*Tiro^s + 98.9*car200^s + 103.5*salto\ largo^s - 55.2*javalina^s + 69*car800^s$$

Obtenemos la desviación estándar de vallas

```
sd(base1$vallas)
```

```
## [1] 0.514564
```

Para este caso las X 's estaban estandarizadas, pero la Y no entonces la interpretación tiene la siguiente estructura:

Por un aumento de 1 desviación estándar en la variable X_j , la respuesta promedio Y (aumenta/disminuye) en promedio β_j^s unidades, manteniendo constantes los demás predictores

Aplicando esa estructura a el ejemplo nos quedaría así:

Por una disminución (esto es por contexto) de 0.51 segundos en la Vallas, la respuesta promedio aumenta.

Recordar que las variables que se le dieron vuelta fueron **vallas**, **car200** y **car800**.

Nota: El objetivo de PCA no es siempre hacer una regresión.

13 Conglomerados

13.1 Distancias entre individuos

Dadas los valores de las variables para los individuos i -ésimo y j -ésimo, interesa tener una medida de la distancia multidimensional entre esos dos individuos.

Si se cuenta con n individuos, la matriz de distancias es de tamaño $n \times n$, con ceros en la diagonal, esto independientemente de q (número de variables).

A continuación se le presenta un ejemplo de la matriz de distancias

$$D = \begin{pmatrix} 0 & d_{12} & \cdots & d_{1n} \\ d_{21} & 0 & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & 0 \end{pmatrix}$$

La distancia es un concepto opuesto al de similitud, entre mayor similitud exista entre dos sujetos, menor es la distancia entre ellos y viceversa.

13.2 Distancia Euclídea

La distancia más común es la Euclídea, definida por:

$$d_{ij} = \sqrt{\sum_{k=1}^q (x_{ik} - x_{jk})^2} = \sqrt{(X_i - X_j)^T (X_i - X_j)}$$

donde x_{ik} es el valor que toma el i -ésimo sujeto en la k -ésima variable, y X_i es el vector de q valores del i -ésimo sujeto: $X_i^T = (x_{i1}, \dots, x_{ik}, \dots, x_{iq})$.

En dos dimensiones, es la medida de la hipotenusa del triángulo rectángulo que se forma a partir de los dos puntos que se están comparando.

El cuadrado de la distancia Euclídea (d_{ij}^2) es otra medida de distancia que se puede usar en algunas ocasiones.

$$d_{ij}^2 = \sum_{k=1}^q (x_{ik} - x_{jk})^2$$


Ejemplo aplicado

Tenemos los siguientes datos tomados en el momento de la clase

id	Peso	Estatura (metros)	Edad
1	94	1.73	23.40
2	84	1.74	21.90
3	60	1.58	21.60
4	85	1.78	20.04
5	71	1.66	25.30

Distancias Euclidianas entre Observaciones

Descomposición geométrica de la distancia mediante diferencias ortogonales



Cáculamos las distancias entre los puntos

$$\begin{aligned}
d(1, 2) &= \sqrt{(94 - 84)^2 + (1.73 - 1.74)^2} = \sqrt{10^2 + (-0.01)^2} = \sqrt{100.0001} \approx 10.0000 \\
d(1, 3) &= \sqrt{(94 - 60)^2 + (1.73 - 1.58)^2} = \sqrt{34^2 + 0.15^2} = \sqrt{1156.0225} \approx 34.0003 \\
d(1, 4) &= \sqrt{(94 - 85)^2 + (1.73 - 1.78)^2} = \sqrt{9^2 + (-0.05)^2} = \sqrt{81.0025} \approx 9.0001 \\
d(1, 5) &= \sqrt{(94 - 71)^2 + (1.73 - 1.66)^2} = \sqrt{23^2 + 0.07^2} = \sqrt{529.0049} \approx 23.0001 \\
\\
d(2, 3) &= \sqrt{(84 - 60)^2 + (1.74 - 1.58)^2} = \sqrt{24^2 + 0.16^2} = \sqrt{576.0256} \approx 24.0005 \\
d(2, 4) &= \sqrt{(84 - 85)^2 + (1.74 - 1.78)^2} = \sqrt{(-1)^2 + (-0.04)^2} = \sqrt{1.0016} \approx 1.0008 \\
d(2, 5) &= \sqrt{(84 - 71)^2 + (1.74 - 1.66)^2} = \sqrt{13^2 + 0.08^2} = \sqrt{169.0064} \approx 13.0002 \\
\\
d(3, 4) &= \sqrt{(60 - 85)^2 + (1.58 - 1.78)^2} = \sqrt{(-25)^2 + (-0.20)^2} = \sqrt{625.0400} \approx 25.0008 \\
d(3, 5) &= \sqrt{(60 - 71)^2 + (1.58 - 1.66)^2} = \sqrt{(-11)^2 + (-0.08)^2} = \sqrt{121.0064} \approx 11.0003 \\
\\
d(4, 5) &= \sqrt{(85 - 71)^2 + (1.78 - 1.66)^2} = \sqrt{14^2 + 0.12^2} = \sqrt{196.0144} \approx 14.0005
\end{aligned}$$

Podemos ver que la diferencias entre el peso en kilogramos, tiene mayor importancia al momneto de hacer el cálculo, para solucionar este problema lo idea el estandarizar las variables.

```
# Si no tienes ggforce instalado: install.packages("ggforce")
library(ggplot2)
library(ggforce)
```

```
## Warning: package 'ggforce' was built under R version 4.5.3
```

```
# 1. Definición del conjunto de datos con asignación de conglomerados/grupos
datos <- data.frame(
  id = factor(1:5),
  Peso = c(94, 84, 60, 85, 71),
  Estatura = c(1.73, 1.74, 1.58, 1.78, 1.66),
  Grupo = factor(c("Grupo A (Pesados / Altos)",
                    "Grupo A (Pesados / Altos)",
                    "Grupo C (Bajo)",
                    "Grupo A (Pesados / Altos)",
                    "Grupo B (Medio)"))
)

# 2. Construcción del gráfico con elipses/círculos envolventes
ggplot(datos, aes(x = Peso, y = Estatura)) +
  # Encerrar los grupos con elipses suaves y sombreado
  geom_mark_ellipse(
    aes(group = Grupo, fill = Grupo, color = Grupo, label = Grupo),
    expand = unit(5, "mm"),
    alpha = 0.12,
    linewidth = 0.9,
    linetype = "dashed",
    show.legend = FALSE,
    label.fontsize = 9.5,
    label.fontface = "bold"
  ) +
```

```

# Puntos observados
geom_point(aes(color = Grupo), size = 4.5) +

# Paleta de colores para los grupos
scale_color_manual(values = c("Grupo A (Pesados / Altos)" = "#2980b9",
                              "Grupo B (Medio)" = "#27ae60",
                              "Grupo C (Bajo)" = "#e67e22")) +
scale_fill_manual(values = c("Grupo A (Pesados / Altos)" = "#3498db",
                              "Grupo B (Medio)" = "#2ecc71",
                              "Grupo C (Bajo)" = "#f39c12")) +


# Límites centrados en los datos
coord_cartesian(
  xlim = c(min(datos$Peso) - 5, max(datos$Peso) + 6),
  ylim = c(min(datos$Estatura) - 0.03, max(datos$Estatura) + 0.05)
) +
scale_x_continuous(breaks = seq(55, 100, by = 5)) +
scale_y_continuous(breaks = seq(1.55, 1.85, by = 0.05)) +

labs(
  title = "Agrupamiento de Observaciones por Proximidad Euclidiana",
  subtitle = "Identificación visual de conglomerados naturales entre Peso y Estatura",
  x = "Peso (kg)",
  y = "Estatura (metros)"
) +
theme_minimal(base_size = 12) +
theme(
  plot.title = element_text(face = "bold", hjust = 0.5),
  plot.subtitle = element_text(hjust = 0.5, color = "gray30", margin = margin(b = 10)),
  panel.grid.minor = element_blank()
)

```

Mapamiento de Observaciones por Proximidad Euclidiana

Visualización de conglomerados naturales entre Peso y Estatura



13.3 Distancia de Mahalanobis

Esta medida de distancia incluye un procedimiento de estandarización dentro de la distancia Euclídea.

No sólo hace una estandarización en los datos escalándolos en términos de su desviación estándar sino que ajusta según las correlaciones entre variables:

$$d_{ij}^M = \sqrt{(X_i - X_j)^T S^{-1} (X_i - X_j)}$$

donde S es la matriz de covariancias de dimensión $q \times q$

Es invariante frente a transformaciones lineales de las variables.

Toma en cuenta las correlaciones entre variables.

No aumenta por el simple hecho de aumentar el número de variables, sino que aumentará cuando las nuevas variables den nueva información.

Aplicación basada en el ejemplo anterior

$$\begin{aligned}
d_{35}^M &= \sqrt{(X_3 - X_5)^\top \mathbf{S}^{-1} (X_3 - X_5)} \\
&= \sqrt{(60 - 71 \quad 1.58 - 1.66) \begin{bmatrix} 177.7000 & 0.9320 \\ 0.9320 & 0.00622 \end{bmatrix}^{-1} \begin{pmatrix} 60 - 71 \\ 1.58 - 1.66 \end{pmatrix}} \\
&= \sqrt{(-11 \quad -0.08) \begin{bmatrix} 0.0263 & -3.9380 \\ -3.9380 & 750.8345 \end{bmatrix} \begin{pmatrix} -11 \\ -0.08 \end{pmatrix}} \\
&= \sqrt{(0.0259 \quad -16.7491) \begin{pmatrix} -11 \\ -0.08 \end{pmatrix}} \\
&= \sqrt{(-11)(0.0259) + (-0.08)(-16.7491)} \\
&= \sqrt{-0.2849 + 1.3399} \\
&= \sqrt{1.0550} \approx \mathbf{1.0269}
\end{aligned}$$

```

X <- as.matrix(datos[, c("Peso", "Estatura")])
n <- nrow(X)
S <- cov(X)
S_inv <- solve(S)

# Matriz de distancias de Mahalanobis par a par
D_M <- matrix(0, nrow = n, ncol = n)
for (i in 1:n) {
  for (j in 1:n) {
    diff <- X[i, ] - X[j, ]
    D_M[i, j] <- sqrt(t(diff) %*% S_inv %*% diff)
  }
}
rownames(D_M) <- colnames(D_M) <- paste0("id_", 1:5)

print("Matriz de Distancias de Mahalanobis (pares):")

```

```

## [1] "Matriz de Distancias de Mahalanobis (pares):"
print(round(D_M, 4))

```

```

##      id_1 id_2 id_3 id_4 id_5
## id_1 0.0000 1.8684 2.6660 2.7477 2.2140
## id_2 1.8684 0.0000 2.0287 0.9553 1.0276
## id_3 2.6660 2.0287 0.0000 2.6607 1.0269
## id_4 2.7477 0.9553 2.6607 0.0000 1.6527
## id_5 2.2140 1.0276 1.0269 1.6527 0.0000

```

Verifique la distancia d_{35}^M es 1.0269

13.4 Distancia City-block (Manhattan)

En esta medida se usa el valor absoluto de las diferencias en lugar de su cuadrado:

$$d_{ij}^{(1)} = \sum_{k=1}^q |x_{ik} - x_{jk}|$$

El nombre nace de la idea de moverse en una ciudad como Manhattan pues, aunque la distancia más corta sería la Euclídea, ésta implica pasar a través de los edificios, mientras que esta distancia asemeja a caminar por las aceras para llegar de un punto a otro.

Es más robusta que la distancia euclídea debido a que no eleva al cuadrado las diferencias.

Tiene la restricción de que asume que las variables no están correlacionadas.

Aplicación basada en el ejemplo anterior

$$\begin{aligned} d(1,2) &= |94 - 84| + |1.73 - 1.74| = 10 + 0.01 = \mathbf{10.01} \\ d(1,3) &= |94 - 60| + |1.73 - 1.58| = 34 + 0.15 = \mathbf{34.15} \\ d(1,4) &= |94 - 85| + |1.73 - 1.78| = 9 + 0.05 = \mathbf{9.05} \\ d(1,5) &= |94 - 71| + |1.73 - 1.66| = 23 + 0.07 = \mathbf{23.07} \\ d(2,3) &= |84 - 60| + |1.74 - 1.58| = 24 + 0.16 = \mathbf{24.16} \\ d(2,4) &= |84 - 85| + |1.74 - 1.78| = 1 + 0.04 = \mathbf{1.04} \\ d(2,5) &= |84 - 71| + |1.74 - 1.66| = 13 + 0.08 = \mathbf{13.08} \\ d(3,4) &= |60 - 85| + |1.58 - 1.78| = 25 + 0.20 = \mathbf{25.20} \\ d(3,5) &= |60 - 71| + |1.58 - 1.66| = 11 + 0.08 = \mathbf{11.08} \\ d(4,5) &= |85 - 71| + |1.78 - 1.66| = 14 + 0.12 = \mathbf{14.12} \end{aligned}$$

Aplicación en r

```
# Distancia de Manhattan para Peso y Estatura
D_manhattan_2v <- dist(datos[, c("Peso", "Estatura")], method = "manhattan")
print(as.matrix(round(D_manhattan_2v, 2)))
```

```
##      1      2      3      4      5
## 1  0.00 10.01 34.15  9.05 23.07
## 2 10.01  0.00 24.16  1.04 13.08
## 3 34.15 24.16  0.00 25.20 11.08
## 4  9.05  1.04 25.20  0.00 14.12
## 5 23.07 13.08 11.08 14.12  0.00
```

```
# Distancia de Manhattan completa (3 variables)
D_manhattan_3v <- dist(datos, method = "manhattan")
print(as.matrix(round(D_manhattan_3v, 2)))
```

```
##      1      2      3      4      5
## 1  0.00 14.68 48.20 16.07 36.09
## 2 14.68  0.00 33.55  4.05 21.44
## 3 48.20 33.55  0.00 34.93 17.44
## 4 16.07  4.05 34.93  0.00 20.16
## 5 36.09 21.44 17.44 20.16  0.00
```

13.4.1 Nota importante de las distancias

Puede ser que usando algunos de los métodos, las agrupaciones que se estén realizando, por lo que dependiendo del caso se debe escoger el tipo de distancia que tenga más sentido. De modo que los grupos sean muy parecidos dentro de ellos, pero muy desiguales entre los grupos existentes.