

# Manual para el curso Minería de Datos y Análisis Multivariado (XS-0126)

**Autor:** Anderson Martínez

**Colaboradores:** Sebastián Calvo, Justin Zhu, Fabián Almirall

## Contents

|          |                                                                  |          |
|----------|------------------------------------------------------------------|----------|
| <b>1</b> | <b>Aprendizaje supervisado</b>                                   | <b>1</b> |
| <b>2</b> | <b>Aprendizaje no supervisado</b>                                | <b>1</b> |
| <b>3</b> | <b>Diferencia entre aprendizaje supervisado y no supervisado</b> | <b>2</b> |
| <b>4</b> | <b>Características del aprendizaje no supervisado</b>            | <b>2</b> |
| <b>5</b> | <b>Proceso de Análisis de componentes principales (PCA)</b>      | <b>5</b> |
| 5.1      | Maldición de la dimensionalidad . . . . .                        | 6        |
| 5.2      | Requisitos para que PCA tenga sentido . . . . .                  | 6        |
| 5.3      | Ejemplo de aplicación . . . . .                                  | 6        |

## 1 Aprendizaje supervisado

Se aprenden funciones, relaciones que asocian entradas con salidas, por lo que se ajustan a un conjunto de ejemplos de los que conocemos la relación entre la entrada y la salida deseada.

Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre:

- Modelos de clasificación, si la salida es un valor categórico (por ejemplo, una enumeración, o un conjunto finito de clases).
- Modelos de regresión, si la salida es un valor de un espacio continuo.

## 2 Aprendizaje no supervisado

No estamos interesados en ajustar pares (entrada, salida), sino en aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros que provengan del mismo fenómeno), por ejemplo:

- Dando una agrupación de los datos según su similitud.
- Simplificando la estructura de los mismos manteniendo sus características fundamentales (como en los procesos de reducción de la dimensionalidad).
- Extrayendo la estructura interna con la que se distribuyen los datos en su espacio original (aprendizaje topológico).

### 3 Diferencia entre aprendizaje supervisado y no supervisado

El aprendizaje supervisado tiene variable respuesta  $Y$ , mientras que el aprendizaje no supervisado no la tiene. Además es importante resaltar que el no supervisado es más descriptivo.

### 4 Características del aprendizaje no supervisado

- No existe una salida o variable respuesta, por lo que no se utiliza un modelo que relacione un conjunto de variables con una respuesta.
- Esto hace que sea difícil validar los resultados, al contrario del aprendizaje supervisado en el que existen métricas que permiten evaluar con claridad la bondad del aprendizaje realizado.
- Es parte de un análisis exploratorio de datos.
- Algoritmos no supervisados resultan ser muy costosos porque requieren de más pruebas de ensayo y error, haciendo que requieran de un aparatado teórico y computacional mucho más elaborado.

#### Ejemplo 1

Suponga que tiene la siguiente regresión:

$$\mu_{y|x} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_{p-1} X_{p-1}$$

Recuerde que  $\mu_{y|x}$  es la respuesta

Se tiene el siguiente subconjunto de  $X$ 's:

$$X_1, \dots, X_k \text{ Altamente Correlacionadas}$$

**Nota:** Cuando las  $X$ 's están muy correlacionadas hay problemas de multicolinealidad y eso nos infla los errores estándar.

Note que este conjunto de variable es de dimensión  $k$ , esto lo que nos dice en realidad es que estas  $X$ 's miden un subconjunto menor de conceptos, lo que nos lleva al siguiente conjunto:

$$Z_1, \dots, Z_q$$

Donde  $q < k$  (No Correlacionadas)

Reemplazando en el modelo original tenemos el siguiente resultado:

$$\mu_{y|x,z} = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \dots + \beta_q Z_q + \beta_{k+1} X_{k+1}$$

En este modelo la primera parte es no supervisado ya que no utilizamos la variable respuesta, para el último modelo obtenido si es supervisado ya que se utiliza con la variable respuesta.


#### Ejemplo 2

1. Se tienen  $X_1, \dots, X_p$  Grupos
2. Formo  $k$  grupos
3. Se crea una variable  $G$ , la cual se crea a partir del aprendizaje no supervisado. Ya que se crea basado en las  $X$ 's

| Observación ( $i$ ) | $X_1$    | $X_2$    | $\dots$  | $X_p$    | $G = f(X_1, \dots, X_p)$ |
|---------------------|----------|----------|----------|----------|--------------------------|
| 1                   | $x_{11}$ | $x_{12}$ | $\dots$  | $x_{1p}$ | $g_1$                    |
| 2                   | $x_{21}$ | $x_{22}$ | $\dots$  | $x_{2p}$ | $g_2$                    |
| $\vdots$            | $\vdots$ | $\vdots$ | $\ddots$ | $\vdots$ | $\vdots$                 |
| $i$                 | $x_{i1}$ | $x_{i2}$ | $\dots$  | $x_{ip}$ | $g_i$                    |
| $\vdots$            | $\vdots$ | $\vdots$ | $\ddots$ | $\vdots$ | $\vdots$                 |
| $n$                 | $x_{n1}$ | $x_{n2}$ | $\dots$  | $x_{np}$ | $g_n$                    |

*Nota:* Si agregamos una variable edad, podríamos realizar un análisis de varianza, ya que dicha variable funcionaría como una variable respuesta.

### Distribución de Edad por Grupo



### Ejemplo 3

| Observación ( $i$ ) | Altura (cm) | N.º de Hojas | Grosor del Tallo (mm) | Peso del Racimo (kg) | pH del Suelo |
|---------------------|-------------|--------------|-----------------------|----------------------|--------------|
| 1                   | 24.5        | 6            | 3.2                   | 0.45                 | 5.4          |
| 2                   | 28.1        | 7            | 3.8                   | 0.58                 | 5.6          |
| 3                   | 31.4        | 8            | 4.1                   | 0.65                 | 5.5          |
| 4                   | 52.6        | 14           | 7.5                   | 1.85                 | 6.1          |
| 5                   | 58.0        | 15           | 8.2                   | 2.10                 | 6.3          |
| 6                   | 61.3        | 17           | 8.9                   | 2.40                 | 6.2          |
| 7                   | 84.7        | 22           | 12.4                  | 4.15                 | 6.8          |

| Observación (i) | Altura (cm) | N.º de Hojas | Grosor del Tallo (mm) | Peso del Racimo (kg) | pH del Suelo |
|-----------------|-------------|--------------|-----------------------|----------------------|--------------|
| 8               | 89.2        | 25           | 13.1                  | 4.60                 | 7.0          |

Note que la Altura (cm), N.º de Hojas, Grosor del Tallo (mm), Peso del Racimo (kg) están muy correlacionadas, mientras que el H del Suelo no tanto.

Con esas variables correlacionadas puede crear una variable  $Z_1$

```
library(ggplot2)
library(dplyr)
# 1. Definir los datos de la tabla (8 observaciones)
datos <- data.frame(
  obs      = 1:8,
  altura   = c(24.5, 28.1, 31.4, 52.6, 58.0, 61.3, 84.7, 89.2),
  hojas    = c(6, 7, 8, 14, 15, 17, 22, 25),
  grosor   = c(3.2, 3.8, 4.1, 7.5, 8.2, 8.9, 12.4, 13.1),
  peso     = c(0.45, 0.58, 0.65, 1.85, 2.10, 2.40, 4.15, 4.60),
  ph_suelo = c(5.4, 5.6, 5.5, 6.1, 6.3, 6.2, 6.8, 7.0)
)


# 2. Extracción de Z_1 como el Primer Componente Principal (CP1 estandarizado)
# Z_1 captura la mayor parte de la variabilidad conjunta del crecimiento/rendimiento
pca_morfologia <- prcomp(
  datos[, c("altura", "hojas", "grosor", "peso")],
  center = TRUE,
  scale. = TRUE
)

# Asignar los scores de Z_1 al dataframe
datos$Z1 <- pca_morfologia$x[, 1]

# 3. Scatterplot con ggplot2
ggplot(datos, aes(x = ph_suelo, y = Z1)) +
  geom_point(color = "#1f77b4", size = 4, alpha = 0.9) +
  geom_smooth(method = "lm", se = TRUE, color = "#d62728", linetype = "dashed", fill = "#e0e0e0", alpha = 0.5) +
  labs(
    title = expression(bold("Diagrama de Dispersión:") ~ bolditalic(Z)[1] ~ bold("vs. pH del Suelo")),
    subtitle = expression(italic(Z)[1] ~ "construida como el primer componente principal (" * CP[1] * ")"),
    x = "pH del Suelo",
    y = expression(italic(Z)[1] ~ "(Índice Morfológico /" ~ CP[1] * ")")
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold", hjust = 0.5),
    plot.subtitle = element_text(hjust = 0.5, color = "gray35", margin = margin(b = 10)),
    axis.title = element_text(face = "bold"),
    panel.grid.minor = element_blank()
  )
```

## Diagrama de Dispersión: $Z_1$ vs. pH del Suelo

$Z_1$  construida como el primer componente principal ( $CP_1$ )



## 5 Proceso de Análisis de componentes principales (PCA)

$$\mu_{y|x_1, x_2, x_3, x_4} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4$$

Suponga que  $X_2, X_3, X_4$  están muy correlacionadas, para ello se crea una variable  $Z_1$ .

$$\mu_{y|x_1, z_1} = \beta_0 + \beta_1 X_1 + \gamma_1 Z_1$$

Sin embargo, como pasamos de tres variables ( $X_2, X_3, X_4$ ) a una ( $Z_1$ ) perdemos cierta información. Es decir  $Z_1$  explica un cierto porcentaje de ( $X_2, X_3, X_4$ ). Por ejemplo  $Z_1$  explica un 80% de ( $X_2, X_3, X_4$ ).

Se puede dar el caso que  $Z_1$  no explique suficiente.

Existe otro modelo que puede explicar más que el siguiente:

$$\mu_{y|x_1, x_3} = \beta_0 + \beta_1 X_1 + \beta_3 X_3$$

*Nota:* Es importante resaltar que los tres modelos anteriores no son lo mismo, cada uno tiene sus ventajas y desventajas.

El PCA sirva para eliminar la multicolinealidad, solo si lo queremos usar para una regresión. Otro uso que se le puede dar es para obtener gráficos más simples.

## 5.1 Maldición de la dimensionalidad

- Cuando se cuenta con demasiadas variables es difícil hacer un análisis gráfico para tener una idea inicial del comportamiento de los datos.
- Muchas variables son un obstáculo para aplicar otras técnicas multivariadas.

## 5.2 Requisitos para que PCA tenga sentido

- Si las variables originales casi no están correlacionadas, nada se gana al llevar a cabo un PCA.
- Cuando el determinante de una matriz es cero, se tiene que hay columnas linealmente dependientes. Esto se llama multicolinealidad.
- Si el determinante de la matriz de correlación (R) es cercano a cero, hay indicación de altas correlaciones entre las variables, de lo contrario, cuando el determinante es alto un PCA puede no tener sentido.

## 5.3 Ejemplo de aplicación

Se tienen los siguientes datos

| Observación ( <i>i</i> ) | $X_1$ | $X_2$ | $X_3$ | $X_4$ |
|--------------------------|-------|-------|-------|-------|
| 1                        | 3     | 4     | 2     | 5     |
| 2                        | 5     | 1     | 1     | 3     |
| 3                        | 4     | 3     | 3     | 2     |
| 4                        | 2     | 7     | 4     | 0     |
| $\bar{X} \rightarrow$    | 3.6   | 3.75  | 2.5   | 2.5   |
| $S \rightarrow$          | 1.24  | 2.5   | 1.24  | 2.05  |

Luego estandarizamos mediante la siguiente fórmula:

$$X_i = \frac{X_i - \bar{X}}{S_i}$$

```
# 1. Definición de la matriz de datos X (4 observaciones x 4 variables)
X <- matrix(
  c(
    3, 4, 2, 5,
    5, 1, 1, 3,
    4, 3, 3, 2,
    2, 7, 4, 0
  ),
  nrow = 4,
  byrow = TRUE,
  dimnames = list(paste0("ID_", 1:4), paste0("X", 1:4))
)

# 2. Visualizar resultados
print("Matriz Original X:")

## [1] "Matriz Original X:"
```

```

print(X)

##      X1 X2 X3 X4
## ID_1  3  4  2  5
## ID_2  5  1  1  3
## ID_3  4  3  3  2
## ID_4  2  7  4  0

# 2. Estandarización con scale()
# scale() por defecto resta la media muestral (center = TRUE)
# y divide entre la desviación estándar muestral s con n-1 grados de libertad (scale = TRUE)
Z <- scale(X, center = TRUE, scale = TRUE)
print("Matriz Estandarizada Z (Z-scores):")

## [1] "Matriz Estandarizada Z (Z-scores):"

print(round(Z, 4))

##      X1  X2  X3  X4
## ID_1 -0.3873  0.1 -0.3873  1.2010
## ID_2  1.1619 -1.1 -1.1619  0.2402
## ID_3  0.3873 -0.3  0.3873 -0.2402
## ID_4 -1.1619  1.3  1.1619 -1.2010
## attr("scaled:center")
##      X1  X2  X3  X4
## 3.50 3.75 2.50 2.50
## attr("scaled:scale")
##      X1      X2      X3      X4
## 1.290994 2.500000 1.290994 2.081666

```

**Interpretación** El ID\_4 en  $X_1$  está 1.16 desviaciones estándar debajo la media (recuerde que la desviación estándar de  $X_1$  es 1.29). Para el ID\_1 está 0.1 desviaciones estándar sobre la media, es decir está prácticamente en la media.

*Nota:* El máximo de desviaciones estándar en una normal son 3 que son el 99.7% de los datos.

Luego obtenemos los coeficientes para  $Z_1$  y hacemos la siguiente regresión:

$$Z_1 = 0.2X_1^s + 0.4X_2^s + 0.01X_3^s + 0.5X_4^s$$

*Nota:* En regresión estandarizabamos los coeficientes para poder compararlos en este caso, estandarizamos y la que tiene más peso en el resultado de  $Z_1$  es  $X_4$

Luego sustituimos con los valores que tenemos

$$\begin{aligned}
 Z_1^{(1)} &= 0.2(-0.39) + 0.4(0.10) + 0.01(-0.39) + 0.5(1.20) \\
 &= -0.078 + 0.040 - 0.0039 + 0.600 = \mathbf{0.5581}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(2)} &= 0.2(1.16) + 0.4(-1.10) + 0.01(-1.16) + 0.5(0.24) \\
 &= 0.232 - 0.440 - 0.0116 + 0.120 = \mathbf{-0.0996}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(3)} &= 0.2(0.39) + 0.4(-0.30) + 0.01(0.39) + 0.5(-0.24) \\
 &= 0.078 - 0.120 + 0.0039 - 0.120 = \mathbf{-0.1581}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(4)} &= 0.2(-1.16) + 0.4(1.30) + 0.01(1.16) + 0.5(-1.20) \\
 &= -0.232 + 0.520 + 0.0116 - 0.600 = \mathbf{-0.3004}
 \end{aligned}$$

*Nota:* Si uno tiene  $p$  variables originales, puede llegar a  $p$  variables nuevas, la idea es siempre obtener menos que  $p$

Más adelante se explicará la obtención de los  $Z$ 's mediante la descomposición espectral.

Además los coeficientes de los  $Z$ 's, como están normalizados la suma de ellos es igual a 1.

### Sub-Ejemplo

Se tiene el siguiente  $Z$

$$Z_2 = 0.8X_1 + 0.8X_2 + 0.01x_3 + 0.01X_4$$

Como  $X_3, X_4$  prácticamente no pesan, por lo que se interpretaría como un promedio entre  $X_1$  y  $X_2$

Para este otro caso

$$Z_3 = 0.8X_1 + 0.6X_2 + 0.5x_3 + 0.01X_4$$

En esta situación es una especie de ponderación donde el que tiene más peso es  $X_1$

Caso inusual

$$Z_4 = 0.5X_1 - 0.5X_2 + 0.01x_3 + 0.01X_4$$

- Si  $X_1 = X_2 = 0$  significa que está muy parecido

PREGUNTAR

- Si  $X_1 > X_2$
- Si  $X_1 < X_2$