

Manual para el curso Minería de Datos y Análisis Multivariado (XS-0126)

Autor: Anderson Martínez

Colaboradores: Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1	Aprendizaje supervisado	3
2	Aprendizaje no supervisado	3
3	Diferencia entre aprendizaje supervisado y no supervisado	3
4	Características del aprendizaje no supervisado	3
5	Proceso de Análisis de componentes principales (PCA)	6
5.1	Maldición de la dimensionalidad	6
5.2	Requisitos para que PCA tenga sentido	7
5.3	Ejemplo de aplicación	7
6	Comparación de análisis factorial con componentes principales	9
6.1	Ejemplo de análisis factorial	9
6.2	Diferencias entre análisis factorial y PCA	10
7	Valores y Vectores propios	10
7.1	¿Cuándo centrar y cuándo estandarizar?	11
7.2	Valores y vectores propios en R	11
7.3	Construcción de Z 's	12
8	Aplicación de PCA ejemplo de HEPTATLON	13
8.1	Proceso de cambios en las variables	13
8.2	Matriz de correlaciones	14
8.2.1	Cálculo en R	14
8.2.2	Gráfico de correlación librería corrgram de colores	14
8.2.3	Gráfico de correlación librería corrgram de números (correlaciones)	15
8.2.4	Gráfico del paquete corplot	15
8.3	Análisis de valores extremos mediante leverage	16
8.3.1	Formas de averiguar y eliminar el valor extremo	16
8.4	Obtención del determinante de la matriz R	16
8.5	Hipótesis de matriz de correlaciones	17
8.6	KMO	17
8.7	Análisis con la matriz de covarianzas	18
8.7.1	Comparación de varianzas de las variables	18
8.7.2	Descomposición espectral de matriz de covarianzas	18
8.8	Obtención de los componentes principales Z 's	20
8.8.1	Cálculo de cuánto porcentaje explica el componente	20

8.8.2	¿Es normal que tenga media cero?	20
8.8.3	Forma automática con <code>prcomp()</code>	20
9	Análisis con matriz de correlaciones	21
9.1	Estadarizando las variables primero	21
9.2	Descomposición espectral de la matriz de correlaciones y obtención de los valores propios.	22
9.3	Porcentaje de explicación de un componente principal	22
9.4	Forma automática	23
9.5	Obtención del primer componente manualmente	23
9.6	Comparación de Varianza y λ s	24
9.7	Cambio a los signos de los coeficientes de Z_1	24
10	Biplot	24
10.1	Biplot categórico	26
11	Gráfico de sedimentación	26
11.0.1	Conclusión de estudio	27
11.1	Reproducción de la matriz de correlaciones	27
11.2	Obtención de correlaciones	29
12	Prueba de los componentes en una regresión	29
12.1	Forma automática	30
12.2	Interpretaciones de regresión	30
13	Conglomerados	31
13.1	Distancias entre individuos	31
13.2	Distancia Euclídea	31
13.3	Distancia de Mahalanobis	33
13.4	Distancia City-block (Manhattan)	34
13.4.1	Nota importante de las distancias	35
14	Ejemplo de aplicación con temperaturas de diferentes cantones de Costa Rica	36
14.0.1	Cálculo distancia euclídea	36
14.0.2	¿Que sucede si transponemos la base?	37
14.0.3	Extracción de valores de un objeto <code>dist()</code>	38
14.0.4	Cálculo distancia de Mahalanobis	38
14.0.5	Cálculo distancia de Manhattan	38
14.1	Creación de dendogramas y distancias entre grupos (linkage)	39
14.1.1	K-vecino más cercano (single linkage)	39
14.1.2	K-vecino más lejano (complete linkage)	40
14.1.3	Salto promedio	42
14.1.4	Distancia de Ward	44
14.2	¿Los dos cantones más correlacionados son los cantones que menor distancia tienen?	46
14.3	¿Que ocurre cuando tenemos variables categóricas?	54
14.3.1	Ejemplo de las universidades	54
15	Método de k-medias y k-medioes	56
15.1	k-medias	56
15.1.1	Algoritmo 1	58
15.1.2	Función de SCDG	58
15.1.3	Algoritmo 2	66
15.1.4	Desventajas	66
15.1.5	Mezcla de dendograma con k-medias	67
15.2	k-medoides	67
15.3	Algoritmo PAM (partitioning around medoids)	68

15.3.1	Observaciones sobre k-medoides	68
15.3.2	CLARA (clustering large applications)	69
15.3.3	Formas automáticas	69
16	Creación de grupos o clusteres	69
16.0.1	Comparación de grupos con variables continuas	70
16.0.2	Comparación de grupos con variables categóricas	71
16.0.3	Combinación de dendograma con gráfico de clúster	73
16.0.4	Código para sacar la distancia entre la mayor y menor probabilidad de cada observación	75
16.0.5	¿Que tan difusos están los datos?	75
16.1	Obtención del número de grupos óptimo mediante el método de la silueta promedio	75
16.1.1	Cluster Jerárquico con Silueta	76
16.2	Estadístico GAP	77
16.2.1	Construcción del estadístico WAP	77
16.3	Validación	78
16.4	Índice Dunn	79
16.4.1	Índice Dunn	79
16.5	Mapas de calor (heatmaps)	80

1 Aprendizaje supervisado

Se aprenden funciones, relaciones que asocian entradas con salidas, por lo que se ajustan a un conjunto de ejemplos de los que conocemos la relación entre la entrada y la salida deseada.

Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre:

- Modelos de clasificación, si la salida es un valor categórico (por ejemplo, una enumeración, o un conjunto finito de clases).
- Modelos de regresión, si la salida es un valor de un espacio continuo.

2 Aprendizaje no supervisado

No estamos interesados en ajustar pares (entrada, salida), sino en aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros que provengan del mismo fenómeno), por ejemplo:

- Dando una agrupación de los datos según su similitud.
- Simplificando la estructura de los mismos manteniendo sus características fundamentales (como en los procesos de reducción de la dimensionalidad).
- Extrayendo la estructura interna con la que se distribuyen los datos en su espacio original (aprendizaje topológico).

3 Diferencia entre aprendizaje supervisado y no supervisado

El aprendizaje supervisado tiene variable respuesta Y , mientras que el aprendizaje no supervisado, no la tiene. Además es importante resaltar que el no supervisado es más descriptivo.

4 Características del aprendizaje no supervisado

- No existe una salida o variable respuesta, por lo que no se utiliza un modelo que relacione un conjunto de variables con una respuesta.

- Esto hace que sea difícil validar los resultados, al contrario del aprendizaje supervisado en el que existen métricas que permiten evaluar con claridad la bondad del aprendizaje realizado.
- Es parte de un análisis exploratorio de datos.
- Algoritmos no supervisados resultan ser muy costosos porque requieren de más pruebas de ensayo y error, haciendo que requieran de un aparataje teórico y computacional mucho más elaborado.

Ejemplo 1

Suponga que tiene la siguiente regresión:

$$\mu_{y|x} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_{p-1} X_{p-1}$$

Recuerde que $\mu_{y|x}$ es la respuesta

Se tiene el siguiente subconjunto de X's:

$$X_1, \dots, X_k \text{ Altamente Correlacionadas}$$

Nota: Cuando las X's están muy correlacionadas hay problemas de multicolinealidad y eso nos infla los errores estándar.

Note que este conjunto de variable es de dimensión k , esto lo que nos dice en realidad es que estas X's miden un subconjunto menor de conceptos, lo que nos lleva al siguiente conjunto:

$$Z_1, \dots, Z_q$$

Donde $q < k$ (No Correlacionadas)

Reemplazando en el modelo original tenemos el siguiente resultado:

$$\mu_{y|x,z} = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \dots + \beta_q Z_q + \beta_{k+1} X_{k+1}$$

En este modelo la primera parte es no supervisado ya que no utilizamos la variable respuesta, para el último modelo obtenido si es supervisado ya que se utiliza con la variable respuesta.


Ejemplo 2

1. Se tienen $X_1, \dots, X_p$ Grupos
2. Formo k grupos
3. Se crea una variable G , la cual se crea a partir del aprendizaje no supervisado. Ya que se crea basado en las X's

Observación (i)	X_1	X_2	$\dots$	X_p	$G = f(X_1, \dots, X_p)$
1	x_{11}	x_{12}	$\dots$	x_{1p}	g_1
2	x_{21}	x_{22}	$\dots$	x_{2p}	g_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
i	x_{i1}	x_{i2}	$\dots$	x_{ip}	g_i
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
n	x_{n1}	x_{n2}	$\dots$	x_{np}	g_n

Nota: Si agregamos una variable edad, podríamos realizar un análisis de varianza, ya que dicha variable funcionaría como una variable respuesta.

Distribución de Edad por Grupo




Ejemplo 3

Observación (i)	Altura (cm)	N.º de Hojas	Grosor del Tallo (mm)	Peso del Racimo (kg)	pH del Suelo
1	24.5	6	3.2	0.45	5.4
2	28.1	7	3.8	0.58	5.6
3	31.4	8	4.1	0.65	5.5
4	52.6	14	7.5	1.85	6.1
5	58.0	15	8.2	2.10	6.3
6	61.3	17	8.9	2.40	6.2
7	84.7	22	12.4	4.15	6.8
8	89.2	25	13.1	4.60	7.0

Note que la Altura (cm), N.º de Hojas, Grosor del Tallo (mm), Peso del Racimo (kg) están muy correlacionadas, mientras que el pH del Suelo no tanto.

Con esas variables correlacionadas puede crear una variable Z_1

Diagrama de Dispersión: Z_1 vs. pH del Suelo



5 Proceso de Análisis de componentes principales (PCA)

$$\mu_{y|x_1, x_2, x_3, x_4} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4$$

Suponga que X_2, X_3, X_4 están muy correlacionadas, para ello se crea una variable Z_1 .

$$\mu_{y|x_1, z_1} = \beta_0 + \beta_1 X_1 + \gamma_1 Z_1$$

Sin embargo, como pasamos de tres variables (X_2, X_3, X_4) a una (Z_1) perdemos cierta información. Es decir Z_1 explica un cierto porcentaje de (X_2, X_3, X_4). Por ejemplo Z_1 explica un 80% de (X_2, X_3, X_4).

Se puede dar el caso que Z_1 no explique suficiente.

Existe otro modelo que puede explicar más que el siguiente:

$$\mu_{y|x_1, x_3} = \beta_0 + \beta_1 X_1 + \beta_3 X_3$$

Nota: Es importante resaltar que los tres modelos anteriores no son lo mismo, cada uno tiene sus ventajas y desventajas.

El PCA sirve para eliminar la multicolinealidad, solo si lo queremos usar para una regresión. Otro uso que se le puede dar es para obtener gráficos más simples.

5.1 Maldición de la dimensionalidad

- Cuando se cuenta con demasiadas variables es difícil hacer un análisis gráfico para tener una idea inicial del comportamiento de los datos.
- Muchas variables son un obstáculo para aplicar otras técnicas multivariadas.

5.2 Requisitos para que PCA tenga sentido

- Si las variables originales casi no están correlacionadas, nada se gana al llevar a cabo un PCA.
- Cuando el determinante de una matriz es cero, se tiene que hay columnas linealmente dependientes. Esto se llama multicolinealidad.
- Si el determinante de la matriz de correlación (R) es cercano a cero, hay indicación de altas correlaciones entre las variables, de lo contrario, cuando el determinante es alto un PCA puede no tener sentido.

5.3 Ejemplo de aplicación

Se tienen los siguientes datos

Observación (i)	X_1	X_2	X_3	X_4
1	3	4	2	5
2	5	1	1	3
3	4	3	3	2
4	2	7	4	0
$\bar{X} \rightarrow$	3.6	3.75	2.5	2.5
$S \rightarrow$	1.24	2.5	1.24	2.05

Luego estandarizamos mediante la siguiente fórmula:

$$X_i = \frac{X_i - \bar{X}}{S_i}$$

```
# 1. Definición de la matriz de datos X (4 observaciones x 4 variables)
X <- matrix(
  c(
    3, 4, 2, 5,
    5, 1, 1, 3,
    4, 3, 3, 2,
    2, 7, 4, 0
  ),
  nrow = 4, byrow = TRUE, dimnames = list(paste0("ID_", 1:4), paste0("X", 1:4)))
# 2. Visualizar resultados
print("Matriz Original X:")
```

```
## [1] "Matriz Original X:"
```

```
print(X)
```

```
##      X1 X2 X3 X4
## ID_1  3  4  2  5
## ID_2  5  1  1  3
## ID_3  4  3  3  2
## ID_4  2  7  4  0
```

```
# 2. Estandarización con scale()
# scale() por defecto resta la media muestral (center = TRUE)
# y divide entre la desviación estándar muestral s con n-1 grados de libertad (scale = TRUE)
Z <- scale(X, center = TRUE, scale = TRUE)
print("Matriz Estandarizada Z (Z-scores):")
```

```
## [1] "Matriz Estandarizada Z (Z-scores):"
```

```
print(round(Z, 4))
```

```
##           X1    X2      X3      X4
## ID_1 -0.3873  0.1 -0.3873  1.2010
## ID_2  1.1619 -1.1 -1.1619  0.2402
## ID_3  0.3873 -0.3  0.3873 -0.2402
## ID_4 -1.1619  1.3  1.1619 -1.2010
## attr("scaled:center")
##      X1    X2    X3    X4
## 3.50 3.75 2.50 2.50
## attr("scaled:scale")
##           X1           X2           X3           X4
## 1.290994 2.500000 1.290994 2.081666
```

Interpretación El ID_4 en X_1 esta 1.16 desviaciones estándar debajo la media (recuerde que la desviación estándar de X_1 es 1.29). También en X_2 el ID_1 está 0.1 desviaciones estándar sobre la media, es decir está prácticamente en la media.

Nota: El máximo de desviaciones estándar en una normal son 3 que son el 99.7% de los datos.

Luego obtenemos los coeficientes para Z_1 y hacemos la siguiente regresión:

$$Z_1 = 0.2X_1^s + 0.4X_2^s + 0.01X_3^s + 0.5X_4^s$$

Nota: En regresión estandarizamos los coeficientes para poder compararlos en este caso, estandarizamos y la que tiene más peso en el resultado de Z_1 es X_4

Luego sustituimos con los valores que tenemos

$$\begin{aligned} Z_1^{(1)} &= 0.2(-0.39) + 0.4(0.10) + 0.01(-0.39) + 0.5(1.20) \\ &= -0.078 + 0.040 - 0.0039 + 0.600 = \mathbf{0.5581} \end{aligned}$$

$$\begin{aligned} Z_1^{(2)} &= 0.2(1.16) + 0.4(-1.10) + 0.01(-1.16) + 0.5(0.24) \\ &= 0.232 - 0.440 - 0.0116 + 0.120 = \mathbf{-0.0996} \end{aligned}$$

$$\begin{aligned} Z_1^{(3)} &= 0.2(0.39) + 0.4(-0.30) + 0.01(0.39) + 0.5(-0.24) \\ &= 0.078 - 0.120 + 0.0039 - 0.120 = \mathbf{-0.1581} \end{aligned}$$

$$\begin{aligned} Z_1^{(4)} &= 0.2(-1.16) + 0.4(1.30) + 0.01(1.16) + 0.5(-1.20) \\ &= -0.232 + 0.520 + 0.0116 - 0.600 = \mathbf{-0.3004} \end{aligned}$$

Nota: Si uno tiene p variables originales, puede llegar a p variables nuevas, la idea es siempre obtener menos que p

Más adelante se explicará la obtención de los Z 's mediante la descomposición espectral.

Además los coeficientes de los Z 's, como están normalizados la suma de ellos es igual a 1.

Sub-Ejemplo

Se tiene el siguiente Z

$$Z_2 = 0.8X_1 + 0.8X_2 + 0.01x_3 + 0.01X_4$$

Como X_3, X_4 prácticamente no pesan, por lo que se interpretaría como un promedio entre X_1 y X_2

Para este otro caso

$$Z_3 = 0.8X_1 + 0.6X_2 + 0.5x_3 + 0.01X_4$$

En esta situación es una especie de ponderación donde el que tiene más peso es X_1

Caso inusual

$$Z_4 = 0.5X_1 - 0.5X_2 + 0.01x_3 + 0.01X_4$$

- Si $X_1 = X_2 = 0$ significa que está muy parecido

PREGUNTAR

- Si $X_1 > X_2$
- Si $X_1 < X_2$

6 Comparación de análisis factorial con componentes principales

Factores comunes	Componentes principales
$X_1 = \lambda_{11}f_1 + \lambda_{12}f_2 + \cdots + \lambda_{1m}f_m + \eta_1$ $X_2 = \lambda_{21}f_1 + \lambda_{22}f_2 + \cdots + \lambda_{2m}f_m + \eta_2$ $\vdots$ $X_q = \lambda_{q1}f_1 + \lambda_{q2}f_2 + \cdots + \lambda_{qm}f_m + \eta_q$	$Z_1 = a_{11}X_1^s + a_{12}X_2^s + \cdots + a_{1q}X_q^s$ $Z_2 = a_{21}X_1^s + a_{22}X_2^s + \cdots + a_{2q}X_q^s$ $\vdots$ $Z_q = a_{q1}X_1^s + a_{q2}X_2^s + \cdots + a_{qq}X_q^s$

- La estructura del análisis de factores es similar a los componentes principales.
- En componentes principales las variables conocidas X se combinan con los coeficientes a para producir nuevas variables Z llamadas componentes principales. Una propiedad importante en el análisis de componentes principales es $Cov(Z_i, Z_j) = 0$
- En factores se combinan factores latentes desconocidos f para formar las variables conocidas X . Esto es más complejo

6.1 Ejemplo de análisis factorial

Tenemos un estudio con f_1 que es la habilidad cuantitativa de una persona y f_2 es la habilidad de razonamiento verbal, para estos dos variables no tienen una forma directa de medirse, ya que f_1 se podría medir mediante un problema o un cuestionario, pero dentro de las preguntas del cuestionario, mientras se mide la habilidad cuantitativa, también se podría estar midiendo el razonamiento verbal, ya que la persona necesita entender la pregunta para resolver el problema.

Por ejemplo una persona obtuvo en una pregunta un valor de $f_1 = 0.5$ y $f_2 = 0.5$, asuma que $\lambda_{11} = 7$ y $\lambda_{12} = 7.5$

Esto nos lleva a que

$$7.25 = 0.5 * 7 + 0.5 * 7.5$$

En otra pregunta se tiene el resultado de otro puntaje, sin embargo lo que cambia es f_1 y f_2 , en el caso de los λ 's no cambian y se pueden obtener por medio de **PCA**, esta es la confusión que muchas personas tienen con este tema.

6.2 Diferencias entre análisis factorial y PCA

Factores comunes	Componentes principales
- El interés es la explicación de la estructura de covarianza o de correlación (o ambas) entre las variables medidas. - Puede haber cambios sustanciales en todos los factores si se cambia el número de factores. - El cálculo de los puntajes es complejo y existen varios métodos. - Se obtienen resultados equivalentes si se usa la matriz de covarianza o la de correlaciones. - Si las variables están casi no correlacionadas este análisis no tiene sentido. - En tal caso los factores no tienen nada que explicar.	- El interés se centra en la explicación de la variabilidad total del conjunto de variables (Como una regresión). - Si el número de componentes que se utilizan se incrementa, esos componentes no cambian. - El cálculo de los puntajes es sencillo y se basa en una única descomposición espectral. No hay relación directa entre los componentes obtenidos de la matriz de covarianza y la de correlaciones. - Si las variables están casi no correlacionadas este análisis no tiene sentido. - En tal caso se obtienen componentes que son muy similares a las variables originales.

Nota: Al agregar Z 's en componentes principales, las coeficientes para obtener los componentes no cambian, en cambio en análisis factorial al yo incluir más cosas que quiero medir (X 's), las f cambian. Además, si las variancias específicas son pequeñas ambos análisis dan resultados similares.

7 Valores y Vectores propios

A continuaci3n el siguiente tema se explica mediante un ejemplo.

Tenemos la siguiente matriz de varianzas y covarianzas:

$$\mathbf{S} = \begin{bmatrix} 8 & 10 & -3 \\ 10 & 6 & -4 \\ -3 & 4 & -2 \end{bmatrix}$$

Note que la $tr(\mathbf{S}) = 8 + 6 + 2 = 16$, esta corresponde a la suma de las varianzas, lo que signica que es la **Varianza total**

Una vez teniendo esto podemos calcular la matriz de correlaci3n por medio de la siguiente f3rmula:

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}$$

Nota: Recordar que en la diagonal la correlaci3n es 1 ya que es la misma variable.

$$\mathbf{R} = \begin{bmatrix} 1 & 1.44 & -0.75 \\ 1.44 & 1 & -1.16 \\ -0.75 & 1.16 & 1 \end{bmatrix}$$

La $tr(\mathbf{R}) = 3$, esta representa el n3mero de variables. Adem3s la matriz de correlaciones es la estandarizaci3n de una matriz de varianzas y covarianzas en este caso, ya que la varianza de cada una de las variables es 1. Esto nos lleva a la siguiente equivalencia:

$$Cov(X_i^s, X_j^s) = r_{ij}$$

As3 que la $tr(\mathbf{R}) = 3$ representa que la varianza total de las variables est3ndarizadas.

7.1 ¿Cuándo centrar y cuándo estandarizar?

Cuando se tienen variables con las mismas escalas solo se necesitan centrar, pero cuando son muy diferentes es altamente recomendado estandarizarlos.

7.2 Valores y vectores propios en R

Valores propios

```
valores = c(8, 10, -3, 10, 6, 4, -3, 4, 2)
S = matrix(
  valores,
  nrow = 3,
  ncol = 3,
  byrow = TRUE
)

v = eigen(S)
round(v$values, 2)
```

```
## [1] 17.07 5.04 -6.11
```

Esto nos dice que $\lambda_1 = 17.07$, $\lambda_2 = 5.04$, $\lambda_3 = -6.11$

Note que la suma de estos valores no da la varianza total original

```
sum(v$values)
```

```
## [1] 16
```

Vectores propios

Estos deben cumplir con la propiedad de que:

$$A \times a = \lambda \times a$$

A continuación se le representa el proceso en R, para obtenerlos

Tenemos la matriz asociada a los vectores propios

```
v$vector
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.73550267 -0.3755265  0.5639288
## [2,] 0.67670738  0.3663738 -0.6386215
## [3,] 0.03321052  0.8513226  0.5235904
```

Los extraemos de la misma matriz

```
e1 = v$vector[, 1] # Asociado a lambda_1 = 17.06
e2 = v$vector[, 2] # Asociado a lambda_2 = 5.05
e3 = v$vector[, 3] # Asociado a lambda_3 = -6.11
```

Verificamos con la condición de modo que $S \%*\% e_1 == \lambda_1 * e_1$

```
t(round(S \%*\% e1, 4))
```

```
##           [,1]      [,2]      [,3]
## [1,] 12.5515 11.5481  0.5667
```

```
round(v$values[1] * e1, 4)
```

```
## [1] 12.5515 11.5481  0.5667
```

Observe que la condición se cumple.

También otra propiedad que se tiene que resaltar es la ornormalidad de los mismos.

Verificación sobre si la norma es 1

```
# Norma 1: ||e_1|| = 1
sqrt(sum(e1^2))
```

```
## [1] 1
```

Verificación de ortogonalidad


```
# Ortogonales entre sí: e_1 %*% e_2 = 0
round(t(e1) %*% e2, 4)
```

```
##      [,1]
## [1,]    0
```

7.3 Construcción de Z's

Cambio de Base en ACP: Traslación y Rotación de Ejes

Lectura de coordenadas (X_1 , X_2) vs. Puntuaciones (Z_1 , Z_2)



Observando la figura anterior tenemos que:

$X_1 = 5.5 \rightarrow Z_1 = 1.95$ y $X_2 = 3.2 \rightarrow Z_2 = -0.82$. Con lo siguiente $r_{x_1, x_2} = 0.45 \rightarrow r_{z_1, z_2} = 0$

¿Cómo se construyen los Z's de la figura anterior?

- Si se utiliza la matriz de correlaciones, se deben estandarizar las variables, esto se hace cuando las escalas de las variables son similares. ($X_1^s, X_2^s \rightarrow S$)
- Si se utiliza la matriz de covarianzas y varianzas, se debe centrar solamente, sin embargo esto se debe hacer solo cuando las escalas sean muy similares. ($X_1^c, X_2^c \rightarrow R$)

Proceso de obtención de los Z's

Sabemos que en el anterior ejercicio los vectores propios son:

```
## El primer vector propio es 0.74 0.67
## El segundo vector propio es -0.67 0.74
```

Tenemos que las medias son:

Media de X1 es 3.5

Media de X2 es 2.5

Hacemos las operaciones para llegar al resultado

$$\begin{aligned} Z_1 &= 0.74 X_1^c + 0.67 X_2^c \\ &= 0.74 (5.5 - 3.5) + 0.67 (3.2 - 2.5) \\ &= 0.74 (2.0) + 0.67 (0.7) \\ &= 1.48 + 0.469 \\ &= 1.95 \end{aligned}$$

$$\begin{aligned} Z_2 &= -0.67 X_1^c + 0.74 X_2^c \\ &= -0.67 (5.5 - 3.5) + 0.74 (3.2 - 2.5) \\ &= -0.67 (2.0) + 0.74 (0.7) \\ &= -1.34 + 0.518 \\ &= -0.82 \end{aligned}$$

Haciendolo en una base de datos grande lo que se está haciendo es lo siguiente:

$$\mathbf{X}^c = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & x_{n3} \end{bmatrix} - \begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \vdots & \vdots & \vdots \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \end{bmatrix}$$

Luego se multiplica por el vector propio:

$$\mathbf{X}^c = \begin{bmatrix} x_{11}^c & x_{12}^c & x_{13}^c \\ x_{21}^c & x_{22}^c & x_{23}^c \\ \vdots & \vdots & \vdots \\ x_{n1}^c & x_{n2}^c & x_{n3}^c \end{bmatrix} \cdot \begin{bmatrix} a_{11} \\ a_{22} \\ a_{33} \end{bmatrix} = \begin{bmatrix} Z_{1(1)} \\ Z_{2(1)} \\ \vdots \\ Z_{n(1)} \end{bmatrix}$$

Con esto llegamos obtener el vector con los valores de la primera variable nueva, para todos los individuos de la base de datos o lo que es lo mismo que decir que el vector del primer componente principal.

Nota: Si se calculan las varianzas de los Z 's da como resultado los λ 's encontrados para los vectores propios, por lo que la variabilidad total es igual si se mantiene el mismo número de variables originales.

8 Aplicación de PCA ejemplo de HEPTATLON

8.1 Proceso de cambios en las variables

Para cambiar el sistema de puntuación realizamos la siguiente transformación de tal manera que:

Observación (i)	→	Observación Nueva
3		7
5		5
8		2
10		0

La fórmula utilizada es:

$$x_{new} = \max - x_i$$

```
load("Heptatlon.Rdata")
base$vallas=with(base,max(vallas)-vallas)
base$car200=with(base,max(car200)-car200)
base$car800=with(base,max(car800)-car800)
```

8.2 Matriz de correlaciones


8.2.1 Cálculo en r

```
round(cor(base[, -8]), 2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.81 0.65  0.77      0.91      0.01  0.78
## saltoalto   0.81      1.00 0.44  0.49      0.78      0.00  0.59
## tiro        0.65      0.44 1.00  0.68      0.74      0.27  0.42
## car200       0.77      0.49 0.68  1.00      0.82      0.33  0.62
## saltolargo   0.91      0.78 0.74  0.82      1.00      0.07  0.70
## javalina     0.01      0.00 0.27  0.33      0.07      1.00 -0.02
## car800       0.78      0.59 0.42  0.62      0.70     -0.02  1.00
```

8.2.2 Gráfico de correlación librería corrgram de colores


```
library(corrgram)
corrgram(base[, -8], lower.panel=panel.pts, order=T) # order = T nos ordena las correlaciones
```



Los colores azules significan una correlación positiva, mientras que los rojos significan una correlación negativa. Además, en los gráficos de puntos, en los ejes están los valores de cada variable según corresponda.


8.2.3 Gráfico de correlación librería corrgram de números (correlaciones)

```
corrgram(base[, -8], lower.panel=panel.pts, upper.panel=panel.conf,
          diag.panel=panel.density, order=T)
```



8.2.4 Gráfico del paquete corrplot

```
library(corrplot)
corrplot(cor(base[, -8]), method = "square", type = "lower")
```



El parámetro lower ordena el correlograma de manera decendente


8.3 Análisis de valores extremos mediante leverage

Recuerde que este proceso se realiza mediante el cálculo de la matriz:

$$H = X(X^T X)^{-1} X^T$$

A continuación se le presenta el código en r, para los leverage

```
lev=hat(base[,-8])
plot(lev)
lim=2*mean(lev)
abline(h=lim)
```



8.3.1 Formas de averiguar y eliminar el valor extremo

Formas de averiguar

```
which.min(base$saltoalto) # Es el punto menor que se ve en los gráficos de correlación más arriba
```

```
## [1] 25
```

```
which.max(lev) # El valor más alto que se sale de la linea en los leverage
```

```
## [1] 25
```

Formas de eliminar

```
base1 = subset(base, lev<lim)
```

```
base1 = base[-25,]
```

Nota: Recordar que en este caso se quitó el valor extremo por términos del ejercicio y nunca se puede quitar sin una justificación en concreto.

8.4 Obtención del determinante de la matriz R

```
base2=base1[,-8] # Es una base sin la respuesta (solo con las X's)
R=cor(base2)
det(R)
```

```
## [1] 0.003511559
```

Conforme las correlaciones, aumenta el determinante tiende a cero.

Correlación alta $\implies$ Determinante casi cero

8.5 Hipótesis de matriz de correlaciones

Existe una prueba de hipótesis que verifica si la matriz de correlaciones es igual a la identidad, ya que si es similar a la identidad, indicaría que las correlaciones son prácticamente cero.

Nota: Para hacer el análisis de PCA **mínimo**, se debe rechazar esta hipótesis.

$$H_0 : R = I$$

```
library(psych)
cortest.bartlett(R,n=nrow(base2)) # Proporcionadle a la función la matriz

## $chisq
## [1] 112.092
##
## $p.value
## [1] 1.973466e-14
##
## $df
## [1] 21

cortest.bartlett(base2) # En esta opción, la base de datos no puede contener la respuesta

## $chisq
## [1] 112.092
##
## $p.value
## [1] 1.973466e-14
##
## $df
## [1] 21
```

8.6 KMO

En ocasiones la prueba de correlaciones falla debido a la gran cantidad de datos, ya que debido a la gran potencia que tienen, ocasiona que la prueba se rechaze siempre.

Una solución ante este problema es usar esta prueba, que tiene como condición que solo si $n/q < 5$, donde q es el número de variables.

A continuación se le presentan los criterios del KMO

Rango KMO	Interpretación / Calidad
[0.9, 1.0]	Muy bueno (Excelente)
[0.8, 0.9]	Meritorio
[0.7, 0.8]	Mediano (Aceptable)
[0.6, 0.7]	Mediocre (Regular)
[0.5, 0.6]	Bajo
[0.0, 0.5]	Inaceptable (Desaconsejable)

KMO(R)

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = R)
## Overall MSA = 0.73
## MSA for each item =
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.87      0.55      0.82      0.72      0.72      0.47      0.84
```

En este caso la Correlación es aceptable

8.7 Análisis con la matriz de covarianzas

Como se mencionó anteriormente, este análisis se recomienda hacerlo cuando las varianzas de las variables son bastantes similares, ya que en este caso las variables no están estandarizadas, tal y como sucede con el análisis de la matriz de correlación.

8.7.1 Comparación de varianzas de la variables

```
v=apply(base2, 2,var) # Note que el 2 es porque es la varianza para cada columna
round(v,3)
```

```
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.265      0.003      2.241      0.878      0.161      12.032      37.789
```

Nota: Con ver este resultado podemos concluir que no tiene sentido hacer un análisis por la matriz de covarianzas debido a la gran diferencia entre varianzas.

Este cálculo lo puede hacer también de la siguiente forma:

```
round(diag(var(base2)),3)
```

```
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.265      0.003      2.241      0.878      0.161      12.032      37.789
```

La variabilidad total de las variables originales la obtenemos, sumando todas las varianzas

```
sum(v)
```

```
## [1] 53.36842
```

8.7.2 Descomposición espectral de matriz de covarianzas

Obtenemos la matriz de covarianzas

```
S=var(base2)
round(S,2)
```

```
##      vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      0.26      0.02 0.59   0.40      0.18      0.59   1.77
## saltoalto    0.02      0.00 0.04   0.02      0.01      0.06   0.05
## tiro         0.59      0.04 2.24   0.94      0.47      1.78   3.76
## car200       0.40      0.02 0.94   0.88      0.31      1.53   3.30
## saltolargo   0.18      0.01 0.47   0.31      0.16      0.40   1.29
## javalina     0.59      0.06 1.78   1.53      0.40     12.03   5.46
## car800       1.77      0.05 3.76   3.30      1.29      5.46  37.79
```

$$S = AA' = A\Lambda^{\frac{1}{2}}\Lambda^{\frac{1}{2}}A'$$

donde:

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

Por medio de `eigen()` hacemos la descomposición

```
espec=eigen(S)
```

A continuación se le presenta código en R, de como obtener los valores y vectores propios

```
lambda=espec$val  
round(lambda,2)
```

```
## [1] 39.82 11.11 2.00 0.35 0.06 0.02 0.00
```

Nota: Observe que la suma de los λ' es lo mismo que la varianza total

```
sum(lambda) # Da lo mismo que la varianza total (summa de las varianzas de cada predictor)
```

```
## [1] 53.36842
```

Esto nos lleva a escribir esta propiedad

$$\sum_{i=1}^q S_i^2 = \sum_{i=1}^q \lambda_j$$

```
A=espec$vec  
round(A,2)
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]  
## [1,] -0.05 0.03 -0.22 -0.26 0.77 -0.54 0.04  
## [2,] 0.00 0.01 -0.01 -0.01 0.11 0.11 -0.99  
## [3,] -0.11 0.11 -0.88 0.42 -0.14 -0.03 -0.01  
## [4,] -0.09 0.08 -0.31 -0.85 -0.40 -0.03 -0.04  
## [5,] -0.04 0.02 -0.18 -0.18 0.46 0.84 0.15  
## [6,] -0.20 0.96 0.16 0.05 0.02 0.01 0.01  
## [7,] -0.97 -0.23 0.11 0.05 -0.01 0.00 0.00
```

```
L = diag(lambda)  
L
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]  
## [1,] 39.82137 0.00000 0.000000 0.0000000 0.00000000 0.00000000 0.00000000  
## [2,] 0.00000 11.11262 0.000000 0.0000000 0.00000000 0.00000000 0.00000000  
## [3,] 0.00000 0.00000 2.003319 0.0000000 0.00000000 0.00000000 0.00000000  
## [4,] 0.00000 0.00000 0.000000 0.3483982 0.00000000 0.00000000 0.00000000  
## [5,] 0.00000 0.00000 0.000000 0.0000000 0.06044327 0.00000000 0.00000000  
## [6,] 0.00000 0.00000 0.000000 0.0000000 0.00000000 0.0213549 0.00000000  
## [7,] 0.00000 0.00000 0.000000 0.0000000 0.00000000 0.00000000 0.000921165
```

Aplicamos la fórmula que esta arriba para obtener la matriz de covarianzas

```
S1 = round(A%*%L%*%t(A),2)  
S1
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
## [1,] 0.26 0.02 0.59 0.40 0.18 0.59 1.77
## [2,] 0.02 0.00 0.04 0.02 0.01 0.06 0.05
## [3,] 0.59 0.04 2.24 0.94 0.47 1.78 3.76
## [4,] 0.40 0.02 0.94 0.88 0.31 1.53 3.30
## [5,] 0.18 0.01 0.47 0.31 0.16 0.40 1.29
## [6,] 0.59 0.06 1.78 1.53 0.40 12.03 5.46
## [7,] 1.77 0.05 3.76 3.30 1.29 5.46 37.79
```

8.8 Obtención de los componentes principales Z 's

```
basec=scale(base2,scale=F) # Datos centrados
Z1=basec%*%A[,1]
head(Z1,5) # Z1 de las 25 competidoras
```

```
##      [,1]
## Joyner-Kersee (USA) -7.647588
## John (GDR) -9.244014
## Behmer (GDR) -11.312888
## Sablovskaitė (URS) -3.185120
## Choubenkova (URS) -8.287030
```

8.8.1 Cálculo de cuánto porcentaje explica el componente

$$\frac{Var(Z_1)}{Var_{total}} * 100$$

```
var(Z1)/sum(diag(var(base2)))*100
```

```
##      [,1]
## [1,] 74.61597
```

Otra forma de obtenerlo

```
lambda[1]/sum(lambda)*100
```

```
## [1] 74.61597
```

8.8.2 ¿Es normal que tenga media cero?

Es completamente normal, ya que cuando se usa la matriz de covarianzas al momento de centrar las variables, la media es prácticamente cero

```
mean(Z1)
```

```
## [1] 1.741662e-15
```

8.8.3 Forma automática con prcomp()

```
pca1=prcomp(base2) #Recordar que base2 no contiene la respuesta
summary(pca1)
```

```
## Importance of components:
##      PC1      PC2      PC3      PC4      PC5      PC6      PC7
## Standard deviation  6.3104 3.3336 1.41539 0.59025 0.24585 0.1461 0.03035
## Proportion of Variance 0.7462 0.2082 0.03754 0.00653 0.00113 0.0004 0.00002
## Cumulative Proportion 0.7462 0.9544 0.99192 0.99845 0.99958 1.0000 1.00000
```

```
names(pca1)
```

```
## [1] "sdev"      "rotation" "center"   "scale"    "x"
```

sdev: Son las desviaciones estándar para obtener lo siguiente:

```
(round(pca1$sdev,2))^2
```

```
## [1] 39.8161 11.0889 2.0164 0.3481 0.0625 0.0225 0.0009
```

rotation: Es la matriz de los vectores propios

```
round(pca1$rotation,2) # Los vectores propios
```

```
##           PC1  PC2  PC3  PC4  PC5  PC6  PC7
## vallas    -0.05 -0.03  0.22  0.26 -0.77 -0.54 -0.04
## saltoalto  0.00 -0.01  0.01  0.01 -0.11  0.11  0.99
## tiro      -0.11 -0.11  0.88 -0.42  0.14 -0.03  0.01
## car200     -0.09 -0.08  0.31  0.85  0.40 -0.03  0.04
## saltolargo -0.04 -0.02  0.18  0.18 -0.46  0.84 -0.15
## javalina   -0.20 -0.96 -0.16 -0.05 -0.02  0.01 -0.01
## car800     -0.97  0.23 -0.11 -0.05  0.01  0.00  0.00
```

x: Es lo que contiene los Z's

```
head(round(pca1$x,2),5)
```

```
##           PC1  PC2  PC3  PC4  PC5  PC6  PC7
## Joyner-Kersee (USA) -7.65 -3.28  1.93  0.61 -0.16  0.23 -0.04
## John (GDR)          -9.24  0.30  2.07 -0.61 -0.07 -0.15 -0.02
## Behmer (GDR)        -11.31 -0.99 -0.18  0.43  0.10  0.07  0.02
## Sablovskaitė (URS)   -3.19 -1.13  1.51 -0.44  0.43 -0.10  0.04
## Choubenkova (URS)    -8.29 -4.61 -0.13 -0.63  0.18 -0.05 -0.06
```

Note que da todos los z's de todos los individuos

```
summary(pca1)
```

```
## Importance of components:
```

```
##           PC1  PC2  PC3  PC4  PC5  PC6  PC7
## Standard deviation  6.3104 3.3336 1.41539 0.59025 0.24585 0.1461 0.03035
## Proportion of Variance 0.7462 0.2082 0.03754 0.00653 0.00113 0.0004 0.00002
## Cumulative Proportion 0.7462 0.9544 0.99192 0.99845 0.99958 1.0000 1.00000
```

Esto nos resume todo lo del análisis y cuánto aporta cada componente

9 Análisis con matriz de correlaciones

9.1 Estadarizando las variables primero

```
v1=scale(base2$vallas)
```

Observe que la media es 0 y la varianza es 1.

```
round(mean(v1),2)
```

```
## [1] 0
```

```
var(v1)
```

```
##      [,1]
## [1,]    1
```

Estandarice todas las variables. Para hacerlo de una sola vez, puede usar: `scale(base2)`.

```
base3=scale(base2)
```

Verificación de que todas las medias son 0 y las variancias son 1.

```
round(apply(base3,2,mean),10)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##           0           0           0           0           0           0           0
```

```
apply(base3,2,var)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##           1           1           1           1           1           1           1
```

9.2 Descomposición espectral de la matriz de correlaciones y obtención de los valores propios.

```
espec1=eigen(R)
lambda1=espec1$val
round(lambda1,2)
```

```
## [1] 4.32 0.90 0.83 0.47 0.30 0.11 0.07
```

```
S = var(base3)
```

```
S1 = var(base2) # esro no es lo mismo que S, no tiene sentido porque las variables no están estandariza
```

```
R = cor(base2)
```

Note que S y R son iguales

```
round(S,2) == round(R,2)
```

```
##      vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      TRUE      TRUE TRUE      TRUE      TRUE      TRUE
## saltoalto    TRUE      TRUE TRUE      TRUE      TRUE      TRUE
## tiro         TRUE      TRUE TRUE      TRUE      TRUE      TRUE
## car200        TRUE      TRUE TRUE      TRUE      TRUE      TRUE
## saltolargo    TRUE      TRUE TRUE      TRUE      TRUE      TRUE
## javalina      TRUE      TRUE TRUE      TRUE      TRUE      TRUE
## car800        TRUE      TRUE TRUE      TRUE      TRUE      TRUE
```

9.3 Porcentaje de explicación de un componente principal

Para averiguar ese porcentaje de explicación utlice la siguiente fórmula:

$$\frac{Var(Z_j)}{\sum_{j=1}^q}$$

donde q es el número total de variables

A continuación se le detalla el proceso en r

Obtenemos el primer valor propio

```
lambda1[1]
```

```
## [1] 4.323642
```

Luego obtenemos el número total de variables o sumamos los valores propios.

```
sum(lambda1)
```

```
## [1] 7
```

```
round(lambda1[1]/sum(lambda1),2)
```

```
## [1] 0.62
```

Esto quiere decir que Z_1 explica un 62% de la variabilidad total, cuando las variables están estandarizadas.

9.4 Forma automática

```
pca1=prcomp(base2,scale=T)
lambda2=pca1$sdev**2
round(lambda2,2)
```

```
## [1] 4.32 0.90 0.83 0.47 0.30 0.11 0.07
```

Note que con `summary()`, podemos obtener directamente cuánto porcentaje explica cada componente.

```
summary(pca1)
```

```
## Importance of components:
```

```
##          PC1      PC2      PC3      PC4      PC5      PC6      PC7
## Standard deviation  2.0793 0.9482 0.9109 0.68320 0.54619 0.33745 0.26204
## Proportion of Variance 0.6177 0.1284 0.1185 0.06668 0.04262 0.01627 0.00981
## Cumulative Proportion 0.6177 0.7461 0.8646 0.93131 0.97392 0.99019 1.00000
```

Obtención del primer vector propio

```
a1=pca1$rot[,1]
round(a1,2)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##      -0.45      -0.31      -0.40      -0.43      -0.45      -0.24      -0.30
```

Observe que la variables con más peso en este caso son: `vallas`, `saltolargo` y `saltolargo`. Además todos son negativos, esto es positiva ya que en terminos de interpretación estos se van a estabilizar.

Es importante fijarse en el signo de los coeficientes que pesen más. Si hay uno que pese muy poco comparado con los demás, pero tiene signo diferente lo que se puede hacer es ignorarlo ya que no va a afectar tanto

9.5 Obtención del primer componente manualmente

```
Z1=base3%*%a1
Z1a=pca1$x[,1]
cbind(Z1,Z1a)
```

```
##          Z1a
## Joyner-Kersey (USA) -4.757530189 -4.757530189
## John (GDR)          -3.147943402 -3.147943402
## Behmer (GDR)        -2.926184760 -2.926184760
## Sablovskaitė (URS)  -1.288135516 -1.288135516
```

```
## Choubenkova (URS)      -1.503450994 -1.503450994
## Schulz (GDR)           -0.958467101 -0.958467101
## Fleming (AUS)          -0.953445060 -0.953445060
## Greiner (USA)          -0.633239267 -0.633239267
## Lajbnerova (CZE)       -0.381571974 -0.381571974
## Bouraga (URS)          -0.522322004 -0.522322004
## Wijnsma (HOL)          -0.217701500 -0.217701500
## Dimitrova (BUL)        -1.075984276 -1.075984276
## Scheider (SWI)          0.003014986  0.003014986
## Braun (FRG)            0.109183759  0.109183759
## Ruotsalainen (FIN)     0.208868056  0.208868056
## Yuping (CHN)           0.232507119  0.232507119
## Hagger (GB)            0.659520046  0.659520046
## Brown (USA)            0.756854602  0.756854602
## Mulliner (GB)          1.880932819  1.880932819
## Hautenauve (BEL)       1.828170404  1.828170404
## Kytola (FIN)           2.118203163  2.118203163
## Geremias (BRA)         2.770706272  2.770706272
## Hui-Ing (TAI)          3.901166920  3.901166920
## Jeong-Mi (KOR)         3.896847898  3.896847898
```

En contexto de este problema mientras más pequeño sea el número mejor es la puntuación, esto nos lleva que la atleta Jeong-Mi (KOR), es la que peor puntuación tiene ya que tiene un valor de Z_1 alto. Otro aspecto importante a notar es que Scheider (SWI) se mantiene muy cerca del promedio, esto debido a su valor en el componente es casi cero.

9.6 Comparación de Varianza y lambdas

```
var(Z1a)
```

```
## [1] 4.323642
```

```
lambda1[1]
```

```
## [1] 4.323642
```

Observe que son iguales, recuerde que esto siempre va a suceder

9.7 Cambio a los signos de los coeficientes de Z_1

```
Z1b=-Z1a
```

```
var(Z1b)
```

```
## [1] 4.323642
```

Nota: Recuerde que la varianza es la misma ya que las constantes salen al cuadrado, por lo que el menos que le incluimos se le anula.


10 Biplot

Este es el código para hacer el gráfico normal

```
biplot(pca1, cex=0.6)
```

El gráfico que se le presenta a continuación fue arreglado para términos de presentación y explicación

```
## Warning: package 'factoextra' was built under R version 4.5.3
```



Del gráfico podemos notar que la participante Joyner-Kersee (USA) tienen a tener puntajes altos por ello se ubica en esa posición. Por otro lado esta la participante Geremias (BRA), esta posicionada al otro lado completamente de la participamos anteriormente, dicha posición es resultado de que a la participante Geremias (BRA) no le fue tan bien en las tres flechas que van en esa dirección (vallas, saltolargo y saltoalto).

Se puede observar que todas las flechas van hacia la izquierda debido a que su signo es negativo. Además, se puede ver que las que pesan más en el primer componente son aquellas que tienen una flecha más larga, por ejemplo en el gráfico anterior javalina es la que tiene una menor longitud en la flecha debido a que el peso de este es menor que el de las demás variables. Por otro lado, las que más pesan como habíamos visto anteriormente son vallas, saltolargo y saltoalto, estas mismas están agrupadas en este gráfico.

Para el segundo componente primero debemos observar el siguiente vector propio:

```
a2=pca1$rot[,2]
round(a2,2)
```

##	vallas	saltoalto	tiro	car200	saltolargo	javalina	car800
##	0.06	-0.65	-0.02	0.19	-0.02	-0.33	0.66


Note que para este caso las que tiene más peso son las variables saltoalto y car800, por esta razón estos son los que tiene una flecha de mayor tamaño con respecto al eje vertical. Además note que el signo de car800 es positivo, por eso es que la flecha tiene una dirección hacia arriba.

Un aspecto importante a resaltar de la participante Brown (USA), es que le fue mejor en saltoalto que en car800, mientras que en vallas, saltolargo y saltolargo está en el promedio, en el otro extremo del gráfico la participante Bouraga (URS), le fue de manera intermedia (o se encuentra en el promedio) en las otras variables, pero le fue mucho mejor en car800 en comparación con saltoalto.

10.1 Biplot categórico

```
library(AMR)
library(dplyr)
data=data.frame(c("AM","EU","EU","EU","EU","EU","OC","AM","EU",
                  "EU","EU","EU","EU","EU","EU","AS","EU","AM",
                  "EU","EU","EU","AM","AS","AS"),row.names(base2),base2)
names(data)=c("Continente","Nombre",names(base2))
pca2=data %>%
  pca(vallas,saltoalto,tiro,car200,saltolargo,javalina,car800)
```


```
ggplot_pca(pca2)
```



11 Gráfico de sedimentación

este gráfico nos sirve para ver como va bajando la varianza explicada de cada componente

```
plot(pca1,type="l")
```



Para este gráfico puede usar `plot(pca$sdev^2)` o `plot(pca)`

El criterio usando el gráfico dice que se deben escoger la cantidad de componentes antes de que caiga abruptamente la variabilidad, en este caso solo podríamos escoger uno, ya que en el gráfico anterior después del primer valor la varianza se desploma.

Cuándo usamos los porcentajes la idea es que el PCA siempre represente al menos un 80% de la variabilidad, para este caso tenemos el siguiente resultado.

```
sum(lambda1[1:3])/length(lambda1)
```

```
## [1] 0.8646255
```

Usaríamos tres componentes en lugar de uno, lo que pasa es que con dos componente no puedo lograr el objetivo de hacer los gráfico más fácil.

Si un componente tiene una varianza menor a uno, no se justifica incluirlo ya que una variable explica más que un componente, debido a que las variables como están estandarizadas tienen varianza 1. Normalmente esto ocurre porque las variables no se están tan correlacionadas entre sí.

11.0.1 Conclusión de estudio

Debido a que según el gráfico solo debemos quedarnos con un componente y con el criterio del porcentaje con tres componentes, lo cual no nos sirve para el análisis, por lo que aplicar PCA para este estudio no fue satisfactorio.

11.1 Reproducción de la matriz de correlaciones

Usando todos los componentes.

```
A=pca1$rot
L=diag(pca1$sdev**2)
R1=A%*%L%*%t(A)
round(R1,2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.58 0.77  0.83      0.89      0.33  0.56
## saltoalto   0.58      1.00 0.46  0.39      0.66      0.35  0.15
## tiro        0.77      0.46 1.00  0.67      0.78      0.34  0.41
## car200       0.83      0.39 0.67  1.00      0.81      0.47  0.57
## saltolargo   0.89      0.66 0.78  0.81      1.00      0.29  0.52
## javalina     0.33      0.35 0.34  0.47      0.29      1.00  0.26
## car800       0.56      0.15 0.41  0.57      0.52      0.26  1.00
```

Verificación

```
round(R,2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.58 0.77  0.83      0.89      0.33  0.56
## saltoalto   0.58      1.00 0.46  0.39      0.66      0.35  0.15
## tiro        0.77      0.46 1.00  0.67      0.78      0.34  0.41
## car200       0.83      0.39 0.67  1.00      0.81      0.47  0.57
## saltolargo   0.89      0.66 0.78  0.81      1.00      0.29  0.52
## javalina     0.33      0.35 0.34  0.47      0.29      1.00  0.26
## car800       0.56      0.15 0.41  0.57      0.52      0.26  1.00
```

```
round(abs(R1-R),10)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      0          0  0      0          0          0  0
## saltoalto    0          0  0      0          0          0  0
## tiro         0          0  0      0          0          0  0
## car200       0          0  0      0          0          0  0
## saltolargo   0          0  0      0          0          0  0
## javalina     0          0  0      0          0          0  0
## car800       0          0  0      0          0          0  0
```

Ahora con sólo dos componentes obtenemos una predicción de R y vea las discrepancias. Para facilidad vea las discrepancias con solo un decimal.

```
A2=pca1$rot[,1:2]
L2=diag(lambda1[1:2])
R2=A2%*%L2%*%t(A2)
round(R2-R,1)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas     -0.1      0.0 0.0      0.0      0.0      0.1  0.1
## saltoalto   0.0     -0.2 0.1      0.1      0.0      0.2 -0.1
## tiro        0.0      0.1 -0.3  0.1      0.0      0.1  0.1
## car200       0.0      0.1 0.1     -0.2      0.0     -0.1  0.1
## saltolargo   0.0      0.0 0.0      0.0     -0.1      0.2  0.1
## javalina     0.1      0.2 0.1     -0.1      0.2     -0.7 -0.1
## car800       0.1     -0.1 0.1      0.1      0.1     -0.1 -0.2
```

- Haga lo mismo con tres componentes y decida si vale la pena usar 3 componentes.

```
A3=pca1$rot[,1:3]
L3=diag(lambd1[1:3])
R3=A3%*%L3%*%t(A3)
round(R3-R,1)

##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      -0.1      0.0  0.0    0.0        0.0        0    0.0
## saltoalto    0.0     -0.2  0.1    0.1        0.0        0   -0.2
## tiro         0.0      0.1 -0.3    0.1        0.0        0    0.1
## car200        0.0      0.1  0.1   -0.2        0.0        0    0.1
## saltolargo    0.0      0.0  0.0    0.0       -0.1        0    0.0
## javalina      0.0      0.0  0.0    0.0        0.0        0    0.0
## car800        0.0     -0.2  0.1    0.1        0.0        0   -0.2
```

11.2 Obtención de correlaciones

Obtenemos la correlación entre cada variable original y Z1a.

```
cor(base2,Z1a)

##          [,1]
## vallas     -0.9365076
## saltoalto  -0.6539754
## tiro       -0.8369090
## car200     -0.8880557
## saltolargo -0.9377059
## javalina   -0.5038399
## car800     -0.6298453
```

Obtenemos las correlaciones a partir del primer valor propio y el primer vector propio. Compare los resultados.

```
a1=sqrt(lambd1[1]) # a1 es el primer vector propio

##          vallas saltoalto      tiro      car200 saltolargo  javalina      car800
## -0.9365076 -0.6539754 -0.8369090 -0.8880557 -0.9377059 -0.5038399 -0.6298453
```

12 Prueba de los componentes en una regresión

```
Z1=pca1$x[,1]
Z2=pca1$x[,2]
Y=base1$puntaje
mod=lm(Y~Z1+Z2)
summary(mod)

##
## Call:
## lm(formula = Y ~ Z1 + Z2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -233.905   -7.667    3.637   25.755   88.441
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6154.125     11.981  513.665  <2e-16 ***
```

```
## Z1          -230.017      5.886 -39.080  <2e-16 ***
## Z2           6.373      12.908   0.494   0.627
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 58.69 on 21 degrees of freedom
## Multiple R-squared:  0.9864, Adjusted R-squared:  0.9851
## F-statistic: 763.8 on 2 and 21 DF,  p-value: < 2.2e-16
```

Observe que Z1 es significativo y Z2 no es significativo, recuerde que estos son variables así que puede ser que los resultados sean muy distintos para otros estudios.

12.1 Forma automática

```
step(mod)

## Start:  AIC=198.27
## Y ~ Z1 + Z2
##
##           Df Sum of Sq      RSS      AIC
## - Z2       1         840    73184 196.54
## <none>                        72344 198.27
## - Z1       1    5261348 5333693 299.48
##
## Step:  AIC=196.54
## Y ~ Z1
##
##           Df Sum of Sq      RSS      AIC
## <none>                        73184 196.54
## - Z1       1    5261348 5334533 297.48
##
## Call:
## lm(formula = Y ~ Z1)
##
## Coefficients:
## (Intercept)          Z1
##          6154         -230
```

12.2 Interpretaciones de regresión

Tenemos esta ecuación resultante del modelo anterior:

$$\hat{y} = 6154.13 - 230.02(-0.45*vallas - 0.31*salto\ alto - 0.4*Tiro - 0.43*car200 - 0.45*salto\ largo + 0.24*javalina - 0.3*car800)$$

Multiplicamos los coeficientes de Z_1 , por el coeficiente de Z_1

```
a = c(-0.45, -0.31, -0.40, -0.43, -0.45, 0.24, -0.3)
-230.02*a
```

```
## [1] 103.5090  71.3062  92.0080  98.9086 103.5090 -55.2048  69.0060
```

$$\hat{y} = 6154.13 + 103.54\ vallas^s + 71.03*salto\ alto^s + 92*Tiro^s + 98.9*car200^s + 103.5*salto\ largo^s - 55.2*javalina^s + 69*car800^s$$

Obtenemos la desviación estándar de vallas

```
sd(base1$vallas)
```

```
## [1] 0.514564
```

Para este caso las X 's estaban estandarizadas, pero la Y no entonces la interpretación tiene la siguiente estructura:

Por un aumento de 1 desviación estándar en la variable X_j , la respuesta promedio Y (aumenta/disminuye) en promedio β_j^s unidades, manteniendo constantes los demás predictores

Aplicando esa estructura a el ejemplo nos quedaría así:

Por una disminución (esto es por contexto) de 0.51 segundos en la Vallas, la respuesta promedio aumenta.

Recordar que las variables que se le dieron vuelta fueron **vallas**, **car200** y **car800**.

Nota: El objetivo de PCA no es siempre hacer una regresión.

13 Conglomerados

13.1 Distancias entre individuos

Dadas los valores de las variables para los individuos i -ésimo y j -ésimo, interesa tener una medida de la distancia multidimensional entre esos dos individuos.

Si se cuenta con n individuos, la matriz de distancias es de tamaño $n \times n$, con ceros en la diagonal, esto independientemente de q (número de variables).

A continuación se le presenta un ejemplo de la matriz de distancias

$$D = \begin{pmatrix} 0 & d_{12} & \cdots & d_{1n} \\ d_{21} & 0 & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & 0 \end{pmatrix}$$

La distancia es un concepto opuesto al de similitud, entre mayor similitud exista entre dos sujetos, menor es la distancia entre ellos y viceversa.

13.2 Distancia Euclídea

La distancia más común es la Euclídea, definida por:

$$d_{ij} = \sqrt{\sum_{k=1}^q (x_{ik} - x_{jk})^2} = \sqrt{(X_i - X_j)^T (X_i - X_j)}$$

donde x_{ik} es el valor que toma el i -ésimo sujeto en la k -ésima variable, y X_i es el vector de q valores del i -ésimo sujeto: $X_i^T = (x_{i1}, \dots, x_{ik}, \dots, x_{iq})$.

En dos dimensiones, es la medida de la hipotenusa del triángulo rectángulo que se forma a partir de los dos puntos que se están comparando.

El cuadrado de la distancia Euclídea (d_{ij}^2) es otra medida de distancia que se puede usar en algunas ocasiones.

$$d_{ij}^2 = \sum_{k=1}^q (x_{ik} - x_{jk})^2$$


Ejemplo aplicado

Tenemos los siguientes datos tomados en el momento de la clase

id	Peso	Estatura (metros)	Edad
1	94	1.73	23.40
2	84	1.74	21.90
3	60	1.58	21.60
4	85	1.78	20.04
5	71	1.66	25.30

Distancias Euclidianas entre Observaciones

Descomposición geométrica de la distancia mediante diferencias ortogonales



Cáculamos las distancias entre los puntos

$$\begin{aligned}
d(1, 2) &= \sqrt{(94 - 84)^2 + (1.73 - 1.74)^2} = \sqrt{10^2 + (-0.01)^2} = \sqrt{100.0001} \approx 10.0000 \\
d(1, 3) &= \sqrt{(94 - 60)^2 + (1.73 - 1.58)^2} = \sqrt{34^2 + 0.15^2} = \sqrt{1156.0225} \approx 34.0003 \\
d(1, 4) &= \sqrt{(94 - 85)^2 + (1.73 - 1.78)^2} = \sqrt{9^2 + (-0.05)^2} = \sqrt{81.0025} \approx 9.0001 \\
d(1, 5) &= \sqrt{(94 - 71)^2 + (1.73 - 1.66)^2} = \sqrt{23^2 + 0.07^2} = \sqrt{529.0049} \approx 23.0001 \\
\\
d(2, 3) &= \sqrt{(84 - 60)^2 + (1.74 - 1.58)^2} = \sqrt{24^2 + 0.16^2} = \sqrt{576.0256} \approx 24.0005 \\
d(2, 4) &= \sqrt{(84 - 85)^2 + (1.74 - 1.78)^2} = \sqrt{(-1)^2 + (-0.04)^2} = \sqrt{1.0016} \approx 1.0008 \\
d(2, 5) &= \sqrt{(84 - 71)^2 + (1.74 - 1.66)^2} = \sqrt{13^2 + 0.08^2} = \sqrt{169.0064} \approx 13.0002 \\
\\
d(3, 4) &= \sqrt{(60 - 85)^2 + (1.58 - 1.78)^2} = \sqrt{(-25)^2 + (-0.20)^2} = \sqrt{625.0400} \approx 25.0008 \\
d(3, 5) &= \sqrt{(60 - 71)^2 + (1.58 - 1.66)^2} = \sqrt{(-11)^2 + (-0.08)^2} = \sqrt{121.0064} \approx 11.0003 \\
\\
d(4, 5) &= \sqrt{(85 - 71)^2 + (1.78 - 1.66)^2} = \sqrt{14^2 + 0.12^2} = \sqrt{196.0144} \approx 14.0005
\end{aligned}$$

Podemos ver que la diferencias entre el peso en kilogramos, tiene mayor importancia al momneto de hacer el cálculo, para solucionar este problema lo idea el estandarizar las variables.

13.3 Distancia de Mahalanobis

Esta medida de distancia incluye un procedimiento de estandarización dentro de la distancia Euclídea.

No sólo hace una estandarización en los datos escalándolos en términos de su desviación estándar sino que ajusta según las correlaciones entre variables:

$$d_{ij}^M = \sqrt{(X_i - X_j)^T S^{-1} (X_i - X_j)}$$

donde S es la matriz de covariancias de dimensión $q \times q$

Es invariante frente a transformaciones lineales de las variables.

Toma en cuenta las correlaciones entre variables.

No aumenta por el simple hecho de aumentar el número de variables, sino que aumentará cuando las nuevas variables den nueva información.

Aplicación basada en el ejemplo anterior

$$\begin{aligned}
d_{35}^M &= \sqrt{(X_3 - X_5)^\top \mathbf{S}^{-1} (X_3 - X_5)} \\
&= \sqrt{(60 - 71 \quad 1.58 - 1.66) \begin{bmatrix} 177.7000 & 0.9320 \\ 0.9320 & 0.00622 \end{bmatrix}^{-1} \begin{pmatrix} 60 - 71 \\ 1.58 - 1.66 \end{pmatrix}} \\
&= \sqrt{(-11 \quad -0.08) \begin{bmatrix} 0.0263 & -3.9380 \\ -3.9380 & 750.8345 \end{bmatrix} \begin{pmatrix} -11 \\ -0.08 \end{pmatrix}} \\
&= \sqrt{(0.0259 \quad -16.7491) \begin{pmatrix} -11 \\ -0.08 \end{pmatrix}} \\
&= \sqrt{(-11)(0.0259) + (-0.08)(-16.7491)} \\
&= \sqrt{-0.2849 + 1.3399} \\
&= \sqrt{1.0550} \approx \mathbf{1.0269}
\end{aligned}$$

```

X = as.matrix(datos[, c("Peso", "Estatura")])
n = nrow(X)
S = cov(X)
S_inv = solve(S)

# Matriz de distancias de Mahalanobis par a par
D_M <- matrix(0, nrow = n, ncol = n)
for (i in 1:n) {
  for (j in 1:n) {
    diff <- X[i, ] - X[j, ]
    D_M[i, j] <- sqrt(t(diff) %*% S_inv %*% diff)
  }
}
rownames(D_M) <- colnames(D_M) <- paste0("id_", 1:5)

print("Matriz de Distancias de Mahalanobis (pares):")

## [1] "Matriz de Distancias de Mahalanobis (pares):"
print(round(D_M, 4))

##           id_1  id_2  id_3  id_4  id_5
## id_1 0.0000 1.8684 2.6660 2.7477 2.2140
## id_2 1.8684 0.0000 2.0287 0.9553 1.0276
## id_3 2.6660 2.0287 0.0000 2.6607 1.0269
## id_4 2.7477 0.9553 2.6607 0.0000 1.6527
## id_5 2.2140 1.0276 1.0269 1.6527 0.0000

```

Verifique la distancia d_{35}^M es 1.0269

13.4 Distancia City-block (Manhattan)

En esta medida se usa el valor absoluto de las diferencias en lugar de su cuadrado:

$$d_{ij}^{(1)} = \sum_{k=1}^q |x_{ik} - x_{jk}|$$

El nombre nace de la idea de moverse en una ciudad como Manhattan pues, aunque la distancia más corta sería la Euclídea, ésta implica pasar a través de los edificios, mientras que esta distancia asemeja a caminar por las aceras para llegar de un punto a otro.

Es más robusta que la distancia euclídea debido a que no eleva al cuadrado las diferencias.

Tiene la restricción de que asume que las variables no están correlacionadas.

Aplicación basada en el ejemplo anterior

$$\begin{aligned} d(1,2) &= |94 - 84| + |1.73 - 1.74| = 10 + 0.01 = \mathbf{10.01} \\ d(1,3) &= |94 - 60| + |1.73 - 1.58| = 34 + 0.15 = \mathbf{34.15} \\ d(1,4) &= |94 - 85| + |1.73 - 1.78| = 9 + 0.05 = \mathbf{9.05} \\ d(1,5) &= |94 - 71| + |1.73 - 1.66| = 23 + 0.07 = \mathbf{23.07} \\ d(2,3) &= |84 - 60| + |1.74 - 1.58| = 24 + 0.16 = \mathbf{24.16} \\ d(2,4) &= |84 - 85| + |1.74 - 1.78| = 1 + 0.04 = \mathbf{1.04} \\ d(2,5) &= |84 - 71| + |1.74 - 1.66| = 13 + 0.08 = \mathbf{13.08} \\ d(3,4) &= |60 - 85| + |1.58 - 1.78| = 25 + 0.20 = \mathbf{25.20} \\ d(3,5) &= |60 - 71| + |1.58 - 1.66| = 11 + 0.08 = \mathbf{11.08} \\ d(4,5) &= |85 - 71| + |1.78 - 1.66| = 14 + 0.12 = \mathbf{14.12} \end{aligned}$$

Aplicación en r

```
# Distancia de Manhattan para Peso y Estructura
D_manhattan_2v <- dist(datos[, c("Peso", "Estructura")], method = "manhattan")
print(as.matrix(round(D_manhattan_2v, 2)))
```

```
##      1      2      3      4      5
## 1  0.00 10.01 34.15  9.05 23.07
## 2 10.01  0.00 24.16  1.04 13.08
## 3 34.15 24.16  0.00 25.20 11.08
## 4  9.05  1.04 25.20  0.00 14.12
## 5 23.07 13.08 11.08 14.12  0.00
```

```
# Distancia de Manhattan completa (3 variables)
D_manhattan_3v <- dist(datos, method = "manhattan")
print(as.matrix(round(D_manhattan_3v, 2)))
```

```
##      1      2      3      4      5
## 1  0.00 11.01 36.15 12.05 27.07
## 2 11.01  0.00 25.16  3.04 16.08
## 3 36.15 25.16  0.00 26.20 13.08
## 4 12.05  3.04 26.20  0.00 15.12
## 5 27.07 16.08 13.08 15.12  0.00
```

13.4.1 Nota importante de las distancias

Puede ser que usando algunos de los métodos, las agrupaciones que se estén realizando, por lo que dependiendo del caso se debe escoger el tipo de distancia que tenga más sentido. De modo que los grupos sean muy parecidos dentro de ellos, pero muy desiguales entre los grupos existentes.

14 Ejemplo de aplicación con temperaturas de diferentes cantones de Costa Rica

```
load("Temp_Cantones.Rdata")
```

Observe la estructura de la base

```
head(base)
```

```
## # A tibble: 6 x 4
##   canton   anio mes   temp_c
##   <chr>   <dbl> <fct>   <dbl>
## 1 Cartago 2025 JAN     19.9
## 2 Cartago 2025 FEB     20.0
## 3 Cartago 2025 MAR     20.7
## 4 Cartago 2025 APR     20.8
## 5 Cartago 2025 MAY     21.6
## 6 Cartago 2025 JUN     21.1
```

Para solucionar este problema debemos pivotar la base de datos con el siguiente código:

```
library(dplyr)
library(tidyr)
library(tibble)
base2 = base %>%
  select(canton, mes, temp_c) %>%
  pivot_wider(
    names_from = mes,
    values_from = temp_c
  ) %>%
  column_to_rownames(var = "canton")
```

```
head(base2)
```

```
##           JAN   FEB   MAR   APR   MAY   JUN   JUL   AUG   SEP   OCT   NOV
## Cartago    19.89 19.99 20.68 20.78 21.60 21.11 20.88 20.94 21.16 20.81 20.39
## Corredores 26.27 26.87 27.73 27.65 26.58 26.04 26.47 26.18 25.88 25.28 25.61
## Limón      24.36 24.35 24.75 24.92 25.62 25.09 25.12 25.17 25.34 25.03 24.76
## Nicoya     27.43 28.63 29.45 29.52 28.28 27.33 27.92 27.64 27.09 26.47 26.85
## Puntarenas 26.59 27.40 28.57 28.51 27.66 26.82 27.40 27.20 26.72 25.95 26.40
## Pérez Zeledón 20.97 21.27 22.10 22.21 22.23 21.75 21.87 21.75 21.68 21.17 21.16
##           DEC
## Cartago    19.67
## Corredores 25.76
## Limón      24.37
## Nicoya     26.96
## Puntarenas 26.28
## Pérez Zeledón 20.78
```

14.0.1 Cálculo distancia euclidiana

A continuación se le proporcionar la disntancia euclidean entre dos individuos

```
x1=base2[1,]
x2=base2[2,]
x12=as.matrix(x1-x2,ncol=1)
sqrt(x12%*%t(x12))
```

```
##          Cartago
## Cartago 19.98362
```

14.0.2 ¿Que sucede si transponemos la base?

```
base3 = t(base2)
head(base3)
```

```
##      Cartago Corredores Limón Nicoya Puntarenas Pérez Zeledón Santa Cruz
## JAN   19.89      26.27 24.36 27.43      26.59      20.97      26.59
## FEB   19.99      26.87 24.35 28.63      27.40      21.27      28.19
## MAR   20.68      27.73 24.75 29.45      28.57      22.10      29.72
## APR   20.78      27.65 24.92 29.52      28.51      22.21      29.78
## MAY   21.60      26.58 25.62 28.28      27.66      22.23      28.63
## JUN   21.11      26.04 25.09 27.33      26.82      21.75      27.20
##      Talamanca Upala Vázquez de Coronado
## JAN      20.52 25.34      22.86
## FEB      20.64 26.31      23.09
## MAR      21.25 28.21      24.05
## APR      21.38 28.23      24.31
## MAY      22.15 27.77      24.15
## JUN      21.71 26.26      23.55
```

En el cálculo de la distancia lo que cambia es la posición de los datos y el lugar de la matriz transpuesta en la multiplicación de matrices

```
x1=as.numeric(base3[,1])
x2=as.numeric(base3[,2])
x12=as.matrix(x1-x2,ncol=1)
sqrt(t(x12)%*%x12)
```

```
##      [,1]
## [1,] 19.98362
```

A continuación se le presenta una forma automática de calcular todas las distancias por medio de la función `dist()`

```
(d=dist(base2))
```

```
##      Cartago Corredores      Limón      Nicoya Puntarenas
## Corredores      19.983618
## Limón          14.732074      5.831569
## Nicoya         24.992805      5.054157 10.641414
## Puntarenas     22.582608      2.749109 8.204767 2.488715
## Pérez Zeledón   3.396145 16.672942 11.592886 21.686860 19.291008
## Santa Cruz     24.327885      4.680833 10.151345 1.493352 2.247221
## Talamanca       2.126006 17.883582 12.611189 22.893610 20.479187
## Upala          20.422030      2.076126 6.326302 4.892852 2.653356
## Vázquez de Coronado 9.772712 10.237846 5.271442 15.236430 12.820729
##      Pérez Zeledón Santa Cruz Talamanca      Upala
## Corredores
## Limón
## Nicoya
## Puntarenas
## Pérez Zeledón
```

```
## Santa Cruz                21.032432
## Talamanca                 1.541006  22.242704
## Upala                     17.162613  4.013365 18.334350
## Vázquez de Coronado       6.491849 14.600449 7.678086 10.723656
```

Observe la clase del objeto d

```
class(d)
```

```
## [1] "dist"
```

14.0.3 Extracción de valores de un objeto dist()

```
d2= as.matrix(d) # Pasamos el objeto dist a una matriz
d2sup = d2
# Para evitar los ceros en la diagonal extraemos la matriz triangular superior
d2sup[lower.tri(d2, diag = TRUE)] <- NA # Se extrae la matriz triangular superior y reemplazan los otros
```

Cantones con Mayor distancia

```
#Extraemos la posición de la distancia más grande
max_pos = which(d2sup == max(d2sup, na.rm = TRUE), arr.ind = TRUE)
#Obtenemos los nombres de las variables de forma automática
cantones_max <- data.frame(
  Canton_1 = rownames(d2)[max_pos[, 1]],
  Canton_2 = colnames(d2)[max_pos[, 2]],
  Distancia = d2[max_pos]
)
cantones_max
```

```
##   Canton_1 Canton_2 Distancia
## 1   Cartago  Nicoya   24.9928
```

Cantones con menor distancia

```
min_pos = which(d2sup == min(d2sup, na.rm = TRUE), arr.ind = TRUE)
cantones_min = data.frame(
  Canton_1 = rownames(d2)[min_pos[, 1]],
  Canton_2 = colnames(d2)[min_pos[, 2]],
  Distancia = d2[min_pos]
)
cantones_min
```

```
##   Canton_1  Canton_2 Distancia
## 1   Nicoya Santa Cruz  1.493352
```

14.0.4 Cálculo distancia de Mahalannobis

```
library(biotools)
S=var(base2)
dM=D2.dist(base2,S)
# DA ERROR PORQUE S NO SE PUEDE INVERTIR
```

14.0.5 Cálculo distancia de Manhattan

```
dMan=dist(base2,method = "manhattan")
as.matrix(dMan)[1,2]
```

```
## [1] 68.42
```

14.1 Creación de dendogramas y distancias entre grupos (linkage)

A partir de una matriz de distancias entre individuos se puede derivar el concepto de distancia entre dos grupos


14.1.1 K-vecino más cercano (singke linkage)

$$\delta(A, B) = \min_{\substack{x_i \in A \\ x_j \in B}} d(x_i, x_j)$$

Para crear un dendrograma de este tipo de distancia se debe indicar con `method = "single"`.

```
cs = hclust(d,method = "single")
```


```
plot(cs,xlab="",main="Vecino más cercano con distancia Euclídea",
     ylab="Distancia",sub="")
```



```
csM = hclust(dM,method = "single")
plot(csM,xlab="",main="Vecino más cercano con distancia de Mahalannobis",
      ylab="Distancia",sub="")
```

```
csMan = hclust(dMan,method = "single")
plot(csMan,xlab="",main="Vecino más cercano con distancia de Manhattan",
      ylab="Distancia",sub="")
```

Vecino más cercano con distancia de Manhattan




14.1.2 K-vecino más lejano (complete linkage)

$$\delta(A, B) = \max_{\substack{x_i \in A \\ x_j \in B}} d(x_i, x_j)$$

Para crear un dendrograma de este tipo de distancia se debe indicar con `method = "complete"`.

```
c.com = hclust(d,method = "complete")
plot(c.com, xlab = "", main = "Vecino más lejano con distancia Euclídea",
      ylab = "Distancia", sub = "")
```


Vecino más lejano con distancia Euclídea



```
cM.com = hclust(dM,method = "complete")
plot(cM.com,xlab="",main="Vecino más lejano con distancia de Mahalanobis",
      ylab="Distancia",sub="")
```

```
cMan.com = hclust(dMan,method = "complete")
plot(cMan.com,xlab="",main="Vecino más lejano con distancia de Manhattan",
      ylab="Distancia",sub="")
```

Vecino más lejano con distancia de Manhattan




14.1.3 Salto promedio

Es el promedio de todas las distancias mínimas.

$$\delta(A, B) = \frac{1}{n_A n_B} \sum_{x_i \in A, x_j \in B} d(x_i, x_j)$$

```
c.av = hclust(d,method = "average")
plot(c.av,xlab="",main="Salto promedio con distancia Euclidea",
      ylab="Distancia",sub="")
```


Salto promedio con distancia Euclidea



```
cM.av = hclust(dM,method = "average")
plot(cM.av,xlab="",main="Salto promedio con distancia de Mahalannobis",
     ylab="Distancia",sub="")
```

```
cMan.av = hclust(dMan,method = "average")
plot(cMan.av,xlab="",main="Salto promedio con distancia de Manhattan",
     ylab="Distancia",sub="")
```

Salto promedio con distancia de Manhattan




14.1.4 Distancia de Ward

$$\delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|g_A - g_B\|^2$$

donde: g_A es el centroide del clúster A


```
c.w = hclust(d,method = "ward.D")
plot(c.w,xlab="",main="Distancia de Ward con distancia Euclidea",
      ylab="Distancia",sub="")
```

Distancia de Ward con distancia Euclidea



```
cM.w = hclust(dM,method = "ward.D")
plot(cM.w,xlab="",main="Distancia de Ward con distancia de Mahalannobis",
      ylab="Distancia",sub="")
```

```
cMan.w = hclust(dMan,method = "ward.D")
plot(cMan.w,xlab="",main="Distancia de Ward con distancia de Manhattan",
      ylab="Distancia",sub="")
```




14.2 ¿Los dos cantones más correlacionados son los cantones que menor distancia tienen?

A continuación se le presenta un gráfico con las temperaturas de todos los meses por cantón

```
#datos largos son los datos pivoteados
ggplot(datos_largos, aes(x = mes, y = temp_c, group = canton, color = canton)) +
  geom_line(linewidth = 0.9, alpha = 0.85) +
  geom_point(size = 2) +
  labs(
    title = "Ciclo anual de temperatura por cantón (2025)",
    x = "Mes",
    y = "Temperatura (°C)",
    color = "Cantón"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    panel.grid.minor = element_blank(),
    legend.position = "right"
  )
```

Ciclo anual de temperatura por cantón (2025)




Recordemos que la menor distancia entre cantones se encontraba entre:

cantones_min *#Buscar en las páginas de arriba como se obtuvo este resultado*

```
## Canton_1 Canton_2 Distancia
## 1 Nicoya Santa Cruz 1.493352
```

A continuación se le presenta un gráfico de la matriz de correlaciones

```
corrgram(base3, lower.panel=panel.pts, upper.panel=panel.conf,
diag.panel=panel.density,order=T)
```



Basado en el gráfico anterior y con la función `cor()` obtenemos la mayor correlación entre cantones.

```
R = cor(base3)
Rsup = R
Rsup[lower.tri(R, diag = TRUE)] <- NA # Se extrae la matriz triangular superior y reemplazan los otros v
max_r = which(Rsup == max(Rsup, na.rm = TRUE), arr.ind = TRUE)

#Obtenemos los nombres de las variables de forma automática
cantones_maxr <- data.frame(
  Canton_1 = rownames(R)[max_r[, 1]],
  Canton_2 = colnames(R)[max_r[, 2]],
  Correlación = R[max_r]
)
```

Basado en el proceso anterior tenemos los siguientes dataframe()

```
cantones_min # el código se encuentra más arriba
```

```
## Canton_1 Canton_2 Distancia
## 1 Nicoya Santa Cruz 1.493352
```

```
cantones_maxr
```

```
## Canton_1 Canton_2 Correlación
## 1 Cartago Talamanca 0.9973338
```

Obtenemos los nombres para poder graficarlos en un solo gráfico

```
d1 = cantones_min[1,1] #Nicoya
d2 = cantones_min[1,2] #Santa Cruz
```

```

r1 = cantones_maxr[1,1] #Cartago
r2 = cantones_maxr[1,2] #Talamanca


# Unir cantones a graficar (sin duplicados)
cantones_a_graficar <- unique(c(d1,d2,r1,r2))

# Filtrar y pivotar a formato largo
datos_lineas <- base2 %>%
  as.data.frame() %>%
  rownames_to_column(var = "canton") %>%
  filter(canton %in% cantones_a_graficar) %>%
  pivot_longer(
    cols = JAN:DEC,
    names_to = "mes",
    values_to = "temp_c"
  ) %>%
  mutate(
    mes = factor(mes, levels = c("JAN", "FEB", "MAR", "APR", "MAY", "JUN",
                                "JUL", "AUG", "SEP", "OCT", "NOV", "DEC"))
  )

# Gráfico lineal comparativo
ggplot(datos_lineas, aes(x = mes, y = temp_c, group = canton, color = canton)) +
  geom_line(linewidth = 1.1) +
  geom_point(size = 2.5) +
  scale_color_brewer(palette = "Set1") +
  labs(
    title = "Gráfico comparativo de los cantones más correlacionados y \ncon menor distancia",
    x = "Mes",
    y = "Temperatura (°C)",
    color = "Cantón"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    panel.grid.minor = element_blank(),
    legend.position = "bottom"
  )

```

Gráfico comparativo de los cantones más correlacionados y con menor distancia



Se puede ver en el anterior gráfico que los cantones de Cartago y Talamanca, tienen el mismo comportamiento, pero no son tan cercanos. Por otro lado, los cantones Santa Cruz y Nicoya son muy cercanos, pero su comportamiento si es más distinto, estos dos tipos de distancia nos sirven dependiendo del tipo de pregunta que buscamos resolver.

A partir de una matriz de correlaciones R , se puede obtener una matriz de distancias de la siguiente forma:

$$D = 1 - R$$


A continuación se le presenta la forma de hacerlo en R

```
D = 1-R
dr = as.dist(D)
```

Hacemos un dendrograma y lo comparamos con el que se obtiene con la distancia euclídea. Es importante resaltar que el mejor tipo de distancia es la distancia de Ward, por esa razón es que los siguientes gráficos van con esta distancia. *Los demás tipos de distancia se encuentran en la anterior sección*


```
c.w = hclust(d,method = "ward.D")
plot(c.w,xlab="",main="Distancia de Ward con distancia Euclídea",
      ylab="Distancia",sub="")
```

Distancia de Ward con distancia Euclídea



```
c.w = hclust(dr,method = "ward.D")
plot(c.w,xlab="",main="Distancia de Ward con distancia de correlación",
      ylab="Distancia",sub="")
```

Distancia de Ward con distancia de correlación



```

grupos <- cutree(cMan.w, k = 2)
# Ver la asignación de cantones por grupo en consola
print(split(names(grupos), grupos))

## $`1`
## [1] "Cartago"          "Limón"             "Pérez Zeledón"
## [4] "Talamanca"        "Vázquez de Coronado"
##
## $`2`
## [1] "Corredores" "Nicoya"          "Puntarenas" "Santa Cruz" "Upala"

# 2. Preparar el data frame calculando la temperatura media anual por cantón
datos_cajas <- as.data.frame(base2) %>%
  rownames_to_column(var = "canton") %>%
  mutate(
    Grupo = factor(paste("Grupo", grupos[canton])),
    temp_media = rowMeans(across(JAN:DEC))
  )


# 3. Boxplot con exactamente dos cajas
ggplot(datos_cajas, aes(x = Grupo, y = temp_media, fill = Grupo)) +
  geom_boxplot(
    width = 0.45,
    alpha = 0.7,
    outlier.shape = NA,
    show.legend = FALSE
  ) +

```

```

# Puntos observados (cantones) con dispersión horizontal leve
geom_jitter(
  width = 0.08,
  size = 3.2,
  aes(color = Grupo),
  show.legend = FALSE
) +
# Etiquetas con el nombre del cantón
geom_text(
  aes(label = canton),
  hjust = -0.15,
  vjust = 0.5,
  size = 3.3,
  fontface = "bold"
) +
scale_fill_manual(values = c("Grupo 1" = "skyblue", "Grupo 2" = "#e74c3c")) +
scale_color_manual(values = c("Grupo 1" = "#1b4f72", "Grupo 2" = "#922b21")) +
labs(
  title = "Comparación térmica entre conglomerados",
  subtitle = "Agrupamiento jerárquico (Ward + Manhattan, Con dos grupos)",
  x = "Conglomerado",
  y = "Temperatura media anual (°C)"
) +
theme_minimal(base_size = 12) +
theme(
  plot.title = element_text(face = "bold", hjust = 0.5),
  plot.subtitle = element_text(hjust = 0.5, color = "gray30", margin = margin(b = 10)),
  panel.grid.minor = element_blank()
)

```



14.3 ¿Que ocurre cuando tenemos variables categóricas?

Luego de ver el laboratorio colocar la función `daisy()`, que saca la distancias entre categóricas y numéricas (EXPLICAR)

Cuando se tienen tanto variables métricas como variables nominales y/o ordinales se recomienda usar la distancia de Gower:

$$d_{ij}^G = \frac{1}{q} \left[\sum_{h=1}^{p_1} \frac{|x_{ih} - x_{jh}|}{R_h} + \beta_{ij} \right]$$

donde:

- R_h : RAngo de la h-ésima variable cuantitativa
- β_{ij} : número de variables cualitativas que no son idénticas
- q : número total de variables

14.3.1 Ejemplo de las universidades

Se cuenta con información de un gran número de universidades de los E.U.A de la edición de 1995 del US News and World Report.

Variables de tipo continuo:

- Tasa de aceptación (número aceptados / número aplicaciones)
- Costo de la matrícula para estudiantes de otros estados

- Número de nuevos estudiantes
- Tasa de graduación

Variables de tipo categórico (binarias):

- Tipo de universidad (pública o privada)
- Elite: si más del 50% de los estudiantes provienen de colegios del top-10%.

A continuación se le presenta el formato de la base de datos del ejemplo

Universidad / Institución	tasa.acept	costo	nuevos	tasa.grad	privado	elite
Abilene Christian University	0.74	7440	721	60	Yes	No
Adelphi University	0.88	12280	512	56	Yes	No
Adrian College	0.77	11250	336	54	Yes	No
Agnes Scott College	0.84	12960	137	59	Yes	Yes
Alaska Pacific University	0.76	7560	55	15	Yes	No
Albertson College	0.82	13500	158	55	Yes	No

Para el cálculo de la distancia de Gower se necesitan los rangos de las variables continuas:

A continuación se le presenta los rangos de cada una de las variables del ejemplo

Nota: Recuerde que el rango es la diferencia entre el valor máximo y el valor mínimo

tasa.acept	costo	nuevos	tasa.grad
0.846	19360	6357	108

Rangos en cada uno de las universidades

Universidad / Institución	tasa.acept	costo	nuevos	tasa.grad
Abilene Christian University	0.74	7440	721	60
Adelphi University	0.88	12280	512	56

Aplicamos la fórmula para la distancia de Gower

$$\begin{aligned}
\sum_{h=1}^4 \frac{|x_{1h} - x_{2h}|}{R_h} &= \frac{0.74 - 0.88}{0.846} + \frac{7440 - 12280}{19360} + \frac{721 - 512}{6357} + \frac{60 - 56}{108} \\
&= \frac{0.14}{0.846} + \frac{4840}{19360} + \frac{209}{6357} + \frac{4}{108} \\
&\approx 0.1655 + 0.2500 + 0.0329 + 0.0370 \\
&= 0.4854 \quad (\approx 0.483)
\end{aligned}$$

Observe que en este caso las que aportan más son las tasas de aceptación y el costo debido a que tienen un aporte de 0.16 y 0.25 respectivamente.

Se tiene la siguiente información de las dos universidades

Universidad / Institución	privado	elite
Abilene Christian University	Yes	No
Adelphi University	Yes	No

En este caso como ambas variables cualitativas son cero entonces $\beta_{12} = 0$

$$d_{12}^G = \frac{1}{q} \left[\sum_{h=1}^4 \frac{|x_{1h} - x_{2h}|}{R_h} + \beta_{12} \right] = \frac{1}{6} [0.483 + 0] = 0.0805$$

Luego de obtener este resultado lo tenemos que visualizar en un dendrograma.


15 Método de k-medias y k-medioes

15.1 k-medias

Si tenemos dos variables numéricas y ubicamos sus centroides, luego de eso calculamos su distancia y obtenemos el siguiente posible resultado:

K-Medias: Paso 1 (Asignación y Detección de Reasignación)


El punto P_4 detecta menor distancia hacia $g_A^{(0)}$ que hacia su propio grupo $g_B^{(0)}$



Luego se hace esa reasignación y se llega al siguiente resultado

K-Medias: Paso 2 (Actualización de Centroides y Convergencia)

P_4 consolidado en $g_A^{(*)}$. Partición estable según la regla de mínima distancia



Para un número determinado k (grupos) se busca la partición que minimiza algún criterio de decisión, para el cual tener valores más bajos es una indicación de una buena solución.

El criterio más común es la suma de cuadrados dentro de grupo ($SCDG$). Dentro del j -ésimo grupo se obtiene $SCDG_j$ como la suma de las distancias euclídeas cuadráticas de cada punto en el j -ésimo cluster respecto al centroide de ese clúster.

La $SCDG$ total es simplemente la suma de las $SCDG_j$

Si se intenta considerar todas las posibles particiones del conjunto de datos en k grupos se puede llegar a números extremadamente altos de posibilidades, lo cual hace el problema computacionalmente impráctico.

15.1.1 Algoritmo 1

Se toma una partición arbitraria en k clústers que puede venir del resultado de otro método de agrupamiento.

A continuación se le da la serie de pasos para este algoritmo

1. Se calcula la $SCDG$ de la partición inicial.
2. Se calcula la $SCDG$ producida al mover cada individuo del clúster en que se encuentra hacia otro clúster.
3. Se realiza el cambio que lleva a la mayor disminución en el criterio.
4. Repetir pasos 1 y 2 hasta que ningún movimiento produzca disminuciones en el criterio.

15.1.2 Función de $SCDG$

```
load("precalculo.Rdata")
base1=base[,c(19,20,21,22,24)]
```

Cálculo del SCDG

```
scdg=function(base,grupo){
  k = length(unique(grupo))
  sc=0
  for(i in 1:k){
    mat=base[grupo==i,]
    centroide=apply(mat,2,mean)
    sc=sc+sum(as.matrix(dist(rbind(centroide,mat)))[1,-1]**2)
  }
  return(sc)
}
```

```
base1 = as.matrix(base1)
grupo=sample(1:3,nrow(datos),replace=T)
scdg(base1,grupo)
```

```
## [1] 3097.695
```


Obtención de los centroides

```
grupo <- sample(1:3, size = nrow(base1), replace = TRUE)
centros=matrix(nrow=3,ncol=5)
for(j in 1:5) centros[,j]=tapply(base1[,j],grupo,mean)
colnames(centros) = colnames(base1)
rownames(centros) = c(1,2,3)
centros
```

```
## Expectativas Evaluacion EntiendeProf Materialutil CharlasCASE
## 1 6.303030 5.969697 6.696970 6.818182 3.575758
## 2 6.454545 6.121212 7.545455 7.333333 4.121212
## 3 7.121951 6.560976 7.780488 7.756098 3.780488
```

Los centroides dan muy similares en este caso por pura aleatoriedad, pero puede que no sea así

```
plot(base1[,1],base1[,2],col=grupo,pch=18,xlab="Expectativas",ylab="Evaluación")
points(centros[,1],centros[,2],col=1:3,pch="*",cex=2)
```



Calcular los centroides y dependiendo de la posición de estos se reasignan los grupos

```
grupo1=c()
for(i in 1:nrow(base1)){
  disti=c()
  for(j in 1:3){
    disti[j]=dist(rbind(centros[j,],base1[i,]) )
  }
  grupo1[i]=which(disti==min(disti))
}
```

Comparación directa

```
head(cbind(grupo, grupo1),10)
```

```
##      grupo grupo1
## [1,]     3      1
## [2,]     3      3
## [3,]     1      1
## [4,]     3      3
## [5,]     3      1
## [6,]     2      3
## [7,]     1      3
## [8,]     2      1
## [9,]     3      3
## [10,]    3      2
```

Comparación para observar el cambio

```
table(grupo, grupo1)
```

```
##      grupo1
## grupo  1  2  3
##      1 17  5 11
##      2 12  3 18
##      3 14  7 20
```

Esto nos quiere decir que los que comenzaron en la primer agrupación en el grupo 1 y terminaron en el grupo 3 en la segunda agrupación fueron 14. *Nota:* La diagonal son lo que se mantienen en el mismo grupos siempre.

```
datos = base1
grupo=sample(1:3,nrow(datos),replace=T)
scdg1 = c()
n.it = 10
check=1
it = 1
```

```
# 1. Guardar la configuración gráfica original y definir la matriz 2x3
par_orig <- par(no.readonly = TRUE)
par(mfrow = c(2, 3), mar = c(4, 4, 2.5, 1))
```


```
# 2. Bucle iterativo de K-medias
while(check > 0 & it < n.it){
  plot(datos[, 1], datos[, 2], col = grupo, pch = 18,
        xlab = "Expectativas", ylab = "Evaluación",
        main = paste("Iteración", it))
  points(centros[, 1], centros[, 2], col = 1:3, pch = "*", cex = 2)

  scdg1[it] = scdg(datos, grupo)


  for(j in 1:2) centros[, j] = tapply(datos[, j], grupo, mean)

  for(i in 1:nrow(datos)){
    disti = c()
    for(j in 1:3){
      disti[j] = dist(rbind(centros[j, ], datos[i, ]))
    }
    grupo1[i] = which(disti == min(disti))
  }


  check = sum(abs(grupo - grupo1))
  it = it + 1
  grupo = grupo1
}
```



3. Restaurar los parámetros gráficos por defecto
`par(par_orig)`



```
plot(scdg1,xlab="iteración",ylab="SCDG",type="o")
```



Conforme la cantidad de reagrupaciones aumenta, la SCDG disminuye.


Cálculo de la suma de cuadrados dentro para cada cantidad de grupos desde 1 hasta 6

```
SCDG1 = c()
for (k in 1:6) SCDG1[k] = kmeans(base1,centers = k)$tot.withinss
SCDG1
```

```
## [1] 3188.131 2094.630 1645.180 1385.847 1135.892 1063.658
```


Gráficamos el resultado anterior

```
plot(1:6, SCDG1, type = "b", xlab = "Número de grupos",ylab = "SCDG")
```



Forma automática de hacer todo lo anterior

```
library(factoextra)
d = dist(base1)
fviz_nbclust(base1, kmeans, method = "wss", diss = d)
```



Otra forma automática

```
km=kmeans(base1,centers = 3)
```

15.1.3 Algoritmo 2

Se toma una partición arbitraria en k clústers que puede venir del resultado de otro método de agrupamiento.

A continuación se le da la serie de pasos para este algoritmo

1. Se obtiene el centroide de cada clúster.
2. Se asigna cada observación al grupo con el centroide más cercano.
3. Repetir pasos 1 y 2 hasta que no se observen movimientos de observaciones entre clústers.

15.1.4 Desventajas

Este método no es invariante ante cambios de escala.

Impone una estructura esférica en los datos aún cuando no se comporten de esa forma.

Las agrupaciones resultantes pueden variar dependiendo de la asignación aleatoria inicial de los centroides. Para minimizar este problema se recomienda repetir el proceso de *clustering* entre 25-50 veces y seleccionar como resultado definitivo el que tenga menor SCDG. Aun así, solo se puede garantizar la reproducibilidad de los resultados si se emplean semillas.

Presenta problemas de robustez frente a *valores atípicos*. La solución es excluirllos o recurrir a otros métodos de clustering más robustos como *K-medoides*

15.1.5 Mezcla de dendograma con k-medias

```
hkm = hkmeans(x = base1, hc.metric = "euclidean", hc.method = "ward.D", k = 4)
```

15.2 k-medoides

Medoide: elemento dentro de un cluster cuya distancia promedio entre él y todos los demás elementos del mismo cluster es lo menor posible. Es el elemento ubicado más hacia el centro del cluster y, por lo tanto, puede considerarse como el más representativo. El hecho de utilizar medoides en lugar de centroides hace de K-medoids un método más robusto que K-medias, viéndose menos afectado por valores atípicos o ruido. A modo de idea intuitiva puede considerarse como la analogía entre media y mediana.

A continuación se le presenta un ejemplo con la diferencia entre centroide y medoide

Tenemos los siguientes datos

Observación	Peso (kg)	Altura (cm)
P_1	60	160
P_2	65	165
P_3	70	190
Centroide (g)	65.00	171.67

Cálculo del centroide

Coordenada del Peso:

$$\bar{x}_{\text{peso}} = \frac{1}{3} \sum_{i=1}^3 x_{i1} = \frac{60 + 65 + 70}{3} = \frac{195}{3} = \mathbf{65.00 \text{ kg}}$$

Coordenada de la Altura:

$$\bar{x}_{\text{altura}} = \frac{1}{3} \sum_{i=1}^3 x_{i2} = \frac{160 + 165 + 190}{3} = \frac{515}{3} \approx \mathbf{171.67 \text{ cm}}$$

Teniendo claro esto también podemos calcular el medoide, de la siguiente manera:

Primero calculamos las distancias

```
pesos = c(60, 65, 70)
alturas = c(160, 168, 190)

datos = cbind(pesos, alturas)

d = dist(datos, method = "manhattan")
m = as.matrix(d)
m
```

```
##      1  2  3
## 1   0 13 40
## 2  13  0 27
## 3  40 27  0
```

Luego sumamos las filas para ver cuál punto está más cerca de los demás:


```
apply(m, 2, \ (x) mean(x[x != 0])) # Este código es para no incluir a el cero en el promedio
```

```
##      1      2      3
## 26.5 20.0 33.5
```

En este caso el medoide es el punto 2

Comparación entre Centroide (Media) y Medoide (Punto Real)

El centroide es un punto sintético; el medoide es la observación real más central (F



15.3 Algoritmo PAM (partitioning around medoids)

Se toman aleatoriamente k observaciones como medoides iniciales. Previamente se obtiene la matriz de distancias entre todas las observaciones.

A continuación se le da la serie de pasos para este algoritmo

1. Se asigna cada observación al grupo representado por el medoide más cercano.
2. Para cada uno de los clusters creados, comprobar si seleccionando otra observación como medoide se consigue reducir la distancia promedio del cluster, si esto ocurre, seleccionar la observación que consigue una mayor reducción como nuevo *medoide*.
3. Si al menos un medoide ha cambiado en el paso 2, volver al paso 1, de lo contrario, se termina el proceso.

15.3.1 Observaciones sobre k-medoides

Por lo general, este método se utiliza cuando se conoce o se sospecha de la presencia de valores atípicos.

Es recomendable utilizar como medida de similitud la distancia de Manhattan, ya que es menos sensible a valores atípicos que la euclídea.

Para conjuntos de datos grandes necesita muchos recursos computacionales. En tal situación se recomienda aplicar el método CLARA.

15.3.2 CLARA (clustering large applications)

Combina la idea de k-medoides con remuestreo para aplicarlo a grandes volúmenes de datos.

Se selecciona una muestra aleatoria de un tamaño determinado y se aplica el algoritmo de PAM para encontrar los clústers óptimos acorde a esa muestra.

Utilizando esos medoides se agrupan las observaciones de toda la base de datos.

Se calcula la suma de las distancias entre cada observación de la base de datos y su correspondiente medoide.

Se repite este proceso un número predeterminado de veces con el objetivo de reducir el sesgo de muestreo.

Se seleccionan como clústers finales los obtenidos con aquellos medoides que han conseguido la menor suma total de distancias.

15.3.3 Formas automáticas

```
library(cluster)
kmedoids=pam(base1,3)
```

A continuación se usa su variante CLARA

```
clara1=clara(base1,k=3,metric="euclidean",stand=T,samples=2,pamLike = T)
```

16 Creación de grupos o clusteres

Se puede crear una variable categórica, que es la asignación de a cuál grupo pertenece la observación según el tipo de distancia hechos en los dendogramas o diferentes análisis.

Con las distancias

```
# cada uno de los c se obtuvieron en los dendogramas de arriba con su respectivo corte
clust.single = cutree(cs, k=3)
clust.complete = cutree(c.com, k=3)
clust.av = cutree(c.av, k=3)
clust.ward = cutree(c.w, k=3)
```

Con difereres análisis

```
clust.km=km$cluster
clust.kmedoid=kmedoids$cluster
clust.clara = clara1$cluster
clust.hkm = hkm$cluster
```

Comparación de los diferentes métodos

```
table(clust.km,clust.kmedoid)
```

```
##          clust.kmedoid
## clust.km  1  2  3
##          1 28  0  0
##          2  0 42  5
##          3  2  0 30
```

Nota: Recordar hacer el boxplot o algún gráfico que me ayuda a observar las diferencias entre grupos y ver que claramente estos grupos tienen sentido. Ya que lo que se quiere observar es que los grupos sean lo mas diferentes posibles, pero dentro de estos no sean muy variables

```
## Warning: package 'biotools' was built under R version 4.5.3
```

```
## Loading required package: MASS

##
## Attaching package: 'MASS'

## The following object is masked from 'package:dplyr':
##
##      select

## ---
## biotools version 4.3


library(dendextend)
corden=cor.dendlist(dendlist("cs"=as.dendrogram(cs),"csM"=as.dendrogram(csM),"csMan"=as.dendrogram(csMan)),
round(corden,1)
```

16.0.1 Comparación de grupos con variables continuas

```
par_orig = par(no.readonly = TRUE)
par(mfrow = c(2, 3), mar = c(4, 4, 2, 1))

p = ncol(base1)
nombres = colnames(base1)

# 2. Bucle de boxplots
for(i in 1:p){
  boxplot(base1[, i] ~ clust.km,
          xlab = "Grupo",
          ylab = nombres[i],
          main = nombres[i])
}
par(par_orig)
```



La idea de hacer estos boxplots es observar diferencias entre grupos y dentro de los mismos poca variabilidad


16.0.2 Comparación de grupos con variables categóricas

A continuación se tienen los siguientes datos

```
##          Facultad
## Cluster  Ingeniería Económicas Ciencias Sociales
## Cluster 1      40          11              7
## Cluster 2       7          36             10
## Cluster 3       2           9             28
```

```
#par(mar = c(4, 4, 3, 2))
mosaicplot(
  tabla_contingencia,
  shade = TRUE,
  main = "Distribución de Facultades por Conglomerado",
  xlab = "Conglomerado (Cluster)",
  ylab = "Facultad",
  las = 1,
  cex.axis = 0.85
)
```

Distribución de Facultades por Conglomerado




K-medias con PCA, para graficar

La cantidad de grupos la personalizamos dentro del cálculo de `kmeans` que se le da a la función.

```
fviz_cluster(kmeans(base1,centers=4), base1, show.clust.cent = TRUE,
             ellipse.type = "euclid", repel = TRUE) +
labs(title = "Resultados K-medias") +
theme_bw() + theme(legend.position = "none")
```

Resultados K-medias




La idea es que todos los puntos se encuentren dentro de los elipses.

16.0.3 Combinación de dendrograma con gráfico de clúster

```
c.w2 = eclust(base1, k=3,"hclust", hc_metric = "euclidean",hc_method = "ward.D",nboot = 2)

fviz_cluster(c.w2, base1,show.clust.cent = TRUE,
             ellipse.type = "euclid", repel = TRUE) +
  labs(title = "Resultados Distancia de Ward") +
  theme_bw() +
  theme(legend.position = "none")
```

Resultados Distancia de Ward



Métodos difusos

La función `fanny` (fuzzy analysis) de la librería `cluster` permite aplicar el algoritmo c-means clustering (FCM). El parámetro `diss=T` se usa cuando se trabaja a partir de una matriz de distancias, de lo contrario se usa `diss=F` cuando se trabaja con los datos originales. Se debe indicar en `metric` la distancia entre individuos, en `k` el número de grupos y en `stand` si se quiere estandarizar los datos.

A continuación se le presenta este método con la distancia euclídeana para 3 grupos

```
fcm=fanny(base1,k=3,diss=F,metric="euclidean",stand = F)
# Si se quiere usar una matriz de distancias específicas se tiene que colocar diss = T
```

```
head(fcm$membership,5)
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.3333334 0.3333333 0.3333333
## [2,] 0.3333333 0.3333334 0.3333333
## [3,] 0.3333333 0.3333333 0.3333333
## [4,] 0.3333333 0.3333334 0.3333333
## [5,] 0.3333334 0.3333333 0.3333333
```

La idea es que las probabilidades sean lo mas distintas entre sí, de modo que haya una muy grande y las demás muy pequeñas. En la tabla anterior no sucede lo que se quiere con este análisis. Cuando muchos puntos tienen las probabilidades muy similares, como sucedió en el caso anterior se dice que es una base de datos difusa.

Si se usa la distancia de Manhattan en ocasiones el algoritmo de este método no converge por lo que se tiene que usar la siguiente función:

```
fcm=fanny(base1,k=3,diss=F,metric="manhattan",stand = F,maxit = 10000)

head(fcm$membership,5)
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.4179941 0.2909970 0.2910089
## [2,] 0.2196863 0.3901651 0.3901486
## [3,] 0.3637407 0.3181259 0.3181334
## [4,] 0.2282669 0.3858769 0.3858563
## [5,] 0.4027272 0.2986306 0.2986422
```

En este caso la situación mejoró ya que se eliminaron un poco los empates.

16.0.4 Código para sacar la distancia entre la mayor y menor probabilidad de cada observación

```
U = fcm$membership
n = nrow(U)
dif_top2 = c()

for (i in 1:n) {
  fila = U[i, ]
  top2 = sort(fila, decreasing = TRUE)[1:2]
  dif_top2[i] = top2[1] - top2[2]
}

idx_menor = which(dif_top2 < 0.03)
idx_mayor = which(dif_top2 >= 0.03) # Casos bien definidos

# Conteos
table(dif_top2 > 0.03) # Condición de cuales tienen una diferencia mayor al umbral

##
## FALSE TRUE
##    68   39
```

16.0.5 ¿Que tan difusos están los datos?

Note que hay individuos que tienen probabilidades de pertenencia muy similares en varios grupos. Esto es una indicación de que hay mucho puntos frontera (difusos). Para medir el nivel de difusión, existe el índice de Dunn, los valores normalizados próximos a 0 indican que la estructura tiene un alto nivel difuso y valores próximos a 1 lo contrario. Para obtener esto use `fcm$coef`.

```
fcm$coef

## dunn_coef normalized
## 0.3426727 0.0140091
```

16.1 Obtención del número de grupos óptimo mediante el método de la silueta promedio

Para cada observación i se calcula el coeficiente silueta de la siguiente forma:

- Calcular el promedio de las distancias entre la observación i y el resto de observaciones que pertenecen al mismo cluster. Este valor se llama a_i . Cuanto menor sea a_i , mejor ha sido la asignación de i a su cluster.
- Calcular la distancia promedio entre la observación i y el resto de clusters. Entendiendo por distancia promedio entre i y un determinado clúster C como la media de las distancias entre i y las observaciones


del clúster C .

- Llame b_i a la menor de las distancias promedio entre i y el resto de los clústers, es decir, la distancia al cluster más próximo.

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

A continuación se le presenta el código en *r* de este proceso

```
fviz_nbclust(base1, kmeans, method = "silhouette", diss = d)
```



16.1.1 Cluster Jerárquico con Silueta

```
length(cutree(c.com, 2)) # Observaciones en el árbol c.com


## [1] 107

nrow(base1) # Observaciones en base1

## [1] 107

sil.k=c()
n.clust=2:15
for(i in 1:length(n.clust)){
  s=silhouette(cutree(c.com,n.clust[i]),get_dist(x = base1, method = "euclidean"))
  sil.k[i]=summary(s)[[4]]
}
```

```
data.frame(clusters = 2:15, silueta = sil.k) %>%
  ggplot(aes(x = clusters, y = silueta)) +
    geom_line() +
    geom_point() +
    scale_x_continuous(breaks = 2:15) +
    theme_bw()
```



16.2 Estadístico GAP

Este estadístico compara, para diferentes valores de k , la varianza total *intra-cluster* observada frente al valor esperado acorde a una distribución uniforme de referencia.

La estimación del número óptimo de clusters es el valor k con el que se consigue maximizar el estadístico gap, es decir, encuentra el valor de k con el que se consigue una estructura de clusters lo más alejada posible de una distribución uniforme aleatoria.

Este método puede aplicarse a cualquier tipo de *clustering*.

16.2.1 Construcción del estadístico WAP

Hacer clustering de los datos para un rango de valores de k y para cada uno calcular la varianza total intracluster (W_k). Es decir que tan separados están los clusters.

Simular B conjuntos de datos de referencia, todos con una distribución uniforme. Aplicar clustering a cada uno de los conjuntos con el mismo rango de valores k empleado en los datos originales, calculando en cada caso la varianza total intra-cluster (W_{kb}). Se recomienda $B = 500$.


Calcular el estadístico gap para cada valor de k :

$$\begin{aligned} gap(k) &= \frac{1}{B} \sum_{b=1}^B \log(W_{kb}) - \log(W_k) \\ &= \frac{1}{B} \sum_{b=1}^B \log\left(\frac{W_{kb}}{W_k}\right) \end{aligned}$$

Nota: Si $\frac{W_{kb}}{W_k} \rightarrow 1$, el resultado tiende a cero.

A continuación se le presenta el código en *r* para realizar el cálculo de este estadístico

```
fviz_nbclust(base1, kmeans, method = "gap", diss = d)
```




16.3 Validación

El uso combinado de las funciones `eclust` y `fviz_silhouette` de la librería `factoextra` permiten obtener los coeficientes de silueta de forma sencilla. La función `eclust`, gracias a su argumento `FUNcluster`, facilita el uso de múltiples algoritmos de clustering mediante una misma función (internamente llama a las funciones `kmeans`, `hclust`, `pam`, `clara`, etc). Use las siguientes instrucciones:

```
km1 = eclust(base1, FUNcluster = "kmeans", k = 3, hc_metric = "euclidean", nstart = 50, graph = F)
fviz_silhouette(sil.obj = km1, print.summary = TRUE)
```

```
## cluster size ave.sil.width
## 1      1  31      0.32
## 2      2  31      0.24
## 3      3  45      0.24
```



La idea con este gráfico es que todos los valores siempre se vean positivos, en este caso el cluster tres podemos ver que tienen algunos puntos con una muy baja silueta, esto nos indica que algunos puntos están como en la frontera, para solucionar ese problema usamos los métodos difusos que vimos anteriormente y que se encuentran en páginas anteriores.

16.4 Índice Dunn

16.4.1 Índice Dunn

Para cada clúster, se calcula la distancia intracúster como el máximo de las distancias entre todos los individuos de ese clúster.

$$\Delta_i = \max_{x,y \in C_i} (x,y)$$

También puede usar como distancia intracúster la distancia media entre todos los pares del clúster, o la distancia media de todos los puntos a su centroide.

Para cada par de clústers, se calcula una medida de distancia entre clústers (D_{ij}).

El índice Dunn se calcula como:

$$D = \frac{\min_{i \neq j} D_{ij}}{\max_k \Delta_k}$$

Si la estructura contiene *clusters* compactos y bien separados, el numerador es grande y el denominador pequeño, dando lugar a valores altos de D.

El objetivo es maximizar el índice *Dunn*.

Esta forma de evaluar la calidad del *clustering* tiene un inconveniente. Si todos los *clusters* tienen un comportamiento ideal excepto uno, cuya calidad es baja, dado que el denominador emplea el máximo en lugar de la media, el índice estará totalmente influenciado por este *clúster* enmascarando al resto. Es importante tener en cuenta que se trata de un indicador de tipo “el peor de los casos”.

A continuación se le presenta el código en r para obtener el índice

```
#install.packages("fpc")
library(fpc)
km_indices = cluster.stats(d, clust.km)
km_indices$dunn
```

```
## [1] 0.1344332
```

Nota: Lo que se quiere siempre es buscar un índice de Dunn lo más bajo posible.


16.5 Mapas de calor (heatmaps)

Los mapas de calor son el resultado obtenido al representar una matriz de valores en la que, en lugar de números, se muestra un gradiente de color proporcional al valor de cada variable en cada posición.

La combinación de un dendrograma con un heatmap permite ordenar por semejanza las filas y/o columnas de la matriz, a la vez que se muestra con un código de colores el valor de las variables.

Se consigue así representar más información que con un simple dendrograma y se facilita la identificación visual de posibles patrones característicos de cada cluster.

```
heatmap(base1, scale = "none",
        distfun = function(x){dist(x, method = "euclidean")},
        hclustfun = function(x){hclust(x, method = "ward.D")},
        cexRow = 0.7)
```



Observe que en el anterior gráfico se puede ver que el dendrograma del eje vertical divide dos grupos, por esta razón es que la parte de abajo es más claro que las partes de arriba. Lo mismo ocurre con el dendrograma de la parte superior en donde igualmente se divide en dos grupos y por ello la parte de la izquierda del mapa de calor es más claro que las parte que siguen a la derecha.

Nota: Este gráfico está hecho para dendrograma si el análisis que está ganando es el de k-medias o el de k-mediodes, esta figura no aplica.