

Manual para el curso Minería de Datos y Análisis Multivariado (XS-0126)

Autor: Anderson Martínez

Colaboradores: Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1	Aprendizaje supervisado	1
2	Aprendizaje no supervisado	1
3	Diferencia entre aprendizaje supervisado y no supervisado	2
4	Características del aprendizaje no supervisado	2
5	Proceso de Análisis de componentes principales (PCA)	5
5.1	Maldición de la dimensionalidad	6
5.2	Requisitos para que PCA tenga sentido	6
5.3	Ejemplo de aplicación	6
6	Comparación de análisis factorial con componentes principales	8
6.1	Ejemplo de análisis factorial	8
6.2	Diferencias entre análisis factorial y PCA	9
7	Valores y Vectores propios	9
7.1	¿Cuándo centrar y cuándo estandarizar?	10
7.2	Valores y vectores propios en R	10
7.3	Construcción de Z's	12

1 Aprendizaje supervisado

Se aprenden funciones, relaciones que asocian entradas con salidas, por lo que se ajustan a un conjunto de ejemplos de los que conocemos la relación entre la entrada y la salida deseada.

Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre:

- Modelos de clasificación, si la salida es un valor categórico (por ejemplo, una enumeración, o un conjunto finito de clases).
- Modelos de regresión, si la salida es un valor de un espacio continuo.

2 Aprendizaje no supervisado

No estamos interesados en ajustar pares (entrada, salida), sino en aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros que provengan del mismo fenómeno), por ejemplo:

- Dando una agrupación de los datos según su similitud.

- Simplificando la estructura de los mismos manteniendo sus características fundamentales (como en los procesos de reducción de la dimensionalidad).
- Extrayendo la estructura interna con la que se distribuyen los datos en su espacio original (aprendizaje topológico).

3 Diferencia entre aprendizaje supervisado y no supervisado

El aprendizaje supervisado tiene variable respuesta Y , mientras que el aprendizaje no supervisado no la tiene. Además es importante resaltar que el no supervisado es más descriptivo.

4 Características del aprendizaje no supervisado

- No existe una salida o variable respuesta, por lo que no se utiliza un modelo que relacione un conjunto de variables con una respuesta.
- Esto hace que sea difícil validar los resultados, al contrario del aprendizaje supervisado en el que existen métricas que permiten evaluar con claridad la bondad del aprendizaje realizado.
- Es parte de un análisis exploratorio de datos.
- Algoritmos no supervisados resultan ser muy costosos porque requieren de más pruebas de ensayo y error, haciendo que requieran de un aparataje teórico y computacional mucho más elaborado.

Ejemplo 1

Suponga que tiene la siguiente regresión:

$$\mu_{y|x} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_{p-1} X_{p-1}$$

Recuerde que $\mu_{y|x}$ es la respuesta

Se tiene el siguiente subconjunto de X 's:

$$X_1, \dots, X_k \text{ Altamente Correlacionadas}$$

Nota: Cuando las X 's están muy correlacionadas hay problemas de multicolinealidad y eso nos infla los errores estándar.

Note que este conjunto de variable es de dimensión k , esto lo que nos dice en realidad es que estas X 's miden un subconjunto menor de conceptos, lo que nos lleva al siguiente conjunto:

$$Z_1, \dots, Z_q$$

Donde $q < k$ (No Correlacionadas)

Reemplazado en el modelo original tenemos el siguiente resultado:

$$\mu_{y|x,z} = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \dots + \beta_q Z_q + \beta_{k+1} X_{k+1}$$

En este modelo la primera parte es no supervisado ya que no utilizamos la variable respuesta, para el último modelo obtenido si es supervisado ya que se utiliza con la variable respuesta.

Ejemplo 2


1. Se tienen $X_1, \dots, X_p$ Grupos
2. Formo k grupos

3. Se crea una variable G , la cual se crea a partir del aprendizaje no supervisado. Ya que se crea basado en las X 's

Observación (i)	X_1	X_2	$\dots$	X_p	$G = f(X_1, \dots, X_p)$
1	x_{11}	x_{12}	$\dots$	x_{1p}	g_1
2	x_{21}	x_{22}	$\dots$	x_{2p}	g_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
i	x_{i1}	x_{i2}	$\dots$	x_{ip}	g_i
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
n	x_{n1}	x_{n2}	$\dots$	x_{np}	g_n

Nota: Si agregamos una variable edad, podríamos realizar un análisis de varianza, ya que dicha variable funcionaría como una variable respuesta.

Distribución de Edad por Grupo



Ejemplo 3

Observación (i)	Altura (cm)	N.º de Hojas	Grosor del Tallo (mm)	Peso del Racimo (kg)	pH del Suelo
1	24.5	6	3.2	0.45	5.4
2	28.1	7	3.8	0.58	5.6
3	31.4	8	4.1	0.65	5.5
4	52.6	14	7.5	1.85	6.1
5	58.0	15	8.2	2.10	6.3

Observación (<i>i</i>)	Altura (cm)	N.º de Hojas	Grosor del Tallo (mm)	Peso del Racimo (kg)	pH del Suelo
6	61.3	17	8.9	2.40	6.2
7	84.7	22	12.4	4.15	6.8
8	89.2	25	13.1	4.60	7.0

Note que la Altura (cm), N.º de Hojas, Grosor del Tallo (mm), Peso del Racimo (kg) están muy correlacionadas, mientras que el H del Suelo no tanto.

Con esas variables correlacionadas puede crear una variable Z_1

```
library(ggplot2)
library(dplyr)
# 1. Definir los datos de la tabla (8 observaciones)
datos <- data.frame(
  obs      = 1:8,
  altura   = c(24.5, 28.1, 31.4, 52.6, 58.0, 61.3, 84.7, 89.2),
  hojas    = c(6, 7, 8, 14, 15, 17, 22, 25),
  grosor   = c(3.2, 3.8, 4.1, 7.5, 8.2, 8.9, 12.4, 13.1),
  peso     = c(0.45, 0.58, 0.65, 1.85, 2.10, 2.40, 4.15, 4.60),
  ph_suelo = c(5.4, 5.6, 5.5, 6.1, 6.3, 6.2, 6.8, 7.0)
)


# 2. Extracción de Z_1 como el Primer Componente Principal (CP1 estandarizado)
# Z_1 captura la mayor parte de la variabilidad conjunta del crecimiento/rendimiento
pca_morfologia <- prcomp(
  datos[, c("altura", "hojas", "grosor", "peso")],
  center = TRUE,
  scale. = TRUE
)

# Asignar los scores de Z_1 al dataframe
datos$Z1 <- pca_morfologia$x[, 1]

# 3. Scatterplot con ggplot2
ggplot(datos, aes(x = ph_suelo, y = Z1)) +
  geom_point(color = "#1f77b4", size = 4, alpha = 0.9) +
  geom_smooth(method = "lm", se = TRUE, color = "#d62728", linetype = "dashed", fill = "#e0e0e0", alpha = 0.5) +
  labs(
    title = expression(bold("Diagrama de Dispersión:") ~ bolditalic(Z)[1] ~ bold("vs. pH del Suelo")),
    subtitle = expression(italic(Z)[1] ~ "construida como el primer componente principal (" * CP[1] * ")"),
    x = "pH del Suelo",
    y = expression(italic(Z)[1] ~ "(Índice Morfológico /" ~ CP[1] * ")")
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold", hjust = 0.5),
    plot.subtitle = element_text(hjust = 0.5, color = "gray35", margin = margin(b = 10)),
    axis.title = element_text(face = "bold"),
    panel.grid.minor = element_blank()
  )
```

Diagrama de Dispersión: Z_1 vs. pH del Suelo

Z_1 construida como el primer componente principal (CP_1)



5 Proceso de Análisis de componentes principales (PCA)

$$\mu_{y|x_1, x_2, x_3, x_4} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4$$

Suponga que X_2, X_3, X_4 están muy correlacionadas, para ello se crea una variable Z_1 .

$$\mu_{y|x_1, z_1} = \beta_0 + \beta_1 X_1 + \gamma_1 Z_1$$

Sin embargo, como pasamos de tres variables (X_2, X_3, X_4) a una (Z_1) perdemos cierta información. Es decir Z_1 explica un cierto porcentaje de (X_2, X_3, X_4). Por ejemplo Z_1 explica un 80% de (X_2, X_3, X_4).

Se puede dar el caso que Z_1 no explique suficiente.

Existe otro modelo que puede explicar más que el siguiente:

$$\mu_{y|x_1, x_3} = \beta_0 + \beta_1 X_1 + \beta_3 X_3$$

Nota: Es importante resaltar que los tres modelos anteriores no son lo mismo, cada uno tiene sus ventajas y desventajas.

El PCA sirva para eliminar la multicolinealidad, solo si lo queremos usar para una regresión. Otro uso que se le puede dar es para obtener gráficos más simples.

5.1 Maldición de la dimensionalidad

- Cuando se cuenta con demasiadas variables es difícil hacer un análisis gráfico para tener una idea inicial del comportamiento de los datos.
- Muchas variables son un obstáculo para aplicar otras técnicas multivariadas.

5.2 Requisitos para que PCA tenga sentido

- Si las variables originales casi no están correlacionadas, nada se gana al llevar a cabo un PCA.
- Cuando el determinante de una matriz es cero, se tiene que hay columnas linealmente dependientes. Esto se llama multicolinealidad.
- Si el determinante de la matriz de correlación (R) es cercano a cero, hay indicación de altas correlaciones entre las variables, de lo contrario, cuando el determinante es alto un PCA puede no tener sentido.

5.3 Ejemplo de aplicación

Se tienen los siguientes datos

Observación (<i>i</i>)	X_1	X_2	X_3	X_4
1	3	4	2	5
2	5	1	1	3
3	4	3	3	2
4	2	7	4	0
$\bar{X} \rightarrow$	3.6	3.75	2.5	2.5
$S \rightarrow$	1.24	2.5	1.24	2.05

Luego estandarizamos mediante la siguiente fórmula:

$$X_i = \frac{X_i - \bar{X}}{S_i}$$

```
# 1. Definición de la matriz de datos X (4 observaciones x 4 variables)
X <- matrix(
  c(
    3, 4, 2, 5,
    5, 1, 1, 3,
    4, 3, 3, 2,
    2, 7, 4, 0
  ),
  nrow = 4,
  byrow = TRUE,
  dimnames = list(paste0("ID_", 1:4), paste0("X", 1:4))
)

# 2. Visualizar resultados
print("Matriz Original X:")

## [1] "Matriz Original X:"
```

```

print(X)

##      X1 X2 X3 X4
## ID_1  3  4  2  5
## ID_2  5  1  1  3
## ID_3  4  3  3  2
## ID_4  2  7  4  0

# 2. Estandarización con scale()
# scale() por defecto resta la media muestral (center = TRUE)
# y divide entre la desviación estándar muestral s con n-1 grados de libertad (scale = TRUE)
Z <- scale(X, center = TRUE, scale = TRUE)
print("Matriz Estandarizada Z (Z-scores):")

## [1] "Matriz Estandarizada Z (Z-scores):"

print(round(Z, 4))

##      X1  X2  X3  X4
## ID_1 -0.3873  0.1 -0.3873  1.2010
## ID_2  1.1619 -1.1 -1.1619  0.2402
## ID_3  0.3873 -0.3  0.3873 -0.2402
## ID_4 -1.1619  1.3  1.1619 -1.2010
## attr("scaled:center")
##      X1  X2  X3  X4
## 3.50 3.75 2.50 2.50
## attr("scaled:scale")
##      X1      X2      X3      X4
## 1.290994 2.500000 1.290994 2.081666

```

Interpretación El ID_4 en X_1 está 1.16 desviaciones estándar debajo la media (recuerde que la desviación estándar de X_1 es 1.29). Para el ID_1 está 0.1 desviaciones estándar sobre la media, es decir está prácticamente en la media.

Nota: El máximo de desviaciones estándar en una normal son 3 que son el 99.7% de los datos.

Luego obtenemos los coeficientes para Z_1 y hacemos la siguiente regresión:

$$Z_1 = 0.2X_1^s + 0.4X_2^s + 0.01X_3^s + 0.5X_4^s$$

Nota: En regresión estandarizabamos los coeficientes para poder compararlos en este caso, estandarizamos y la que tiene más peso en el resultado de Z_1 es X_4

Luego sustituimos con los valores que tenemos

$$\begin{aligned}
 Z_1^{(1)} &= 0.2(-0.39) + 0.4(0.10) + 0.01(-0.39) + 0.5(1.20) \\
 &= -0.078 + 0.040 - 0.0039 + 0.600 = \mathbf{0.5581}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(2)} &= 0.2(1.16) + 0.4(-1.10) + 0.01(-1.16) + 0.5(0.24) \\
 &= 0.232 - 0.440 - 0.0116 + 0.120 = \mathbf{-0.0996}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(3)} &= 0.2(0.39) + 0.4(-0.30) + 0.01(0.39) + 0.5(-0.24) \\
 &= 0.078 - 0.120 + 0.0039 - 0.120 = \mathbf{-0.1581}
 \end{aligned}$$

$$\begin{aligned}
 Z_1^{(4)} &= 0.2(-1.16) + 0.4(1.30) + 0.01(1.16) + 0.5(-1.20) \\
 &= -0.232 + 0.520 + 0.0116 - 0.600 = \mathbf{-0.3004}
 \end{aligned}$$

Nota: Si uno tiene p variables originales, puede llegar a p variables nuevas, la idea es siempre obtener menos que p

Más adelante se explicará la obtención de los Z 's mediante la descomposición espectral.

Además los coeficientes de los Z 's, como están normalizados la suma de ellos es igual a 1.

Sub-Ejemplo

Se tiene el siguiente Z

$$Z_2 = 0.8X_1 + 0.8X_2 + 0.01x_3 + 0.01X_4$$

Como X_3, X_4 prácticamente no pesan, por lo que se interpretaría como un promedio entre X_1 y X_2

Para este otro caso

$$Z_3 = 0.8X_1 + 0.6X_2 + 0.5x_3 + 0.01X_4$$

En esta situación es una especie de ponderación donde el que tiene más peso es X_1

Caso inusual

$$Z_4 = 0.5X_1 - 0.5X_2 + 0.01x_3 + 0.01X_4$$

- Si $X_1 = X_2 = 0$ significa que está muy parecido

PREGUNTAR

- Si $X_1 > X_2$
- Si $X_1 < X_2$

6 Comparación de análisis factorial con componentes principales

- La estructura del análisis de factores es similar a los componentes principales.
- En componentes principales las variables conocidas X se combinan con los coeficientes a para producir nuevas variables Z llamadas componentes principales. Una propiedad importante en el análisis de componentes principales es $Cov(Z_i, Z_j) = 0$
- En factores se combinan factores latentes desconocidos f para formar las variables conocidas X . Esto es más complejo

6.1 Ejemplo de análisis factorial

Tenemos un estudio con f_1 que es la habilidad cuantitativa de una persona y f_2 es la habilidad de razonamiento verbal, para estos dos variables no tienen una forma directa de medirse, ya que f_1 se podría medir mediante un problema o un cuestionario, pero dentro de las preguntas del cuestionario, mientras se mide la habilidad cuantitativa, también se podría estar midiendo el razonamiento verbal, ya que la persona necesita entender la pregunta para resolver el problema.

Por ejemplo una persona obtuvo en una pregunta un valor de $f_1 = 0.5$ y $f_2 = 0.5$, asuma que $\lambda_{11} = 7$ y $\lambda_{12} = 7.5$

Esto nos lleva a que

$$7.25 = 0.5 * 7 + 0.5 * 7.5$$

En otra pregunta se tiene el resultado de otro puntaje, sin embargo lo que cambia es f_1 y f_2 , en el caso de los λ 's no cambian y se pueden obtener por medio de **PCA**, esta es la confusión que muchas personas tienen con este tema.

Factores comunes	Componentes principales
$\begin{aligned} X_1 &= \lambda_{11}f_1 + \lambda_{12}f_2 + \cdots + \lambda_{1m}f_m + \eta_1 \\ X_2 &= \lambda_{21}f_1 + \lambda_{22}f_2 + \cdots + \lambda_{2m}f_m + \eta_2 \\ &\vdots \\ X_q &= \lambda_{q1}f_1 + \lambda_{q2}f_2 + \cdots + \lambda_{qm}f_m + \eta_q \end{aligned}$	$\begin{aligned} Z_1 &= a_{11}X_1^s + a_{12}X_2^s + \cdots + a_{1q}X_q^s \\ Z_2 &= a_{21}X_1^s + a_{22}X_2^s + \cdots + a_{2q}X_q^s \\ &\vdots \\ Z_q &= a_{q1}X_1^s + a_{q2}X_2^s + \cdots + a_{qq}X_q^s \end{aligned}$

6.2 Diferencias entre análisis factorial y PCA

Factores comunes	Componentes principales
- El interés es la explicación de la estructura de covarianza o de correlación (o ambas) entre las variables medidas. - Puede haber cambios sustanciales en todos los factores si se cambia el número de factores. - El cálculo de los puntajes es complejo y existen varios métodos. - Se obtienen resultados equivalentes si se usa la matriz de covarianza o la de correlaciones. - Si las variables están casi no correlacionadas este análisis no tiene sentido. - En tal caso los factores no tienen nada que explicar.	- El interés se centra en la explicación de la variabilidad total del conjunto de variables (Como una regresión). - Si el número de componentes que se utilizan se incrementa, esos componentes no cambian. - El cálculo de los puntajes es sencillo y se basa en una única descomposición espectral. No hay relación directa entre los componentes obtenidos de la matriz de covarianza y la de correlaciones. - Si las variables están casi no correlacionadas este análisis no tiene sentido. - En tal caso se obtienen componentes que son muy similares a las variables originales.

Nota: Al agregar Z 's en componentes principales, las coeficientes para obtener los componentes no cambien, en cambio en análisis factorial al yo incluir más cosas que quiero medir (X 's), las f cambian. Además, si las variancias específicas son pequeñas ambos análisis dan resultados similares.

7 Valores y Vectores propios

A continuaci3n el siguiente tema se explica mediante un ejemplo.

Tenemos la siguiente matriz de varianzas y covarianzas:

$$\mathbf{S} = \begin{bmatrix} 8 & 10 & -3 \\ 10 & 6 & -4 \\ -3 & 4 & -2 \end{bmatrix}$$

Note que la $tr(\mathbf{S}) = 8 + 6 + 2 = 16$, esta corresponde a la suma de las varianzas, lo que signica que es la **Varianza total**

Una vez teniendo esto podemos calcular la matriz de correlaci3n por medio de la siguiente f3rmula:

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}$$

Nota: Recordar que en la diagonal la correlación es 1 ya que es la misma variable.

$$\mathbf{R} = \begin{bmatrix} 1 & 1.44 & -0.75 \\ 1.44 & 1 & -1.16 \\ -0.75 & 1.16 & 1 \end{bmatrix}$$

La $tr(R) = 3$, esta representa el número de variables. Además la matriz de correlaciones es la estandarización de una matriz de varianzas y covarianzas en este caso, ya que la varianza de cada una de las variables es 1. Esto nos lleva a la siguiente equivalencia:

$$Cov(X_i^s, X_j^s) = r_{ij}$$

Así que la $tr(R) = 3$ representa que la varianza total de las variables estandarizadas.

7.1 ¿Cuándo centrar y cuándo estandarizar?

Cuando se tienen variables con las mismas escalas solo se necesitan centrar, pero cuando son muy diferentes es altamente recomendado estandarizarlos.

7.2 Valores y vectores propios en R

Valores propios

```
valores = c(8, 10, -3, 10, 6, 4, -3, 4, 2)
S = matrix(
  valores,
  nrow = 3,
  ncol = 3,
  byrow = TRUE
)

v = eigen(S)
round(v$values, 2)
```

```
## [1] 17.07 5.04 -6.11
```

Esto nos dice que $\lambda_1 = 17.07$, $\lambda_2 = 5.04$, $\lambda_3 = -6.11$

Note que la suma de estos valores no da la varianza total original

```
sum(v$values)
```

```
## [1] 16
```

Vectores propios

Estos deben cumplir con la propiedad de que:

$$A \times a = \lambda \times a$$

A continuación se le representa el proceso en R, para obtenerlos

Tenemos la matriz asociada a los vectores propios

```
v$vectors
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.73550267 -0.3755265  0.5639288
## [2,] 0.67670738  0.3663738 -0.6386215
## [3,] 0.03321052  0.8513226  0.5235904
```

Los extraemos de la misma matriz

```
e1 = v$vectors[, 1] # Asociado a lambda_1 = 17.06
e2 = v$vectors[, 2] # Asociado a lambda_2 = 5.05
e3 = v$vectors[, 3] # Asociado a lambda_3 = -6.11
```

Verificamos con la condición de modo que $S \%*\% e_1 == \lambda_1 * e_1$

```
t(round(S \%*\% e1, 4))
```

```
##           [,1]      [,2]      [,3]
## [1,] 12.5515 11.5481  0.5667
```

```
round(v$values[1] * e1, 4)
```

```
## [1] 12.5515 11.5481  0.5667
```

Observe que la condición se cumple.

También otra propiedad que se tiene que resaltar es la ornormalidad de los mismos.

Verificación sobre si la norma es 1

```
# Norma 1: ||e_1|| = 1
sqrt(sum(e1^2))
```

```
## [1] 1
```

Verificación de ortogonalidad


```
# Ortogonales entre sí: e_1 \%*\% e_2 = 0
round(t(e1) \%*\% e2, 4)
```

```
##           [,1]
## [1,]      0
```

7.3 Construcción de Z's

Cambio de Base en ACP: Traslación y Rotación de Ejes

Lectura de coordenadas (X_1, X_2) vs. Puntuaciones (Z_1, Z_2)



Observando la figura anterior tenemos que:

$X_1 = 5.5 \rightarrow Z_1 = 1.95$ y $X_2 = 3.2 \rightarrow Z_2 = -0.82$. Con lo siguiente $r_{x_1, x_2} = 0.45 \rightarrow r_{z_1, z_2} = 0$

¿Cómo se construyen los Z's de la figura anterior?

- Si se utiliza la matriz de correlaciones, se deben estandarizar las variables, esto se hace cuando las escalas de las variables son similares. ($X_1^s, X_2^s \rightarrow S$)
- Si se utiliza la matriz de covarianzas y varianzas, se debe centrar solamente, sin embargo esto se debe hacer solo cuando las escalas sean muy similares. ($X_1^c, X_2^c \rightarrow R$)

Proceso de obtención de los Z's

Sabemos que en el anterior ejercicio los vectores propios son:

El primer vector propio es 0.74 0.67

El segundo vector propio es -0.67 0.74

Tenemos que las medias son:

Media de X_1 es 3.5

Media de X_2 es 2.5

Hacemos las operaciones para llegar al resultado

$$\begin{aligned}
Z_1 &= 0.74 X_1^c + 0.67 X_2^c \\
&= 0.74 (5.5 - 3.5) + 0.67 (3.2 - 2.5) \\
&= 0.74 (2.0) + 0.67 (0.7) \\
&= 1.48 + 0.469 \\
&= 1.95
\end{aligned}$$

$$\begin{aligned}
Z_2 &= -0.67 X_1^c + 0.74 X_2^c \\
&= -0.67 (5.5 - 3.5) + 0.74 (3.2 - 2.5) \\
&= -0.67 (2.0) + 0.74 (0.7) \\
&= -1.34 + 0.518 \\
&= -0.82
\end{aligned}$$

Haciendolo en una base de datos grande lo que se está haciendo es lo siguiente:

$$\mathbf{X}^c = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & x_{n3} \end{bmatrix} - \begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \vdots & \vdots & \vdots \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \end{bmatrix}$$

Luego se multiplica por el vector propio:

$$\mathbf{X}^c = \begin{bmatrix} x_{11}^c & x_{12}^c & x_{13}^c \\ x_{21}^c & x_{22}^c & x_{23}^c \\ \vdots & \vdots & \vdots \\ x_{n1}^c & x_{n2}^c & x_{n3}^c \end{bmatrix} \cdot \begin{bmatrix} a_{11} \\ a_{22} \\ a_{33} \end{bmatrix} = \begin{bmatrix} Z_{1(1)} \\ Z_{2(1)} \\ \vdots \\ Z_{n(1)} \end{bmatrix}$$

Con esto llegamos obtener el vector con los valores de la primera variable nueva, para todos los individuos de la base de datos o lo que es lo mismo que decir que el vector del primer componente principal.

Nota: Si se calculan las varianzas de los Z 's da como resultado los λ 's encontrados para los vectores propios, por lo que la variabilidad total es igual si se mantiene el mismo número de variables originales.