

Manual para el curso Minería de Datos y Análisis Multivariado (XS-0126)

Autor: Anderson Martínez

Colaboradores: Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1	Aprendizaje supervisado	2
2	Aprendizaje no supervisado	3
3	Diferencia entre aprendizaje supervisado y no supervisado	3
4	Características del aprendizaje no supervisado	3
5	Proceso de Análisis de componentes principales (PCA)	5
5.1	Maldición de la dimensionalidad	6
5.2	Requisitos para que PCA tenga sentido	6
5.3	Ejemplo de aplicación	6
6	Comparación de análisis factorial con componentes principales	8
6.1	Ejemplo de análisis factorial	9
6.2	Diferencias entre análisis factorial y PCA	9
7	Valores y Vectores propios	10
7.1	¿Cuándo centrar y cuándo estandarizar?	10
7.2	Valores y vectores propios en R	10
7.3	Construcción de Z 's	12
8	HEPTATLON	13
8.1	Proceso de cambios en las variables	13
8.2	Matriz de correlaciones	14
8.2.1	Cálculo en R	14
8.2.2	Gráfico de correlación librería corrgram de colores	14
8.2.3	Gráfico de correlación librería corrgram de números (correlaciones)	15
8.2.4	Gráfico del paquete corplot	15
8.3	Análisis de valores extremos mediante leverage	16
8.3.1	Formas de averiguar y eliminar el valor extremo	17
8.4	Obtención del determinante de la matriz R	17
8.5	Hipótesis de matriz de correlaciones	18
8.6	KMO	18
8.7	Análisis con la matriz de covarianzas	19
8.7.1	Comparación de varianzas de las variables	19
8.7.2	Descomposición espectral de matriz de covarianzas	19
8.8	Obtención de los componentes principales Z 's	21
8.8.1	Cálculo de cuánto porcentaje explica el componente	21

8.8.2	¿Es normal que tenga media cero?	22
8.8.3	Forma automática con <code>prcomp()</code>	22
9	Análisis con matriz de correlaciones	23
9.1	Estadizarizando las variables pprmero	23
9.2	Descomposición espectral de la matriz de correlaciones y obtención de los valores propios.	24
9.3	Porcentaje de explicación de un componente principal	25
9.4	Forma automática	25
9.5	Obtención del primer componente manualmente	26
9.6	Comparación de Varianza y lambdas	26
9.7	Cambio a los signos de los coeficientes de Z_1	27
10	Biplot	27
10.1	Biplot categórico	28
11	Gráfico de sedimentación	29
11.0.1	Conclusión de estudio	30
11.1	Reproducción de la matriz de correlaciones	30
11.2	Obtención de correlaciones	32
12	Prueba de los componentes en una regresión	32
12.1	Forma automática	33
12.2	Interpretaciones de regresión	33
13	Conglomerados	34
13.1	Distancias entre individuos	34
13.2	Distancia Euclidea	34
13.3	Distancia de Mahalanobis	36
13.4	Distancia City-block (Manhattan)	38
13.4.1	Nota importante de las distancias	39
14	Ejemplo de aplicación con temperaturas de diferentes cantones de Costa Rica	39
14.0.1	Cálculo distancia euclidiana	40
14.0.2	¿Que sucede si transponemos la base?	40
14.0.3	Extracción de valores de un objeto <code>dist()</code>	41
14.0.4	Cálculo distancia de Mahalanobis	42
14.0.5	Cálculo distancia de Manhattan	42
14.1	Creación de dendogramas	42
14.1.1	K-vecino más cercano	42
14.1.2	K-vecino más lejano	44
14.1.3	Salto promedio	46
14.1.4	Distancia de Ward	48
14.2	¿Los dos cantones más correlacionados son los cantones que menor distancia tienen?	50
14.3	¿Que ocurre cuando tenemos variables categóricas?	58
14.3.1	Ejemplo de las universidades	58

1 Aprendizaje supervisado

Se aprenden funciones, relaciones que asocian entradas con salidas, por lo que se ajustan a un conjunto de ejemplos de los que conocemos la relación entre la entrada y la salida deseada.

Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre:

- Modelos de clasificación, si la salida es un valor categórico (por ejemplo, una enumeración, o un conjunto finito de clases).

- Modelos de regresión, si la salida es un valor de un espacio continuo.

2 Aprendizaje no supervisado

No estamos interesados en ajustar pares (entrada, salida), sino en aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros que provengan del mismo fenómeno), por ejemplo:

- Dando una agrupación de los datos según su similitud.
- Simplificando la estructura de los mismos manteniendo sus características fundamentales (como en los procesos de reducción de la dimensionalidad).
- Extrayendo la estructura interna con la que se distribuyen los datos en su espacio original (aprendizaje topológico).

3 Diferencia entre aprendizaje supervisado y no supervisado

El aprendizaje supervisado tiene variable respuesta Y , mientras que el aprendizaje no supervisado, no la tiene. Además es importante resaltar que el no supervisado es más descriptivo.

4 Características del aprendizaje no supervisado

- No existe una salida o variable respuesta, por lo que no se utiliza un modelo que relacione un conjunto de variables con una respuesta.
- Esto hace que sea difícil validar los resultados, al contrario del aprendizaje supervisado en el que existen métricas que permiten evaluar con claridad la bondad del aprendizaje realizado.
- Es parte de un análisis exploratorio de datos.
- Algoritmos no supervisados resultan ser muy costosos porque requieren de más pruebas de ensayo y error, haciendo que requieran de un aparataje teórico y computacional mucho más elaborado.

Ejemplo 1

Suponga que tiene la siguiente regresión:

$$\mu_{y|x} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_{p-1} X_{p-1}$$

Recuerde que $\mu_{y|x}$ es la respuesta

Se tiene el siguiente subconjunto de X 's:

$$X_1, \dots, X_k \text{ Altamente Correlacionadas}$$

Nota: Cuando las X 's están muy correlacionadas hay problemas de multicolinealidad y eso nos infla los errores estándar.

Note que este conjunto de variable es de dimensión k , esto lo que nos dice en realidad es que estas X 's miden un subconjunto menor de conceptos, lo que nos lleva al siguiente conjunto:

$$Z_1, \dots, Z_q$$

Donde $q < k$ (No Correlacionadas)

Reemplazando en el modelo original tenemos el siguiente resultado:

$$\mu_{y|x,z} = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \dots + \beta_q Z_q + \beta_{k+1} X_{k+1}$$


En este modelo la primera parte es no supervisado ya que no utilizamos la variable respuesta, para el último modelo obtenido si es supervisado ya que se utiliza con la variable respuesta.

Ejemplo 2

1. Se tienen $X_1, \dots, X_p$ Grupos
2. Formo k grupos
3. Se crea una variable G , la cual se crea a partir del aprendizaje no supervisado. Ya que se crea basado en las X 's

Observación (i)	X_1	X_2	$\dots$	X_p	$G = f(X_1, \dots, X_p)$
1	x_{11}	x_{12}	$\dots$	x_{1p}	g_1
2	x_{21}	x_{22}	$\dots$	x_{2p}	g_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
i	x_{i1}	x_{i2}	$\dots$	x_{ip}	g_i
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
n	x_{n1}	x_{n2}	$\dots$	x_{np}	g_n

Nota: Si agregamos una variable edad, podríamos realizar un análisis de varianza, ya que dicha variable funcionaría como una variable respuesta.



Ejemplo 3


Observación (i)	Altura (cm)	N.º de Hojas	Grosor del Tallo (mm)	Peso del Racimo (kg)	pH del Suelo
1	24.5	6	3.2	0.45	5.4
2	28.1	7	3.8	0.58	5.6
3	31.4	8	4.1	0.65	5.5
4	52.6	14	7.5	1.85	6.1
5	58.0	15	8.2	2.10	6.3
6	61.3	17	8.9	2.40	6.2
7	84.7	22	12.4	4.15	6.8
8	89.2	25	13.1	4.60	7.0

Note que la Altura (cm), N.º de Hojas, Grosor del Tallo (mm), Peso del Racimo (kg) están muy correlacionadas, mientras que el H del Suelo no tanto.

Con esas variables correlacionadas puede crear una variable Z_1

Diagrama de Dispersión: Z_1 vs. pH del Suelo

Z_1 construida como el primer componente principal (CP_1)



5 Proceso de Análisis de componentes principales (PCA)

$$\mu_{y|x_1, x_2, x_3, x_4} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4$$

Suponga que X_2, X_3, X_4 están muy correlacionadas, para ello se crea una variable Z_1 .

$$\mu_{y|x_1, z_1} = \beta_0 + \beta_1 X_1 + \gamma_1 Z_1$$

Sin embargo, como pasamos de tres variables (X_2, X_3, X_4) a una (Z_1) perdemos cierta información. Es decir Z_1 explica un cierto porcentaje de (X_2, X_3, X_4). Por ejemplo Z_1 explica un 80% de (X_2, X_3, X_4).

Se puede dar el caso que Z_1 no explique suficiente.

Existe otro modelo que puede explicar más que el siguiente:

$$\mu_{y|x_1, x_3} = \beta_0 + \beta_1 X_1 + \beta_3 X_3$$

Nota: Es importante resaltar que los tres modelos anteriores no son lo mismo, cada uno tiene sus ventajas y desventajas.

El PCA sirva para eliminar la multicolinealidad, solo si lo queremos usar para una regresión. Otro uso que se le puede dar es para obtener gráficos más simples.

5.1 Maldición de la dimensionalidad

- Cuando se cuenta con demasiadas variables es difícil hacer un análisis gráfico para tener una idea inicial del comportamiento de los datos.
- Muchas variables son un obstáculo para aplicar otras técnicas multivariadas.

5.2 Requisitos para que PCA tenga sentido

- Si las variables originales casi no están correlacionadas, nada se gana al llevar a cabo un PCA.
- Cuando el determinante de una matriz es cero, se tiene que hay columnas linealmente dependientes. Esto se llama multicolinealidad.
- Si el determinante de la matriz de correlación (R) es cercano a cero, hay indicación de altas correlaciones entre las variables, de lo contrario, cuando el determinante es alto un PCA puede no tener sentido.

5.3 Ejemplo de aplicación

Se tienen los siguientes datos

Observación (i)	X_1	X_2	X_3	X_4
1	3	4	2	5
2	5	1	1	3
3	4	3	3	2
4	2	7	4	0
$\bar{X} \rightarrow$	3.6	3.75	2.5	2.5
$S \rightarrow$	1.24	2.5	1.24	2.05

Luego estandarizamos mediante la siguiente fórmula:

$$X_i = \frac{X_i - \bar{X}}{S_i}$$

```
# 1. Definición de la matriz de datos X (4 observaciones x 4 variables)
X <- matrix(
  c(
    3, 4, 2, 5,
    5, 1, 1, 3,
    4, 3, 3, 2,
```

```

    2, 7, 4, 0
  ),
  nrow = 4,
  byrow = TRUE,
  dimnames = list(paste0("ID_", 1:4), paste0("X", 1:4))
)

```

```

# 2. Visualizar resultados
print("Matriz Original X:")

```

```
## [1] "Matriz Original X:"
```

```
print(X)
```

```
##      X1 X2 X3 X4
## ID_1  3  4  2  5
## ID_2  5  1  1  3
## ID_3  4  3  3  2
## ID_4  2  7  4  0

```

```

# 2. Estandarización con scale()
# scale() por defecto resta la media muestral (center = TRUE)
# y divide entre la desviación estándar muestral s con n-1 grados de libertad (scale = TRUE)
Z <- scale(X, center = TRUE, scale = TRUE)
print("Matriz Estandarizada Z (Z-scores):")

```

```
## [1] "Matriz Estandarizada Z (Z-scores):"
```

```
print(round(Z, 4))
```

```
##      X1  X2  X3  X4
## ID_1 -0.3873 0.1 -0.3873 1.2010
## ID_2 1.1619 -1.1 -1.1619 0.2402
## ID_3 0.3873 -0.3 0.3873 -0.2402
## ID_4 -1.1619 1.3 1.1619 -1.2010
## attr("scaled:center")
##      X1  X2  X3  X4
## 3.50 3.75 2.50 2.50
## attr("scaled:scale")
##      X1      X2      X3      X4
## 1.290994 2.500000 1.290994 2.081666

```

Interpretación El ID_4 en X_1 esta 1.16 desviaciones estándar debajo la media (recuerde que la desviación estándar de X_1 es 1.29). También en X_2 el ID_1 está 0.1 desviaciones estándar sobre la media, es decir está prácticamente en la media.

Nota: El máximo de desviaciones estándar en una normal son 3 que son el 99.7% de los datos.

Luego obtenemos los coeficientes para Z_1 y hacemos la siguiente regresión:

$$Z_1 = 0.2X_1^s + 0.4X_2^s + 0.01X_3^s + 0.5X_4^s$$

Nota: En regresión estandarizabamos los coeficientes para poder compararlos en este caso, estadarizamos y la que tiene más peso en el resultado de Z_1 es X_4

Luego sustituimos con los valores que tenemos

$$\begin{aligned} Z_1^{(1)} &= 0.2(-0.39) + 0.4(0.10) + 0.01(-0.39) + 0.5(1.20) \\ &= -0.078 + 0.040 - 0.0039 + 0.600 = \mathbf{0.5581} \end{aligned}$$

$$\begin{aligned} Z_1^{(2)} &= 0.2(1.16) + 0.4(-1.10) + 0.01(-1.16) + 0.5(0.24) \\ &= 0.232 - 0.440 - 0.0116 + 0.120 = \mathbf{-0.0996} \end{aligned}$$

$$\begin{aligned} Z_1^{(3)} &= 0.2(0.39) + 0.4(-0.30) + 0.01(0.39) + 0.5(-0.24) \\ &= 0.078 - 0.120 + 0.0039 - 0.120 = \mathbf{-0.1581} \end{aligned}$$

$$\begin{aligned} Z_1^{(4)} &= 0.2(-1.16) + 0.4(1.30) + 0.01(1.16) + 0.5(-1.20) \\ &= -0.232 + 0.520 + 0.0116 - 0.600 = \mathbf{-0.3004} \end{aligned}$$

Nota: Si uno tiene p variables originales, puede llegar a p variables nuevas, la idea es siempre obtener menos que p

Más adelante se explicará la obtención de los Z 's mediante la descomposición espectral.

Además los coeficientes de los Z 's, como están normalizados la suma de ellos es igual a 1.

Sub-Ejemplo

Se tiene el siguiente Z

$$Z_2 = 0.8X_1 + 0.8X_2 + 0.01x_3 + 0.01X_4$$

Como X_3, X_4 prácticamente no pesan, por lo que se interpretaría como un promedio entre X_1 y X_2

Para este otro caso

$$Z_3 = 0.8X_1 + 0.6X_2 + 0.5x_3 + 0.01X_4$$

En esta situación es una especie de ponderación donde el que tiene más peso es X_1

Caso inusual

$$Z_4 = 0.5X_1 - 0.5X_2 + 0.01x_3 + 0.01X_4$$

- Si $X_1 = X_2 = 0$ significa que está muy parecido

PREGUNTAR

- Si $X_1 > X_2$
- Si $X_1 < X_2$

6 Comparación de análisis factorial con componentes principales

- La estructura del análisis de factores es similar a los componentes principales.
- En componentes principales las variables conocidas X se combinan con los coeficientes a para producir nuevas variables Z llamadas componentes principales. Una propiedad importante en el análisis de componentes principales es $Cov(Z_i, Z_j) = 0$
- En factores se combinan factores latentes desconocidos f para formar las variables conocidas X . Esto es más complejo

6.1 Ejemplo de análisis factorial

Tenemos un estudio con f_1 que es la habilidad cuantitativa de una persona y f_2 es la habilidad de razonamiento verbal, para estos dos variables no tienen una forma directa de medirse, ya que f_1 se podría medir mediante un problema o un cuestionario, pero dentro de las preguntas del cuestionario, mientras se mide la habilidad cuantitativa, también se podría estar midiendo el razonamiento verbal, ya que la persona necesita entender la pregunta para resolver el problema.

Por ejemplo una persona obtuvo en una pregunta un valor de $f_1 = 0.5$ y $f_2 = 0.5$, asuma que $\lambda_{11} = 7$ y $\lambda_{12} = 7.5$

Esto nos lleva a que

$$7.25 = 0.5 * 7 + 0.5 * 7.5$$

En otra pregunta se tiene el resultado de otro puntaje, sin embargo lo que cambia es f_1 y f_2 , en el caso de los λ 's no cambian y se pueden obtener por medio de **PCA**, esta es la confusión que muchas personas tienen con este tema.

Factores comunes	Componentes principales
$X_1 = \lambda_{11}f_1 + \lambda_{12}f_2 + \dots + \lambda_{1m}f_m + \eta_1$ $X_2 = \lambda_{21}f_1 + \lambda_{22}f_2 + \dots + \lambda_{2m}f_m + \eta_2$ $\vdots$ $X_q = \lambda_{q1}f_1 + \lambda_{q2}f_2 + \dots + \lambda_{qm}f_m + \eta_q$	$Z_1 = a_{11}X_1^s + a_{12}X_2^s + \dots + a_{1q}X_q^s$ $Z_2 = a_{21}X_1^s + a_{22}X_2^s + \dots + a_{2q}X_q^s$ $\vdots$ $Z_q = a_{q1}X_1^s + a_{q2}X_2^s + \dots + a_{qq}X_q^s$

6.2 Diferencias entre análisis factorial y PCA

Factores comunes	Componentes principales
• El interés es la explicación de la estructura de covarianza o de correlación (o ambas) entre las variables medidas. • Puede haber cambios sustanciales en todos los factores si se cambia el número de factores. • El cálculo de los puntajes es complejo y existen varios métodos. • Se obtienen resultados equivalentes si se usa la matriz de covarianza o la de correlaciones. • Si las variables están casi no correlacionadas este análisis no tiene sentido. • En tal caso los factores no tienen nada que explicar.	• El interés se centra en la explicación de la variabilidad total del conjunto de variables (Como una regresión). • Si el número de componentes que se utilizan se incrementa, esos componentes no cambian. • El cálculo de los puntajes es sencillo y se basa en una única descomposición espectral. • No hay relación directa entre los componentes obtenidos de la matriz de covarianza y la de correlaciones. • Si las variables están casi no correlacionadas este análisis no tiene sentido. • En tal caso se obtienen componentes que son muy similares a las variables originales.

Nota: Al agregar Z 's en componentes principales, las coeficientes para obtener los componentes no cambian, en cambio en análisis factorial al yo incluir más cosas que quiero medir (X 's), las f cambian. Además, si las variancias específicas son pequeñas ambos análisis dan resultados similares.

7 Valores y Vectores propios

A continuación el siguiente tema se explica mediante un ejemplo.

Tenemos la siguiente matriz de varianzas y covarianzas:

$$\mathbf{S} = \begin{bmatrix} 8 & 10 & -3 \\ 10 & 6 & -4 \\ -3 & 4 & -2 \end{bmatrix}$$

Note que la $tr(S) = 8 + 6 + 2 = 16$, esta corresponde a la suma de las varianzas, lo que significa que es la **Varianza total**

Una vez teniendo esto podemos calcular la matriz de correlación por medio de la siguiente fórmula:

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}s_{jj}}}$$

Nota: Recordar que en la diagonal la correlación es 1 ya que es la misma variable.

$$\mathbf{R} = \begin{bmatrix} 1 & 1.44 & -0.75 \\ 1.44 & 1 & -1.16 \\ -0.75 & 1.16 & 1 \end{bmatrix}$$

La $tr(R) = 3$, esta representa el número de variables. Además la matriz de correlaciones es la estandarización de una matriz de varianzas y covarianzas en este caso, ya que la varianza de cada una de las variables es 1. Esto nos lleva a la siguiente equivalencia:

$$Cov(X_i^s, X_j^s) = r_{ij}$$

Así que la $tr(R) = 3$ representa que la varianza total de las variables estandarizadas.

7.1 ¿Cuándo centrar y cuándo estandarizar?

Cuando se tienen variables con las mismas escalas solo se necesitan centrar, pero cuando son muy diferentes es altamente recomendado estandarizarlos.

7.2 Valores y vectores propios en R

Valores propios

```
valores = c(8, 10, -3, 10, 6, 4, -3, 4, 2)
S = matrix(
  valores,
  nrow = 3,
  ncol = 3,
  byrow = TRUE
)

v = eigen(S)
round(v$values, 2)

## [1] 17.07 5.04 -6.11
```

Esto nos dice que $\lambda_1 = 17.07, \lambda_2 = 5.04, \lambda_3 = -6.11$

Note que la suma de estos valores no da la varianza total original

```
sum(v$values)
```

```
## [1] 16
```

Vectores propios

Estos deben cumplir con la propiedad de que:

$$A \times a = \lambda \times a$$

A continuación se le representa el proceso en r, para obtenerlos

Tenemos la matriz asociada a los vectores propios

```
v$vectors
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.73550267 -0.3755265  0.5639288
## [2,] 0.67670738  0.3663738 -0.6386215
## [3,] 0.03321052  0.8513226  0.5235904
```

Los extraemos de la misma matriz

```
e1 = v$vectors[, 1] # Asociado a lambda_1 = 17.06
e2 = v$vectors[, 2] # Asociado a lambda_2 = 5.05
e3 = v$vectors[, 3] # Asociado a lambda_3 = -6.11
```

Verificamos con la condición de modo que $S \%*\% e_1 == \lambda_1 * e_1$

```
t(round(S \%*\% e1, 4))
```

```
##           [,1]      [,2]      [,3]
## [1,] 12.5515 11.5481  0.5667
```

```
round(v$values[1] * e1, 4)
```

```
## [1] 12.5515 11.5481  0.5667
```

Observe que la condición se cumple.

También otra propiedad que se tiene que resaltar es la ornormalidad de los mismos.

Verificación sobre si la norma es 1

```
# Norma 1: ||e_1|| = 1
sqrt(sum(e1^2))
```

```
## [1] 1
```

Verificación de ortogonalidad


```
# Ortogonales entre sí: e_1 \%*\% e_2 = 0
round(t(e1) \%*\% e2, 4)
```

```
##           [,1]
## [1,]      0
```

7.3 Construcción de Z's

Cambio de Base en ACP: Traslación y Rotación de Ejes

Lectura de coordenadas (X_1, X_2) vs. Puntuaciones (Z_1, Z_2)



Observando la figura anterior tenemos que:

$X_1 = 5.5 \rightarrow Z_1 = 1.95$ y $X_2 = 3.2 \rightarrow Z_2 = -0.82$. Con lo siguiente $r_{x_1, x_2} = 0.45 \rightarrow r_{z_1, z_2} = 0$

¿Cómo se construyen los Z's de la figura anterior?

- Si se utiliza la matriz de correlaciones, se deben estandarizar las variables, esto se hace cuando las escalas de las variables son similares. ($X_1^s, X_2^s \rightarrow S$)
- Si se utiliza la matriz de covarianzas y varianzas, se debe centrar solamente, sin embargo esto se debe hacer solo cuando las escalas sean muy similares. ($X_1^c, X_2^c \rightarrow R$)

Proceso de obtención de los Z's

Sabemos que en el anterior ejercicio los vectores propios son:

El primer vector propio es 0.74 0.67

El segundo vector propio es -0.67 0.74

Tenemos que las medias son:

Media de X_1 es 3.5

Media de X_2 es 2.5

Hacemos las operaciones para llegar al resultado

$$\begin{aligned}
Z_1 &= 0.74 X_1^c + 0.67 X_2^c \\
&= 0.74 (5.5 - 3.5) + 0.67 (3.2 - 2.5) \\
&= 0.74 (2.0) + 0.67 (0.7) \\
&= 1.48 + 0.469 \\
&= 1.95
\end{aligned}$$

$$\begin{aligned}
Z_2 &= -0.67 X_1^c + 0.74 X_2^c \\
&= -0.67 (5.5 - 3.5) + 0.74 (3.2 - 2.5) \\
&= -0.67 (2.0) + 0.74 (0.7) \\
&= -1.34 + 0.518 \\
&= -0.82
\end{aligned}$$

Haciendolo en una base de datos grande lo que se está haciendo es lo siguiente:

$$\mathbf{X}^c = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & x_{n3} \end{bmatrix} - \begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \\ \vdots & \vdots & \vdots \\ \bar{x}_1 & \bar{x}_2 & \bar{x}_3 \end{bmatrix}$$

Luego se multiplica por el vector propio:

$$\mathbf{X}^c = \begin{bmatrix} x_{11}^c & x_{12}^c & x_{13}^c \\ x_{21}^c & x_{22}^c & x_{23}^c \\ \vdots & \vdots & \vdots \\ x_{n1}^c & x_{n2}^c & x_{n3}^c \end{bmatrix} \cdot \begin{bmatrix} a_{11} \\ a_{22} \\ a_{33} \end{bmatrix} = \begin{bmatrix} Z_{1(1)} \\ Z_{2(1)} \\ \vdots \\ Z_{n(1)} \end{bmatrix}$$

Con esto llegamos obtener el vector con los valores de la primera variable nueva, para todos los individuos de la base de datos o lo que es lo mismo que decir que el vector del primer componente principal.

Nota: Si se calculan las varianzas de los Z 's da como resultado los λ 's encontrados para los vectores propios, por lo que la variabilidad total es igual si se mantiene el mismo número de variables originales.

8 HEPTATLON

8.1 Proceso de cambios en las variables

Para cambiar el sistema de puntuación realizamos la siguiente transformación de tal manera que:

Observación (i)	→	Observación Nueva
3		7
5		5
8		2
10		0

La fórmula utilizada es:

$$x_{new} = max - x_i$$

```
load("Heptatlon.Rdata")
base$vallas=with(base,max(vallas)-vallas)
base$car200=with(base,max(car200)-car200)
base$car800=with(base,max(car800)-car800)
```

8.2 Matriz de correlaciones


8.2.1 Cálculo en r

```
round(cor(base[, -8]), 2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.81 0.65  0.77      0.91      0.01   0.78
## saltoalto   0.81      1.00 0.44  0.49      0.78      0.00   0.59
## tiro        0.65      0.44 1.00  0.68      0.74      0.27   0.42
## car200       0.77      0.49 0.68  1.00      0.82      0.33   0.62
## saltolargo   0.91      0.78 0.74  0.82      1.00      0.07   0.70
## javalina     0.01      0.00 0.27  0.33      0.07      1.00  -0.02
## car800       0.78      0.59 0.42  0.62      0.70     -0.02   1.00
```

8.2.2 Gráfico de correlación librería corrgram de colores

```
library(corrgram)
corrgram(base[, -8], lower.panel=panel.pts, order=T) # order = T nos ordena las correlaciones
```




Los colores azules significan una correlación positiva, mientras que los rojos significan una correlación negativa.

Además, en los gráficos de puntos, en los ejes están los valores de cada variable según corresponda.

8.2.3 Gráfico de correlación librería corrgram de números (correlaciones)

```
corrgram(base[, -8], lower.panel=panel.pts, upper.panel=panel.conf,
          diag.panel=panel.density, order=T)
```




8.2.4 Gráfico del paquete corrplot

```
library(corrplot)
```

```
## Warning: package 'corrplot' was built under R version 4.5.3
```

```
corrplot(cor(base[, -8]), method = "square", type = "lower")
```



El parámetro lower ordena el correlograma de manera decendente


8.3 Análisis de valores extremos mediante leverage

Recuerde que este proceso se realiza mediante el cálculo de la matriz:

$$H = X(X^T X)^{-1} X^T$$

A continuación se le presenta el código en r, para los leverage

```
lev=hat(base[, -8])
plot(lev)
lim=2*mean(lev)
abline(h=lim)
```



8.3.1 Formas de averiguar y eliminar el valor extremo

Formas de averiguar

```
which.min(base$saltoalto) # Es el punto menor que se ve en los gráficos de correlación más arriba
```

```
## [1] 25
```

```
which.max(lev) # El valor más alto que se sale de la línea en los leverage
```

```
## [1] 25
```

Formas de eliminar

```
base1 = subset(base, lev<lim)
```

```
base1 = base[-25,]
```

Nota: Recordar que en este caso se quitó el valor extremo por términos del ejercicio y nunca se puede quitar sin una justificación en concreto.

8.4 Obtención del determinante de la matriz R

```
base2=base1[,-8] # Es una base sin la respuesta (solo con las X's)
```

```
R=cor(base2)
```

```
det(R)
```

```
## [1] 0.003511559
```

Conforme las correlaciones, aumenta el determinante tiende a cero.

Correlación alta $\implies$ Determinante casi cero

8.5 Hipótesis de matriz de correlaciones

Existe una prueba de hipótesis que verifica si la matriz de correlaciones es igual a la identidad, ya que si es similar a la identidad, indicaría que las correlaciones son prácticamente cero.

Nota: Para hacer el análisis de PCA **mínimo**, se debe rechazar esta hipótesis.

$$H_0 : R = I$$

```
library(psych)
cortest.bartlett(R,n=nrow(base2)) # Proporcionadle a la función la matriz

## $chisq
## [1] 112.092
##
## $p.value
## [1] 1.973466e-14
##
## $df
## [1] 21

cortest.bartlett(base2) # En esta opción, la base de datos no puede contener la respuesta

## $chisq
## [1] 112.092
##
## $p.value
## [1] 1.973466e-14
##
## $df
## [1] 21
```

8.6 KMO

En ocasiones la prueba de correlaciones falla debido a la gran cantidad de datos, ya que debido a la gran potencia que tienen, ocasiona que la prueba se rechaze siempre.

Una solución ante este problema es usar esta prueba, que tiene como condición que solo si $n/q < 5$, donde q es el número de variables.

A continuación se le presentan los criterios del KMO

Rango KMO	Interpretación / Calidad
[0.9, 1.0]	Muy bueno (Excelente)
[0.8, 0.9]	Meritorio
[0.7, 0.8]	Mediano (Aceptable)
[0.6, 0.7]	Mediocre (Regular)
[0.5, 0.6]	Bajo
[0.0, 0.5]	Inaceptable (Desaconsejable)

KMO(R)

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = R)
## Overall MSA = 0.73
## MSA for each item =
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.87      0.55      0.82      0.72      0.72      0.47      0.84
```

En este caso la Correlación es aceptable

8.7 Análisis con la matriz de covarianzas

Cpmo se mencionó anteriormente, este análisis se recomienda hacerlo cuando las varianzas de las variables son bastantes similares, ya que en este caso los valores no están estandarizados, tal y como sucede con el análisis de la matriz de correlación.

8.7.1 Comparación de varianzas de las variables

```
v=apply(base2, 2,var) # Note que el 2 es porque es la varianza para cada columna
round(v,3)
```

```
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.265      0.003      2.241      0.878      0.161      12.032      37.789
```

Nota: Con ver este resultado podemos concluir que no tiene sentido hacer un análisis por la matriz de covarianzas debido a la gran diferencia entre varianzas.

Este cálculo lo puede hacer también de la siguiente forma:

```
round(diag(var(base2)),3)
```

```
##      vallas saltoalto      tiro      car200 saltolargo   javalina      car800
##      0.265      0.003      2.241      0.878      0.161      12.032      37.789
```

La variabilidad total de las variables originales la obtenemos, sumando todas las varianzas

```
sum(v)
```

```
## [1] 53.36842
```

8.7.2 Descomposición espectral de matriz de covarianzas

Obtenemos la matriz de covarianzas

```
S=var(base2)
round(S,2)
```

```
##      vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      0.26      0.02 0.59   0.40      0.18      0.59   1.77
## saltoalto    0.02      0.00 0.04   0.02      0.01      0.06   0.05
## tiro         0.59      0.04 2.24   0.94      0.47      1.78   3.76
## car200        0.40      0.02 0.94   0.88      0.31      1.53   3.30
## saltolargo    0.18      0.01 0.47   0.31      0.16      0.40   1.29
## javalina      0.59      0.06 1.78   1.53      0.40     12.03   5.46
## car800        1.77      0.05 3.76   3.30      1.29      5.46  37.79
```

$$S = AA'A' = A\Lambda^{\frac{1}{2}}\Lambda^{\frac{1}{2}}A'$$

donde:

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

Por medio de `eigen` hacemos la descomposición

```
espec=eigen(S)
```

A continuación se le presenta código en `R`, de como obtener los valores y vectores propios

```
lambda=espec$val
round(lambda,2)
```

```
## [1] 39.82 11.11 2.00 0.35 0.06 0.02 0.00
```

Nota: Observe que la suma de los λ ' es lo mismo que la varianza total

```
sum(lambda) # Da lo mismo que la varianza total (summa de las varianzas de cada predictor)
```

```
## [1] 53.36842
```

Esto nos lleva a escribir esta propiedad

$$\sum_{i=1}^q S_i^2 = \sum_{i=1}^q \lambda_j$$

```
A=espec$vec
round(A,2)
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
## [1,] -0.05 0.03 -0.22 -0.26 0.77 -0.54 0.04
## [2,] 0.00 0.01 -0.01 -0.01 0.11 0.11 -0.99
## [3,] -0.11 0.11 -0.88 0.42 -0.14 -0.03 -0.01
## [4,] -0.09 0.08 -0.31 -0.85 -0.40 -0.03 -0.04
## [5,] -0.04 0.02 -0.18 -0.18 0.46 0.84 0.15
## [6,] -0.20 0.96 0.16 0.05 0.02 0.01 0.01
## [7,] -0.97 -0.23 0.11 0.05 -0.01 0.00 0.00
```

```
L = diag(lambda)
L
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
## [1,] 39.82137 0.00000 0.000000 0.0000000 0.0000000 0.0000000 0.000000000
## [2,] 0.00000 11.11262 0.000000 0.0000000 0.0000000 0.0000000 0.000000000
## [3,] 0.00000 0.00000 2.003319 0.0000000 0.0000000 0.0000000 0.000000000
## [4,] 0.00000 0.00000 0.000000 0.3483982 0.0000000 0.0000000 0.000000000
## [5,] 0.00000 0.00000 0.000000 0.0000000 0.06044327 0.0000000 0.000000000
## [6,] 0.00000 0.00000 0.000000 0.0000000 0.0000000 0.0213549 0.000000000
## [7,] 0.00000 0.00000 0.000000 0.0000000 0.0000000 0.0000000 0.000921165
```

Aplicamos la fórmula que esta arriba para obtener la matriz de covarianzas

```
S1 = round(A%*%L%*%t(A),2)
S1
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
## [1,] 0.26 0.02 0.59 0.40 0.18 0.59 1.77
```

```
## [2,] 0.02 0.00 0.04 0.02 0.01 0.06 0.05
## [3,] 0.59 0.04 2.24 0.94 0.47 1.78 3.76
## [4,] 0.40 0.02 0.94 0.88 0.31 1.53 3.30
## [5,] 0.18 0.01 0.47 0.31 0.16 0.40 1.29
## [6,] 0.59 0.06 1.78 1.53 0.40 12.03 5.46
## [7,] 1.77 0.05 3.76 3.30 1.29 5.46 37.79
```

8.8 Obtención de los componentes principales Z 's

```
basec=scale(base2,scale=F) # Datos centrados
Z1=basec%*%A[,1]
Z1 # Z1 de las 25 competidoras
```

```
## [1]
## Joyner-Kersee (USA) -7.6475882
## John (GDR) -9.2440142
## Behmer (GDR) -11.3128880
## Sablovskaitė (URS) -3.1851196
## Choubenkova (URS) -8.2870298
## Schulz (GDR) -9.1650206
## Fleming (AUS) -2.1745470
## Greiner (USA) -0.6871351
## Lajbnerova (CZE) 0.8133054
## Bouraga (URS) 0.2255227
## Wijnsma (HOL) -2.5575479
## Dimitrova (BUL) -2.1814057
## Scheider (SWI) -1.0375723
## Braun (FRG) 6.9911347
## Ruotsalainen (FIN) 1.3308934
## Yuping (CHN) 11.8352342
## Hagger (GB) 4.6816897
## Brown (USA) 10.6025928
## Mulliner (GB) 3.8401768
## Hautenauve (BEL) 0.4282646
## Kytola (FIN) -0.8310151
## Geremias (BRA) 9.2945847
## Hui-Ing (TAI) 3.2318624
## Jeong-Mi (KOR) 5.0356220
```

8.8.1 Cálculo de cuánto porcentaje explica el componente

$$\frac{Var(Z_1)}{Var_{total}} * 100$$

```
var(Z1)/sum(diag(var(base2)))*100
```

```
## [1]
## [1,] 74.61597
```

Otra forma de obtenerlo

```
lambda[1]/sum(lambda)*100
```

```
## [1] 74.61597
```

8.8.2 ¿Es normal que tenga media cero?

Es completamente normal, ya que cuando se usa la matriz de covarianzas al momento de centrar las variables, la media es prácticamente cero

```
mean(Z1)
```

```
## [1] 1.741662e-15
```

8.8.3 Forma automática con prcomp()

```
pca1=prcomp(base2) #Recordar que base2 no contiene la respuesta  
pca1
```

```
## Standard deviations (1, .., p=7):  
## [1] 6.3104174 3.3335599 1.4153864 0.5902527 0.2458521 0.1461332 0.0303507  
##  
## Rotation (n x k) = (7 x 7):  
##  
##          PC1      PC2      PC3      PC4      PC5  
## vallas    -0.048990549 -0.025316574 0.21976922 0.258721171 -0.770392335  
## saltoalto -0.001689277 -0.005045357 0.01412828 0.007663199 -0.113562325  
## tiro      -0.109842256 -0.109469326 0.88429017 -0.415089588 0.143844257  
## car200     -0.093344900 -0.082933532 0.30995644 0.850113115 0.403820065  
## saltolargo -0.035796182 -0.016070106 0.18428548 0.183911499 -0.457550175  
## javalina   -0.203545182 -0.964064905 -0.16268061 -0.046437981 -0.021370194  
## car800     -0.966491838 0.225372406 -0.11416509 -0.045089141 0.005346563  
##  
##          PC6      PC7  
## vallas    -0.535642857 -0.036141682  
## saltoalto 0.106582607 0.987652319  
## tiro      -0.029989278 0.009599705  
## car200     -0.033144859 0.038395656  
## saltolargo 0.836474571 -0.147084795  
## javalina   0.006126305 -0.005703870  
## car800     0.001303485 0.001955278
```

```
names(pca1)
```

```
## [1] "sdev"      "rotation" "center"    "scale"     "x"
```

sdev: Son las desviaciones estándar para obtener lo siguiente:

```
(round(pca1$sdev,2))^2
```

```
## [1] 39.8161 11.0889 2.0164 0.3481 0.0625 0.0225 0.0009
```

rotation: Es la matriz de los vectores propios

```
round(pca1$rotation,2) # Los vectores propios
```

```
##          PC1  PC2  PC3  PC4  PC5  PC6  PC7  
## vallas    -0.05 -0.03 0.22 0.26 -0.77 -0.54 -0.04  
## saltoalto 0.00 -0.01 0.01 0.01 -0.11 0.11 0.99  
## tiro      -0.11 -0.11 0.88 -0.42 0.14 -0.03 0.01  
## car200     -0.09 -0.08 0.31 0.85 0.40 -0.03 0.04  
## saltolargo -0.04 -0.02 0.18 0.18 -0.46 0.84 -0.15  
## javalina   -0.20 -0.96 -0.16 -0.05 -0.02 0.01 -0.01  
## car800     -0.97 0.23 -0.11 -0.05 0.01 0.00 0.00
```

x: Es lo que contiene los Z's

```
round(pca1$x,2)
```

```
##          PC1  PC2  PC3  PC4  PC5  PC6  PC7
## Joyner-Kersee (USA) -7.65 -3.28 1.93 0.61 -0.16 0.23 -0.04
## John (GDR)          -9.24 0.30 2.07 -0.61 -0.07 -0.15 -0.02
## Behmer (GDR)        -11.31 -0.99 -0.18 0.43 0.10 0.07 0.02
## Sablovskaitė (URS)  -3.19 -1.13 1.51 -0.44 0.43 -0.10 0.04
## Choubenkova (URS)   -8.29 -4.61 -0.13 -0.63 0.18 -0.05 -0.06
## Schulz (GDR)        -9.17 0.54 -1.00 -0.65 -0.01 0.13 0.03
## Fleming (AUS)       -2.17 1.44 0.05 1.03 0.05 -0.08 0.01
## Greiner (USA)       -0.69 3.32 1.36 -0.12 -0.01 0.07 0.00
## Lajbnerova (CZE)    0.81 -1.24 0.88 -0.67 -0.02 -0.15 0.04
## Bouraga (URS)       0.23 2.14 0.28 1.31 -0.03 -0.23 -0.01
## Wijnsma (HOL)      -2.56 4.12 -0.09 -0.28 -0.17 0.13 0.05
## Dimitrova (BUL)    -2.18 1.43 0.08 1.07 -0.06 -0.15 0.01
## Scheider (SWI)     -1.04 -5.80 -2.56 0.07 -0.32 0.04 0.03
## Braun (FRG)         6.99 -4.95 0.28 0.03 -0.18 -0.06 0.01
## Ruotsalainen (FIN)  1.33 -4.40 -1.23 0.20 -0.13 -0.02 -0.01
## Yuping (CHN)        11.84 -0.15 2.56 -0.14 0.03 0.23 0.03
## Hagger (GB)         4.68 4.63 0.74 -0.07 -0.58 -0.02 -0.04
## Brown (USA)         10.60 -5.46 0.23 0.27 0.00 0.15 0.01
## Mulliner (GB)       3.84 2.79 0.22 0.03 0.42 0.26 -0.05
## Hautenauve (BEL)    0.43 5.87 -0.84 -0.21 -0.15 0.02 0.00
## Kytola (FIN)        -0.83 2.37 -1.78 -0.53 0.04 0.00 0.02
## Geremias (BRA)      9.29 -0.35 0.58 -0.46 0.30 -0.32 -0.01
## Hui-Ing (TAI)       3.23 1.97 -2.77 0.55 0.53 0.07 -0.01
## Jeong-Mi (KOR)      5.04 1.44 -2.19 -0.80 -0.19 -0.05 -0.05
```

Note que da todos los z's de todos los individuos

```
summary(pca1)
```

```
## Importance of components:
##          PC1  PC2  PC3  PC4  PC5  PC6  PC7
## Standard deviation  6.3104 3.3336 1.41539 0.59025 0.24585 0.1461 0.03035
## Proportion of Variance 0.7462 0.2082 0.03754 0.00653 0.00113 0.0004 0.00002
## Cumulative Proportion 0.7462 0.9544 0.99192 0.99845 0.99958 1.0000 1.00000
```

Esto nos resume todo lo del análisis y cuánto aporta cada componente

9 Análisis con matriz de correlaciones

9.1 Estadarizando las variables prrimero

```
v1=scale(base2$vallas)
```

Observe que la media es 0 y la varianza es 1.

```
mean(v1)
```

```
## [1] -1.550003e-16
```

```
var(v1)
```

```
##      [,1]
## [1,]    1
```

Estandarice todas las variables. Para hacerlo de una sola vez, puede usar: `scale(base2)`.

```
base3=scale(base2)
```

Verificación de que todas las medias son 0 y las variancias son 1.

```
round(apply(base3,2,mean),10)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##           0           0           0           0           0           0           0
```

```
apply(base3,2,var)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##           1           1           1           1           1           1           1
```

9.2 Descomposición espectral de la matriz de correlaciones y obtención de los valores propios.

```
espec1=eigen(R)
lambda1=espec1$val
round(lambda1,2)
```

```
## [1] 4.32 0.90 0.83 0.47 0.30 0.11 0.07
```

```
S = var(base3)
```

```
S1 = var(base2) # esro no es lo mismo que S, no tiene sentido porque las variables no están estandariza
```

```
R = cor(base2)
```

Note que S y R son iguales

```
S;R
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina
## vallas      1.0000000 0.5817409 0.7666860 0.8300371 0.8893472 0.3324779
## saltoalto 0.5817409 1.0000000 0.4646854 0.3909024 0.6626910 0.3480793
## tiro      0.7666860 0.4646854 1.0000000 0.6694330 0.7840380 0.3430333
## car200     0.8300371 0.3909024 0.6694330 1.0000000 0.8106176 0.4707969
## saltolargo 0.8893472 0.6626910 0.7840380 0.8106176 1.0000000 0.2870826
## javalina   0.3324779 0.3480793 0.3430333 0.4707969 0.2870826 1.0000000
## car800     0.5587794 0.1523350 0.4082925 0.5731902 0.5233809 0.2559348
```

```
##      car800
## vallas      0.5587794
## saltoalto   0.1523350
## tiro        0.4082925
## car200      0.5731902
## saltolargo  0.5233809
## javalina    0.2559348
## car800      1.0000000
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina
## vallas      1.0000000 0.5817409 0.7666860 0.8300371 0.8893472 0.3324779
## saltoalto 0.5817409 1.0000000 0.4646854 0.3909024 0.6626910 0.3480793
## tiro      0.7666860 0.4646854 1.0000000 0.6694330 0.7840380 0.3430333
## car200     0.8300371 0.3909024 0.6694330 1.0000000 0.8106176 0.4707969
## saltolargo 0.8893472 0.6626910 0.7840380 0.8106176 1.0000000 0.2870826
## javalina   0.3324779 0.3480793 0.3430333 0.4707969 0.2870826 1.0000000
## car800     0.5587794 0.1523350 0.4082925 0.5731902 0.5233809 0.2559348
```

```
##          car800
## vallas    0.5587794
## saltoalto 0.1523350
## tiro      0.4082925
## car200    0.5731902
## saltolargo 0.5233809
## javalina  0.2559348
## car800    1.0000000
```

9.3 Porcentaje de explicación de un componente principal

Para averiguar ese porcentaje de explicación utilice la siguiente fórmula:

$$\frac{Var(Z_j)}{\sum_{j=1}^q}$$

donde q es el número total de variables

A continuación se le detalla el proceso en r

Obtenemos el primer valor propio

```
lambda1[1]
```

```
## [1] 4.323642
```

Luego obtenemos el número total de variables o sumamos los valores propios.

```
sum(lambda1)
```

```
## [1] 7
```

```
round(lambda1[1]/sum(lambda1),2)
```

```
## [1] 0.62
```

Esto quiere decir que Z_1 explica un 62% de la variabilidad total, cuando las variables están estandarizadas.

9.4 Forma automática

```
pca1=prcomp(base2,scale=T)
lambda2=pca1$sdev**2
round(lambda2,2)
```

```
## [1] 4.32 0.90 0.83 0.47 0.30 0.11 0.07
```

Note que con `summary()`, podemos obtener directamente cuánto porcentaje explica cada componente.

```
summary(pca1)
```

```
## Importance of components:
##          PC1      PC2      PC3      PC4      PC5      PC6      PC7
## Standard deviation  2.0793 0.9482 0.9109 0.68320 0.54619 0.33745 0.26204
## Proportion of Variance 0.6177 0.1284 0.1185 0.06668 0.04262 0.01627 0.00981
## Cumulative Proportion 0.6177 0.7461 0.8646 0.93131 0.97392 0.99019 1.00000
```

Obtención del primer vector propio

```
a1=pca1$rot[,1]
round(a1,2)
```

```
##      vallas saltoalto      tiro      car200 saltolargo      javalina      car800
##      -0.45      -0.31      -0.40      -0.43      -0.45      -0.24      -0.30
```

Observe que la variables con más peso en este caso son: `vallas`, `saltolargo` y `saltolargo`. Además todos son negativos, esto es positiva ya que en terminos de interpretación estos se van a estabilizar.

Es importante fijarse en el signo de los coeficientes que pesen más. Si hay uno que pese muy poco comparado con los demás, pero tiene signo diferente lo que se puede hacer es ignorarlo ya que no va a afectar tanto

9.5 Obtención del primer componente manualmente

```
Z1=base3%*%a1
Z1a=pca1$x[,1]
cbind(Z1,Z1a)
```

```
##                                Z1a
## Joyner-Kersee (USA) -4.757530189 -4.757530189
## John (GDR)          -3.147943402 -3.147943402
## Behmer (GDR)        -2.926184760 -2.926184760
## Sablovskaitė (URS)  -1.288135516 -1.288135516
## Choubenkova (URS)   -1.503450994 -1.503450994
## Schulz (GDR)        -0.958467101 -0.958467101
## Fleming (AUS)        -0.953445060 -0.953445060
## Greiner (USA)       -0.633239267 -0.633239267
## Lajbnerova (CZE)    -0.381571974 -0.381571974
## Bouraga (URS)       -0.522322004 -0.522322004
## Wijnsma (HOL)       -0.217701500 -0.217701500
## Dimitrova (BUL)     -1.075984276 -1.075984276
## Scheider (SWI)       0.003014986  0.003014986
## Braun (FRG)          0.109183759  0.109183759
## Ruotsalainen (FIN)  0.208868056  0.208868056
## Yuping (CHN)         0.232507119  0.232507119
## Hagger (GB)          0.659520046  0.659520046
## Brown (USA)          0.756854602  0.756854602
## Mulliner (GB)        1.880932819  1.880932819
## Hautenauve (BEL)     1.828170404  1.828170404
## Kytola (FIN)         2.118203163  2.118203163
## Geremias (BRA)       2.770706272  2.770706272
## Hui-Ing (TAI)        3.901166920  3.901166920
## Jeong-Mi (KOR)       3.896847898  3.896847898
```

En contexto de este problema mientras más pequeño sea el número mejor es la puntuación, esto nos lleva que la atleta `Jeong-Mi (KOR)`, es la que peor puntuación tiene ya que tiene un valor de Z_1 alto. Otro aspecto importante a notar es que `Scheider (SWI)` se mantiene muy cerca del promedio, esto debido a su valor en el componente es casi cero.

9.6 Comparación de Varianzas y lambdas

```
var(Z1a)
```

```
## [1] 4.323642
```

```
lambda1[1]
```

```
## [1] 4.323642
```

Observe que son iguales, **recuerde que esto siempre va a suceder**

9.7 Cambio a los signos de los coeficientes de Z_1

```
Z1b=-Z1a  
var(Z1b)
```

```
## [1] 4.323642
```

Nota: Recuerde que la varianza es la misma ya que las constantes salen al cuadrado, por lo que el menos que le incluimos se le anula.


10 Biplot

Este es el código para hacer el gráfico normal

```
biplot(pca1, cex=0.6)
```

El gráfico que se le presenta a continuación fue arreglado para términos de presentación y explicación

```
## Warning: package 'factoextra' was built under R version 4.5.3
```



Del gráfico podemos notar que la participante Joyner-Kersee (USA) tienen a tener puntajes altos por ello se ubica en esa posición. Por otro lado está la participante Geremias (BRA), esta posicionada al otro lado completamente de la participamos anteriormente, dicha posición es resultado de que a la participante Geremias (BRA) no le fue tan bien en las tres flechas que van en esa dirección (vallás, saltolargo y saltolargo).

Se puede observar que todas las flechas van hacia la izquierda debido a que su signo es negativo. Además, se puede ver que las que pesan más en el primer componente son aquellas que tienen una flecha más larga, por ejemplo en el gráfico anterior *jabalina* es la que tiene una menor longitud en la flecha debido a que el peso de este es menor que el de las demás variables. Por otro lado, las que más pesan como habíamos visto anteriormente son *vallas*, *saltolargo* y *saltolargo*, estas mismas están agrupadas en este gráfico.

Para el segundo componente primero debemos observar el siguiente vector propio:

```
a2=pca1$rot[,2]
round(a2,2)
```

```
##      vallas saltoalto      tiro      car200 saltolargo  javalina      car800
##      0.06      -0.65     -0.02       0.19      -0.02     -0.33       0.66
```


Note que para este caso las que tiene más peso son las variables *saltoalto* y *car800*, por esta razón estos son los que tiene una flecha de mayor tamaño con respecto al eje vertical. Además note que el signo de *car800* es positivo, por eso es que la flecha tiene una dirección hacia arriba.

Un aspecto importante a resaltar de la participante *Brown* (USA), es que le fue mejor en *saltoalto* que en *car800*, mientras que en *vallas*, *saltolargo* y *saltolargo* está en el promedio, en el otro extremo del gráfico la participante *Bouraga* (URS), le fue de manera intermedia (o se encuentra en el promedio) en las otras variables, pero le fue mucho mejor en *car800* en comparación con *saltoalto*.

10.1 Biplot categórico

```
library(AMR)
library(dplyr)
data=data.frame(c("AM","EU","EU","EU","EU","EU","OC","AM","EU",
                  "EU","EU","EU","EU","EU","EU","AS","EU","AM",
                  "EU","EU","EU","AM","AS","AS"),row.names(base2),base2)
names(data)=c("Continente","Nombre",names(base2))
pca2=data %>%
  pca(vallas,saltoalto,tiro,car200,saltolargo,jabalina,car800)

ggplot_pca(pca2)
```

Para este gráfico puede usar `plot(pca$sdev^2)` o `plot(pca)`

El criterio usando el gráfico dice que se deben escoger la cantidad de componentes antes de que caiga abruptamente la variabilidad, en este caso solo podríamos escoger uno, ya que en el gráfico anterior después del primer valor la varianza se desploma.

Cuándo usamos los porcentajes la idea es que el PCA siempre represente al menos un 80% de la variabilidad, para este caso tenemos el siguiente resultado.

```
sum(lambda1[1:3])/length(lambda1)
```

```
## [1] 0.8646255
```

Usaríamos tres componentes en lugar de uno, lo que pasa es que con dos componente no puedo lograr el objetivo de hacer los gráfico más fácil.

Si un componente tiene una varianza menor a uno, no se justifica incluirlo ya que una variable explica más que un componente, debido a que las variables como están estandarizadas tienen varianza 1. Normalmente esto ocurre porque las variables no se están tan correlacionadas entre sí.

11.0.1 Conclusión de estudio

Debido a que según el gráfico solo debemos quedarnos con un componente y con el criterio del porcentaje con tres componentes, lo cual no nos sirve para el análisis, por lo que aplicar PCA para este estudio no fue satisfactorio.

11.1 Reproducción de la matriz de correlaciones

Usando todos los componentes.

```
A=pca1$rot
L=diag(pca1$sdev**2)
R1=A%*%L%*%t(A)
round(R1,2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.58 0.77   0.83      0.89      0.33   0.56
## saltoalto    0.58      1.00 0.46   0.39      0.66      0.35   0.15
## tiro         0.77      0.46 1.00   0.67      0.78      0.34   0.41
## car200       0.83      0.39 0.67   1.00      0.81      0.47   0.57
## saltolargo   0.89      0.66 0.78   0.81      1.00      0.29   0.52
## javalina     0.33      0.35 0.34   0.47      0.29      1.00   0.26
## car800       0.56      0.15 0.41   0.57      0.52      0.26   1.00
```

Verificación

```
round(R,2)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      1.00      0.58 0.77   0.83      0.89      0.33   0.56
## saltoalto    0.58      1.00 0.46   0.39      0.66      0.35   0.15
## tiro         0.77      0.46 1.00   0.67      0.78      0.34   0.41
## car200       0.83      0.39 0.67   1.00      0.81      0.47   0.57
## saltolargo   0.89      0.66 0.78   0.81      1.00      0.29   0.52
## javalina     0.33      0.35 0.34   0.47      0.29      1.00   0.26
## car800       0.56      0.15 0.41   0.57      0.52      0.26   1.00
```

```
round(abs(R1-R),10)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      0          0   0       0          0          0       0
## saltoalto    0          0   0       0          0          0       0
## tiro         0          0   0       0          0          0       0
## car200       0          0   0       0          0          0       0
## saltolargo   0          0   0       0          0          0       0
## javalina     0          0   0       0          0          0       0
## car800       0          0   0       0          0          0       0
```

Ahora con sólo dos componentes obtenemos una predicción de R y vea las discrepancias. Para facilidad vea las discrepancias con solo un decimal.

```
A2=pca1$rot[,1:2]
L2=diag(lambda1[1:2])
R2=A2%*%L2%*%t(A2)
round(R2-R,1)
```

```
##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas     -0.1      0.0 0.0       0.0          0.0      0.1      0.1
## saltoalto   0.0     -0.2 0.1       0.1          0.0      0.2     -0.1
## tiro        0.0      0.1 -0.3      0.1          0.0      0.1      0.1
## car200      0.0      0.1 0.1      -0.2          0.0     -0.1      0.1
## saltolargo  0.0      0.0 0.0       0.0         -0.1      0.2      0.1
## javalina    0.1      0.2 0.1     -0.1          0.2     -0.7     -0.1
## car800      0.1     -0.1 0.1       0.1          0.1     -0.1     -0.2
```

- Haga lo mismo con tres componentes y decida si vale la pena usar 3 componentes.

```

A3=pca1$rot[,1:3]
L3=diag(lambda1[1:3])
R3=A3%*%L3%*%t(A3)
round(R3-R,1)

##          vallas saltoalto tiro car200 saltolargo javalina car800
## vallas      -0.1      0.0  0.0    0.0      0.0      0    0.0
## saltoalto    0.0     -0.2  0.1    0.1      0.0      0   -0.2
## tiro         0.0      0.1 -0.3    0.1      0.0      0    0.1
## car200        0.0      0.1  0.1   -0.2      0.0      0    0.1
## saltolargo    0.0      0.0  0.0    0.0     -0.1      0    0.0
## javalina      0.0      0.0  0.0    0.0      0.0      0    0.0
## car800        0.0     -0.2  0.1    0.1      0.0      0   -0.2

```

11.2 Obtención de correlaciones

Obtenemos la correlación entre cada variable original y Z1a.

```

cor(base2,Z1a)

##          [,1]
## vallas     -0.9365076
## saltoalto  -0.6539754
## tiro       -0.8369090
## car200     -0.8880557
## saltolargo -0.9377059
## javalina   -0.5038399
## car800     -0.6298453

```

Obtenemos las correlaciones a partir del primer valor propio y el primer vector propio. Compare los resultados.

```

a1=sqrt(lambda1[1]) # a1 es el primer vector propio

##          vallas saltoalto      tiro      car200 saltolargo  javalina      car800
## -0.9365076 -0.6539754 -0.8369090 -0.8880557 -0.9377059 -0.5038399 -0.6298453

```

12 Prueba de los componentes en una regresión

```

Z1=pca1$x[,1]
Z2=pca1$x[,2]
Y=base1$puntaje
mod=lm(Y~Z1+Z2)
summary(mod)

##
## Call:
## lm(formula = Y ~ Z1 + Z2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -233.905   -7.667    3.637   25.755   88.441
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6154.125     11.981  513.665  <2e-16 ***

```

```
## Z1          -230.017      5.886 -39.080  <2e-16 ***
## Z2           6.373      12.908   0.494   0.627
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 58.69 on 21 degrees of freedom
## Multiple R-squared:  0.9864, Adjusted R-squared:  0.9851
## F-statistic: 763.8 on 2 and 21 DF,  p-value: < 2.2e-16
```

Observe que Z1 es significativo y Z2 no es significativo, recuerde que estos son variables así que puede ser que los resultados sean muy distintos para otros estudios.

12.1 Forma automática

```
step(mod)

## Start:  AIC=198.27
## Y ~ Z1 + Z2
##
##           Df Sum of Sq      RSS      AIC
## - Z2       1         840   73184 196.54
## <none>                      72344 198.27
## - Z1       1   5261348 5333693 299.48
##
## Step:  AIC=196.54
## Y ~ Z1
##
##           Df Sum of Sq      RSS      AIC
## <none>                      73184 196.54
## - Z1       1   5261348 5334533 297.48
##
## Call:
## lm(formula = Y ~ Z1)
##
## Coefficients:
## (Intercept)          Z1
##          6154         -230
```

12.2 Interpretaciones de regresión

Tenemos esta ecuación resultante del modelo anterior:

$$\hat{y} = 6154.13 - 230.02(-0.45*vallas - 0.31*salto\ alto - 0.4*Tiro - 0.43*car200 - 0.45*salto\ largo + 0.24*javalina - 0.3*car800)$$

Multiplicamos los coeficientes de Z_1 , por el coeficiente de Z_1

```
a = c(-0.45, -0.31, -0.40, -0.43, -0.45, 0.24, -0.3)
-230.02*a
```

```
## [1] 103.5090  71.3062  92.0080  98.9086 103.5090 -55.2048  69.0060
```

$$\hat{y} = 6154.13 + 103.54\ vallas^s + 71.03*salto\ alto^s + 92*Tiro^s + 98.9*car200^s + 103.5*salto\ largo^s - 55.2*javalina^s + 69*car800^s$$

Obtenemos la desviación estándar de vallas

```
sd(base1$vallas)
```

```
## [1] 0.514564
```

Para este caso las X 's estaban estandarizadas, pero la Y no entonces la interpretación tiene la siguiente estructura:

Por un aumento de 1 desviación estándar en la variable X_j , la respuesta promedio Y (aumenta/disminuye) en promedio β_j^s unidades, manteniendo constantes los demás predictores

Aplicando esa estructura a el ejemplo nos quedaría así:

Por una disminución (esto es por contexto) de 0.51 segundos en la Vallas, la respuesta promedio aumenta.

Recordar que las variables que se le dieron vuelta fueron **vallas**, **car200** y **car800**.

Nota: El objetivo de PCA no es siempre hacer una regresión.

13 Conglomerados

13.1 Distancias entre individuos

Dadas los valores de las variables para los individuos i -ésimo y j -ésimo, interesa tener una medida de la distancia multidimensional entre esos dos individuos.

Si se cuenta con n individuos, la matriz de distancias es de tamaño $n \times n$, con ceros en la diagonal, esto independientemente de q (número de variables).

A continuación se le presenta un ejemplo de la matriz de distancias

$$D = \begin{pmatrix} 0 & d_{12} & \cdots & d_{1n} \\ d_{21} & 0 & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & 0 \end{pmatrix}$$

La distancia es un concepto opuesto al de similitud, entre mayor similitud exista entre dos sujetos, menor es la distancia entre ellos y viceversa.

13.2 Distancia Euclídea

La distancia más común es la Euclídea, definida por:

$$d_{ij} = \sqrt{\sum_{k=1}^q (x_{ik} - x_{jk})^2} = \sqrt{(X_i - X_j)^T (X_i - X_j)}$$

donde x_{ik} es el valor que toma el i -ésimo sujeto en la k -ésima variable, y X_i es el vector de q valores del i -ésimo sujeto: $X_i^T = (x_{i1}, \dots, x_{ik}, \dots, x_{iq})$.

En dos dimensiones, es la medida de la hipotenusa del triángulo rectángulo que se forma a partir de los dos puntos que se están comparando.

El cuadrado de la distancia Euclídea (d_{ij}^2) es otra medida de distancia que se puede usar en algunas ocasiones.

$$d_{ij}^2 = \sum_{k=1}^q (x_{ik} - x_{jk})^2$$


Ejemplo aplicado

Tenemos los siguientes datos tomados en el momento de la clase

id	Peso	Estatura (metros)	Edad
1	94	1.73	23.40
2	84	1.74	21.90
3	60	1.58	21.60
4	85	1.78	20.04
5	71	1.66	25.30

Distancias Euclidianas entre Observaciones

Descomposición geométrica de la distancia mediante diferencias ortogonales



Cáculamos las distancias entre los puntos


$$\begin{aligned}
d(1, 2) &= \sqrt{(94 - 84)^2 + (1.73 - 1.74)^2} = \sqrt{10^2 + (-0.01)^2} = \sqrt{100.0001} \approx 10.0000 \\
d(1, 3) &= \sqrt{(94 - 60)^2 + (1.73 - 1.58)^2} = \sqrt{34^2 + 0.15^2} = \sqrt{1156.0225} \approx 34.0003 \\
d(1, 4) &= \sqrt{(94 - 85)^2 + (1.73 - 1.78)^2} = \sqrt{9^2 + (-0.05)^2} = \sqrt{81.0025} \approx 9.0001 \\
d(1, 5) &= \sqrt{(94 - 71)^2 + (1.73 - 1.66)^2} = \sqrt{23^2 + 0.07^2} = \sqrt{529.0049} \approx 23.0001 \\
\\
d(2, 3) &= \sqrt{(84 - 60)^2 + (1.74 - 1.58)^2} = \sqrt{24^2 + 0.16^2} = \sqrt{576.0256} \approx 24.0005 \\
d(2, 4) &= \sqrt{(84 - 85)^2 + (1.74 - 1.78)^2} = \sqrt{(-1)^2 + (-0.04)^2} = \sqrt{1.0016} \approx 1.0008 \\
d(2, 5) &= \sqrt{(84 - 71)^2 + (1.74 - 1.66)^2} = \sqrt{13^2 + 0.08^2} = \sqrt{169.0064} \approx 13.0002 \\
\\
d(3, 4) &= \sqrt{(60 - 85)^2 + (1.58 - 1.78)^2} = \sqrt{(-25)^2 + (-0.20)^2} = \sqrt{625.0400} \approx 25.0008 \\
d(3, 5) &= \sqrt{(60 - 71)^2 + (1.58 - 1.66)^2} = \sqrt{(-11)^2 + (-0.08)^2} = \sqrt{121.0064} \approx 11.0003 \\
\\
d(4, 5) &= \sqrt{(85 - 71)^2 + (1.78 - 1.66)^2} = \sqrt{14^2 + 0.12^2} = \sqrt{196.0144} \approx 14.0005
\end{aligned}$$

Podemos ver que la diferencias entre el peso en kilogramos, tiene mayor importancia al momento de hacer el cálculo, para solucionar este problema lo idea el estandarizar las variables.

Warning: package 'ggforce' was built under R version 4.5.3

Agrupamiento de Observaciones

ntificación visual de conglomerados naturales entre Peso y Estatura



13.3 Distancia de Mahalanobis

Esta medida de distancia incluye un procedimiento de estandarización dentro de la distancia Euclídea.

No sólo hace una estandarización en los datos escalándolos en términos de su desviación estándar sino que ajusta según las correlaciones entre variables:

$$d_{ij}^M = \sqrt{(X_i - X_j)^T S^{-1} (X_i - X_j)}$$

donde S es la matriz de covariancias de dimensión $q \times q$

Es invariante frente a transformaciones lineales de las variables.

Toma en cuenta las correlaciones entre variables.

No aumenta por el simple hecho de aumentar el número de variables, sino que aumentará cuando las nuevas variables den nueva información.

Aplicación basada en el ejemplo anterior

$$\begin{aligned} d_{35}^M &= \sqrt{(X_3 - X_5)^T \mathbf{S}^{-1} (X_3 - X_5)} \\ &= \sqrt{(60 - 71 \quad 1.58 - 1.66) \begin{bmatrix} 177.7000 & 0.9320 \\ 0.9320 & 0.00622 \end{bmatrix}^{-1} \begin{pmatrix} 60 - 71 \\ 1.58 - 1.66 \end{pmatrix}} \\ &= \sqrt{(-11 \quad -0.08) \begin{bmatrix} 0.0263 & -3.9380 \\ -3.9380 & 750.8345 \end{bmatrix} \begin{pmatrix} -11 \\ -0.08 \end{pmatrix}} \\ &= \sqrt{(0.0259 \quad -16.7491) \begin{pmatrix} -11 \\ -0.08 \end{pmatrix}} \\ &= \sqrt{(-11)(0.0259) + (-0.08)(-16.7491)} \\ &= \sqrt{-0.2849 + 1.3399} \\ &= \sqrt{1.0550} \approx \mathbf{1.0269} \end{aligned}$$

```
X <- as.matrix(datos[, c("Peso", "Estatura")])
n <- nrow(X)
S <- cov(X)
S_inv <- solve(S)

# Matriz de distancias de Mahalanobis par a par
D_M <- matrix(0, nrow = n, ncol = n)
for (i in 1:n) {
  for (j in 1:n) {
    diff <- X[i, ] - X[j, ]
    D_M[i, j] <- sqrt(t(diff) %*% S_inv %*% diff)
  }
}
rownames(D_M) <- colnames(D_M) <- paste0("id_", 1:5)

print("Matriz de Distancias de Mahalanobis (pares):")

## [1] "Matriz de Distancias de Mahalanobis (pares):"
```

```
print(round(D_M, 4))
```

```
##          id_1  id_2  id_3  id_4  id_5
## id_1 0.0000 1.8684 2.6660 2.7477 2.2140
## id_2 1.8684 0.0000 2.0287 0.9553 1.0276
## id_3 2.6660 2.0287 0.0000 2.6607 1.0269
## id_4 2.7477 0.9553 2.6607 0.0000 1.6527
## id_5 2.2140 1.0276 1.0269 1.6527 0.0000
```

Verifique la distancia d_{35}^M es 1.0269

13.4 Distancia City-block (Manhattan)

En esta medida se usa el valor absoluto de las diferencias en lugar de su cuadrado:

$$d_{ij}^{(1)} = \sum_{k=1}^q |x_{ik} - x_{jk}|$$

El nombre nace de la idea de moverse en una ciudad como Manhattan pues, aunque la distancia más corta sería la Euclídea, ésta implica pasar a través de los edificios, mientras que esta distancia asemeja a caminar por las aceras para llegar de un punto a otro.

Es más robusta que la distancia euclídea debido a que no eleva al cuadrado las diferencias.

Tiene la restricción de que asume que las variables no están correlacionadas.

Aplicación basada en el ejemplo anterior

$$\begin{aligned} d(1,2) &= |94 - 84| + |1.73 - 1.74| = 10 + 0.01 = \mathbf{10.01} \\ d(1,3) &= |94 - 60| + |1.73 - 1.58| = 34 + 0.15 = \mathbf{34.15} \\ d(1,4) &= |94 - 85| + |1.73 - 1.78| = 9 + 0.05 = \mathbf{9.05} \\ d(1,5) &= |94 - 71| + |1.73 - 1.66| = 23 + 0.07 = \mathbf{23.07} \\ d(2,3) &= |84 - 60| + |1.74 - 1.58| = 24 + 0.16 = \mathbf{24.16} \\ d(2,4) &= |84 - 85| + |1.74 - 1.78| = 1 + 0.04 = \mathbf{1.04} \\ d(2,5) &= |84 - 71| + |1.74 - 1.66| = 13 + 0.08 = \mathbf{13.08} \\ d(3,4) &= |60 - 85| + |1.58 - 1.78| = 25 + 0.20 = \mathbf{25.20} \\ d(3,5) &= |60 - 71| + |1.58 - 1.66| = 11 + 0.08 = \mathbf{11.08} \\ d(4,5) &= |85 - 71| + |1.78 - 1.66| = 14 + 0.12 = \mathbf{14.12} \end{aligned}$$

Aplicación en r

```
# Distancia de Manhattan para Peso y Estatura
D_manhattan_2v <- dist(datos[, c("Peso", "Estatura")], method = "manhattan")
print(as.matrix(round(D_manhattan_2v, 2)))
```

```
##          1      2      3      4      5
## 1  0.00 10.01 34.15  9.05 23.07
## 2 10.01  0.00 24.16  1.04 13.08
## 3 34.15 24.16  0.00 25.20 11.08
## 4  9.05  1.04 25.20  0.00 14.12
## 5 23.07 13.08 11.08 14.12  0.00
```

```
# Distancia de Manhattan completa (3 variables)
D_manhattan_3v <- dist(datos, method = "manhattan")
print(as.matrix(round(D_manhattan_3v, 2)))
```

```
##      1      2      3      4      5
## 1  0.00 14.68 48.20 16.07 36.09
## 2 14.68  0.00 33.55  4.05 21.44
## 3 48.20 33.55  0.00 34.93 17.44
## 4 16.07  4.05 34.93  0.00 20.16
## 5 36.09 21.44 17.44 20.16  0.00
```

13.4.1 Nota importante de las distancias

Puede ser que usando algunos de los métodos, las agrupaciones que se estén realizando, por lo que dependiendo del caso se debe escoger el tipo de distancia que tenga más sentido. De modo que los grupos sean muy parecidos dentro de ellos, pero muy desiguales entre los grupos existentes.

14 Ejemplo de aplicación con temperaturas de diferentes cantones de Costa Rica

```
load("Temp_Cantones.Rdata")
```

Observe la estructura de la base

```
head(base)
```

```
## # A tibble: 6 x 4
##   canton  anio mes   temp_c
##   <chr>   <dbl> <fct>   <dbl>
## 1 Cartago 2025 JAN     19.9
## 2 Cartago 2025 FEB     20.0
## 3 Cartago 2025 MAR     20.7
## 4 Cartago 2025 APR     20.8
## 5 Cartago 2025 MAY     21.6
## 6 Cartago 2025 JUN     21.1
```

Para solucionar este problema debemos pivotar la base de datos con el siguiente código:

```
library(dplyr)
library(tidyr)
library(tibble)
base2 = base %>%
  select(canton, mes, temp_c) %>%
  pivot_wider(
    names_from = mes,
    values_from = temp_c
  ) %>%
  column_to_rownames(var = "canton")
```

```
head(base2)
```

```
##           JAN  FEB  MAR  APR  MAY  JUN  JUL  AUG  SEP  OCT  NOV
## Cartago    19.89 19.99 20.68 20.78 21.60 21.11 20.88 20.94 21.16 20.81 20.39
## Corredores 26.27 26.87 27.73 27.65 26.58 26.04 26.47 26.18 25.88 25.28 25.61
## Limón      24.36 24.35 24.75 24.92 25.62 25.09 25.12 25.17 25.34 25.03 24.76
```

```
## Nicoya      27.43 28.63 29.45 29.52 28.28 27.33 27.92 27.64 27.09 26.47 26.85
## Puntarenas  26.59 27.40 28.57 28.51 27.66 26.82 27.40 27.20 26.72 25.95 26.40
## Pérez Zeledón 20.97 21.27 22.10 22.21 22.23 21.75 21.87 21.75 21.68 21.17 21.16
##            DEC
## Cartago     19.67
## Corredores  25.76
## Limón       24.37
## Nicoya      26.96
## Puntarenas  26.28
## Pérez Zeledón 20.78
```

14.0.1 Cálculo distancia euclidiana

A continuación se le proporcionar la distancia euclidiana entre dos individuos

```
x1=base2[1,]
x2=base2[2,]
x12=as.matrix(x1-x2,ncol=1)
sqrt(x12%*%t(x12))
```

```
##           Cartago
## Cartago 19.98362
```

14.0.2 ¿Que sucede si transponemos la base?

```
base3 = t(base2)
head(base3)
```

```
##      Cartago Corredores Limón Nicoya Puntarenas Pérez Zeledón Santa Cruz
## JAN   19.89      26.27 24.36  27.43      26.59      20.97      26.59
## FEB   19.99      26.87 24.35  28.63      27.40      21.27      28.19
## MAR   20.68      27.73 24.75  29.45      28.57      22.10      29.72
## APR   20.78      27.65 24.92  29.52      28.51      22.21      29.78
## MAY   21.60      26.58 25.62  28.28      27.66      22.23      28.63
## JUN   21.11      26.04 25.09  27.33      26.82      21.75      27.20
##      Talamanca Upala Vázquez de Coronado
## JAN   20.52 25.34      22.86
## FEB   20.64 26.31      23.09
## MAR   21.25 28.21      24.05
## APR   21.38 28.23      24.31
## MAY   22.15 27.77      24.15
## JUN   21.71 26.26      23.55
```

En el cálculo de la distancia lo que cambia es la posición de los datos y el lugar de la matriz transpuesta en la multiplicación de matrices

```
x1=as.numeric(base3[,1])
x2=as.numeric(base3[,2])
x12=as.matrix(x1-x2,ncol=1)
sqrt(t(x12)%*%x12)
```

```
##           [,1]
## [1,] 19.98362
```

A continuación se le presenta una forma automática de calcular todas las distancias por medio de la función dist()

```
(d=dist(base2))
```

```
##           Cartago Corredores      Limón   Nicoya Puntarenas
## Corredores      19.983618
## Limón           14.732074    5.831569
## Nicoya          24.992805    5.054157  10.641414
## Puntarenas      22.582608    2.749109   8.204767   2.488715
## Pérez Zeledón   3.396145   16.672942  11.592886  21.686860   19.291008
## Santa Cruz      24.327885    4.680833  10.151345   1.493352   2.247221
## Talamanca       2.126006   17.883582  12.611189  22.893610  20.479187
## Upala           20.422030    2.076126   6.326302   4.892852   2.653356
## Vázquez de Coronado 9.772712  10.237846   5.271442  15.236430  12.820729
##           Pérez Zeledón Santa Cruz Talamanca      Upala
## Corredores
## Limón
## Nicoya
## Puntarenas
## Pérez Zeledón
## Santa Cruz      21.032432
## Talamanca       1.541006   22.242704
## Upala           17.162613    4.013365  18.334350
## Vázquez de Coronado 6.491849  14.600449   7.678086  10.723656
```

Observe la clase del objeto d

```
class(d)
```

```
## [1] "dist"
```

14.0.3 Extracción de valores de un objeto dist()

```
d2= as.matrix(d) # Pasamos el objeto dist a una matriz
d2sup = d2
# Para evitar los ceros en la diagonal extraemos la matriz triangular superior
d2sup[lower.tri(d2, diag = TRUE)] <- NA # Se extrae la matriz triangular superior y reemplazan los otros
```

Cantones con Mayor distancia

```
#Extraemos la posición de la distancia más grande
max_pos = which(d2sup == max(d2sup, na.rm = TRUE), arr.ind = TRUE)
#Obtenemos los nombres de las variables de forma automática
cantones_max <- data.frame(
  Canton_1 = rownames(d2)[max_pos[, 1]],
  Canton_2 = colnames(d2)[max_pos[, 2]],
  Distancia = d2[max_pos]
)
cantones_max
```

```
##   Canton_1 Canton_2 Distancia
## 1   Cartago   Nicoya   24.9928
```

Cantones con menor distancia

```
min_pos = which(d2sup == min(d2sup, na.rm = TRUE), arr.ind = TRUE)
cantones_min = data.frame(
  Canton_1 = rownames(d2)[min_pos[, 1]],
  Canton_2 = colnames(d2)[min_pos[, 2]],
```

```

    Distancia = d2[min_pos]
)
cantones_min

```

```

##   Canton_1   Canton_2 Distancia
## 1   Nicoya Santa Cruz  1.493352

```

14.0.4 Cálculo distancia de Mahalannobis

```

library(biotools)
S=var(base2)
dM=D2.dist(base2,S)
# DA ERROR PORQUE S NO SE PUEDE INVERTIR

```

14.0.5 Cálculo distancia de Manhattan

```

dMan=dist(base2,method = "manhattan")
as.matrix(dMan)[1,2]

```

```

## [1] 68.42

```

14.1 Creación de dendogramas

14.1.1 K-vecino más cercano

Para crear un dendograma de este tipo de distancia se debe indicar con `method = "single"`.

```

cs = hclust(d,method = "single")


```

```

plot(cs,xlab="",main="Vecino más cercano con distancia Euclídea",
      ylab="Distancia",sub="")

```


Vecino más cercano con distancia Euclídea



```
csM = hclust(dM,method = "single")
plot(csM,xlab="",main="Vecino más cercano con distancia de Mahalanobis",
      ylab="Distancia",sub="")
```

```
csMan = hclust(dMan,method = "single")
plot(csMan,xlab="",main="Vecino más cercano con distancia de Manhattan",
      ylab="Distancia",sub="")
```

Vecino más cercano con distancia de Manhattan




14.1.2 K-vecino más lejano

Para crear un dendrograma de este tipo de distancia se debe indicar con `method = "complete"`.

```
c.com = hclust(d,method = "complete")  
plot(c.com, xlab = "", main = "Vecino más lejano con distancia Euclídea",  
      ylab = "Distancia", sub = "")
```


Vecino más lejano con distancia Euclídea



```
cM.com = hclust(dM,method = "complete")
plot(cM.com,xlab="",main="Vecino más lejano con distancia de Mahalannobis",
      ylab="Distancia",sub="")
```

```
cMan.com = hclust(dMan,method = "complete")
plot(cMan.com,xlab="",main="Vecino más lejano con distancia de Manhattan",
      ylab="Distancia",sub="")
```


Vecino más lejano con distancia de Manhattan



14.1.3 Salto promedio

```
c.av = hclust(d,method = "average")
plot(c.av,xlab="",main="Salto promedio con distancia Euclidean",
      ylab="Distancia",sub="")
```


Salto promedio con distancia Euclidea



```
cM.av = hclust(dM,method = "average")
plot(cM.av,xlab="",main="Salto promedio con distancia de Mahalannobis",
      ylab="Distancia",sub="")
```

```
cMan.av = hclust(dMan,method = "average")
plot(cMan.av,xlab="",main="Salto promedio con distancia de Manhattan",
      ylab="Distancia",sub="")
```


Salto promedio con distancia de Manhattan



14.1.4 Distancia de Ward


```
c.w = hclust(d,method = "ward.D")  
plot(c.w,xlab="",main="Distancia de Ward con distancia Euclidea",  
      ylab="Distancia",sub="")
```

Distancia de Ward con distancia Euclidea



```
cM.w = hclust(dM,method = "ward.D")
plot(cM.w,xlab="",main="Distancia de Ward con distancia de Mahalanobis",
      ylab="Distancia",sub="")
```

```
cMan.w = hclust(dMan,method = "ward.D")
plot(cMan.w,xlab="",main="Distancia de Ward con distancia de Manhattan",
      ylab="Distancia",sub="")
```




14.2 ¿Los dos cantones más correlacionados son los cantones que menor distancia tienen?

A continuación se le presenta un gráfico con las temperaturas de todos los meses por cantón

```
#datos largos son los datos pivoteados
ggplot(datos_largos, aes(x = mes, y = temp_c, group = canton, color = canton)) +
  geom_line(linewidth = 0.9, alpha = 0.85) +
  geom_point(size = 2) +
  labs(
    title = "Ciclo anual de temperatura por cantón (2025)",
    x = "Mes",
    y = "Temperatura (°C)",
    color = "Cantón"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    panel.grid.minor = element_blank(),
    legend.position = "right"
  )
```

Ciclo anual de temperatura por cantón (2025)




Recordemos que la menor distancia entre cantones se encontraba entre:

cantones_min *#Buscar en las páginas de arriba como se obtuvo este resultado*

```
## Canton_1 Canton_2 Distancia
## 1 Nicoya Santa Cruz 1.493352
```

A continuación se le presenta un gráfico de la matriz de correlaciones

```
corrgram(base3, lower.panel=panel.pts, upper.panel=panel.conf,
diag.panel=panel.density,order=T)
```



Basado en el gráfico anterior y con la función `cor()` obtenemos la mayor correlación entre cantones.

```
R = cor(base3)
Rsup = R
Rsup[lower.tri(R, diag = TRUE)] <- NA # Se extrae la matriz triangular superior y reemplazan los otros v
max_r = which(Rsup == max(Rsup, na.rm = TRUE), arr.ind = TRUE)

#Obtenemos los nombres de las variables de forma automática
cantones_maxr <- data.frame(
  Canton_1 = rownames(R)[max_r[, 1]],
  Canton_2 = colnames(R)[max_r[, 2]],
  Correlación = R[max_r]
)
```

Basado en el proceso anterior tenemos los siguientes dataframe()

```
cantones_min # el código se encuentra más arriba
```

```
## Canton_1 Canton_2 Distancia
## 1 Nicoya Santa Cruz 1.493352
```

```
cantones_maxr
```

```
## Canton_1 Canton_2 Correlación
## 1 Cartago Talamanca 0.9973338
```

Obtenemos los nombres para poder graficarlos en un solo gráfico

```
d1 = cantones_min[1,1] #Nicoya
d2 = cantones_min[1,2] #Santa Cruz
```

```

r1 = cantones_maxr[1,1] #Cartago
r2 = cantones_maxr[1,2] #Talamanca


# Unir cantones a graficar (sin duplicados)
cantones_a_graficar <- unique(c(d1,d2,r1,r2))

# Filtrar y pivotar a formato largo
datos_lineas <- base2 %>%
  as.data.frame() %>%
  rownames_to_column(var = "canton") %>%
  filter(canton %in% cantones_a_graficar) %>%
  pivot_longer(
    cols = JAN:DEC,
    names_to = "mes",
    values_to = "temp_c"
  ) %>%
  mutate(
    mes = factor(mes, levels = c("JAN", "FEB", "MAR", "APR", "MAY", "JUN",
                                "JUL", "AUG", "SEP", "OCT", "NOV", "DEC"))
  )

# Gráfico lineal comparativo
ggplot(datos_lineas, aes(x = mes, y = temp_c, group = canton, color = canton)) +
  geom_line(linewidth = 1.1) +
  geom_point(size = 2.5) +
  scale_color_brewer(palette = "Set1") +
  labs(
    title = "Gráfico comparativo de los cantones más correlacionados y \ncon menor distancia",
    x = "Mes",
    y = "Temperatura (°C)",
    color = "Cantón"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    panel.grid.minor = element_blank(),
    legend.position = "bottom"
  )

```

Gráfico comparativo de los cantones más correlacionados y con menor distancia



Se puede ver en el anterior gráfico que los cantones de Cartago y Talamanca, tienen el mismo comportamiento, pero no son tan cercanos. Por otro lado, los cantones Santa Cruz y Nicoya son muy cercanos, pero su comportamiento si es más distinto, estos dos tipos de distancia nos sirven dependiendo del tipo de pregunta que busquemos resolver.

A partir de una matriz de correlaciones R , se puede obtener una matriz de distancias de la siguiente forma:

$$D = 1 - R$$


A continuación se le presenta la forma de hacerlo en R

```
D = 1-R
dr = as.dist(D)
```

Hacemos un dendograma y lo comparamos con el que se obtiene con la distancia euclídea. Es importante resaltar que el mejor tipo de distancia es la distancia de Ward, por esa razón es que los siguientes gráficos van con esta distancia. *Los demás tipos de distancia se encuentran en la anterior sección*


```
c.w = hclust(d,method = "ward.D")
plot(c.w,xlab="",main="Distancia de Ward con distancia Euclídea",
      ylab="Distancia",sub="")
```

Distancia de Ward con distancia Euclídea



```
c.w = hclust(dr,method = "ward.D")
plot(c.w,xlab="",main="Distancia de Ward con distancia de correlación",
      ylab="Distancia",sub="")
```

Distancia de Ward con distancia de correlación



```

grupos <- cutree(cMan.w, k = 2)
# Ver la asignación de cantones por grupo en consola
print(split(names(grupos), grupos))

## $`1`
## [1] "Cartago"          "Limón"             "Pérez Zeledón"
## [4] "Talamanca"        "Vázquez de Coronado"
##
## $`2`
## [1] "Corredores" "Nicoya"          "Puntarenas" "Santa Cruz" "Upala"

# 2. Preparar el data frame calculando la temperatura media anual por cantón
datos_cajas <- as.data.frame(base2) %>%
  rownames_to_column(var = "canton") %>%
  mutate(
    Grupo = factor(paste("Grupo", grupos[canton])),
    temp_media = rowMeans(across(JAN:DEC))
  )


# 3. Boxplot con exactamente dos cajas
ggplot(datos_cajas, aes(x = Grupo, y = temp_media, fill = Grupo)) +
  geom_boxplot(
    width = 0.45,
    alpha = 0.7,
    outlier.shape = NA,
    show.legend = FALSE
  ) +

```

```

# Puntos observados (cantones) con dispersión horizontal leve
geom_jitter(
  width = 0.08,
  size = 3.2,
  aes(color = Grupo),
  show.legend = FALSE
) +
# Etiquetas con el nombre del cantón
geom_text(
  aes(label = canton),
  hjust = -0.15,
  vjust = 0.5,
  size = 3.3,
  fontface = "bold"
) +
scale_fill_manual(values = c("Grupo 1" = "skyblue", "Grupo 2" = "#e74c3c")) +
scale_color_manual(values = c("Grupo 1" = "#1b4f72", "Grupo 2" = "#922b21")) +
labs(
  title = "Comparación térmica entre conglomerados",
  subtitle = "Agrupamiento jerárquico (Ward + Manhattan, Con dos grupos)",
  x = "Conglomerado",
  y = "Temperatura media anual (°C)"
) +
theme_minimal(base_size = 12) +
theme(
  plot.title = element_text(face = "bold", hjust = 0.5),
  plot.subtitle = element_text(hjust = 0.5, color = "gray30", margin = margin(b = 10)),
  panel.grid.minor = element_blank()
)

```



14.3 ¿Que ocurre cuando tenemos variables categóricas?

Luego de ver el laboratorio colocar la función `daisy()`, que saca la distancias entre categóricas y numéricas (EXPLICAR)

Cuando se tienen tanto variables métricas como variables nominales y/o ordinales se recomienda usar la distancia de Gower:

$$d_{ij}^G = \frac{1}{q} \left[\sum_{h=1}^{p_1} \frac{|x_{ih} - x_{jh}|}{R_h} + \beta_{ij} \right]$$

donde:

- R_h : RAngo de la h-ésima variable cuantitativa
- β_{ij} : número de variables cualitativas que no son idénticas
- q : número total de variables

14.3.1 Ejemplo de las universidades

Se cuenta con información de un gran número de universidades de los E.U.A de la edición de 1995 del US News and World Report.

Variables de tipo continuo:

- Tasa de aceptación (número aceptados / número aplicaciones)
- Costo de la matrícula para estudiantes de otros estados

- Número de nuevos estudiantes
- Tasa de graduación

Variables de tipo categórico (binarias):

- Tipo de universidad (pública o privada)
- Elite: si más del 50% de los estudiantes provienen de colegios del top-10%.

A continuación se le presenta el formato de la base de datos del ejemplo

Universidad / Institución	tasa.acept	costo	nuevos	tasa.grad	privado	elite
Abilene Christian University	0.74	7440	721	60	Yes	No
Adelphi University	0.88	12280	512	56	Yes	No
Adrian College	0.77	11250	336	54	Yes	No
Agnes Scott College	0.84	12960	137	59	Yes	Yes
Alaska Pacific University	0.76	7560	55	15	Yes	No
Albertson College	0.82	13500	158	55	Yes	No

Para el cálculo de la distancia de Gower se necesitan los rangos de las variables continuas:

A continuación se le presenta los rangos de cada una de las variables del ejemplo

Nota: Recuerde que el rango es la diferencia entre el valor máximo y el valor mínimo

tasa.acept	costo	nuevos	tasa.grad
0.846	19360	6357	108

Rangos en cada uno de las universidades

Universidad / Institución	tasa.acept	costo	nuevos	tasa.grad
Abilene Christian University	0.74	7440	721	60
Adelphi University	0.88	12280	512	56

Aplicamos la fórmula para la distancia de Gower

$$\begin{aligned}
\sum_{h=1}^4 \frac{|x_{1h} - x_{2h}|}{R_h} &= \frac{0.74 - 0.88}{0.846} + \frac{7440 - 12280}{19360} + \frac{721 - 512}{6357} + \frac{60 - 56}{108} \\
&= \frac{0.14}{0.846} + \frac{4840}{19360} + \frac{209}{6357} + \frac{4}{108} \\
&\approx 0.1655 + 0.2500 + 0.0329 + 0.0370 \\
&= 0.4854 \quad (\approx 0.483)
\end{aligned}$$

Observe que en este caso las que aportan más son las tasas de aceptación y el costo debido a que tienen un aporte de 0.16 y 0.25 respectivamente.

Se tiene la siguiente información de las dos universidades

Universidad / Institución	privado	elite
Abilene Christian University	Yes	No
Adelphi University	Yes	No

En este caso como ambas variables cualitativas son cero entonces $\beta_{12} = 0$

$$d_{12}^G = \frac{1}{q} \left[\sum_{h=1}^4 \frac{|x_{1h} - x_{2h}|}{R_h} + \beta_{12} \right] = \frac{1}{6} [0.483 + 0] = 0.0805$$

Luego de obtener este resultado lo tenemos que visualizar en un dendrograma