

Manual para el curso Minería de Datos y Análisis Multivariado (XS-0126)

Segundo examen

Autor: Anderson Martínez

Colaboradores: Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1	Escalamiento multidimensional (MDS)	1
1.1	Escalamiento multidimensional métrico (MMDS)	1
1.1.1	Datos Curiosos de MMDS	1
1.1.2	Escalamiento Multidimensional en r	3
1.1.3	Reconstrucción por la matriz B	3
1.2	Bondad de ajuste (Mardia et al. 1979)	4
1.2.1	Obtención de valores propios (Eigen values)	4
1.2.2	Aplicación de la bondad de ajuste	4
1.3	Falta de ajuste (stress)	5
1.3.1	Aplicación del stress	5
1.3.2	Comparación de valores de r de coordenadas con los valores propios	6

1 Escalamiento multidimensional (MDS)

Se trata de agrupar los individuos según las distancias de sus observaciones en las distintas variables (entre más cerca se encuentren dos individuos más parecidos son).

En la construcción de las nuevas coordenadas basadas en la distancia no existe una variable respuesta. Todas las variables funcionan al mismo nivel y se construyen nuevas variables a partir de ese conjunto de variables disponibles.

1.1 Escalamiento multidimensional métrico (MMDS)

El escalamiento multidimensional métrico es también conocido como escalamiento multidimensional clásico (CMDS) o análisis de coordenadas principales (PCoA).

El escalamiento multidimensional clásico se puede hacer con cualquier distancia que el investigador considere pertinente: euclídea, manhattan, mahalanobis, etc.

1.1.1 Datos Curiosos de MMDS

Si se realiza el MMDS con la distancia euclídea se obtiene el mismo resultado que realizar un análisis de componentes principales.

Por ende, agrupar minimizando las distancias lineales entre individuos (MMDS) es lo mismo que agrupar maximizando las correlaciones lineales entre esos mismos individuos (PCA).

Comparativa de PCA vs MDS

PCA

MDS

Descomposición en valores propios

1. ****Coordenadas**** para una representación gráfica más simple.
2. ****Porcentaje de variación explicada**** / proporción de los valores propios.
3. ****Acomodo**** de los componentes principales / las coordenadas en orden de importancia.

A partir de la matriz de datos $\mathbf{X}$ se obtiene una matriz de distancias $\mathbf{D}$ de dimensión $n \times n$. El MMDS parte de $\mathbf{D}$ y trata de encontrar $\mathbf{X}$.

Para comprender la mecánica se asume que $\mathbf{X}$ es conocida y se obtiene el producto $\mathbf{B} = \mathbf{X}\mathbf{X}^\top$. Entonces cada elemento de $\mathbf{B}$ se puede expresar como:

$$b_{ij} = \sum_{k=1}^q x_{ik}x_{jk}$$

De esta forma la distancia Euclídea al cuadrado se puede expresar como:

$$d_{ij}^2 = b_{ii} + b_{jj} - 2b_{ij}$$

Se impone la restricción de que los datos de cada variable estén centrados en cero, por lo que $\sum_{i=1}^n x_{ik} = 0$. De esta forma todos los elementos de $\mathbf{B}$ son tales que la suma de cualquier fila (o columna) es cero: $\sum_{j=1}^n b_{ij} = 0$. Se obtienen las siguientes relaciones:

$$\sum_{i=1}^n d_{ij}^2 = T + nb_{jj} \quad \sum_{j=1}^n d_{ij}^2 = T + nb_{ii} \quad \sum_{i=1}^n \sum_{j=1}^n d_{ij}^2 = 2nT$$

donde $T = \text{tr}(\mathbf{B}) = \sum_{i=1}^n b_{ii}$. De esta forma:

$$b_{ij} = -\frac{1}{2} (d_{ij}^2 - d_{i.}^2 - d_{.j}^2 + d_{..}^2)$$

donde las medias marginales y global de las distancias al cuadrado se definen como:

$$d_{i.}^2 = \frac{1}{n} \sum_{j=1}^n d_{ij}^2 \quad d_{.j}^2 = \frac{1}{n} \sum_{i=1}^n d_{ij}^2 \quad d_{..}^2 = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n d_{ij}^2$$

Ahora se hace la descomposición espectral de $\mathbf{B}$:

$$\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top$$

La matriz $\mathbf{\Lambda}$ es diagonal con los n valores propios de $\mathbf{B}$ en la diagonal. Si el rango de $\mathbf{B}$ es q , entonces los últimos $n - q$ valores propios son cero por lo que se pueden eliminar y escribir $\mathbf{B}$ en función solamente de los primeros q vectores y valores propios. Finalmente se puede escribir la matriz $\mathbf{X}$ como:

$$\mathbf{X} = \mathbf{V}_1\mathbf{\Lambda}_1^{1/2}$$

Donde $\mathbf{V}_1$ es la matriz que contiene solo los primeros q vectores propios, y $\mathbf{\Lambda}_1$ es la matriz diagonal con solo los primeros q valores propios. La mejor representación de dimensión k está dada por los k vectores propios de $\mathbf{B}$, asociados a los k valores propios más grandes.

A continuación todo los ejemplos de este de tema se basaran en los siguientes datos

```
base = cbind(c(3,5,6,1,4,2,0,0,7,2),
             c(4,1,2,1,7,2,4,6,6,1),
             c(4,1,0,1,3,5,1,4,5,4),
             c(6,7,2,0,6,1,1,3,1,3),
             c(1,3,6,3,2,0,1,5,4,1))
```

```
d = dist(base)
```

1.1.2 Escalamiento Multidimensional en r

'cmds<-cmdscale(d,k=5,eig=TRUE,x.ret=TRUE)', donde

- d <- es la matriz de distancias
- k <- indica el número de dimensiones requeridas
- eig <- indica si debería devolver los valores propios
- X.ret <- devuelve parte de la matriz B (La matriz B se obtiene multiplicando $(-1/2)*cmds\$x$)

Tienen que agregarse todos estos argumentos porque de lo contrario solo da los primeros vectores propios.

```
cmds = cmdscale(d,k=5,eig=TRUE,x.ret=TRUE) # 5 dimensiones, # d tiene que seer un objeto distancia
```

```
cmds2 = cmdscale(d,k=2,eig=TRUE,x.ret=TRUE) # 2 dimensiones
```

1.1.3 Reconstrucción por la matriz B

Los elementos de la matriz B se pueden obtener de acuerdo a las fórmulas vistas en la presentación en clase o también utilizando la siguiente fórmula: $B = -\frac{1}{2}CD^2C$. Donde D^2 es la matriz de distancias al cuadrado y C está definida como $C = I - \frac{1}{n}J_n$. Aquí I es la matriz identidad de dimensión $n \times n$ y J_n es una matriz de unos, de dimensión $n \times n$.

```
n = dim(base)[1]
D = as.matrix(dist(base,diag = T,upper = T))
Jn = matrix(1,n,n)
C = diag(n)-(1/n)*Jn

B = -0.5*C*%(D^2)*%C
```

1.2 Bondad de ajuste (Mardia et al. 1979)

La idoneidad de las nuevas coordenadas resultantes del escalamiento multidimensional, se puede juzgar según la proporción de valores propios representados por dichas coordenadas.

$$P_k^{(1)} = \frac{\sum_{i=1}^k |\lambda_i|}{\sum_{i=1}^n |\lambda_i|} \quad P_k^{(2)} = \frac{\sum_{i=1}^k \lambda_i^2}{\sum_{i=1}^n \lambda_i^2}$$

Donde entre más cercano esté a uno, mejor es la representación de los datos en las nuevas coordenadas.

*Nota: Note que la cantidad de valores propios es igual al número de observaciones.

Sin embargo, dicha proporción nunca es igual a uno puesto que lo que se quiere es disminuir dimensiones, para poder tener una representación más sencilla de los datos.

$$k < q$$

donde:

- q : es el número de dimensiones originales.
- k : es el número de dimensiones escogidas después de aplicar el escalonamiento multidimensional.

Se recomiendan valores mayores que 0,8 para ambos criterios.

1.2.1 Obtención de valores propios (Eigen values)

```
round(cmds$eig,2)

## [1] 75.19 58.81 49.61 30.43 10.37 0.00 0.00 0.00 0.00 0.00
```

1.2.2 Aplicación de la bondad de ajuste

Primer Criterio

Si $k = 2$, entonces el calculo es el siguiente:

```
round(sum(abs(cmds$eig[1:2]))/sum(abs(cmds$eig))*100,2)
```

```
## [1] 59.71
```

Si $k = 3$

```
round(sum(abs(cmds$eig[1:3]))/sum(abs(cmds$eig))*100,2)
```

```
## [1] 81.82
```

Se necesitarían al menos 3 dimensiones para alcanzar más de un 80%. Por lo que en este caso obtener una representación con dos dimensiones no es muy buena.

Segundo Criterio

Si $k = 2$, entonces el calculo es el siguiente:

```
round(sum(cmds$eig[1:2]^2)/sum(cmds$eig^2)*100,2)
```

```
## [1] 72.28
```

el ajuste es mejor que con el otro criterio

Si $k = 3$

```
round(sum(cmds$eig[1:3]^2)/sum(cmds$eig^2)*100,2)
```

```
## [1] 91.8
```

NO hay ninguno mejor que otro, lo mejor es tener un equilibrio entre los dos criterios.

1.3 Falta de ajuste (stress)

Es una medida de la falta de ajuste que consiste en la diferencia de las distancias observadas y las distancias predichas, estandarizadas por las distancias observadas al cuadrado para obtener valores entre 0 y 1.

Me dice que tan bien puedo reproducir los datos

$$stress = \sqrt{\frac{\sum (d_{ij} - \hat{d}_{ij})^2}{\sum d_{ij}^2}}$$

Donde entre más cercano esté a cero, mejor es la representación de los datos en las nuevas coordenadas.

Al evaluar bondad de ajuste del MDS, para este propósito Kruskal en 1964, propuso la siguiente regla de dedo:

Stress	Bondad de ajuste
0.000	perfecto
0.025	excelente
0.050	bueno
0.100	aceptable
0.200	pobre

Notas:

- Recuerde que puede usar cualquier distancia que sea pertinente para los datos.
- El *stress* puede usarse también para calificar la falta de ajuste de un escalamiento multidimensional no métrico.

1.3.1 Aplicación del stress

Para este caso el mayor número de dimensiones puede ser $k = 5$, debido a la cantidad de filas que tienen nuestros datos (cantidad de sujetos)

Para $k = 2$

```
k = 2
coor2=cmds$points[,1:k]
d2=as.matrix(dist(coor2))
d=as.matrix(d2)
sqrt(sum((d-d2)^2)/sum(d^2)) # d es la matriz de distancias observadas
```

```
## [1] 0.3371175
```

Para $k = 2$

```
k = 4
coord2=cmds$points[,1:k]
d2=as.matrix(dist(coord2))
d=as.matrix(d)
sqrt(sum((d-d2)^2)/sum(d^2))
```

```
## [1] 0.05019229
```

Con el resultado anterior podemos observar que con cuatro dimensiones alcanza un ajuste bueno, mas no excelente.

1.3.2 Comparación de valores de r de coordenadas con los valores propios

```
eB = eigen(B)
```


```
cmds$points[,1:2]
```

```
##           [,1]      [,2]
## [1,] -1.6038325  2.38060903
## [2,] -2.8246377 -2.30937202
## [3,] -1.6908272 -5.13970089
## [4,]  3.9527719 -2.43233961
## [5,] -3.5984894  2.75538195
## [6,]  2.9520356  1.35475175
## [7,]  3.4689928  0.76411068
## [8,]  0.3545235  2.31408566
## [9,] -2.9362323 -0.01279597
## [10,] 1.9256952  0.32526941
```


```
eB$vectors[,1:2]
```

```
##           [,1]      [,2]
## [1,] -0.18496398  0.310440748
## [2,] -0.32575486 -0.301151163
## [3,] -0.19499676 -0.670237142
## [4,]  0.45585835 -0.317186619
## [5,] -0.41500028  0.359312607
## [6,]  0.34044719  0.176664938
## [7,]  0.40006592  0.099643028
## [8,]  0.04088587  0.301765840
## [9,] -0.33862466 -0.001668644
## [10,] 0.22208321  0.042416406
```

```
plot(cmds$points[,1:2])
```



```
plot(eB$ectors[,1:2])
```



Se pueden observar en los anteriores gráficos, los coordenadas son prácticamente iguales.