Manual para el curso Mineria de Datos y Análisis Multivariado (XS-0126)

Segundo examen

Autor: Anderson Martínez
Colaboradores: Sebastián Calvo, Justin Zhu, Fabián Almirall

Contents

1 Escalamiento multidimensional (MDS) 1
1.1 Escalamiento multidimensional métrico (MMDS) . . . 1
1.1.1 Datos Curiosos de MMDS . . . 2
1.1.2 Escalamiento Multidimensional en r . . . 3
1.1.3 Reconstrucción por la matriz B . . . 4
1.2 Bondad de ajuste (Mardia et al. 1979) . . . 4
1.2.1 Obtención de valores propios (Eigen values) . . . 4
1.2.2 Aplicación de la bondad de ajuste . . . 4
1.3 Falta de ajuste (stress) . . . 5
1.3.1 Aplicación del strees . . . 5
1.3.2 Comparación de valores de r de coordernadas con los valores propios . . . 6

2 Clasificación 8
2.1 Apredizaje o entrenamiento . . . 8
2.2 Validación . . . 9
2.3 Predicción . . . 9
2.4 Regresión logística multinomial . . . 9
2.4.1 Supuesto . . . 9
2.4.2 Modelo . . . 10
2.4.3 Ejemplo aplicado en clase . . . 10

1 Escalamiento multidimensional (MDS)

Se trata de agrupar los individuos según las distancias de sus observaciones en las distintas variables (entre más cerca se encuentren dos individuos más parecidos son).

En la construcción de las nuevas coordenadas basadas en la distancia no existe una variable respuesta. Todas las variables funcionan al mismo nivel y se construyen nuevas variables a partir de ese conjunto de variables disponibles.

1.1 Escalamiento multidimensional métrico (MMDS)

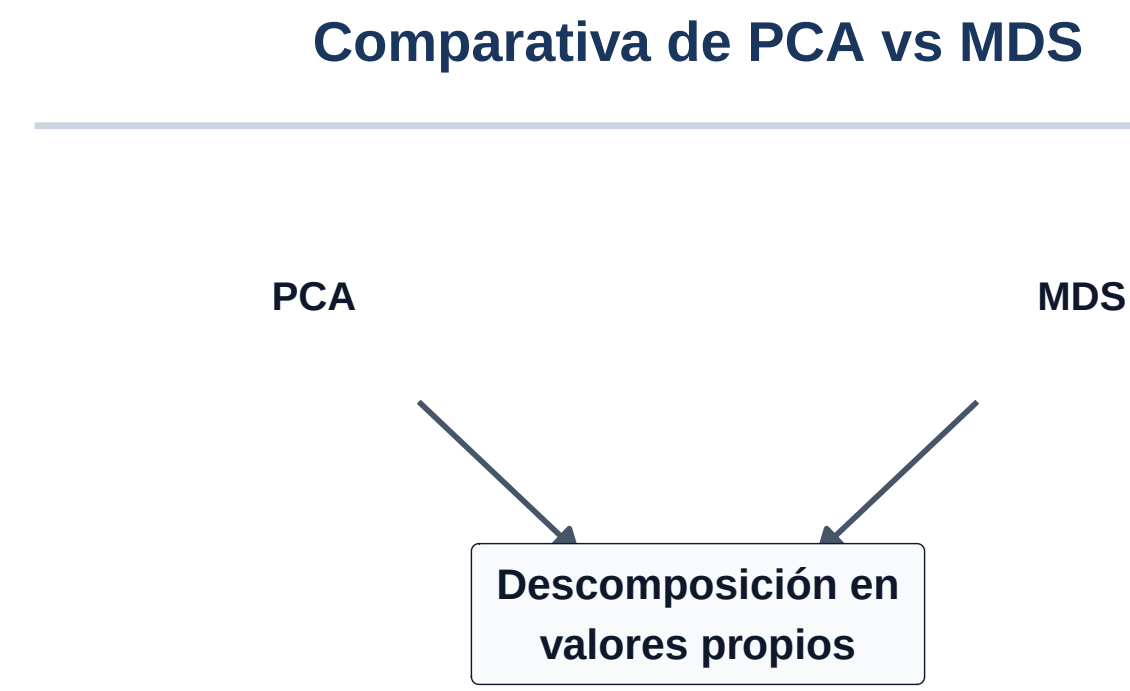
El escalamiento multidimensional métrico es también conocido como escalamiento multidimensional clásico (CMDS) o análisis de coordenadas principales (PCoA).

El escalamiento multidimensional clásico se puede hacer con cualquier distancia que el investigador considere pertinente: euclídea, manhattan, mahalanobis, etc.

1.1.1 Datos Curiosos de MMDS

Si se realiza el MMDS con la distancia euclídea se obtiene el mismo resultado que realizar un análisis de componentes principales.

Por ende, agrupar minimizando las distancias lineales entre individuos (MMDS) es lo mismo que agrupar maximizando las correlaciones lineales entre esos mismos individuos (PCA).



1. **Coordenadas*para una representación gráfica más simple.
2. **Porcentaje de variación explicada*/ proporción de los valores propios.
3. **Acomodo*de los componentes principales / las coordenadas en orden de importancia.

A partir de la matriz de datos $\mathbf{X}$ se obtiene una matriz de distancias $\mathbf{D}$ de dimensión $n \times n$. El MMDS parte de $\mathbf{D}$ y trata de encontrar $\mathbf{X}$.

Para comprender la mecánica se asume que $\mathbf{X}$ es conocida y se obtiene el producto $\mathbf{B} = \mathbf{X}\mathbf{X}^\top$. Entonces cada elemento de $\mathbf{B}$ se puede expresar como:

$$b_{ij} = \sum_{k=1}^{q} x_{ik} x_{jk}$$

De esta forma la distancia Euclídea al cuadrado se puede expresar como:

$$d_{ij}^2 = b_{ii} + b_{jj} - 2b_{ij}$$

Se impone la restricción de que los datos de cada variable estén centrados en cero, por lo que $\sum_{i=1}^{n} x_{ik} = 0$. De esta forma todos los elementos de $\mathbf{B}$ son tales que la suma de cualquier fila (o columna) es cero: $\sum_{j=1}^{n} b_{ij} = 0$.

Se obtienen las siguientes relaciones:

$$\sum_{i=1}^{n} d_{ij}^2 = T + nb_{jj} \qquad \sum_{j=1}^{n} d_{ij}^2 = T + nb_{ii} \qquad \sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}^2 = 2nT$$

donde $T = \text{tr}(\mathbf{B}) = \sum_{i=1}^{n} b_{ii}$. De esta forma:

$$b_{ij} = -\frac{1}{2}\left(d_{ij}^2 - d_{i\cdot}^2 - d_{\cdot j}^2 + d_{\cdot\cdot}^2\right)$$

donde las medias marginales y global de las distancias al cuadrado se definen como:

$$d_{i\cdot}^2 = \frac{1}{n}\sum_{j=1}^{n} d_{ij}^2 \qquad d_{\cdot j}^2 = \frac{1}{n}\sum_{i=1}^{n} d_{ij}^2 \qquad d_{\cdot\cdot}^2 = \frac{1}{n^2}\sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}^2$$

Ahora se hace la descomposición espectral de $\mathbf{B}$:

$$\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top$$

La matriz $\mathbf{\Lambda}$ es diagonal con los n valores propios de $\mathbf{B}$ en la diagonal. Si el rango de $\mathbf{B}$ es q, entonces los últimos $n - q$ valores propios son cero por lo que se pueden eliminar y escribir $\mathbf{B}$ en función solamente de los primeros q vectores y valores propios. Finalmente se puede escribir la matriz $\mathbf{X}$ como:

$$\mathbf{X} = \mathbf{V}_1\mathbf{\Lambda}_1^{1/2}$$

Donde $\mathbf{V}_1$ es la matriz que contiene solo los primeros q vectores propios, y $\mathbf{\Lambda}_1$ es la matriz diagonal con solo los primeros q valores propios. La mejor representación de dimensión k está dada por los k vectores propios de $\mathbf{B}$, asociados a los k valores propios más grandes.

A continuación todo los ejemplos de este de tema se basaran en los siguientes datos

```
base = cbind(c(3,5,6,1,4,2,0,0,7,2),
             c(4,1,2,1,7,2,4,6,6,1),
             c(4,1,0,1,3,5,1,4,5,4),
             c(6,7,2,0,6,1,1,3,1,3),
             c(1,3,6,3,2,0,1,5,4,1))
```

```
d = dist(base)
```

1.1.2 Escalamiento Multidimensional en r

'cmds<-cmdscale(d,k=5,eig=TRUE,x.ret=TRUE)', donde

- d <- es la matriz de distancias
- k <- indica el número de dimensiones requeridas
- eig <- indica si debería devolver los valores propios
- X.ret <- devuelve parte de la matriz B (La matriz B se obtiene multiplicando (-1/2)*cmds$x)

Tienen que agregarse todos estos argumentos porque de lo contrario solo da los primeros vectores propios.

```
cmds = cmdscale(d,k=5,eig=TRUE,x.ret=TRUE) # 5 dimensiones, # d tiene que seer un objeto distancia
```

```
cmds2 = cmdscale(d,k=2,eig=TRUE,x.ret=TRUE) # 2 dimensiones
```

1.1.3 Reconstrucción por la matriz B

Los elementos de la matriz B se pueden obtener de acuerdo a las fórmulas vistas en la presentación en clase o también utilizando la siguiente fórmula: $B = -\frac{1}{2}CD^2C$. Donde D^2 es la matriz de distancias al cuadrado y C está definida como $C = I - \frac{1}{n}J_n$. Aquí I es la matriz identidad de dimensión $n \times n$ y J_n es una matriz de unos, de dimensión $n \times n$.

```
n = dim(base)[1]
D = as.matrix(dist(base,diag = T,upper = T))
Jn = matrix(1,n,n)
C = diag(n)-(1/n)*Jn

B = -0.5*C%*%(D^2)%*%C
```

1.2 Bondad de ajuste (Mardia et al. 1979)

La idoneidad de las nuevas coordenadas resultantes del escalamiento multidimensional, se puede juzgar según la proporción de valores propios representados por dichas coordenadas.

$$P_k^{(1)} = \frac{\sum_{i=1}^{k} |\lambda_i|}{\sum_{i=1}^{n} |\lambda_i|} \qquad P_k^{(2)} = \frac{\sum_{i=1}^{k} \lambda_i^2}{\sum_{i=1}^{n} \lambda_i^2}$$

Donde entre más cercano esté a uno, mejor es la representación de los datos en las nuevas coordenadas.

*Nota:Note que la cantidad de valores propios es igual al número de observaciones.

Sin embargo, dicha proporción nunca es igual a uno puesto que lo que se quiere es disminuir dimensiones, para poder tener una representación más sencilla de los datos.

$$k < q$$

donde:

- q: es el número de dimensiones originales.
- k: es el número de dimensiones escogidas después de aplicar el escalonamiento multidimensional.

Se recomiendan valores mayores que *0,8* para ambos criterios.

1.2.1 Obtención de valores propios (Eigen values)

```
round(cmds$eig,2)
```

```
##  [1] 75.19 58.81 49.61 30.43 10.37  0.00  0.00  0.00  0.00  0.00
```

1.2.2 Aplicación de la bondad de ajuste

Primer Criterio

Si $k = 2$, entonces el calculo es el siguiente:

```
round(sum(abs(cmds$eig[1:2]))/sum(abs(cmds$eig))*100,2)
```

```
## [1] 59.71
```

Si $k = 3$

```
round(sum(abs(cmds$eig[1:3]))/sum(abs(cmds$eig))*100,2)
```

```
## [1] 81.82
```

Se necesitarian al menos 3 dimensiones para alcanzar más de un 80%. Por lo que en este caso obtener una representación con dos dimensiones no es muy buena.

Segundo Criterio

Si $k = 2$, entonces el calculo es el siguiente:

```
round(sum(cmds$eig[1:2]^2)/sum(cmds$eig^2)*100,2)
```

```
## [1] 72.28
```

el ajuste es mejor que con el otro criterio

Si $k = 3$

```
round(sum(cmds$eig[1:3]^2)/sum(cmds$eig^2)*100,2)
```

```
## [1] 91.8
```

NO hay ninguno mejor que otro, lo mejor es tener un equilibrio entre los dos criterios.

1.3 Falta de ajuste (stress)

Es una medida de la falta de ajuste que consiste en la diferencia de las distancias observadas y las distancias predichas, estandarizadas por las distancias observadas al cuadrado para obtener valores entre 0 y 1.

Me dice que tan bien puedo reproducir los datos

$$stress = \sqrt{\frac{\sum(d_{ij} - \hat{d}_{ij})^2}{\sum d_{ij}^2}}$$

Donde entre más cercano esté a cero, mejor es la representación de los datos en las nuevas coordenadas.

Al evaluar bondad de ajuste del MDS, para este propósito Kruskal en 1964, propuso la siguiente regla de dedo:

Stress	Bondad de ajuste
0.000	perfecto
0.025	excelente
0.050	bueno
0.100	aceptable
0.200	pobre

Notas:

- Recuerde que puede usar cualquier distancia que sea pertinente para los datos.
- El *stresspuede* usarse también para calificar la falta de ajuste de un escalamiento multidimensional no métrico.

1.3.1 Aplicación del strees

Para este caso el mayor número de dimensiones puede ser $k = 5$, debido a la cantidad de filas que tienen nuestros datos (cantidad de sujetos)

Para $k = 2$

```r
k = 2
coor2=cmds$points[,1:k]
d2=as.matrix(dist(coor2))
d=as.matrix(d)
sqrt(sum((d-d2)^2)/sum(d^2)) # d es la matriz de distancias observadas
```

```
## [1] 0.3371175
```

Para $k = 2$

```r
k = 4
coor2=cmds$points[,1:k]
d2=as.matrix(dist(coor2))
d=as.matrix(d)
sqrt(sum((d-d2)^2)/sum(d^2))
```

```
## [1] 0.05019229
```

Con el resultado anterior podemos observar que con cuatro dimensiones alcanza un ajuste bueno, mas no excelente.

1.3.2 Comparación de valores de r de coordernadas con los valores propios

```r
eB = eigen(B)
```

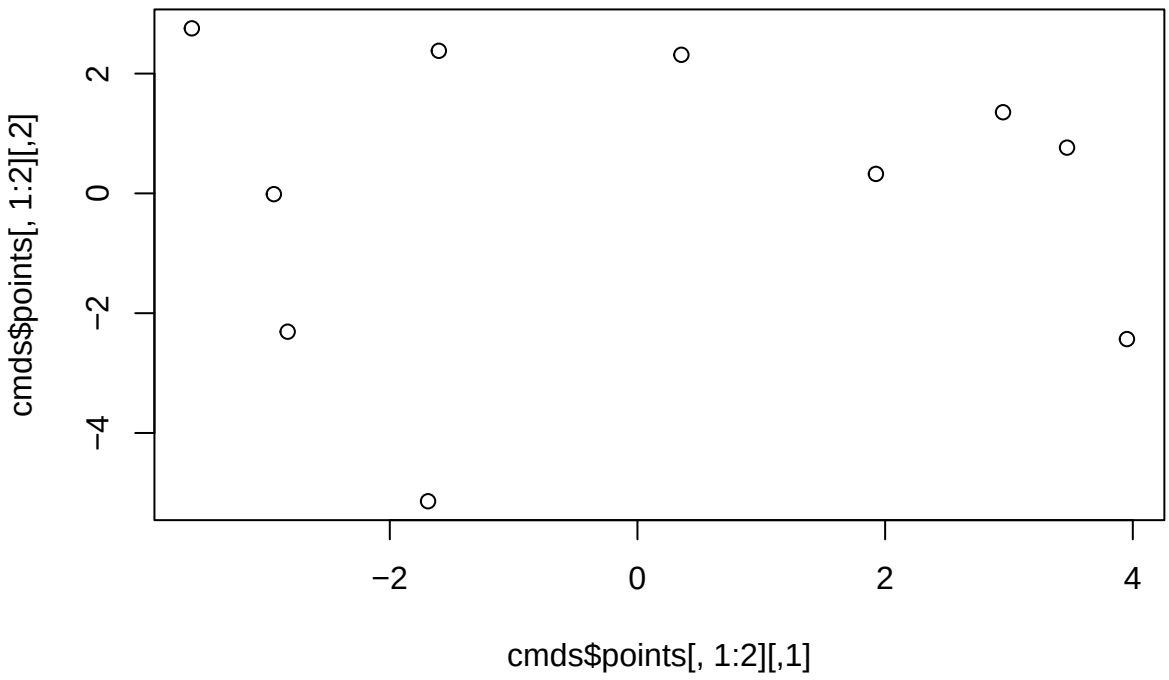
```r
cmds$points[,1:2]
```

```
##             [,1]        [,2]
##  [1,] -1.6038325  2.38060903
##  [2,] -2.8246377 -2.30937202
##  [3,] -1.6908272 -5.13970089
##  [4,]  3.9527719 -2.43233961
##  [5,] -3.5984894  2.75538195
##  [6,]  2.9520356  1.35475175
##  [7,]  3.4689928  0.76411068
##  [8,]  0.3545235  2.31408566
##  [9,] -2.9362323 -0.01279597
## [10,]  1.9256952  0.32526941
```

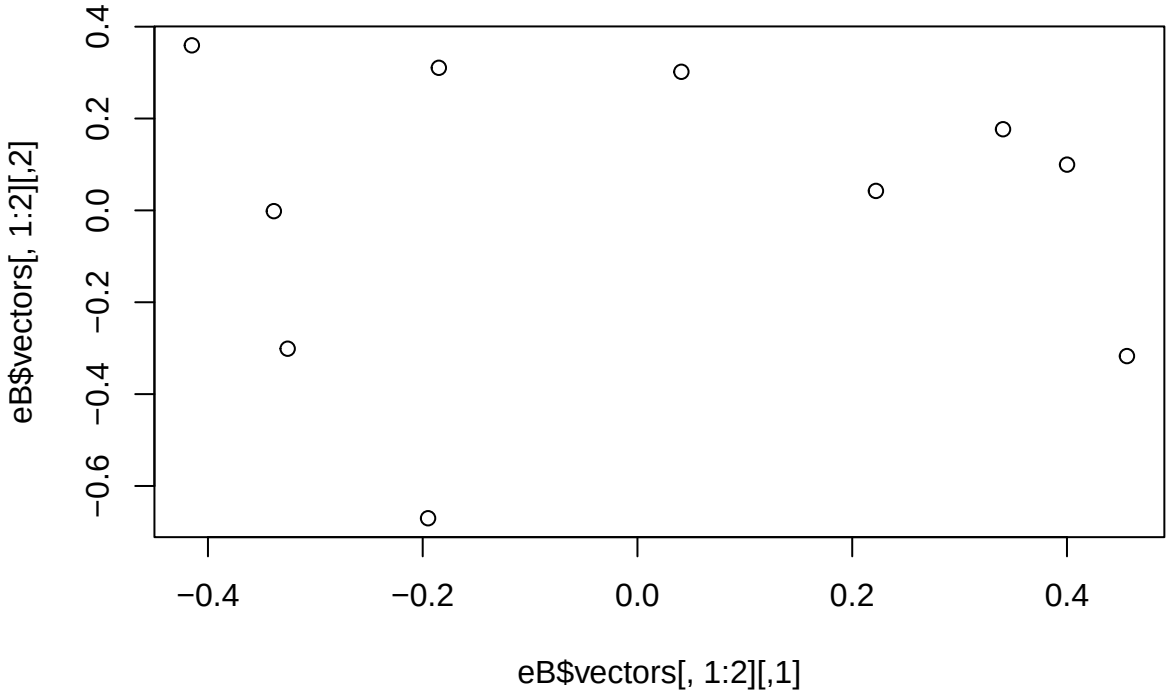
```r
eB$vectors[,1:2]
```

```
##              [,1]         [,2]
##  [1,] -0.18496398  0.310440748
##  [2,] -0.32575486 -0.301151163
##  [3,] -0.19499676 -0.670237142
##  [4,]  0.45585835 -0.317186619
##  [5,] -0.41500028  0.359312607
##  [6,]  0.34044719  0.176664938
##  [7,]  0.40006592  0.099643028
##  [8,]  0.04088587  0.301765840
##  [9,] -0.33862466 -0.001668644
## [10,]  0.22208321  0.042416406
```

```r
plot(cmds$points[,1:2])
```




```
plot(eB$vectors[,1:2])
```



Se pueden observar en los anteriores gráficos, los coordenadas son prácticamente iguales.

2 Clasificación

Clasificación consiste en asignar una observación con q variables en uno de varios grupos preestablecidos. El objetivo básico es construir una regla que tome la información de las q variables para resumirla en un indicador con el cual se pueda clasificar la observación de manera correcta en uno de los grupos. La regla se conoce como función discriminante. Varios métodos desarrollados para abordar el problema de clasificación:

- Análisis discriminante.
- Regresión logística (binomial/multinomial).
- K-vecinos más cercanos.
- Máquinas vectoriales de soporte.
- Métodos basados en árboles.

2.1 Apredizaje o entrenamiento

Se parte de un conjunto de observaciones cuya pertenencia a uno de los k grupos es conocida. Este conjunto se llama muestra de aprendizaje.

En cada grupo se tienen n_j observaciones medidas en q variables.

Con este conjunto de n observaciones ($n = \sum n_j$) se construye la función discriminante o regla de clasificación.

2.2 Validación

Se utiliza otro conjunto de datos para los cuales también se conoce su pertenencia a cada uno de los k grupos. Este conjunto se llama muestra de validación.

Se aplica la función discriminante a ese conjunto de datos y se evalúa qué tan bien fueron clasificados.

La ventaja de hacer esto es que estos individuos no participaron en la construcción de la regla.

Sin embargo, si hay pocos datos se puede usar como muestra de validación la misma muestra de entrenamiento.

Existen métodos secuenciales de validación.

2.3 Predicción

Una vez que la regla ha sido validada se puede aplicar a nuevos datos para los cuales no se conoce su pertenencia a uno de los k grupos.

Se confía en que la regla hará una buena clasificación.

2.4 Regresión logística multinomial

Anteriormente en el curso de modelos avanzados vimos que la regresión logística era:

$$log\left(\frac{\pi_x}{1-\pi_x}\right) = \beta_0 + \beta_1 X_1 + ... + \beta_n X_n$$

donde teníamos el siguiente caso:

$$Y < \begin{matrix} 0 \\ 1 \end{matrix} \implies \pi_x = P(Y = 1 \mid X)$$

Por lo tante la regresión logística multinomial es

Es una extensión del modelo de regresión logístico cuando la respuesta condicional es categórica pero hay más de dos categorías.

Entra dentro de los modelos lineales generalizados.

Puede incluir tanto variables métricas como categóricas en la parte sistemática, es decir, en las variables independientes.

Las variables métricas no deben seguir ninguna distribución particular. (LAS X'S NO SON NORMALES)

Matemáticamente se veería de la siguiente manera:

$$Y \left\langle \begin{array}{lll} a & \implies & \pi_a(x) = P(Y = a \mid X) \\ b & \implies & \pi_b(x) = P(Y = b \mid X) \\ c & \implies & \pi_c(x) = P(Y = c \mid X) \\ d & \implies & \pi_d(x) = P(Y = d \mid X) \end{array} \right.$$

2.4.1 Supuesto

Se basa en el supuesto de independencia de alternativas irrelevantes (IIA, siglas en inglés), lo que no siempre es deseable.

Las probabilidades de preferir una clase sobre otra no dependen de la presencia o ausencia de otras alternativas "irrelevantes".

Por ejemplo, las probabilidades relativas de ir al trabajo en automóvil o autobús no cambian si se agrega una bicicleta como posibilidad adicional.

Los individuos a menudo violan esta suposición al tomar decisiones.

Si las opciones incluyen un automóvil y un autobús azul y se introduce la opción de un autobús rojo, una persona puede ser indiferente entre un autobús rojo y un autobús azul. Aquí, la opción del autobús rojo no es irrelevante, porque un autobús rojo es un sustituto perfecto del autobús azul.

2.4.2 Modelo

El modelo se utiliza para calcular la probabilidad de que el i-ésimo individuo pertenerza al j-ésimo grupo, tomando como referencia el grupo 1 (puede tomarse cualquier otro grupo).

Se deriva un conjunto de $k-1$ ecuaciones.

Cada ecuación tiene un vector de coeficientes $\beta^{(j)}$.

$$log\left(\frac{\pi_j}{\pi_1}\right) = \beta_0^{(j)} + \beta_1^{(j)} X_1 + ... + \beta_q^{(j)} X_q$$

2.4.3 Ejemplo aplicado en clase

Para este ejemplo nuestra variable respuesta será de que depende el medio de transporte según la cantidad de kilométros.

Hay tres respuestas:

1: Transporte Público

2: Moto o automóvil

3: Bicicleta o caminando

Y	D
1	4
1	12
1	21
2	11
2	12
2	1
2	2
2	5
2	9

Lo que trata el modelo es crear un modelo para predecir nuevas unidades de forma certera, un ejemplo de aplicación de esto puede ser en fraude o en casas de apuestas.

Note que en el modelo se pone la primera categoría de referencia en este caso es π_1.

Siguiendo con el mismo ejemplo como tenemos 3 categorías tenemos dos ecuaciones del modelo

$$log\left(\frac{\pi_2}{\pi_1}\right) = \beta_0^{(2)} + \beta_1^{(2)} D$$

$$log\left(\frac{\pi_3}{\pi_1}\right) = \beta_0^{(3)} + \beta_1^{(3)} D$$

La regla general de cuántos coeficientes tiene que calcular el modelo es $(k-1)\cdot p$, donde k es el número de categorías y p el número de coeficientes por ecuación.

Riego relativo

De estas ecuacione podemos obtener el riesgo relativo de la siguiente manera:

$$\frac{\pi_2}{\pi_1}$$

Teniendo en cuenta el ejemplo anterior y la fórmula del riesgo relativo, tenemos lo siguiente:

$$\frac{\pi_2}{\pi_1} = e^{\beta_0^{(2)}+\beta_1^{(2)}D} = A \qquad \frac{\pi_3}{\pi_1} = e^{\beta_0^{(3)}+\beta_1^{(3)}D} = B$$

Para simplificar el proceso asuma que los RR son A y B

Despejamos π_1 en las dos ecuaciones

$$\pi_1 = \frac{\pi_2}{A} \qquad \pi_1 = \frac{\pi_3}{B}$$

Igualamos las dos ecuaciones de π_1

$$\frac{\pi_2}{A} = \frac{\pi_3}{B}$$

De esta ecuación despejamos π_2

$$\pi_2 = \frac{A\pi_3}{B}$$

Sabemos que:

$$\pi_1 + \pi_2 + \pi_3 = 1$$

Reemplazamos π_2 y nos lleva al siguiente resultado

$$\pi_1 + \frac{A\pi_3}{B} + \pi_3 = 1$$

Despejando los tres π llegamos al siguiente resultado:

$$\pi_3 = \frac{B}{1+A+B} \qquad \pi_2 = \frac{A}{1+A+B} \qquad \pi_1 = \frac{1}{1+A+B} \text{ ó } 1 - \left(\frac{B}{1+A+B} + \frac{A}{1+A+B}\right)$$